

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104364-104252

**Fúzia dát zo snímačov pre zlepšenie
spoľahlivosti lokalizácie mobilného robota**

Písomná práca k dizertačnej skúške

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104364-104252

Fúzia dát zo snímačov pre zlepšenie spoľahlivosti lokalizácie mobilného robota

Písomná práca k dizertačnej skúške

Študijný program:	Robotika a kybernetika
Študijný odbor:	kybernetika
Školiace pracovisko:	Ústav robotiky a kybernetiky
Školiteľ:	prof. Ing. František Duchoň, PhD.
Konzultant:	Ing. Martin Dekan, PhD.

Obsah

Zoznam obrázkov a tabuliek

Zoznam značiek a skratiek

AGV	Autonomous Ground Vehicle
AMCW	Amplitude-Modulated Continuous Wave
AOA	Angle Of Arrival
BPSK	Binary Phase Shift Keying
BRIEF	Binary Robust Independent Elementary
CLINS	Continuous-time LiDAR-Inertial Navigation System
CNN	Convolutional Neural Network
DFFN	Deep Feed-Forward Network
DGPS	Differential GPS
DL	Deep Learning
DLT	Direct Linear Transform
DoF	Degree of Freedom
DoG	Difference of Gaussians
DOP	Dilution Of Precision
EGNOS	European Geostationary Navigation Overlay Service
EKF	Extended Kalman Filter
ELM	Extreme Learning Machine
EPnP	Efficient PnP
FAST	Features From Accelerated Segment Test
FMCW	Frequency-Modulated Continuous Wave
FOV	Field Of View
GLONASS	Globalnaja Navigacionnaja Sputnikovaja Sistema
GNSS	Global Navigation Satellite Systems
GPS	Global Positioning System
GPU	Graphical Processing Unit
GRU	Gated Recurrent Unit
ICP	Iterative Closest Point
IMU	Inertial Measurement Unit
INS	Inertial Navigation System
IRC	Incremental rotary encoder
IRNSS	Indian Regional Navigation Satellite System
KISS-ICP	Keep It Small and Simple ICP
LiDAR	Light Detection and Ranging

LIO	LiDAR-Inertial Odometry
LIO-SAM	LiDAR-Inertial Odometry Smoothing and Mapping
LIOR	LiDAR Odometry with Intensity and Occlusion Removal
LO	LiDAR Odometry
LO-Net	Lidar Odometry Network
LOAM	LiDAR Odometry and Mapping
LodoNet	LiDAR Odometry Deep Neural Network
LSTM	Long Short-Term Memory
MEMS	Micro-Electro-Mechanical Systems
MKP	Matched Keypoint Pair
MLE	maximum-likelihood estimation
MLP	Multi-Layer Perceptron
MoCap	motion capture
NAS	National Airspace System (USA)
NDT-ICP	Normal Distribution Transform ICP
OOK	On-OFF Keying
OPA	Optical Phased Array
ORB	Oriented FAST and rotated BRIEF
ORB-SLAM	ORB-SLAM
PAM	Pulse Amplitude Modulation
PnP	Perspective-n-Point
PPM	Pulse Position Modulation
PSK	Phase Shift Keying
PWM	Pulse Width Modulation
QZSS	Quasi-Zenith Satellite System
RANSAC	Random Sample Consensus
ReLU	Rectified Linear Unit
RMSE	Root Mean Square Error
RNN	Recurrent Neural Network
RPE	reprojection error
RSS	Received Signal Strength
RTK	Real-Time Kinematic
SBAS	Satellite-based Augmentation Systems
SGD	Stochastic Gradient Descent
SIFT	Scale-Invariant Feature Transform

SLAM	Simultaneous Localization and Mapping
SLP	Single-Layer Perceptron
SuMa	Surfel-based Mapping
SURF	Speeded-Up Robust Features
TDOA	Time Difference Of Arrival
TH	Time Hopping
TOA	Time Of Arrival
ToF	Time of Flight
UAV	Unmanned Aerial Vehicle
UI	Umelá inteligencia
UNS	Umelá neurónová sieť
UWB	Ultra-Wideband
VO	Visual odometry
WAAS	Wide Area Augmentation System
WeatherNet	Weather-Robust Deep LiDAR Odometry Network
WGS	World Geodetic System
WiMAX	Worldwide Interoperability for Microwave Access
WMS	Wide Area Master Stations
WRS	Wide Area Reference Stations

Zoznam algoritmov

1	Základný ICP algoritmus podľa [baiICPAlgorithmTheory2023] . . .	25
---	---	----

1 Osnova dizertačného projektu

1. Prehľad matematických nástrojov používaných pri metódach fúzie údajov zo snímačov.
2. **Súhrn snímačov používaných pre lokalizáciu mobilných robotov a analýza princípov ich fungovania.** Globálny navigačný systém (GNSS), inerciálna jednotka (IMU), magnetometer, kolesová odometria, vizuálna odometria (monokamera, stereokamera), lidarová odometria, ultrazvukový senzor, radar.
3. **Súhrn a analýza dostupných metód fúzie dát zo snímačov.** Bayesov filter, Kalmanov filter a jeho variácie, časticový filter a Monte Carlo.
4. **Využitie metód umelej inteligencie a strojového učenia pri fúzii dát zo snímačov.** Umelé neurónové siete, rekurentné neurónové siete, učenie s posilňovaním.
5. Príklady a porovnanie implementácií fúzie dát zo snímačov pre lokalizáciu mobilných robotov.

2 Charakteristika a delenie snímačov

V súvislosti so snímačmi používanými v mobilnej robotike treba mať na pamäti tri zásadné faktory [duchonSnimaceMobilnejRobotike2012]:

1. Meranie skutočnými snímačmi je zašumené;
2. Skutočné snímače poskytujú nekompletný opis prostredia;
3. Skutočné snímače nemôžu byť úplne modelované.

Vlastnosti a miera použiteľnosti snímačov sú dané mnohými parametrami, ktoré ich vzájomne odlišujú. Z nich medzi najvýznamnejšie môžeme zaradiť [duchonSnimaceMobilnejRobotike2012]:

- *Zorné (detekčné) pole (FOV)* – šírka záberu snímača, zvyčajne vyjadrená v stupňoch. Niektoré typy snímačov majú definované vertikálne aj horizontálne zorné pole;
- *Merací rozsah* – pracovný rozsah snímania vrátane obmedzenia hĺbky (môže byť minimálne aj maximálne);
- *Dynamický rozsah* – pomer medzi maximálnou a minimálnou vstupnou hodnotou snímača. Hodnota býva vyjadrená v decibeloch;
- *Rozlíšenie* – minimálny rozdiel medzi dvoma hodnotami, ktoré snímač dokáže detegovať;
- *Lineárnosť* – ak je gradient vstupno-výstupnej závislosti konštantný, snímač je lineárny;
- *Šírka pásma/frekvencia* – rýchlosť merania snímača. Zvyčajne býva vyjadrená v hertzoch;
- *Citlivosť* – miera zmeny výstupného signálu vzhľadom na mieru zmeny vstupného signálu. Môže byť ovplyvnená aj prostredím;
- *Chyba* – odchýlka výstupnej hodnoty od skutočnej. Vo všeobecnosti rozlišujeme medzi dvomi typmi chýb:
 - *systematická (deterministická)* – sústavná (konštantná) odchýlka meraní od skutočnosti. Môže byť spôsobená faktormi alebo procesmi, ktoré je možné modelovať;

- *náhodná (stochastická)* – premenlivá odchýlka meraní od skutočnosti. Je možné ju vyjadriť pravdepodobnostnými metrikami;
- *Presnosť* – miera systematickej chyby. Vyjadrená býva v pomere k skutočnej hodnote;
- *Opakovateľnosť* – miera náhodnej chyby. Je nezávislá od presnosti snímača;
- *Drift* – postupný odklon meraní od reálnych hodnôt, vzniká kumuláciou chýb merania;
- *Latencia* – oneskorenie medzi momentom výskytu fyzikálneho javu a momentom poskytnutia informácie o ňom senzorom. Môže byť spôsobená viacerými faktormi, vrátane fyzikálnych vlastností senzora, spôsobu spracovania signálu či času potrebného na odoslanie údajov.

Snímače a systémové komponenty využívané na lokalizáciu mobilných robotov možno klasifikovať viacerými spôsobmi podľa rôznych hľadísk, vo všeobecnosti podľa toho čo a akým spôsobom snímajú. Každé z týchto hľadísk zvýrazňuje iný aspekt senzorov. Medzi najčastejšie kritériá delenia snímačov patria:

1. Podľa spôsobu interakcie so snímaným prostredím [**christensenSensingEstimation2016**]:
 - *aktívne* – senzory, ktoré samy vysielajú energiu do prostredia (napr. LiDAR, ultrazvuk),
 - *pasívne* – senzory, ktoré len pasívne prijímajú signály (napr. kamery, magnetometre),
2. Podľa typu meranej veličiny [**siegwartIntroductionAutonomousMobile2011, thrunProbabilisticRobotics2005**]:
 - *inerciálne veličiny* – gyroscopy, akcelerometre,
 - *vzdialenosť* – LiDAR, ultrazvuk,
 - *elektromagnetické signály* – GNSS, magnetometre;
3. Podľa referenčného rámca výstupu [**inproceedings**]:
 - *lokálne* – poskytujú odhad polohy vzhľadom na predchádzajúci stav robota (napr. odometria),
 - *globálne* – poskytujú polohu vzhľadom na externý (globálny) rámec (napr. GNSS, MoCap systémy);

4. Podľa spôsobu vnímania [**siegwartIntroductionAutonomousMobile2011**]:

- *proprioceptívne* – merajú vnútorný stav robota samotného (napr. IMU),
- *exteroceptívne* – merajú informácie o vonkajšom prostredí (napr. LiDAR, kamera);

5. Podľa potreby infraštruktúry [**ferreiraVehicleLocalizationSystem2013**]:

- *interné* („*on-board*“) – schopné fungovať samostatne ako súčasť robota (napr. kamera, LiDAR, IMU),
- *externé* („*off-board*“) – vyžadujú externú inštaláciu alebo systém (napr. GPS, MoCap, UWB);

V tejto práci použijeme na systematizáciu predstavenia senzorov používaných na lokalizáciu mobilných robotov práve posledné spomenuté delenie.

3 Interné senzorické systémy

3.1 Odometria

Jedným zo spôsobov lokalizácie objektov je hrubé stanovenie polohy. Aktuálna poloha je odvodená na základe informácií o predošlých polohách a aktuálnom smere a rýchlosti pohybu. Najjednoduchšou implementáciou takéhoto prístupu je odometria. Využíva odometer – snímač, ktorý je schopný zaznamenať zmenu kinematiky – umiestnený na palube mobilného zariadenia (robota). Na základe uplynutého času, prejdenej dráhy vypočítanej z odometrie a orientácie, ktorá musí byť získaná iným spôsobom, je následne odvodený odhad aktuálnej polohy [duchonSnimaceMobilnejRobotike2012].

V prípade kolesových robotov je obvykle snímaný pohyb kolies, tzv. kolesová odometria, a to najčastejšie pomocou inkrementálnych snímačov polohy [duchonSnimaceMobilnejRobotike2012]. Princíp odometrie je však možné využiť aj pri spracovaní údajov z iných snímačov. V súčasnosti už dobre zaužívanou metódou je vizuálna odometria, ktorá využíva obraz z kamery, a pomerne nedávnou oblasťou je spracovanie meraní z LiDAR-u – lidarová odometria.

3.1.1 Kolesová odometria

Kolesová odometria využíva snímanie otáčok kolies, resp. motora pomocou optického inkrementálneho snímača (IRC). Ten je schopný zaznamenávať otáčanie hriadeľa pomocou prerušovania svetelného lúča cez mriežku na rotujúcom disku. Pri jeho otáčaní vznikajú impulzy – sínusové alebo pravouhlé – ktoré reprezentujú zmenu uhla. Rozlíšenie snímača sa vyjadruje ako počet impulzov (cyklov) na jednu otáčku. Základný typ snímača však nevie určiť smer pohybu, preto sa v mobilnej robotike používa tzv. kvadraturný inkrementálny snímač. Ten má dva optické kanály posunuté o 90° fázovo, čo umožňuje určiť nielen uhol, ale aj smer otáčania. Navyše, každý impulz možno ďalej interpolovať, čím sa zvyšuje presnosť merania [duchonSnimaceMobilnejRobotike2012].

Výhodou IRC je ich jednoduchosť, nízka cena a vysoká presnosť v rámci vnútornej štruktúry robota – chyby priamo v snímači sú spravidla zanedbateľné v porovnaní s chybami v mechanickom prenose (napr. v hriadeľi). Najväčším problémom IRC je však akumulácia chýb – spôsobená napríklad pretáčaním kolies, nepresným priemerom kolies alebo nerovným povrchom. Preto sú odometrické merania pomocou inkrementálnych snímačov síce veľmi presné v krátkom časovom horizonte, ale dlhodobu sa ich chyba zväčšuje. Na kompenzáciu sa preto bežne používajú korekčné algoritmy, ako je napríklad Kalmanov filter, ktorý kombinuje výstupy z viacerých senzorov [duchonSnimaceMobilnejRobotike2012].

3.2 Vizuálna odometria

Vizuálna odometria (VO) je technika odhadu polohy na základe vstupného obrazu z jednej alebo viacerých kamier. Na rozdiel od kolesovej odometrie, zaznamenáva posunutie obrazu medzi za sebou nasledujúcimi snímkami. Funguje v reálnom čase, v porovnaní s kolesovou odometriou má podstatne vyššiu spoľahlivosť a je vhodná v prostrediach bez dostupnosti signálu GPS.

Podľa počtu použitých kamier sa rozlišujú tri typy vizuálnej odometrie [krombachCombiningFeat

1. *monokulárna* – využíva jednu kameru, meria posuny obrazu medzi snímkami a odhaduje pohyb, jej nevýhodou je faktor neurčitej mierky, ktorý je nutné kompenzovať prídavnými senzormi;
2. *stereovízna* – kombinuje dve synchronizované kamery, získava hĺbku priamo pomocou stereo triangulácie, čím odstraňuje problém neurčitej mierky;
3. *všesmerová* – pozostáva z komplexného systému viacerých mono- alebo stereo-kamier. Poskytuje veľmi široké zorné pole (až do 360°), vďaka čomu je rotačne invariantná. Vyžaduje však presnú kalibráciu a synchronizáciu medzi kamerami a je nákladnejšia [aqelReviewVisualOdometry2016].

Existuje viacero spôsobov určovania pohybu na základe obrazu z kamier. Medzi dominujúce prístupy VO patria [krombachCombiningFeatureBasedDirect2017]:

- *textúrna* – (obr. ??) pracuje s detekciou a sledovaním výrazných obrazových prvkov – textúr (napr. rohy, línie, krivky, ...). Je presná v dobre štruktúrovanom



(a) vstupný obraz



(b) výstup zo sledovača textúr – krúžky reprezentujú aktuálne pozície textúr, čiary sú znázorňujú ich pohyb po obrázku

Obr. 3.1: Princíp textúrnej vizuálnej odometrie [nisterVisualOdometry2004].

prostredí, avšak jej robustnosť klesá pri monotónnych scénach. Na kompenzáciu driftu sa často požíva v kombinácii s metódami optimalizácie pozičného grafu.

- *priama* - pracuje priamo s intenzitami všetkých pixelov snímku, bez predchádzajúcej extrakcie, a to za účelom minimalizácie fotometrickej chyby. Je preto výpočtovo náročnejšia a pomalšia než textúrna vizuálna odometria. Je tiež citlivejšia na svetelné zmeny.
- *hybridná* – využíva kombináciu dvoch predošlých typov na rekonštrukciu trojrozmerného prostredia. V prvom slede sa použije textúrna VO na získanie hrubého odhadu polohy, ktorý je neskôr spresnený pomocou priamej VO.
- *vizuálno-inerciálna* – kombinuje kameru s IMU, čo zlepšuje metriku aj stabilitu: IMU poskytuje rýchlo-časové odhady a pomáha pri rýchlych pohyboch či nízkej textúre. Niektoré takéto systémy dosahujú centimetrovú presnosť a robustnosť v náročných prostrediach [qinVINSMonoRobustVersatile2018].

Vďaka efektívnejšiemu výkonu sú v súčasnosti rozšírenejšie skôr textúrne než priame metódy VO. Základné problémy, ktoré musí riešiť každý algoritmus textúrnej VO sú rekonštrukcia pohybu, nelineárna optimalizácia, párovanie textúr, rekonštrukcia hĺbky a aktualizácia stavu. Ich princíp vysvetlíme v nasledujúcich častiach podľa [chienWhenUseWhat2016].

3.2.1 Rekonštrukcia pohybu


Pre rekonštrukciu pohybu kamery je potrebné získať 3D súradnice bodu na obraze z kamery. To je možné na základe tzv. *dierkového modelu kamery* (angl. *pinhole camera model*, viď obr. ??). Pre bod v priestore $\mathbf{P} = (x, y, z)^\top$ a jeho projekciu v rovine obrazu $\mathbf{p} = (u, v)^\top$ je projekčný model definovaný takto:

$$\begin{bmatrix} \mathbf{p} \\ 1 \end{bmatrix} \sim \begin{bmatrix} f_u & 0 & u_c & 0 \\ 0 & f_v & v_c & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{0} \end{bmatrix} \mathbf{P}, \quad (3.1)$$

kde $\mathbf{K}$ je tzv. *matica kamery*, ktorá obsahuje vnútorné parametre kamery: fokálne vzdialenosti f_u, f_v a súradnice stredu optickej osi (u_c, v_c) .

Za predpokladu, že $\mathbf{P}$ je stacionárny bod v priestore, jeho projekcia v nasledujúcej snímke z kamery sa dá vyjadriť ako

$$\begin{bmatrix} \mathbf{p}' \\ 1 \end{bmatrix} \sim \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix} \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix}, \quad (3.2)$$



Obr. 3.2: Dierkový model kamery – projekcia 3D bodu do 2D obrazu kamery (podľa [CameraCalibration3D])

kde rotačná matica $\mathbf{R} \in SO(3)$ a translačný vektor $t \in \mathbb{R}^3$ predstavujú Euklidovskú transformáciu danú pohybom kamery.

V kontexte problému odhadu pohybu je transformácia $[\mathbf{R} \ t]$ riešenou neznámou, ktorú je potrebné určiť na základe množiny 3D–2D korešpondencií $(x, y, z) \leftrightarrow (u', v')$. Tento problém je známy ako úloha *perspective-from-n-points* (PnP). Ak sa na celú projekčnú maticu $\mathbf{P} = \mathbf{K} [\mathbf{R} \ t]$ pozeráme ako na problém čiernej skrinky (t. j. bez znalosti vnútorných závislostí), riešenie je možné získať jednoducho vyriešením homogénneho lineárneho systému. Takýto prístup je známy ako metóda *priamej lineárnej transformácie* (DLT) [chienWhenUseWhat2016]. Rotácia určená týmto spôsobom však nemusí byť platným prvkom špeciálnej ortogonálnej skupiny $SO(3)$ kvôli nadbytočnej parametrizácii. Preto sa na nájdenie riešenia rovnice ?? v praxi často používa algoritmus *Efficient PnP* (EPnP) [lepetitEPnPAccurateSolution2009], ktorý ponúka výpočtovo efektívne a stabilné riešenie úlohy PnP. Jeho hlavnou výhodou je, že reprezentuje 3D body ako lineárnu kombináciu štyroch kontrolných bodov, čím znižuje počet neznámych a dosahuje lineárnu výpočtovú zložitosť vzhľadom na počet korešpondencií. Táto vlastnosť robí EPnP obzvlášť vhodným pre použitie v reálnom čase a v systémoch, kde sa pracuje s veľkým množstvom bodov, ako je tomu aj v tomto prípade.

3.2.2 Nelineárna optimalizácia

Pohyb kamery odhadnutý pomocou lineárnych metód (napr. DLT alebo EPnP), poskytuje len suboptimálne riešenie. Na dosiahnutie riešenia *metódou maximálnej vierohodnosti* (MLE) je potrebná nelineárna optimalizácia. Za predpokladu, že šum v meraniach má Gaussovské rozdelenie, možno odhad MLE pre N sledovaných textúr dosiahnuť

minimalizáciou sumy štvorcov reprojekčnej chyby:

$$\phi_{\text{RPE}}(\mathbf{R}, \mathbf{t}) = \sum_{i=1}^N \|\mathbf{p}'_i - \pi_{\mathbf{K}}(\mathbf{R} \cdot \mathbf{P}_i + \mathbf{t})\|_{\Sigma_i}^2, \quad (3.3)$$

kde $\pi_{\mathbf{K}} : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ je projekčná funkcia, ktorá zobrazuje 3D bod do projekčného priestoru P^2 pomocou matice kamery $\mathbf{K}$ a následne prevádza homogénne súradnice na karteziánske. Symbol $|\cdot|_{\Sigma}$ označuje Mahalanobisovu vzdialenosť vzhľadom na kovariančnú maticu Σ .

Na zvýšenie stability optimalizácie sa okrem korešpondencií 3D–2D zohľadňujú aj korešpondencie 2D–2D, t. j. $(u, v) \leftrightarrow (u', v')$, pre ktoré sa definuje epipolárna chybová funkcia:

$$\phi_{\text{EPI}}(\mathbf{R}, \mathbf{t}) = \sum_{i=1}^N \delta(\mathbf{p}_i, \mathbf{p}'_i; \mathbf{F}), \quad (3.4)$$

kde δ označuje Sampsonovu vzdialenosť [sampsonFittingConicSections1982] medzi dvojicou bodov vzhľadom na fundamentálnu maticu $\mathbf{F}$:

$$\delta(\mathbf{p}, \mathbf{p}'; \mathbf{F}) = \frac{(\mathbf{p}'^\top \mathbf{F} \mathbf{p})^2}{(\mathbf{F} \mathbf{p})_0^2 + (\mathbf{F} \mathbf{p})_1^2 + (\mathbf{F}^\top \mathbf{p}')_0^2 + (\mathbf{F}^\top \mathbf{p}')_1^2} \quad (3.5)$$

Fundamentálna matica $\mathbf{F}$ je definovaná ako:

$$\mathbf{F} = \mathbf{K}^{-\top} [\mathbf{t}]_{\times} \mathbf{R} \mathbf{K}^{-1}, \quad (3.6)$$

kde $[\mathbf{t}]_{\times}$ je antisymetrická matica odvodená z translačného vektora $\mathbf{t} = (t_x, t_y, t_z)^\top$:

$$[\mathbf{t}]_{\times} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix} \quad (3.7)$$

Optimalizovaná funkcia energie, ktorá kombinuje reprojekčnú aj epipolárnu chybu, je definovaná ako:

$$\Phi(\mathbf{R}, \mathbf{t}) = (1 - \alpha) \cdot \phi_{\text{RPE}}(\mathbf{R}, \mathbf{t}) + \alpha \cdot \phi_{\text{EPI}}(\mathbf{R}, \mathbf{t}), \quad (3.8)$$

kde $\alpha \in [0, 1]$ je regulačný parameter určujúci váhu epipolárneho člena. Aby boli členy porovnateľné, hodnota α je normalizovaná vzhľadom na počet zodpovedajúcich bodov. Nech $\beta \in [0, 1]$ je požadovaný pomer váh, N_{RPE} počet 3D–2D korešpondencií a N_{EPI} počet 2D–2D korešpondencií. Potom sa α vypočíta nasledovne:

$$\alpha = \left(1 + \frac{N_{\text{EPI}}}{N_{\text{RPE}}} \cdot \frac{1 - \beta}{\beta} \right)^{-1} \quad (3.9)$$

Rovnicu (??) nie je možné vyriešiť v uzavretom tvare, a preto sa na jej minimalizáciu používa nelineárna optimalizačná metóda najmenších štvorcov, napríklad algoritmus Levenberg-Marquardt, pričom sa vychádza z lineárneho počiatočného odhadu.

3.2.3 Párovanie textúr

Párovanie obrazových textúr (angl. *feature matching*) sa bežne využíva na určenie 2D–2D pixelových korešpondencií, ktoré sú potrebné na výpočet členov vo vzťahu (??). Po vyriešení relatívneho pohybu aktuálneho snímku sa tieto korešpondencie znova využívajú na získanie 3D–2D korešpondencií požadovaných vo vzťahu (??), a to pomocou prístupu opísaného v nasledujúcej časti.

Príznačky sa spočiatku zladujú v príznakovom priestore. Nech $\mathcal{F}$ a $\mathcal{F}'$ označujú množiny príznakov (textúr) extrahovaných v dvoch po sebe idúcich snímkach. Príznak $\chi \in \mathcal{F}$ sa priradí k $\chi' \in \mathcal{F}'$ podľa pravidla:

$$\chi' = \arg \min_{\chi' \in \mathcal{F}'} d(\chi, \chi'), \quad (3.10)$$

kde $d : \mathcal{F} \times \mathcal{F}' \rightarrow \mathbb{R}$ je zvolená metrika podobnosti medzi dvoma príznakmi.

Nejednoznačné zhody sa identifikujú pomocou rozdielového pomeru. Nech $\tilde{\chi}' \in \mathcal{F}'$ označuje druhú najlepšiu zhodu pre príznak χ . Korešpondencia $\chi \rightarrow \chi'$ je považovaná za nejednoznačnú, ak platí:

$$\frac{d(\chi, \chi')}{d(\chi, \tilde{\chi}')} < r, \quad (3.11)$$

kde $r \in (0, 1)$ je vopred určený prah.

Nejednoznačné korešpondencie sa následne odstránia spätným overením z množiny $\mathcal{F}'$ do $\mathcal{F}$. Korešpondencia $\chi \rightarrow \chi'$ je považovaná za nekonzistentnú, ak:

$$\arg \min_{\tilde{\chi} \in \mathcal{F}} d(\tilde{\chi}, \chi') \neq \chi \quad (3.12)$$

Po aplikovaní podmienok (??) a (??) získame množinu jednoznačných a symetrických korešpondencií $\chi \leftrightarrow \chi'$.

Tieto korešpondencie sa ďalej rozširujú pomocou sledovania príznakov KLT [**tomasiDetectionTrack**] aplikovaného na príznaky z $\mathcal{F}$, ktoré sa nepodarilo spojiť s prvkami z $\mathcal{F}'$.

Na rozšírenej množine príznakov sa následne vykonáva eliminácia odľahlých bodov pomocou robustnej metódy RANSAC [**fischlerRandomSampleConsensus1981**]. V každej iterácii sa náhodne vyberie päť korešpondencií, na základe ktorých sa odhadne esenciálna matica $\mathbf{E}$ pomocou päťbodového algoritmu [**nisterEfficientSolutionFivepoint2004**]. Následne sa pre všetky zhody vypočítajú Sampsonove vzdialenosti vzhľadom na $\mathbf{E}$. Tento proces sa opakuje, kým sa nenájde dostatočný počet prilahlých bodov, ktoré súhlasia s esenciálnou maticou v rámci tolerovanej vzdialenosti, napríklad 0,5 pixelu.

3.2.4 Rekonštrukcia hĺbkы

Na odhad pohybu kamery v konzistentnej mierke je potrebné pracovať v Euklidovských súradniciach. V prípade monokulárneho systému však absolútnu mierku nie je možné

určiť iba na základe projekcie. Pohyb medzi prvým a druhým snímkom sa preto zvyčajne určuje pomocou dekompozície esenciálnej matice, ktorá následne slúži na rekonštrukciu 3D súradníc príznakov. Takto inicializovaný proces vizuálnej odometrie potom umožňuje určovať relatívny pohyb kamery v konzistentnej mierke počas celej sekvencie snímok.

Nech (u, v) a (u', v') označujú obrazové súradnice zodpovedajúceho príznaku $\chi \leftrightarrow \chi'$ v dvoch po sebe idúcich snímkach. Pri danom pohybe kamery $[\mathbf{R} \ \mathbf{t}]$ možno 3D súradnice príznaku χ rekonštruovať minimalizáciou nasledujúcej vzdialenosti vzhľadom na voľné parametre $k, k' \in \mathbb{R}^+$:

$$\delta_{\text{mid}}(k, k') = \|k \mathbf{a} - (k' \mathbf{a}' + \mathbf{c}')\|^2, \quad (3.13)$$

kde $\mathbf{a} = \mathbf{K}^{-1}(u, v, 1)^\top$ a $\mathbf{a}' = \mathbf{R}^\top \mathbf{K}^{-1}(u', v', 1)^\top$ sú smerové vektory spätných projekcií lúčov v prvom a druhom snímku. Vektor $\mathbf{c}' = -\mathbf{R}^\top \mathbf{t}$ predstavuje nový stred kamery (t. j. pozíciu kamery po pohybe).

Minimum vo výraze (??) možno nájsť ako riešenie metódy najmenších štvorcov pre nasledujúcu lineárnu sústavu:

$$\begin{bmatrix} \mathbf{a} & -\mathbf{a}' \end{bmatrix} \begin{bmatrix} k \\ k' \end{bmatrix} = \mathbf{A} \begin{bmatrix} k \\ k' \end{bmatrix} = \mathbf{c}' \quad (3.14)$$

Výsledné hodnoty k a k' určujú dva body na príslušných spätných lúčoch (zodpovedajúcich príznaku χ v oboch snímkach), ktoré sú v priestore k sebe najbližšie.

Stred týchto dvoch bodov, ktorý predstavuje 3D odhad súradníc príznaku, sa potom vypočíta ako:

$$(x, y, z)^\top = \frac{1}{2} \left(\begin{bmatrix} \mathbf{a} & \mathbf{a}' \end{bmatrix} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top + \mathbf{I} \right) \mathbf{c}' \quad (3.15)$$

Týmto spôsobom sa získa odhad 3D súradníc príznaku, pričom tento postup je známy ako *triangulácia pomocou stredového bodu* (angl. *mid-point triangulation*).

3.2.5 Aktualizácia stavu

Na zlepšenie stability procesu vizuálnej odometrie sa stavy sledovaných príznakov uchovávaajú počas celej sekvencie. Nech $\mathbf{m}_{i,k}$ je pozorovaný stavový vektor príznaku i v snímke k a $\omega_{i,k} \in \langle 0, 1 \rangle$ je váha vyjadrujúca mieru dôvery, že pozorovanie zodpovedá skutočnému stavu. Odhad skutočného stavu sa potom vypočíta ako:

$$\hat{\mathbf{m}}_{i,k} = \frac{\hat{\omega}_{i,k-1} \cdot f_{k-1,k}(\hat{\mathbf{m}}_{i,k-1}) + \omega_{i,k} \cdot \mathbf{m}_{i,k}}{\hat{\omega}_{i,k}}, \quad (3.16)$$

kde $\hat{\omega}_{i,k} = \hat{\omega}_{i,k-1} + \omega_{i,k}$ predstavuje kumulatívnu váhu a $f_{k-1,k}$ je prechodová funkcia, ktorá transformuje stav z predchádzajúceho snímku $k-1$ do aktuálneho snímku k .

Na dočasné zlepšenie odhadov hĺbok sledovaných príznakov možno vektor $\mathbf{m}$ interpretovať ako 3D súradnice príznaku a následne aplikovať aktualizáciu vzťah (??). V tomto prípade je $f_{k-1,k}$ Euklidovská transformácia určená odhadnutým relatívnym pohybom kamery $\begin{bmatrix} \mathbf{R}_k & \mathbf{t}_k \end{bmatrix}$, a váha sa nastavuje ako:

$$\omega_{i,k} = \frac{1}{1 + \delta_{i,k}}, \quad (3.17)$$

kde $\delta_{i,k}$ je odhadnutá chyba triangulácie. V prípade použitia metódy triangulácie pomocou stredového bodu sa $\delta_{i,k}$ definuje ako súčet najkratších vzdialeností triangulovaného bodu od oboch spätných projekčných lúčov.

3.2.6 Prehľad súčasných riešení

Jedným z prvých algoritmov na extrakciu textúr bol algoritmus SIFT, v súčasnosti sa skôr využívajú jeho alternatívy SURF a ORB, ktoré popisujeme nižšie.

SIFT

Algoritmus SIFT, ktorý predstavil Lowe v roku 1999 [loweObjectRecognitionLocal1999], patrí medzi najskoršie komplexné metódy detekcie kľúčových bodov a extrakcie deskriptorov príznakov. Na zabezpečenie mierkovej invariance buduje SIFT viacúrovňovú pyramídu z rozmazaných verzií vstupného obrazu a aplikuje operátory rozdielu Gaussov (DoG) na detekciu lokálnych extrémov v mierkovom priestore. Lokálnosť je definovaná oknom veľkosti $3 \times 3 \times 3$. Vybrané sú iba extrémny s vysokým lokálnym kontrastom, ktoré neležia na hranách – tie sa označujú ako kľúčové body.

V okolí každého kľúčového bodu sa v okne 16×16 počítajú gradienty obrazu, ktoré sa následne zoskupia do 4×4 podoblastí. V každej podoblasti sa gradienty kvantizujú do osem-prvkového histogramu smerov. Spojením všetkých histogramov (16 oblastí $\times 8$ binov) vzniká vektor deskriptora dĺžky 128 prvkov.

SURF

Šesť rokov po zavedení SIFT predstavili autori Bay a kol. algoritmus SURF [baySURFSpeededRobust1999], ktorý mal byť rýchlejší a robustnejší. Namiesto DoG operátorov využíva SURF aproximované druhé derivácie výpočtom pomocou filtrov s rovnomerným váhovaním, ktoré možno efektívne aplikovať pomocou integrálneho obrazu. To umožňuje výrazné zrýchlenie oproti SIFT.

Robustnosť SURF príznakov spočíva v určení dominantného smeru oblasti okolo kľúčového bodu ešte pred výpočtom deskriptora. Tento smer sa odhaduje na základe Gaussovsky vážených odpovedí na horizontálne a vertikálne Haarove vlnenia v kruhovej oblasti okolo kľúčového bodu. Odpovede sa prevedú do polárnych súradníc, rozdelia do uhlových segmentov a v každom sa spočítajú vektorové odpovede. Smer segmentu

s najdlhším súčtovým vektorom je určený ako dominantný smer lokálneho okolia. Na základe tohto smeru sa potom oblasť rotuje a extrahuje sa Gaussovsky vážený deskriptor z odpovedí na Haarove vlnenia.

ORB

Algoritmus ORB, ktorý v roku 2011 navrhli autori Rublee a kol. [**rubleeORBEfficientAlternative2011**], predstavuje rýchlu a výpočtovo nenáročnú alternatívu k SIFT a SURF. Kombinuje modifikovaný detektor FAST [**rostenMachineLearningHighSpeed2006**] s rotačne invariantnou verziou binárneho deskriptora BRIEF [**calonderBRIEFBinaryRobust2010**].

Pre dosiahnutie mierkovej invariance sa FAST detekcia opakuje na každej úrovni mierkovej pyramídy. Výber príznakov je ďalej filtrovaný pomocou Harrisovej miery [**harrisCombinedCo**], ktorá odstraňuje body, ktoré nie sú rohmi.

Deskriptory sa tvoria ako binárne reťazce dĺžky n porovnávaním jasov vopred určených dvojíc pixelov v okolí príznaku. Keďže pôvodný BRIEF nie je rotačne invariantný, ORB najprv určí smer každého príznaku pomocou metódy obrazových momentov [**kletteConciseComputerVision2014**]. Smer príznaku je určený vektorom spájajúcim jeho stred s centroidom príslušnej obrazovej oblasti. Tento smer sa následne použije na rotáciu testovacej masky pred extrakciou binárneho deskriptora, čím sa dosahuje rotačná invariantnosť.

3.2.7 Vizualný SLAM

Kým vizuálna odometria sa zameriava predovšetkým na lokálny odhad pohybu kamery medzi po sebe idúcimi snímkami, cieľom vizuálneho SLAM-u je súčasne odhadovať trajektóriu kamery aj rekonštruovať štruktúru pozorovaného prostredia. To si vyžaduje riešiť zložitejšie problémy, ako je uzatváranie slučiek, správa globálne konzistentnej mapy či eliminácia chýb akumulovaných počas lokalizácie.

Kľúčovou súčasťou väčšiny moderných SLAM systémov je nelineárna optimalizácia známa ako „bundle adjustment“, ktorá umožňuje spresniť odhady pozícií kamery aj 3D súradníc pozorovaných bodov (tzv. mapových bodov) tak, aby čo najlepšie zodpovedali skutočným pozorovaniam. Hoci je táto technika výpočtovo náročná, vývoj efektívnych algoritmov a organizačných princípov umožnil jej využitie aj v reálnom čase.

Aby bol vizuálny SLAM efektívny a zároveň presný, systém musí zabezpečiť:

1. výber tzv. *klúčových snímkok* (angl. *keyframes*), ktoré reprezentujú rôzne pohľady na scénu a poskytujú dostatočnú paralaxu pre rekonštrukciu hĺbky,
2. sledovanie spoločných prvkov scény medzi kľúčovými snímkami, čo vytvára dobre prepojenú sieť pozorovaní (tzv. *graf snímkok*),

3. dobrý počiatočný odhad pozícií snímok aj 3D bodov, ktorý slúži ako vstup pre optimalizáciu,
4. lokálne obmedzenú optimalizáciu, ktorá znižuje výpočtové nároky a umožňuje škálovateľnosť,
5. globálne optimalizačné kroky – napríklad optimalizáciu grafu pozícií snímok – ktoré umožňujú uzatváranie slučiek v reálnom čase.

Jednou z najznámejších a široko používaných implementácií vizuálneho SLAM-u, ktorá úspešne spája všetky vyššie uvedené aspekty, je algoritmus ORB-SLAM [mur-artalORB-SLAMV

ORB-SLAM

ORB-SLAM je komplexný systém vizuálneho SLAM-u, prvýkrát predstavený v roku 2015, ktorý využíva len jednu monokulárnu, stereo alebo RGB-D kameru a je schopný pracovať v reálnom čase. Systém je postavený na ORB detekcii príznakov, pričom tá istá sada príznakov je využívaná na všetky úlohy: sledovanie pohybu, mapovanie aj uzavretie slučky. ORB-SLAM spája klasickú odometriu s mapovaním a optimalizáciou, čím umožňuje presnú a konzistentnú lokalizáciu aj pri dlhodobom sledovaní scény. Pozostáva z troch základných modulov, ktoré spolupracujú paralelne v reálnom čase:

1. Sledovanie (Tracking)

Tento modul sa stará o spracovanie prichádzajúcich snímok a odhad pohybu kamery vzhľadom na mapu. Ak mapa ešte nie je inicializovaná, vykoná sa monokulárna triangulácia medzi prvými dvoma kľúčovými snímkami. V ďalších krokoch modul odhaduje pozíciu novej snímky pomocou zodpovedajúcich ORB príznakov a porovnaním s aktuálnou mapou. V prípade výraznej zmeny scény alebo straty sledovania môže byť iniciovaný relokalizáciou pomocou databázy kľúčových snímok.

2. Správa mapy (Local Mapping)

Body v mape sa triangulujú zo zodpovedajúcich príznakov v rôznych snímkach. Počas spracovania sa vyberajú nové kľúčové snímky, ktoré rozširujú mapu a umožňujú jej lokálnu optimalizáciu pomocou lokálnej *balíkovej optimalizácie* (angl. *bundle adjustment*). Výber kľúčových snímok je optimalizovaný tak, aby zachytili dostatočný pohyb a nový pohľad na scénu, ale zároveň nezahltili systém nadbytočnými údajmi.

3. Uzatváranie slučiek (Loop Closing)

Na odstránenie akumulovaných chýb a dosiahnutie globálnej konzistencie systému využíva ORB-SLAM detekciu slučiek, t. j. opätovného návratu kamery do už navštívených oblastí. Po detekcii slučky sa vykoná globálna optimalizácia grafu pozícií snímok (angl. *pose graph*), ktorá opraví globálnu trajektóriu a prispôbi mapu.

Pre efektívne porovnávanie snímok a detekciu slučiek používa ORB-SLAM prístup tzv. *zásobníka slov* (angl. *Bag of Words*), ktorý umožňuje rýchle vyhľadávanie vizuálne podobných snímok na základe ORB deskriptorov.

Systém poskytuje ako výstup trajektóriu kamery a riedku trojrozmernú rekonštrukciu scény – s dostatočnou presnosťou pre potreby lokalizácie, ale zároveň s dôrazom na výpočtovú efektivitu.

3.3 Lidarová odometria

Téma lidarovej odometrie (LO) zaznamenala v posledných niekoľkých rokoch veľký rozmach, keďže prináša nové možnosti aplikácie zvlášť v prostrediach a podmienkach, kde sú iné spôsoby lokalizácie nedostatočné. Neustále pribúdajú nové riešenia, ktoré využívajú lidar spolu s ďalšími modernými prístupmi a technológiami za účelom získania čo najpresnejšej polohy.

3.3.1 LiDAR technológia

Light Detection and Ranging (LiDAR) je technológia diaľkového snímania založená na meraní času, za ktorý sa laserový impulz odrazí späť od objektu. Výsledkom sú vysoko presné 3D reprezentácie prostredia vo forme mračien bodov (z angl. *point clouds*). Lidar je nezávislý od osvetlenia a stal sa kľúčovým senzorom v oblasti autonómnej navigácie a mapovania [leeLiDAROdometrySurvey2024].

Lidary možno klasifikovať podľa dvoch hlavných kritérií [leeLiDAROdometrySurvey2024]:

1. Mechanizmus snímania:

- *mechanický* – využíva rotujúce časti na rozptyl lúčov. Ponúka široké zorné pole, dobrú kvalitu meraní, ale tá môže časom degradovať vplyvom opotrebovania mechanických prvkov;
- *polovodičový* (angl. *solid-state*) – nepohyblivé systémy (napr. MEMS, OPA), ktoré sú kompaktnejšie a menej poruchové. Využívajú sa technológie MEMS, ktorá rozptyľuje stacionárny lúč pomocou elektromechanických zrkadiel alebo OPA, ktorá využíva moduláciu tvaru svetelných vln;
- *s plošným osvetlením* (angl. *flash*) – osvetľuje celé zorné pole naraz, veľmi rýchly, no menej používaný v odometrii.

2. Princíp merania:

- *čas letu* (*ToF*) – meria vzdialenosť na základe rýchlosti svetla a doby letu laserového impulzu, za ktorú sa odrazí od objektu a vráti naspäť. Je jed-

noduchý a presný, no môže byť náchylný na rušenie externými svetelnými zdrojmi.

- *frekvenčne modulovaná spojitá vlna (FMCW)* – vysiela súvislé svetelné vlny s premenlivou frekvenciou a analyzuje frekvenčný posun odrazeného svetla, ktorý je priamo úmerný vzdialenosti objektu. Poskytuje navyše aj informácie o relatívnej rýchlosti. Je rezistentný voči interferencii a viaccestnému šíreniu, ale zložitejší a zvyčajne drahší než ToF.
- *amplitúdovo modulovaná spojitá vlna (AMCW)* – meria čas odrazu pomocou vysielania vln s variabilnou amplitúdou.

3.3.2 Prehľad metód lidarovej odometrie

Cieľom LO je odhadnúť trajektóriu robota na základe údajov z lidar. Kľúčom k tomu je princíp odometrie, spočívajúci vo vyhodnotení posunu od predošlému stavu k súčasnemu, čo je však prípade lidarového mračna bodov podstatne komplexnejšie úloha než v prípade kolesovej odometrie. Prístupov k riešeniu tohto problému je mnoho, ponúkame teda najvýznamnejšie z nich podľa zdroja [leeLiDAROdometrySurvey2024].

Odometria založená výlučne na lidare (angl. LiDAR-only odometry)

Využíva výhradne údaje z jedného lidar, pričom porovnáva rozdiel medzi predošlým a súčasným skenom. Jej výhodou je nezávislosť od iných senzorov, nevýhodou nižšia robustnosť v degenerovaných prostrediach. Delí sa na:

- *Metódy priamej zhody (angl. direct matching)* – sú založené na odhade transformačnej matice medzi po sebe nasledujúcimi skenmi, najčastejšie pomocou ICP algoritmu (viac v kap. ??).
- *Textúrne zamerané prístupy (angl. feature-based)* – sú založené na extrakcii významných bodov z mračna bodov a ich použití na odhad transformačného pohybu medzi skenmi, vďaka čomu sú výpočtovo efektívnejšie a odolnejšie voči šumu. Kľúčovou úlohou je však výber vhodných príznakov. Príkladmi implementácie je LOAM, ktorý rozlišuje medzi hranovými a rovinnými bodmi podľa lokálnej hladkosti povrchu či SuMa, resp. SuMa++, ktoré využívajú normálové mapy povrchu a zohľadňujú aj sémantické informácie, čo zvyšuje robustnosť voči chybám registrácie.
- *Metódy hlbokého učenia (angl. deep learning-based)* – pokúšajú sa zlepšiť nachádzanie zhody medzi skenmi pomocou DL prístupov. Túto triedu zastupujú algoritmy ako LO-Net, ktorý predvída dynamiku jednotlivých regiónov a LodoNet, kde sa využíva proces spätnej projekcie zhodných párov kľúčových bodov (MKP).

Lidarovo-inerciálna odometria (LIO)

Ide o kombináciu dát z lidararu a IMU. Prináša vyššiu presnosť a stabilitu. Existujú dve jej variácie podľa toho, akým spôsobom sú spracúvané údaje z IMU:

- *voľne previazaná (angl. loosely coupled)* – spracovanie údajov prebieha samostatne, následne sú fúzované na základe pridelených váh, napr. pomocou EKF.
- *tesne previazaná (angl. tightly coupled)* – optimalizuje všetky merania v spoločnom grafe (napr. LIO-SAM, CLINS). Je výpočtovo náročnejšia a môže byť zraniteľná v prípade, že jeden zo senzorov poskytuje nekvalitné údaje.

Fúzia viacerých senzorov

S cieľom zvýšiť kvalitu merania celého systému (zorné pole, presnosť, robustnosť, ...) sa často využíva kombinácia viacerých senzorov, pričom treba rozlišovať dva základné typy:

- *kombinácia viacerých lidarov* – predchádza dôsledkom výpadku meraní pri použití jediného lidararu, zároveň však kladie vyššie nároky na synchronizáciu a výpočty (napr.);
- *kombinácia lidararu a iných senzorov* – fúzia s kamerami, radarmi, termálnymi senzormi či IMU kompenzuje nedostatky lidararu v nevhodných prostrediach akými sú nepriaznivé poveternostné podmienky či monotónne štruktúry (napr. tunely či diaľnice).

Predmetom výskumu LO sú viaceré pretrvávajúce nedostatky riešení. Spracovanie veľkého množstva údajov si vyžaduje využitie efektívnych dátových štruktúr (napr. ikd-Tree [caiIkdTreeIncrementalKD2021], iVox [baiFasterLIOLightweightTightly2022]). Pri pohybe lidararu dochádza k skresleniu nameraných dát, čo sa rieši zavádzaním vyrovnávacích korekcií a modelov trajektórie. Spoľahlivosť LO stále ovplyvňuje aj povaha okolitého prostredia. V monotónnych prostrediach je preto nevyhnutné aj využitie intenzity merania, Dopplerovho efektu či fúzie s kamerou. Pri fúzii s inými senzormi sú však výzvami faktory ako presná kalibrácia a synchronizácia, ale aj výpočtová náročnosť. Z povahy princípu fungovania lidararu sú problémové najmä daždivé, hmlisté či reflexné prostredia; pre tieto prípady už vznikli viaceré riešenia, napr. WeatherNet alebo LIOR [leeLiDAROdometrySurvey2024].

3.3.3 Iteratívny algoritmus najbližších bodov (ICP)

Jedným z najpoužívanějších súčasných prístupov pre geometrické zarovnanie pri registrácii trojrozmerných povrchov je Iteratívny algoritmus najbližších bodov (ICP). Jeho pôvodná verzia bola vytvorená autormi Besl a kol. [beslMethodRegistration3D1992]

v roku 1992, no modifikácie sú vyvíjané dodnes. Trojrozmerná registrácia povrchu je proces, ktorý zarovnáva 3D mračno bodov (napr. z hĺbkovej kamery alebo z lidar) z rôznych uhlov pohľadu za účelom získania úplnejšej reprezentácie prostredia a určenia pohybu senzora. V prípade, že vstupné dáta sú asociované, t. j. je známa korešpondencia $\mathcal{C}(\mathbf{s}_i) = \{(i, j)\}$ medzi zdrojovým mračnom $\mathcal{S} = \{\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_I\}$ a cieľovým mračnom $\mathcal{D} = \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_J\}$, je možné ich vzájomnú transláciu $\mathbf{t}$ a rotáciu $\mathbf{R}$ určiť minimalizáciou sumy štvorcov odchýlok ako

$$\mathcal{F}(\mathcal{C}(\mathcal{S}), \mathcal{S}, \mathcal{D}) = \min_{\mathbf{R}, \mathbf{t}} \sum_{i=1}^I \sum_{j=1}^J \|\mathbf{d}_i - \mathbf{R} \cdot \mathbf{s}_j - \mathbf{t}\|_2^2 \quad (3.18)$$

Avšak v prípadoch, kedy korešpondencia známa nie je, asociáciu medzi mračnami bodov je potrebné získať heuristicky. Na to existuje viacero metód, napr. numerická Newtonova metóda či dynamický genetický algoritmus, no najčastejšie sa na tento účel využívajú práve variácie ICP algoritmu [**baiICPAlgorithmTheory2023**].

Podstata algoritmu spočíva v troch základných krokoch:

1. počiatočný odhad možných asociácií na základe vstupných dát,
2. iteratívne transformovanie cieľového mračna bodov k zdrojovému tak, aby sa minimalizovala celková odchýlka, až kým sa nedosiahne prahová hodnota konvergenzie,
3. výpočet výslednej translácie a rotácie.

Podrobnejšie je celý proces znázornený v algoritme ??, kde je sú vstupmi zdrojové mračno bodov $\mathcal{S}$, cieľové mračno bodov $\mathcal{D}$ a prah konvergenzie θ . Ďalej v ňom vystupuje operátor výpočtu ťažiska $\mathcal{M}$, operátor registrácie povrchov pri známych korešpondenciách $\mathcal{F}$, odchýlku ε vypočítanú pre danú iteráciu, množinu korešpondencií $\mathcal{C} = \{(i, j)\}$, operátor tuhého transformačného odhadu $\mathcal{T}$ a operátor aplikácie transformácie $\mathbf{T}_{\mathbf{R}, \mathbf{t}}$.

Ako už bolo spomenuté, existuje viacero variantov ICP algoritmu, ktoré je možné rozdeliť na základe viacerých kritérií [**rusinkiewiczEfficientVariantsICP**]:

1. Podľa typu minimalizačnej metriky:

Algoritmus 1 Základný ICP algoritmus podľa [**baiICPAlgorithmTheory2023**]

$\mathcal{S} = \{\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_I\}$, $\mathcal{D} = \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_J\}$, θ $\mathbf{T}_{\mathbf{R}, \mathbf{t}}$, $\varepsilon_k \leq \theta$ $\mathcal{T}(\mathcal{S} \rightarrow \mathcal{D})$ s.t. $\mathcal{M}(\mathcal{S}) = \mathcal{M}(\mathcal{D})$ $\varepsilon_0 \Leftarrow \infty$ ($\varepsilon_k > \theta \wedge \varepsilon_k < \varepsilon_{k-1}$) $\vee \varepsilon_k = \infty$ $\mathbf{s}_i \in \mathcal{S}$ $\mathcal{C}(\mathbf{s}_i) \Leftarrow (\mathbf{d}_j, \mathbf{s}_i)$ s.t. $\|(\mathbf{d}_j, \mathbf{s}_i)\|^2 \rightarrow \min$ $\mathbf{T}_{\mathbf{R}, \mathbf{t}} \Leftarrow \mathcal{F}(\mathcal{C}(\mathcal{S}), \mathcal{S}, \mathcal{D})$ $\varepsilon_{k+1} \Leftarrow \frac{1}{|I|} \sum_{i=1}^I (\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_j)^2$
 $\mathbf{T}_{\mathbf{R}, \mathbf{t}}$

- *bod na bod* – najjednoduchšia verzia, minimalizuje euklidovskú vzdialenosť medzi korešpondujúcimi bodmi, vhodná pri povrchoch bez výraznej štruktúry

$$\min_{\mathbf{R}, \mathbf{t}} \sum_i \|\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_i\|^2$$

- *bod na plochu* – minimalizuje vzdialenosť od bodu k rovine určenej normálou cieľového bodu, rýchlejšie konverguje, vhodný pre hladké povrchy

$$\min_{\mathbf{R}, \mathbf{t}} \sum_i [(\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_i) \cdot \mathbf{n}_i]^2$$

- *plocha na plochu* – predpokladá, že oba body majú definované normály a minimalizuje vzdialenosť medzi dotyčnými rovinami. Používa sa napr. v NDT-ICP alebo pokročilých SLAM systémoch.

2. Podľa stratégie výberu korešpondencií:

- *Brute-force nearest neighbor* – každý bod zo zdrojového mračna sa spáruje s najbližším bodom v cieľovom;
- *Mutual nearest neighbor* – korešpondencia sa akceptuje iba vtedy, ak si oba body navzájom zodpovedajú ako najbližší sused;
- *Color ICP* – pri výbere korešpondencií sa berie do úvahy aj podobnosť farby alebo intenzity;
- *Feature-based ICP* – body sú doplnené o deskriptory a párujú sa na základe ich podobnosti.

3. Podľa robustnosti a rýchlosti:

- *Generalized ICP (G-ICP)* – spája metódy *bod na bod* a *bod na plochu* pomocou modelovania pravdepodobnostného rozloženia bodov ako Gaussových distribúcií, vhodný pre zarovnávanie s neistotou alebo nehomogenitou;
- *Sparse ICP* – používa len podmnožinu bodov, čo šetrí výpočtový čas;
- *Robust ICP* – používa robustné funkcie na potlačenie vplyvu odľahlých bodov.
- *Color/Photometric ICP* – rozširuje ICP o intenzitné alebo farebné informácie (vhodné pri RGB-D údajoch).

4. Iné pokročilé varianty:

- *Normal Distributions Transform (NDT)* – Mračná bodov sa reprezentujú ako hustotné mapy (napr. v bunkách), nie ako explicitné body;

- *Iterative Closest Line/Keypoint (ICLK)* – rozšírenia pre špecifické geometrie (čiary, body, hrany);
- *KISS-ICP* – minimalistický robustný point-to-point ICP s adaptívnym prahom a robustným jadrom.

KISS ICP

KISS-ICP predstavuje odľahčený variant klasického ICP algoritmu typu *bod na bod* pre LO. Cieľom autorov bolo preukázať, že dobre navrhnuté jednoduché komponenty dokážu prekonať zložité metódy. Systém má rádovo menej parametrov než iné metódy a väčšinou nevyžaduje žiadne špecifické ladenie pre rôzne typy lidarov či prostredia [vizzoKISSICPDefensePointtoPoint2023].

Algoritmus prebieha v štyroch základných krokoch. Najskôr sa vykonáva predikcia a kompenzácia pohybu (angl. *deskewing*), ktorej cieľom je kompenzovať rozptyl meraných bodov spôsobený pohybom lidarů počas skenovania a predpovedať aktuálnu pozíciu registrovaných bodov. Namiesto fúzie s kolesovou odometriou či IMU sa v tomto prípade používa model konštantnej rýchlosti, a to práve pre jeho jednoduchosť a nezávislosť od ďalších senzorov či časovej synchronizácie. Model konštantnej rýchlosti predikuje aktuálnu polohu $\mathbf{T}_{pred,t}$ v čase t na základe rozdielu dvoch predošlých polôh definovaných pomocou translačného vektora a rotačnej matice $\mathbf{T}_{t-1} = (\mathbf{R}_{t-1}, \mathbf{t}_{t-1})$, $\mathbf{T}_{t-2} = (\mathbf{R}_{t-2}, \mathbf{t}_{t-2})$, pričom sa predpokladá, že translačná $\mathbf{v}_t$ a rotačná rýchlosť $\boldsymbol{\omega}_t$ sa nemení.

Predikovaná poloha a z toho odvodené rýchlosti sa vypočítajú ako

$$\mathbf{T}_{pred,t} = \begin{bmatrix} \mathbf{R}_{t-2}^\top \mathbf{R}_{t-1} & \mathbf{R}_{t-2}^\top (\mathbf{t}_{t-1} - \mathbf{t}_{t-2}) \\ \mathbf{0} & 1 \end{bmatrix}, \quad (3.19)$$

$$\mathbf{v}_t = \frac{\mathbf{R}_{t-2}^\top (\mathbf{t}_{t-1} - \mathbf{t}_{t-2})}{\Delta t}, \quad (3.20)$$

$$\boldsymbol{\omega}_t = \frac{\text{Log}(\mathbf{R}_{t-2}^\top \mathbf{R}_{t-1})}{\Delta t}, \quad (3.21)$$

kde Δt je čas akvizície lidarového snímku a $\text{Log} : SO(3) \rightarrow \mathbb{R}^3$ extrahuje osovo-uhlovú reprezentáciu rotácie. Ďalej sa predpokladá, že každý zosnímaný bod v jednom skene $\mathbf{p}_i \in \mathcal{P}$ má relatívnu časovú značku v rozmedzí $s_i \in \langle 0, \Delta t \rangle$, predstavujúcu uplynutý čas od začiatku snímania daného skenu. Korekcia pozície nameraných bodov je potom počítaná ako

$$\mathbf{p}_i^* = \text{Exp}(s_i \boldsymbol{\omega}_t) \mathbf{p}_i + s_i \mathbf{v}_t, \quad (3.22)$$

kde $\text{Exp} : \mathbb{R}^3 \rightarrow SO(3)$ počíta rotačnú maticu z osovo-uhlovej reprezentácie.

Následne prebieha podvzorkovanie skenu pre zefektívnenie registrácie mračien. Mnohé iné prístupy vyhľadávajú význačné body, čo však pridáva ďalšiu vrstvu komplexnosti. KISS-ICP namiesto toho pracuje s dvojkrokovým podvzorkovaním pomocou tvz.

voxelov, teda trojrozmerných buniek. Kým lokálna mapa je reprezentovaná voxelovou mriežkou s rozlíšením $v \times v \times v$, v prvom kroku je vstupné mračno $\mathcal{P}^*$ podvzorkované na voxely veľkosti αv – čím vzniká mračno $\mathcal{P}_{\text{merge}}^*$ ktoré je neskôr použité na aktualizáciu mapy – a v druhom kroku na voxely veľkosti βv za vzniku mračna $\hat{\mathcal{P}}^*$, ktoré sa použije na registráciu, platí $\alpha \in (0, 1)$ a $\beta \in \langle 1, 2 \rangle$. Na rozdiel od iných metód, v ktorých sa súradnice voxelu určujú ako priemer všetkých bodov, ktoré obsahuje, v tomto prípade sa použijú súradnice prvého bodu spadajúceho pod daný voxel, čím sa zamedzí vzniku diskretizačnej odchýlky, a teda platí $\hat{\mathcal{P}}^* \subseteq \mathcal{P}^*$

Ďalším krokom je určenie korešpondencií. Oproti klasickému ICP, kde sa porovnávajú dva po sebe nasledujúce snímky, KISS-ICP registruje vstupný snímok na celú lokálnu mapu, teda množinu všetkých v minulosti registrovaných bodov. Následne sa voxelová mriežka mapy doplní o novo registrované body s tou podmienkou, že každý voxel má obmedzenú kapacitu, čo opäť cieľi na celkovú efektivitu algoritmu. Na nastavenie prahovej hodnoty τ_t pre filtráciu odľahlých bodov sa využíva adaptívny výpočet. Ten zohľadňuje veľkosť zrýchlenia, ktoré spôsobuje nepresnosť predikcie v predchádzajúcich krokoch.

Proces získania globálneho odhadu polohy $\mathbf{T}_t$ začína transformáciou vstupného mračna pomocou predošlej polohy $\mathbf{T}_{t-1}$ a predikcie $\mathbf{T}_{\text{pred},t}$:

$$\mathcal{S} = \{\mathbf{s}_i = \mathbf{T}_{t-1} \mathbf{T}_{\text{pred},t} \mathbf{p} \mid \mathbf{p} \in \hat{\mathcal{P}}^*\} \quad (3.23)$$

V každej iterácii j sa získa množina korešpondencií medzi mračnom $\mathcal{S}$ a lokálnou mapou $\mathcal{L} = \{\mathbf{q}_i \mid \mathbf{q}_i \in \mathbb{R}^3\}$ pomocou metódy najbližšieho suseda s prahovou hodnotou τ_t . Odhad korekcie polohy sa potom počíta takto:

$$\Delta \mathbf{T}_{\text{est},j} = \underset{\mathbf{T}}{\operatorname{argmin}} \sum_{(\mathbf{s}, \mathbf{q}) \in \mathcal{C}(\tau_t)} \rho(\|\mathbf{T}\mathbf{s} - \mathbf{q}\|_2), \quad (3.24)$$

kde $\mathcal{C}(\tau_t)$ je množina korešpondencií najbližších susedov, ktorých vzdialenosť je menšia ako τ_t a ρ je Geman-McClure-ova robustná účelová funkcia. Vstupné body sú potom aktualizované pomocou vypočítanej korekcie, pričom celý postup sa opakuje až kým nie je splnená podmienka konvergenzie, ktorou je $\Delta \mathbf{T}_{\text{est},j} < \gamma$:

$$\{\mathbf{s}_i \leftarrow \Delta \mathbf{T}_{\text{est},j} \mathbf{s}_i \mid \mathbf{s}_i \in \mathcal{S}\} \quad (3.25)$$

Výsledkom je tak transformácia $\mathbf{T}_t = \Delta \mathbf{T}_{\text{icp},t} \mathbf{T}_{t-1} \mathbf{T}_{\text{pred},t}$. Napokon, korekcia je aplikovaná na mračno $\mathcal{P}_{\text{merge}}^*$, ktoré je následne integrované do lokálnej mapy.

3.4 Inerčné snímače

Inerčné snímače, resp. snímače zotrvačnosti slúžia na meranie vlastných stavových veličín – lineárnych a uhlových rýchlostí a zrýchlení robota. Nemerajú polohu priamo,

ale v kombinácii s inými meraniami polohy môžu prispieť k spresneniu odhadu polohy a korekcii chýb iných meraní. Zaradujeme tu gyroskopy, akcelerometre a tiež magnetometre.

3.4.1 Gyroskopy

Gyroskopy zaznamenávajú zmeny v natočení objektu, pričom poskytujú informáciu o orientácii, príp. jej zmene vo všetkých osiach. Ich výstupom sú hodnoty vzťahnuté na pevný referenčný rámec. Väčšinou nie sú citlivé na elektromagnetické a feromagnetické anomálie, takže na rozdiel od magnetických kompasov je ich využitie možné aj v prostrediach bez prítomnosti geomagnetického poľa [duchonSnimaceMobilnejRobotike2012].

Gyroskopy je možné podľa technológie merania rozdeliť na mechanické a optické. Podľa typu výstupných dát sa delia na derivačné a integračné. Výstup derivačných gyroskopov je úmerný rotácii. Integračné gyroskopy sú schopné poskytnúť aj informáciu o absolútnej polohe pomocou integrovania relatívnych hodnôt vzťahnutých na globálnu referenciu. Podobne ako u odometrických snímačov, aj v tomto prípade dochádza driftu. Na jeho potlačenie je možné využiť niektorú z techník [duchonSnimaceMobilnejRobotike2012]:

- potlačenie šumu odstránením odľahlých hodnôt,
- potlačenie šumu aplikáciou metódy kĺzavého priemeru,
- aplikácia mierky na zmenu absolútnych uhlov,
- recalibrácia gyroskopu vzorkovaním na strednú hodnotu,
- recalibrácia gyroskopu vzorkovaním na minimálnu a maximálnu hodnotu.

Mechanické gyroskopy

Fungujú na princípe zákona zachovania hybnosti, pričom sa delia podľa toho, aký typ hybnosti využívajú [duchonSnimaceMobilnejRobotike2012]:

1. *spojitá uhlová hybnosť* – gyroskopy so zotrvačníkom, čiastkové gyroskopy,
2. *kmitajúca uhlová rýchlosť* – gyroskopy s torznou závesnou hmotou kmitajúcou na vlastnej frekvencii,
3. *spojitá lineárna hybnosť* – gyroskopy so stabilným tokom tekutiny, plazmy alebo elektrónov, ktoré majú tendenciu udržiavať vektor svojej rýchlosti pri otáčaní meracej platformy,
4. *kmitajúca lineárna hybnosť* – gyroskopy používajúce množinu kmitajúcej diskretnej hmoty, pričom kmity sú vyvolané pozdĺž rovných čiar.

Mechanický gyroskop na báze zotrvačníka pozostáva s rýchlo rotujúceho kotúča alebo gule, ktorej väčšina hmoty je sústredená na vonkajšej periférii, a to pre dosiahnutie vyššieho momentu zotrvačnosti. Rotujúce teleso je upevnené na dvoch na seba kolmých voľne rotujúcich osiach. Rotácia kotúča okolo prvej osi spôsobuje vznik momentu hybnosti L . Pri vzniknutí krútiaceho momentu τ na kolmú os (vplyvom vonkajších síl) dochádza k zmene smeru momentu hybnosti prvej osi


$$d\vec{L} = \vec{\tau} dt. \quad (3.26)$$

Tejto jav sa nazýva *precesia gyroskopu* [moebUniversityPhysics2016]. Na obr. ?? je bez straty na všeobecnosti znázornená situácia s klasickým zotrvačníkom, v ktorej je moment τ spôsobený tiažovým zrýchlením. Zo vzťahu ?? je možné následne odvodiť, že veľkosť precesie ω_P je priamo úmerná krútiacemu momentu τ [duchonSnimaceMobilnejRobotike2012]


$$\tau = J\omega\Omega, \quad (3.27)$$

kde J je moment zotrvačnosti rotačného objektu a ω je jeho uhlová rýchlosť, pričom platí $\omega_P \ll \omega$ [moebUniversityPhysics2016]. Typický príklad mechanického dvojsového gyroskopu je na obr. ??.

Zvyškové trenie v ložiskách gyroskopu, vonkajšie vplyvy a malé nerovnováhy v konštrukcii spôsobujú malú odchýlku v zmysle dlhotrvajúcej stability, ktorá sa u vysokokvalitných produktov pohybuje na úrovni okolo $0,1^\circ$ za 6 hodín prevádzky [duchonSnimaceMobilnejRobo



(a) Precesia gyroskopu so znázornením všetkých pôsobiacich síl a momentov [moebUniversityPhysics2016]



(b) Dvojsoý mechanický gyroskop so zotrvačníkom [duchonSnimaceMobilnejRobotike2012]

Obr. 3.3: Gyroskop – ilustrácia

Derivačné mechanické gyroskopy

Fungujú na princípe mechanickej ladičky, ktorej vidlice vibrujú k sebe a od seba s pevnou amplitúdou. Takýto snímač pozostáva z páru vidlíc – riadenej a snímacej. Rotácia okolo vertikálnej (torznej) osi vyvoláva vznik Coriolisových síl, pričom na každú z vidlíc pôsobí sila

$$F = 2m\Omega v_r, \quad (3.28)$$

kde F je Coriolisova sila pôsobiaca na vidlicu, m je hmotnosť vidlice, Ω je vstupná rýchlosť otáčania a v_r je okamžitá uhlová rýchlosť vidlice. Coriolisove sily generujú rotačný moment, ktorý je priamo úmerný vstupnej uhlovej rýchlosti a spôsobuje kmitanie snímacej vidlice, ktorá tak generuje signál [duchonSnimaceMobilnejRobotike2012]. Schematický náčrt takéhoto typu gyroskopu sa nachádza na obr. ??.

Optické gyroskopy

Uhlová rýchlosť je snímaná pomocou dvoch monochromatických svetelných lúčov, ktoré sú vysielané z rovnakého zdroja do opačného smeru v uzavretom kruhovom optickom vlákne. Lúče vytvárajú vo vnútri vlákna stojaté vlnenie s kmitňami a uzlami. Teoreticky by mal detektor s každou otočkou laserového kruhu zaznamenať počet uzlov rovný dvojnásobku dráhy lúčov vydeleného ich vlnovou dĺžkou. V skutočnosti však dosiahnutie takéhoto riešenia nie je možné kvôli vplyvu konštrukčných nedokonalostí [duchonSnimaceMobilnejRobotike2012].

Optické gyroskopy sa používajú v nasledujúcich základných konfiguráciách [duchonSnimaceMobilnejRobotike2012].

- *Aktívne optické rezonátory* – využívajú tzv. Sagnacov efekt. Laserové lúče sú vysielané oproti sebe v cyklickej dráhe. Pri rotácii dochádza k predĺženiu dráhy jedného lúča a skráteniu dráhy druhého. Rozdiel je priamoúmerný rotačnej rýchlosti. Ich nevýhodou je jav uzamknutia frekvencie pri nízkych rýchlostiach, ktorí súvisí s periodickou moduláciou lasera v spojení s malým množstvom odrazov na reflexných plochách. Výsledkom je pásmo necitlivosti.
- *Pasívne optické rezonátory* – používajú externý laser, čo zabraňuje vzniku uzamknutia frekvencie. Klasické implementácie používajú zrkadlové optické rezonátory. V porovnaní s aktívnymi majú menšie rozmery, vyššiu citlivosť aj robustnosť a nižšiu cenu.
- *Neradené interferometrické gyroskopy z optických vlákien (analog)* – vďaka využitiu optických vlákien je možné zmenšenie rozmerov a predĺženie dráhy lúčov, z čoho vyplýva zvýšenie rozlíšenia a znížené výrobné náklady. Medzi výhody tiež patrí vysoká tolerancia na vibrácie a otrasy, necitlivosť na gravitačné efekty,

rýchly štart a dobrá citlivosť. Nevýhodami sú veľká dĺžka optického vlákna, obmedzený dynamický rozsah a odchýlky kvôli použitým analógovým komponentom. Používajú sa zväčša v jednoduchších aplikáciách vyžadujúcich strednú presnosť.

- *Riadené interferometrické gyroskopy z optických vlákien (digitál)* – citlivý prvok merajúci fázový posun nevyužíva Sagnacov efekt, ale pracujú s fázovým posunom lúčov $\Delta\phi = 0$. Ich výhodou je veľká presnosť, nezávislosť od intenzity svetla vysielaného v gyroskope, nezávislosť od zosilnení jednotlivých komponentov gyroskopu a lineárnosť a stabilita závislá len od nerecipročného fázového vysieláča. Drift tohto typu gyroskopov sa pohybuje v rozmedzí 0,0001–0,01°/hod.
- *Rezonančné gyroskopy s optickými vláknami* – princíp ich činnosti bol odvodený od pasívnych optických rezonátorov. Výhodami sú vysoká spoľahlivosť, dlhá životnosť, rýchly štart a malá hmotnosť. Nevýhodou je nutnosť použitia vysoko koherentného zdroja svetla a extrémne bezstratových komponentov optického vlákna.

3.4.2 Akcelerometre

Zrýchlenie je vektorová fyzikálna veličina popisujúca zmenu vektoru rýchlosti – jeho veľkosti alebo smeru. Z Newtonových pohybových zákonov je známe, že teleso mení rýchlosť len keď na neho pôsobí sila (I. zákon) a táto sila spôsobuje jej úmerné zrýchlenie (II. zákon). Akcelerometre sú snímače vyvinuté na zaznamenanie síl na nich pôsobiacich, teda výstupom z nich je signál priamo úmerný akcelerácii.

Na zaznamenanie rôznych fyzikálnych síl sa v akcelerometroch využívajú rôzne citlivé elementy. Podľa toho sa akcelerometre delia na **[duchonSnimaceMobilnejRobotike2012]**:

- *mechanické* – (obr. ??) merajú zrýchlenie pomocou pružiny, pričom využívajú Newtonov druhý pohybový zákon a Hookov zákon opisujúci tuhosť pružiny. Zrýchlenie spôsobuje deformáciu pružiny, ktorá je úmerná zrýchleniu;
- *piezoelektrické* – (obr. ??) využívajú piezoelektrický efekt – pri deformácii keramického kryštálu sa pôsobením zrýchlenia generuje elektrický náboj, ktorý je úmerný sile. Pracujú najlepšie v stredných a vysokých frekvenciách;
- *piezorezistívne* – sú založené na zmene elektrického odporu pri mechanickom namáhaní piezorezistívneho materiálu. Umožňujú merať aj konštantné zrýchlenie (0 Hz), čo ich odlišuje od piezoelektrického typu;
- *tepelné* – (obr. ??) merajú zrýchlenie na základe zmien rozloženia teploty v plyne ohrievanom výhrevným telesom. Neobsahujú pohyblivé časti a sú veľmi odolné, ale citlivé na zmeny okolitej teploty;

- *elektromechanické* – obsahujú pohyblivý mechanický prvok spojený s elektrickou časťou (napr. kondenzátorom). Zrýchlenie spôsobuje pohyb prvku, čo vedie k zmene elektrickej veličiny – najčastejšie kapacity.

Akcelerometre sú schopné zaznamenať zrýchlenie len v jednej osi. Pre meranie trojrozmerného zrýchlenia sa používajú systémy zložené z kombinácie troch vzájomne kolmých akcelerometrov. Ich najväčšou nevýhodou je vysoká citlivosť na vibrácie mechanických častí robota ako aj na rôzne parazitné zrýchlenia. Tento problém sa obvykle rieši zvýšením pomeru dĺžky citlivého elementu k jeho šírke v požadovanom smere [duchonSnimaceMobilnejRobotike2012].

3.4.3 Magnetometre

Magnetometre (magnetické kompas) sú prístroje, ktoré sú schopné zaznamenať magnetické pole Zeme. Na základe ich meraní je možné stanoviť orientáciu robota. Magnetické kompasy využívané v mobilnej robotike sa delia na [duchonSnimaceMobilnejRobotike2012]:

- *mechanické magnetické kompas* – tradičné kompas s otočným diskom v kvapaline, často upevnené na guľovom závесе na kompenzáciu pohybu. Okolité magnetické anomálie sa potláčajú pomocou nastaviteľných permanentných magnetov. Sú náchylné na odchýlky z externých zdrojov.
- *kompas s magnetickou indukčnou sondou* – používajú dvojicu navzájom kolmých cievok s feritovým jadrom. Merajú horizontálnu zložku magnetického poľa pomocou sínusových výstupov. Ich výhodou je nízka spotreba, odolnosť voči otrasom a rýchly štart. Nevýhodou je citlivosť na magnetické anomálie, ktorú možno potlačiť spojením s gyroskopom.
- *magneticko-indukčné kompas* – využívajú solenoid ako súčasť L/R oscilátora, kde frekvencia závisí od indukcie ovplyvnenej magnetickým poľom. Elektronika je jednoduchšia a spotreba energie nižšia ako pri kompasoch na báze magnetickej indukčnej sondy. Výstup má digitálny charakter.
- *kompas na báze Hallovho efektu* – merajú rozdiely napätí v polovodiči so stálym prúdom pri prítomnosti magnetického poľa. Dvojica kolmých senzorov umožňuje výpočet uhla natočenia. Sú lacné, ale s nízkym rozlíšením a silným vplyvom vnútorných chýb, čo vyžaduje filtrovanie a znižuje šírku pásma.
- *magneticko-rezistívne kompas* – Využívajú zmenu odporu anizotropného materiálu pri zmene smeru magnetizácie. Umožňujú veľmi citlivé meranie natočenia, sú vhodnú najmä pre aplikácie vyžadujúce vysokú presnosť.

- *magneticko-elastické kompas*y – sú založené na zmene Youngovho modulu magneticko-striktívnych materiálov pri pôsobení magnetického poľa. Meranie je založené na detekcii deformácie materiálu vyžaduje zliatiny s vysokou magnetostrikciou.

3.4.4 IMU

Inerčná meracia jednotka (niekedy nazývaná aj inerčná referenčná jednotka alebo pohybová referenčná jednotka, skr. IMU, alebo tiež inerčný navigačný systém, skr. INS) je zväčša elektromechanické alebo polovodičové zariadenie, ktoré obsahuje kombináciu viacerých senzorov (zvyčajne akcelerometrov a gyroskopov, ale tiež magnetometrov a tlakových senzorov) schopných merať pohyb, teda lineárne a uhlové zrýchlenia, uhlové rýchlosti, príp. aj orientáciu, a to vo všetkých troch osiach. Je schopná zaznamenať zotrvačné sily a transformovať ich na výstupné údaje, ktoré opisujú pohyb objektu [InertialMeasurementUnit2023].

Najpoužívanejšou konštrukčnou technológiou pre IMU je MEMS. Sú to miniatúrne zariadenia s veľkosťou rádovo v mikrometroch, ktoré sú tvorené kombináciou elektrických a mechanických prvkov tvorených z rôznych materiálov (napr. kremík, polyméry, kov). Existujú rôzne typy MEMS komponentov, od jednoduchých prepínačov až po mimoriadne zložité elektromechanické systémy s viacerými integrovanými snímačmi a mikroelektronikou [InertialMeasurementUnit2023].

Výhody použitia MEMS technológie spočívajú najmä v mimoriadne malej veľkosti a hmotnosti komponentov v kombinácii s nízkou spotrebou energie. Vďaka tomu je možné takéto snímače umiestniť na malých plošných spojoch do kompaktných puzdier a sú vhodné na umiestnenie v mobilných robotoch, ktoré majú obvykle značné priestorové aj napájacie obmedzenia. Jednotlivé komponenty, materiály a konštrukčné techniky zabezpečujú vysokú spoľahlivosť a dlhú životnosť, pričom tieto parametre sú stále predmetom neustáleho zdokonaľovania sa [InertialMeasurementUnit2023].

Na druhú stranu, pre správnu interpretáciu výstupných dát z IMU je potrebné ďalšie spracovanie, a to za účelom odstránenia tiažového zrýchlenia a tiež filtrácie šumu meraní, ktorý pri vysokej citlivosti snímačov môže spôsobiť vznik drift odhadu polohy. Vzhľadom na vysokú mieru šumu meraní sa IMU senzory väčšinou nepoužívajú samostatne, ale vo fúzii s inými senzormi. Vďaka skutočnosti, že meria reálne fyzikálne veličiny na základe priameho vplyvu zotrvačných síl, údaje z nej sú nápomocné v kombinácii so snímačmi, ktoré merajú polohu na základe rôznych metód odhadu (kamera, lidar, GPS, a i.) a u ktorých zvykne dochádzať napríklad ku skokovým zmenám odhadu, ktoré fyzikálne nie sú možné. Algoritmy, ktoré sa zaoberajú fúziou dát z viacerých snímačov budeme bližšie rozoberať v ďalších častiach práce.

Open GINS

4 Externé lokalizačné systémy

4.1 GNSS systémy

Globálne navigačné satelitné systémy (GNSS) sú systémy slúžiace na určenie polohy, rýchlosti a času [duchonSnimaceMobilnejRobotike2012]. Pozostávajú zo zoskupení satelitov, ktoré neustále vysielajú informáciu o svojej polohe a čase, zo siete pozemných staníc a z prijímačov, ktoré vypočítavajú polohu na zemi pomocou trilaterácie. Používajú sa vo všetkých formách dopravy: na vesmírnych staniciach, v letectve, námornej doprave, železničnej doprave, cestnej doprave a hromadnej doprave [GNSS].

V súčasnosti existuje niekoľko globálnych systémov [WhatGNSS]:

- GPS (Spojené štáty americké),
- GLONASS (Ruská federácia),
- GALILEO (Európska Únia),
- COMPASS/Bei-Dou (Čína).

Okrem nich sú v priebežnom vývoji aj ďalšie regionálne systémy, ako napríklad indický IRNSS a japonský QZSS. V momente dokončenia všetkých týchto systémov bude pre užívateľov k dispozícii dokopy viac než sto satelitov. Jednou z najaktuálnejších tém v rámci oblasti GNSS je zabezpečenie interoperability medzi globálnymi systémami, čo by umožnilo užívateľom prijímať a spracúvať signál z viacerých satelitných systémov pomocou jedného zariadenia [GNSS].

Výkonnosť GNSS sa hodnotí podľa štyroch kritérií [WhatGNSS]:

1. *presnosť* – rozdiel medzi nameranou a skutočnou polohou, rýchlosťou alebo časom prijímača,
2. *integrita* – schopnosť systému poskytnúť určenú mieru spoľahlivosti a v prípade poruchy v údajoch o polohe vydať varovanie,
3. *kontinuita* – schopnosť systému fungovať bez prerušenia,
4. *dostupnosť* – percentuálny podiel času, počas ktorého signál spĺňa uvedené kritériá presnosti, integrity a kontinuity.

Túto výkonnosť je možné zlepšiť pomocou regionálnych satelitných augmentačných systémov (SBAS). Ich kombinácia s overenými pozemnými technológiami, ako je inerciálna navigácia, prináša možnosti novým aplikáciám, ktoré nevyžadujú len presnosť, ale predovšetkým spoľahlivosť a integritu.

Medzi hlavné výhody GNSS patria vysoká presnosť, údaje v jednotnom svetovom súradnicovom systéme WGS a nezávislosť na počasi či fáze dňa. Nevýhodami sú nemožnosť využitia v podzemí, vo vode aj v interiéroch s hrubými či početnými stenami, horšia presnosť v prostrediach s menšou viditeľnosťou na oblohu (napr. oblasti husto zastavané vysokými budovami, lesy, údolia) či možnosť rušenia signálu externým zdrojom [duchonSnimaceMobilnejRobotike2012].

4.1.1 Princíp činnosti

Princíp určovania polohy pomocou GNSS spočíva v meraní času letu rádiového signálu z družíc. Každý satelit vysiela svoje identifikačné údaje, polohu a časovú značku. Prijímač vypočíta odhad vzdialenosti družice na základe rozdielu medzi časom vyslania a prijatia signálu. Polohu meraného bodu je možné určiť vyhodnotením takéhoto signálu z viacerých satelitov. Z geometrického hľadiska by na určenie trojrozmernej polohy mal stačiť prienik vzdialeností troch družíc. Keďže ale nie je možné zaručiť presnú synchronizáciu hodín prijímača, je potrebný údaj z ešte aspoň jedného satelitu, čím vznikne viacero bodov prieniku. Čas prijímača je následne posúvaný tak, aby tieto body splynuli do jediného, čím vzniká výsledné meranie polohy. Pre dosiahnutie vyššej presnosti potrebné poznať polohy čo najväčšieho počtu vhodne rozložených družíc [duchonSnimaceMobilnejRobotike2012].

4.1.2 Chyby GPS

Merania GPS sú sprevádzané niekoľkými typmi chýb [duchonSnimaceMobilnejRobotike2012]:

- *Geometria rozloženia satelitov* – pokiaľ aktuálne viditeľné satelity nie sú rovnomerne rozložené po celej oblohe, môže dôjsť k nepresnej triangulácii, a teda aj k chybe odhadu polohy. Viditeľnosť satelitov negatívne ovplyvňuje aj meranie vnútri vozidla, v blízkosti vysokých budov či v členitom teréne. Tento typ chyby vyjadruje parameter zníženia presnosti (DOP).
- *Atmosférické efekty* – zemská atmosféra ovplyvňuje GPS signály dvomi hlavnými vrstvami: troposférou a ionosférou. Troposféra ako elektricky neutrálne prostredie spôsobuje nedisperzné odchýlky závislé od teploty, tlaku a vlhkosti, ktoré rovnomerne postihujú fázové aj kódové GPS merania. Ionosféra je elektricky aktívna vrstva s voľnými elektrónmi a iónmi, kde dochádza k odrazu a útlmu rádiových vln, najmä v dôsledku interakcie s neutrálnymi molekulami. Jej účinky závisia od slnečnej aktivity a polohy v atmosfére a spôsobujú spomalenie elektromagnetických vln úmerné k prevrátenej hodnote kvadrátu ich frekvencie. Vplyv ionosféry

možno čiastočne eliminovať porovnaním signálov na rôznych frekvenciách, čo využívajú napríklad vojenské GPS prijímače pracujúce.

- *Efekt viaccestného šírenia sa signálu (angl. multipath)* – nastáva, keď sa GPS signál odrazí od objektov v okolí prijímača a dorazí k nemu oneskorene. Tieto odrazené signály predlžujú dráhu, ktorú signál prejde, čo vedie k chybám v určení polohy – typicky v rozsahu niekoľkých metrov. GPS satelity vysielajú signál v širokom kuželi, takže odrazy sú bežné najmä v mestskom alebo členitom prostredí. Na zníženie tohto efektu sa používajú antény so špeciálnou konštrukciou (napr. s ochranným tanierom), pokročilé technológie v prijímači a efektívne metódy spracovania signálu. Tieto opatrenia znižujú príjem odrazených signálov, čím zlepšujú presnosť určenia polohy.
- *Relativistické efekty* – zohrávajú významnú úlohu pri určovaní polohy pomocou GPS, najmä kvôli veľkej rýchlosti a výške družíc. Zmeny frekvencie signálu v dôsledku rýchlosti pohybu družíc (Dopplerov jav) a rozdiely v priebehu času spôsobené gravitáciou (dilatácia času) ovplyvňujú presnosť meraní. Tieto efekty sú dôsledkom špeciálnej aj všeobecnej teórie relativity a musia byť zahrnuté do výpočtov polohy. Bez ich korekcie by chyba v určovaní času spôsobila výrazné chyby v polohe, až rádovo kilometre denne. Preto sú súčasťou rovníc používaných v GPS prijímačoch aj korekcie na relativistické poruchy dráh družíc a šírenia signálu.
- *Ďalšie chyby GPS*
 - nepresnosť hodín v GPS prijímači (prijímač nemôže obsahovať atómové hodiny, odstránenie chyby sa rieši použitím signálu z viacerých satelitov),
 - nepresné určenie parametrov dráhy družice (tzv. ephemeris error),
 - počet viditeľných satelitov (pre väčšiu presnosť merania je potrebné mať väčší počet viditeľných satelitov).

4.1.3 Augmentačné systémy

Spomenuté chyby GPS meraní je možné v rôznej miere potlačiť pomocou systémov so zvýšenou presnosťou. Tie bývajú častou voľbou aj v prípade mnohých robotických aplikácií, pre potreby ktorých je presnosť meraní pomocou GNSS nedostatočná [duchonSnimaceMobilnejRobotike2012].

Inertial Navigation System (INS)

Pridaním INS ku GPS je možné dosiahnuť presnosť v rozsahu približne jedného metra. Výstup z oboch systémov býva porovnávaný obvykle pomocou Kalmanovho filtra, ktorý poskytuje najviac pravdepodobné meranie;

Differential GPS (DGPS)

Potrebné sú dva GPS prijímače, z ktorých jeden sa nachádza na geodeticky vymeranej polohe. Využíva sa skutočnosť, že blízke prijímače majú vysokú koreláciu chýb. Referenčná stanica vypočítava a vysiela korekcie na základe rozdielov medzi očakávanými a nameranými údajmi zo všetkých viditeľných družíc. V prijímači užívateľa DGPS je korekčný údaj využitý na opravu merania. Použitím DGPS môže užívateľ získať presnosť určovania polohy v reálnom čase na úrovni desiatok centimetrov až metrov, v závislosti od vzdialenosti od referenčnej stanice.

Real-Time Kinematic (RTK) GPS

RTK je vysoko presná technológia pre lokalizáciu a navigáciu, využívaná v širokom spektre aplikácií od prieskumu a mapovania, cez poľnohospodárstvo až po stavebníctvo. Funguje, podobne než DGPS, na kombinácii referenčnej stanice a užívateľského prijímača. Na rozdiel od DGPS však referenčná stanica uskutočňuje aj meranie nosnej fázy signálu. Prijímač potom odlišnosti v nosnej fáze vyhodnocuje, čo dramaticky zvyšuje presnosť merania polohy [RTKGPSTechnologyPrecise].

Wide Area Augmentation System (WAAS)

Systém WAAS poskytuje extrémne vysokú presnosť lokalizácie, využiteľnú najmä v leteckej doprave. Pozostáva z 38 referenčných staníc (WRS), 3 hlavných staníc (WMS), 3 geostacionárnych družíc a 6 pozemných vysielačích staníc. Referenčné stanice slúžia na prijímanie signálu GPS. Ich polohy sú zvolené tak, aby bolo možné zachytiť akékoľvek chyby v signáloch GPS. Informácie z WRS sa posielajú do WMS, ktoré vysielaajú správy pre užívateľov s frekvenciou 1 Hz. Tieto správy umožňujú významnú korekciu GPS meraní na strane užívateľa. WMS vysiela správy aj na pozemné vysielačie stanice, odkiaľ sú prenášané k navigačným zariadeniam na geostacionárnych komunikačných satelitoch. Tie následne vysielaajú signál podobný GPS, ktorý môžu prijímače využiť spolu s korekčnými údajmi na spresnenie lokalizácie. Systém WAAS je dostupný v rámci NAS [SatelliteNavigationWAAS]. V Európe funguje na podobnom princípe systém EGNOS [EGNOS].

4.2 UWB systémy

Ultra-širokopásmové (UWB) systémy predstavujú modernú bezdrôtovú technológiu využívajúcu veľmi krátke rádiové impulzy (rádovo v nanosekundách) v širokom frekvenčnom pásme (typicky 3,1 – 10,6 GHz) s nízkou spektrálnou hustotou výkonu, vďaka

čomu má malú spotrebu energie. Je schopná prenášať dáta vysokou rýchlosťou (do 100 Mb/s) na krátku vzdialenosť. Používanie krátkych impulzných vln namiesto kontinuálneho šírenia signálu znižuje riziko vzniku „multipath“ efektu (spomínaného v časti ??) a zjednodušuje určenie času príchodu signálu (TOA) pri dávkovom prenose dát medzi vysielačom a prijímačom, čo dáva UWB výhodu vo vnútornom prostredí oproti iným technológiám. Navyše, nízka frekvencia pulzov umožňuje prienik signálu cez iné objekty alebo steny. Vďaka tomu je technológia UWB okrem iných využití vhodná aj pre lokalizáciu a sledovanie objektov, a to zvlášť vo vnútornom prostredí, kde iné technológie zlyhávajú kvôli potrebe priamej viditeľnosti alebo vysokému rušeniu. Odchýlka UWB lokalizácie sa pohybuje rádovo v jednotkách centimetrov a jej dosah je približne 30 – 50 m. [alarifiUltraWidebandIndoor2016].

Systémy UWB lokalizácie tvoria dva základné prvky: kotvy (z angl. anchors) a značky (z angl. tags). Anchory sú vo väčšine topológií využívané ako prijímače signálov vysielačných tagmi, na základe ktorých určujú vzdialenosť (príp. uhol) medzi daným anchorom a tagom. Túto informáciu odosielaajú do výpočtového systému, kde za na základe informácií z viacerých anchorov a ich známych polôh vypočíta poloha sledovaného objektu. Na pokrytie prostredia sa používajú viaceré anchory v rôznych typoch rozložení v závislosti od použitej metódy lokalizácie [al-okbyUWBBasedRealTimeIndoor2024].

4.2.1 Modulácia signálu

Nakoľko prenos UWB signálov prebieha zvyčajne v prostredí, kde sa vyskytujú aj iné typy signálov, kľúčovou zložkou technológie je *modulácia signálu*. Je to proces, ktorým sa na impulzný signál (nosnú vlnu) prenáša informácia zmenou jednej alebo viacerých jeho vlastností. V UWB systémoch zohráva modulácia zásadnú úlohu nielen pri prenose dát, ale aj pri samotnej lokalizácii, pretože ovplyvňuje schopnosť presne identifikovať impulzy aj v prítomnosti šumu, rušenia či odrazených signálov. Pre tento prípad sa využívajú viaceré variácie modulácie signálov, ktoré môžeme kategorizovať nasledovne [alarifiUltraWidebandIndoor2016]:

1. Podľa počtu stavov signálu

- *Binárna modulácia* – dva možné stavy signálu (napr. logická 0 a 1),
- *Ternárna modulácia* – tri úrovne (napr. záporná, nulová a kladná amplitúda),
- *M-árna modulácia* – viacero stavov (napr. 4-PSK, 8-PPM);

2. Podľa modifikovanej vlastnosti signálu

- Základné:

- *Amplitúdová (PAM)* – mení sa amplitúda impulzu,
- *Frekvenčná* – zriedkavá pri UWB,
- *Fázová (PSK)* – mení sa fáza impulzu,
- *Šírková (PWM)* – mení sa dĺžka impulzu,
- *Časová (PPM)* – mení sa poloha impulzu v časovom okne,
- Rozšírené:
 - *Binárne fázové kódovanie (BPSK)* – impulz mení fázu o 180° ; vhodná pri vyšších dátových prenosoch a odolná voči šumu,
 - „*On-Off*“ *kódovanie (OOK)* – informácia sa kóduje prítomnosťou alebo neprítomnosťou impulzu; jednoduchá, no citlivá na šum,
 - *Skoky času (TH-PPM/TH-BPSK)* – impulzy sa vysielajú v náhodne vybraných časových oknách podľa kľúča, čo zvyšuje odolnosť voči rušeniu a umožňuje viacerým zariadeniam zdieľať pásmo.

Správna voľba modulácie je dôležitá pre presnosť lokalizácie, robustnosť voči viaccestnému šíreniu, energetickú efektivitu vysielача, ale aj výpočtovú náročnosť prijímača.

4.2.2 Metódy UWB lokalizácie

Za účelom získania informácií o polohe objektu z rádiových signálov bolo vyvinutých viacero algoritmov, ktoré je možné principiálne rozdeliť do nasledujúcich kategórií [alarifiUltraWidebandIndoor2016]:

1. *Čas príchodu signálu (TOA)* – meria sa čas šírenia signálu medzi vysielateľom a prijímačom. Na základe známej rýchlosti šírenia signálu (pre rádiové vlny je to rýchlosť svetla) je možné priamo vypočítať vzdialenosť. Výsledná poloha sa odhaduje ako priesečník kružníc so stredmi v jednotlivých anchoroch a polomermi určenými odhadom vzdialenosti (podobne ako pri GNSS);
2. *Uhol príchodu signálu (AOA)* – vyžaduje informáciu o uhle príchodu signálu od minimálne dvoch, optimálne aspoň troch prijímačov; poloha objektu je určená prienikom uhlových priamok. Je citlivý na rôzne faktory spôsobujúce odchýlku, zásadný vplyv na presnosť má aj vzdialenosť objektu od antény. Je navyše zložitejší než iné algoritmy;
3. *Intenzita prijatého signálu (RSS)* – odvodzuje vzdialenosť na základe útlmu signálu. Hoci je implementačne jednoduchá, trpí vysokou neistotou v prostredí s odrazmi, čím je menej vhodná pre UWB;

4. *Časový rozdiel príchodzieho signálu (TDOA)* – využíva sa rozdiel časov príchodu signálu do viacerých anchorov. Prijímače musia byť navzájom zosynchronizované. Výsledná poloha sa odhaduje ako priesečník hyperbol, čo umožňuje získať polohu bez potreby synchronizácie mobilného uzla;
5. *Hybridné algoritmy* – Kombinujú viacero vyššie uvedených prístupov (napr. TDOA+AOA) s cieľom zlepšiť presnosť a robustnosť voči rušeniu a „multipath“ efektom.

Technológia UWB je sprevádzaná aj viacerými nevýhodami a výzvami. Nakoľko je frekvenčné pásmo zdieľané aj s inými bezdrôtovými technológiami (napr. WiMAX, 3G), môže dochádzať k rušeniu signálu. V prípade lokalizácie viacerých objektov môže taktiež dochádzať k problémom s prístupom na kanál. Spracovanie impulzov z tagov si vyžaduje komplexný hardvér a pre presnú lokalizáciu je potrebná presná časová synchronizácia zariadení. Na korekciu chýb spôsobených nedostatočnou synchronizáciou sa používajú rôzne filtračné a optimalizačné metódy a algoritmy, napr. metóda najmenších štvorcov, Kalmanove filtre či časticové filtre [al-okbyUWBBasedRealTimeIndoor2024].

4.3 Systémy na snímanie pohybu

Systémy na snímanie pohybu (MoCap) boli vyvinuté na zaznamenávanie pohybu objektov alebo ľudí, pôvodne za účelom analýzy chôdze [furtadoComparativeAnalysisOptitrack18]. Technológia sa však postupne rozšírila aj do ďalších oblastí vrátane robotiky.

Najpoužívanějšími prístupmi k MoCap v posledných rokoch sú [furtadoComparativeAnalysisOptitrack18].

1. *opticko-pasívny* – najpraktickejší a najpoužívanější spôsob v súčasnosti; sledovaný objekt je označený retroreflexnými značkami (markermi), ktoré sú zaznamenávané viacerými infračervenými kamerami. Každý marker musí byť zachytený viacerými kamerami, jeho polohu je potom možné určiť trianguláciou s chybou pod 1 mm;
2. *opticko-aktívny* – sledovaný objekt je označený infračervenými LED diódami, ktoré sú snímané infračervenými kamerami. Princíp určovania polohy je rovnaký ako v predošlom prípade, hlavná nevýhoda však spočíva v nutnosti napájania aktívnych markerov;
3. *video* – každá snímka je spracúvaná softvérom na detekciu objektov. Dosahuje menšiu presnosť než riešenia využívajúce markery;
4. *inerciálny* – je nezávislý od kamier, využíva inerčné snímače. Slabou stránkou je krátkodobá presnosť.

Súčasným lídrom v oblasti MoCap je opticko-pasívny systém OptiTrack. Predstavuje jedno z najmodernejších riešení lokalizácie objektov, vyznačujúce sa nízkou latenciou, vysokou presnosťou, relatívne jednoduchým používaním a schopnosťou zaznamenať všetkých 6 stupňov voľnosti (DoF) ako u pozemných (AGV), tak u lietajúcich (UAV) autonómnych vozidiel [**MotionCaptureRobotics**]. Často sa využíva na validáciu počítačového videnia či ako referencia pre iné metódy lokalizácie. Praktický je hlavne vo vnútorných laboratórnych podmienkach [**furtadoComparativeAnalysisOptitrack18**]. Medzi jeho hlavné nevýhody patrí potreba priamej viditeľnosti medzi kamerami a značkami, výrazný pokles presnosti mimo optimálnej oblasti, vysoké náklady, inštalačná náročnosť a tiež nevhodnosť použitia v exteriéri.

5 Čo sú umelé neurónové siete

Cieľom umelých neurónových sietí (UNS) je napodobniť štruktúru a spôsob fungovania ľudského mozgu. Ten je na vonkajšej strane pokrytý mozgovou kôrou, ktorá obsahuje obrovské množstvo neurónov (v literatúre sa uvádza číslo približne 10^{10} [mehligMachineLearningNeural2] ktoré sú vzájomne prepojené axónmi cez spojenia tvorené synapsami na jednej strane a dendridmi na druhej, vďaka čomu dochádza k prenosu informácií v podobe elektrického signálu. Jeden ľudský neurón môže byť prepojený s tisíckami iných [mehligMachineLearningNeural2]. Centrálna nervová sústava je schopná paralelne spracúvať veľké množstvo informácií z receptorov, pracovať s pamäťou a učiť sa z poznatkov, názorných aj analogických príkladov, zovšeobecňovať, konkretizovať a v konečnom dôsledku generovať riadiace pokyny pre ostatné časti tela.

Elementárnym prvkom UNS je *umelý neurón*. Zjednodušený model umelého neurónu, používaný v podstate dodnes, bol predstavený ešte v roku 1943 v práci McCullocha a Pittsa [mccullochLogicalCalculusIdeas1943]. Jeho grafické znázornenie môžeme vidieť na obrázku ???. Matematicky je možné vyjadriť vstupno-výstupnú závislosť umelého neurónu ako

$$y = f\left(\sum_{i=1}^n w_i x_i - \theta\right) = f(a), \quad (5.1)$$

kde x_i sú vstupy do neurónu, w_i váhy synaptických prepojení smerujúcich do neurónu, θ je prah neurónu (nazývaný tiež *bias*), a predstavuje vnútornú aktivitu, $f(a)$ aktivačnú funkciu a y je výstup z neurónu.

UNS sa skladajú z množstva neurónov, ktoré sú usporiadané do vrstiev. Prvá vrstva sa nazýva vstupná, neuróny v nej prijímajú vstupné informácie a posielajú ich ďalej. Posledná vrstva neurónovej siete, ktorá poskytuje výsledok, sa nazýva výstupná. Medzi vstupnou a výstupnou vrstvou sa môžu vyskytovať tzv. skryté vrstvy, ktoré slúžia na vykonávanie medzivýpočtov, čím umožňujú riešenie komplexnejších úloh. Výpočtový výkon siete je daný práve schopnosťou skrytých vrstiev modelovať nelineárne vzťahy medzi vstupmi a výstupmi. UNS je možné rozdeliť do viacerých kategórií:

1. Podľa architektúry usporiadania neurónov do vrstiev:

- (a) *Jednovrstvové siete – perceptróny (SLP)* – skladajú sa len zo vstupnej (nevykonávajúcej výpočty) a výstupnej vrstvy; využíva sa úplné prepojenie, teda každý vstupný neurón je prepojený s každým výstupným; obvykle využívajú skokové aktivačné funkcie a ich účelom je klasifikácia do tried;
- (b) *Viacvrstvové siete – viacvrstvové perceptróny (MLP)* – obsahujú aspoň jednu skrytú vrstvu; vstupná vrstva slúži iba na distribúciu vstupných informácií,

výkonnú funkciu majú iba skryté vrstvy a výstupná vrstva. Umožňujú riešenie lineárne neseparovateľných problémov.

- (c) *Hlboké neurónové siete* – majú vyšší počet skrytých vrstiev, umožňujú modelovanie komplexnejších závislostí. Medzi najznámejšie architektúry patria hlboké dopredné neurónové siete (DFFN), konvolučné neurónové siete (CNN), používané v oblasti spracovania obrazu, a rekurentné neurónové siete (RNN), vhodné na spracovanie sekvenčných dát [lecunDeepLearning2015, schmidhuberDeepLearningNeural2015].

2. Podľa spôsobu šírenia informácií v rámci siete:

- (a) *Dopredné siete* – (angl. *feed-forward*) obsahujú iba väzby v smere od vstupov k výstupom,
- (b) *Rekurentné siete* – obsahujú aspoň jednu spätnú väzbu v rámci tej istej vrstvy alebo v rámci rôznych vrstiev,

Kľúčom k úspešnosti neurónových sietí vo vykonávaní učenej úlohy je proces ich učenia. Učenie je možné definovať ako proces zlepšovania výkonu na základe pozorovania okolitého prostredia [russellArtificialIntelligenceModern2010]. Proces učenia neurónovej siete zahŕňa úpravu váh w_i na základe chyby medzi predikovaným a skutočným výstupom. Najčastejšie sa používa algoritmus *gradientného zostupu* v kombinácii s technikou *spätného šírenia* (angl. *backpropagation*) [rumelhartLearningRepresentationsBackpropagating19]. Cieľom je minimalizovať hodnotu funkcie odchýlky, napr. strednej kvadratickej chyby:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2, \quad (5.2)$$

kde y_i je skutočný a $\hat{y}_i$ predikovaný výstup.

5.1 Aktivačná funkcia

Aktivačná funkcia zabezpečuje nelinearitu neurónu, vďaka čomu je UNS schopná riešiť zložitejšie problémy. Výber vhodnej aktivačnej funkcie je jednou z kritických častí návrhu UNS a musí byť prispôsobený typu úlohy, ktorú má neurónová sieť vykonávať. V pôvodnom modeli [mccullochLogicalCalculusIdeas1943] sa používala len binárna (skoková) funkcia $f(a) = \text{sgn}(a)$. Tá je stále používaná v perceptrónových neurónových sieťach, ktoré vykonávajú klasifikáciu. V mnohých prípadoch sa však vyžaduje spojitý výstup siete, preto sa používajú viaceré typy spojitých aktivačných funkcií [aggarwalNeuralNetworksDeep2018]:

- *lineárna funkcia*: $f(a) = a$ – používa sa v prípade, že výstupná premenná je reálne číslo; v takom prípade rieši sieť regresiu najmenších štvorcov $\hat{y} = \sum_{i=1}^n w_i x_i$;
- *sigmoida*: $f(a) = S(a) = \frac{1}{1+e^{-\beta a}}$ – vhodná pre prípad odhadu pravdepodobnosti binárnej triedy, účelová funkcia má tvar $\hat{y} = -\log \left| \frac{y}{2} - 0,5 + \hat{y} \right|$ za predpokladu $y \in \{-1, 1\}$;
- *hyperbolický tangens*: $f(a) = \tanh\left(\frac{a}{2}\right) = \frac{1-e^{-a}}{1+e^{-a}} = 2S(2a) - 1$ – ide v podstate o preškálovaný a transformovaný sigmoid tak, že pripomína skokovú funkciu, avšak na rozdiel od nej je diferencovateľná. Je vhodná v prípade, že výstup môže nadobúdať kladné aj záporné hodnoty. Navyše, jej gradient je viac koncentrovaný okolo nuly, vďaka čomu sa trénuje jednoduchšie než sigmoid. Tento efekt sa zvykne ešte zosilniť modifikáciami, ako napr. $f(a) = \tanh(3a)$;
- *upravená lineárna jednotka (ReLU)*: $f(a) = \max\{a, 0\}$ – patrí k novším typom aktivačných funkcií; je výhodná pri trénovaní viacvrstvových sietí s množstvom neurónov, a to najmä vďaka rýchlejšiemu výpočtu gradientu, ale tiež pre nižšie riziko výskytu *efektu miznúceho gradientu* a zabránenie saturácii. Nevýhodou je strata informácie zo záporných vstupov a riziko vzniku tzv. *mŕtveho neurónu*: keď sa raz váhy neurónu natrénujú na záporné hodnoty, jeho výstup bude vždy nulový;
- „*Hard Tanh*“: $f(a) = \max\{\min[v, 1], -1\}$ – je to po častiach lineárna aproximácia hyperbolického tangensu; výpočtovo menej náročná, zachováva saturáciu, čo býva žiaduce napríklad pri výstupných neurónoch; podobne ako ReLU má v citlivej časti konštantný nenulový gradient, čo má význam pri spätnom šírení gradientu.

Aktivačné funkcie ReLU a Hard Tanh v poslednej dobe zväčša nahrádzajú klasické typy, ako sú sigmoid a hyperbolický tangens, a to pre zjednodušenie trénovania viacvrstvových neurónových sietí s týmito funkciami [aggarwalNeuralNetworksDeep2018]. Grafické znázornenia aktivačných funkcií sa nachádzajú na obr. ??.

V MLP sieťach sa v neurónoch výstupnej vrstvy často využíva aj aktivačná funkcia *softmax*. Jej úlohou je prepočítať výstupy poslednej skrytej vrstvy na pravdepodobnostné hodnoty, teda musí platiť $y_i \in \langle 0; 1 \rangle$ a zároveň $\sum_i y_i = 1$. To je zabezpečené predpisom funkcie

$$f(y_i) = \frac{\exp(h_i)}{\sum_{j=1}^k \exp(h_j)} ; \forall i \in \{1, \dots, k\}, \quad (5.3)$$

kde $H = (h_1, \dots, h_k)^\top$ je vektor výstupov poslednej skrytej vrstvy a k je počet výstupných neurónov aj neurónov poslednej skrytej vrstvy. Tento typ aktivačnej funkcie je výhodné použiť na klasifikáciu väčšieho množstva tried [aggarwalNeuralNetworksDeep2018].

6 Perceptróny

Základným typom neurónových sietí sú perceptróny. Slúžia na klasifikáciu vstupných údajov a pôvodne boli predstavené predstavené Rosenblattom v roku 1958 [rosenblattPerceptronProbab ktorý ich architektúru rozdelil na tri vrstvy: senzorickú, asociačnú a výstupnú. Senzorická vrstva sa namiesto plnohodnotných neurónov skladá len zo vstupných terminálov, ktorých počet zodpovedá rozmeru vstupného vektora a ich úlohou je preposielanie vstupných hodnôt ďalej (príp. normalizácia vstupných hodnôt). Za ňou môže nasledovať asociačná, teda skrytá vrstva, v ktorej neuróny slúžia na vykonávanie medzivýpočtov a umožňujú riešenie lineárne neseparovateľných problémov (viac v časti ??). Výstupy skrytej vrstvy nie sú čitateľné, slúžia ako vstupy pre neuróny poslednej, výstupnej vrstvy. V pôvodnej architektúre váhy skrytej vrstvy nepodliehali učeniu. Napokon, výstupná vrstva slúži na výsledné výpočty siete. Počet neurónov v nej zodpovedá počtu tried, ktoré sa v rámci úlohy klasifikácie rozlišujú. Neuróny v takejto sieti sú pospájané v doprednom smere (angl. *feed-forward*), teda zľava doprava. Všetky prepojenia perceptrónu sú jednosmerné, informácie sa posielajú len v smere dopredu k neurónom susediacim sprava. Nenachádzajú sa v ňom žiadne spätné prepojenia ani prepojenia preskakujúce vrstvu [mehligMachineLearningNeural2021].

Počas nasledujúceho vývoju v oblasti UNS však došlo z didaktických dôvodov k ustáleniu termínu *perceptrón* iba na jednovrstvovú lineárne separovateľnú architektúru, *jednovrstvový perceptrón (SLP)*. Klasifikačné siete s menej ako štyrmi skrytými vrstvami sa zvyknú označovať aj *viacvrstvové perceptróny (MLP)*.

6.1 Jednovrstvové perceptróny

Vstupná vrstva jednovrstvého perceptrónu obsahuje d vstupných terminálov pre vstupný vektor $X = (x_1, x_2, \dots, x_d)^\top$, ku ktorým je priradený vektor váh $W = (w_1, w_2, \dots, w_d)^\top$. Výstupná jednotka vypočíta vážený súčet vstupov a výsledok spracuje pomocou skokovej funkcie, ktorá určuje výstupnú triedu [aggarwalNeuralNetworksDeep2018]:

$$\hat{y} = \text{sign}(W \cdot X + \theta) = \text{sign} \left(\sum_{j=1}^d w_j x_j + \theta \right), \quad (6.1)$$

kde θ predstavuje tzv. *bias* – prahovú hodnotu, ktorá umožňuje posun rozhodovacej hranice. V implementáciách sa často reprezentuje ako špeciálny vstup s hodnotou 1 a vlastnou váhou.

Perceptrón funguje ako lineárny klasifikátor: rozhodovaciu hranicu tvorí hyper-rovina $W \cdot X + \theta = 0$, ktorá rozdeľuje vstupný priestor na dve triedy. Tento prístup je účinný v prípadoch, keď sú dáta *lineárne separovateľné*.

6.2 Lineárna separovateľnosť – problém klasifikácie

Problém lineárnej separovateľnosti je možné priblížiť na jednoduchom príklade. Majme klasifikačnú úlohu pre dvojrozmerné reálne vstupné vektory $X = (x_1, x_2)^\top$, ktoré majú byť rozdelené do cieľových skupín, teda tried $y \in \{-1, 1\}$. Na riešenie teoreticky stačí použiť jeden neurón so skokovou aktivačnou funkciou, teda výstup neurónu je počítaný ako skalárny súčin vstupov a váh:

$$\hat{y} = \text{sgn}(w_1x_1 + w_2x_2 - \theta) = \text{sgn}(W \cdot X - \theta), \quad (6.2)$$

kde $W = (w_1, w_2)$ je vektor váh, ktoré pripájajú vstupy neurónu [mehligMachineLearningNeural2020]. Skalárny súčin, ktorý vystupuje vo vzťahu ??, je možné riešiť aj geometricky po úprave:

$$\begin{aligned} W &= |W| \begin{bmatrix} \cos \alpha \\ \sin \alpha \end{bmatrix} ; |W| = \sqrt{w_1^2 + w_2^2}, \\ X &= |X| \begin{bmatrix} \cos \beta \\ \sin \beta \end{bmatrix} ; |X| = \sqrt{x_1^2 + x_2^2}, \\ W \cdot X &= |W||X| \cos(\alpha - \beta) = |W||X| \cos \varphi, \end{aligned} \quad (6.3)$$

kde α a β sú uhly, ktoré zvierajú vektor váh, resp. vstupov s osou x_1 a φ je uhol medzi nimi. Z toho je zrejmé, že výsledok skalárneho súčinu bude kladný pre $\varphi \in (-\frac{\pi}{2}, \frac{\pi}{2})$, inak bude záporný. Dôsledkom toho je zabezpečená správna klasifikácia vtedy, keď je vektor váh kolmý na rozhodovaciu hranicu, ktorá vymedzuje jednotlivé triedy. Situácia je graficky znázornená na obr. ??.

V uvedenom príklade sme pre zjednodušenie neuvažovali s biasom neurónu θ . Jeho vplyv na rozhodovaciu hranicu je však zrejímavý keď položíme argument zo vzťahu ?? rovný nule a odvodíme

$$x_2 = -\frac{w_1}{w_2}x_1 + \frac{\theta}{w_2}, \quad (6.4)$$

z čoho vyplýva, že bias má vplyv na priesečník rozhodovacej hranice s osou x_2 [mehligMachineLearningNeural2020].

Ak existuje taká lineárna hranica (napr. priamka v 2D, rovina v 3D, hyper-rovina vo vyšších dimenziách), ktorá dokáže oddeliť všetky vstupné prvky jednej triedy od druhej bez chyby, takúto množinu vstupov nazývame *lineárne separovateľná* a jej klasifikácia je zvládnuteľná pomocou jediného jediného neurónu.

Dobрым príkladom na demonštráciu lineárnej separovateľnosti sú aj logické funkcie. Na obr. ?? je porovnanie funkcií konjunkcie, ktorá je lineárne separovateľná a exkluzívnej disjunkcie, ktorá nie je.

6.3 Viacvrstvové perceptróny

V prípade SLP je jediná výpočtová vrstva výstupná, keďže vstupná vrstva nevykonáva žiadne výpočty. Viacvrstvové perceptróny (MLP) obsahujú viacero výpočtových vrstiev. Keďže ale výsledky vrstiev pridaných medzi vstupnú a výstupnú vrstvu nie sú viditeľné pre užívateľa, označujú sa ako *skryté vrstvy*.

Pridanie skrytej vrstvy umožňuje MLP riešiť lineárne neseparovateľné problémy, nakoľko rozdeľuje klasifikačný priestor na viac než len dva segmenty. Jednoduchý príklad takejto siete, ktorá klasifikuje dvojrozmerný vstupný vektor pomocou troch skrytých a jedného výstupného neurónu, môžeme vidieť na obr. ?? . Neuróny vypočítavajú výstupné hodnoty pomocou skokovej aktivačnej funkcie v tvare

$$h_j = f \left(\sum_k w_{jk} x_k - \theta_j \right), \quad (6.5a)$$

$$\hat{y}_i = f \left(\sum_j W_{ij} h_j - \theta_i \right), \quad (6.5b)$$

pričom výsledok môže nadobúdať hodnoty $y_i = \{-1, +1\}$ [mehligMachineLearningNeural2021]. Každý z neurónov v skrytej vrstve má vlastnú rozhodovaciu hranicu. Cieľom je teda nájsť také hodnoty w_{jk} a θ_j , aby rozhodovacie hranice rozdelili vstupnú rovinu (keďže máme dvojrozmerný vstup, môžeme si ho predstaviť ako súradnice bodov v rovine) na také segmenty, ktoré budú obsahovať len prvky jednej triedy. Situácia je znázornená na obr. ??.

Mechanizmus klasifikácie je možné si predstaviť tak, že každý zo vstupných bodov obdrží množinu výstupných hodnôt skrytých neurónov $\{h_1, h_2, h_3\}$. Každý zo segmentov je potom charakterizovaný unikátnou kombináciou výstupov skrytej vrstvy. Váhy w_{1j} a prahové hodnoty θ_j musia byť nastavené tak, aby každému vzniknutému segmentu vstupnej roviny pridelil výstupný neurón správnu triedu y_i , čo už opäť predstavuje lineárne separovateľný problém. To prebieha v tomto konkrétnom prípade na základe vzťahu

$$\hat{y}_1 = \text{sgn} (h_1 + h_2 + h_3) . \quad (6.6)$$

Je potrebné si uvedomiť, že neexistuje jedinečné riešenie takéhoto problému; sú možné viaceré kombinácie váh a prahových hodnôt neurónov, ktoré by spĺňali požiadavky klasifikácie, ako aj viaceré rozloženia siete. Vo všeobecnosti však platí, že pre zložitejšie problémy klasifikácie je potrebných viac skrytých neurónov [mehligMachineLearningNeural2021].

V práci autorov Minsky a Papert z roku 1969 [minskyPerceptronsIntroductionComputational201] bolo preukázané, že všetky logické operácie je možné vyriešiť pomocou MLP za podmienky, že aspoň jeden zo skrytých neurónov je pripojený ku všetkým vstupným terminálom.

Pri základnej architektúre dopredných sietí sa predpokladá, že všetky neuróny jednej vrstvy sú pripojené ku všetkým neurónom nasledujúcej vrstvy. V prípade, že sieť obsahuje len jednu skrytú vrstvu, hovoríme o tzv. *plytkej sieti*. MLP však môže obsahovať viac než len jednu skrytú vrstvu. Je matematicky dokázané, že UNS s tromi vrstvami sú schopné aproximovať ľubovoľnú spojitú nelineárnu funkciu a siete so štyrmi vrstvami stačia na aproximáciu ľubovoľnej nespojitej nelineárnej funkcie. Ak sieť obsahuje viac ako tri skryté vrstvy, zvykne sa nazývať *hlboká (dopredná) sieť (DFFN)*.

Pre praktický zápis matematických operácií vnútri siete sa na označenie jednotlivých prvkov používa vektorová, resp. maticová forma. MLP obsahuje vstupnú vrstvu označenú vektorom X veľkosti $d \times 1$, kde d je rozmer vstupných dát, k skrytých vrstiev o veľkosti $p_1 \dots p_k$, ktorých výstupy označujú vektory $H_1 \dots H_k$. Vstupná vrstva je na prvú skrytú vrstvu pripojená váhami označenými maticou W_1 veľkosti $d \times p_1$, zatiaľ čo r -tá skrytá vrstva je prepojená s $(r + 1)$ -ou maticou W_r veľkosti $p_r \times p_{r+1}$. Za predpokladu, že máme vektor výstupných neurónov $O = (o_1, \dots, o_m)^\top$, tie sa pripájajú k poslednej skrytej vrstve pomocou váh označených maticou W_{k+1} s veľkosťou $p_k \times m$. Vstupno-výstupný výpočet MLP je potom možné zapísať pomocou nasledujúcich rekurzívnych vzťahov [aggarwalNeuralNetworksDeep2018]:

$$H_1 = f(W_1^\top X) \quad (6.7a)$$

$$H_{p+1} = f(W_{p+1}^\top H_p) \quad \forall p \in (1 \dots k - 1) \quad (6.7b)$$

$$o = f(W_{k+1}^\top H_k). \quad (6.7c)$$

Základnými parametrami pri návrhu siete sú teda počet skrytých vrstiev, počty skrytých vrstiev a neurónov v jednotlivých vrstvách, a tiež výber aktivačných funkcií neurónov. V neposlednom rade, úspešnosť trénovania neurónovej siete závisí od výberu optimalizačnej funkcie odchýlky.

7 Trénovanie UNS

Trénovanie umelých neurónových sietí predstavuje kľúčový proces, prostredníctvom ktorého sa model učí z dostupných dát optimalizáciou svojich parametrov, najmä váh a prahov neurónov. Cieľom trénovania je minimalizovať odchýlku medzi výstupom siete $\hat{y}$ a požadovaným výstupom y , čo sa dosahuje iteratívnym prispôbovaním parametrov na základe výpočtu gradientu chyby. Jedným z kľúčových aspektov trénovania je preto výber vhodnej funkcie na výpočet odchýlky (v angl. literatúre označovanej *loss function*) vzhľadom ku konkrétnemu typu úlohy, ktorú UNS rieši. Obrázok ?? znázorňuje základný princíp trénovania UNS. V tejto časti sa podrobnejšie pozrieme na jeden z prvých používaných algoritmov – perceptrónové kritérium – ale aj na v súčasnosti najbežnejšiu metódu spätného šírenia chyby. Priblížime tiež časté problémy, ktoré sa pri procese trénovania môžu vyskytnúť.

7.1 Perceptrónové kritérium

Pôvodný perceptrónový algoritmus prebiehal heuristicky pomocou elektrických obvodov, na rozdiel od súčasného chápania problému ako optimalizačnej úlohy. V každom prípade, cieľ ostáva zachovaný a je ním nájsť také váhy W , ktoré minimalizujú počet chybne klasifikovaných príkladov v množine trénovacích vstupno-výstupných párov (X, y) . Úlohu perceptrónového algoritmu je teda možné zapísať v tvare účelovej funkcie najmenších štvorcov pre všetky trénovacie objekty datasetu $\mathcal{D}$ [aggarwalNeuralNetworksDeep2018] ako

$$\mathcal{L} = \arg \min_W \sum_{(X,y) \in \mathcal{D}} (y - \hat{y})^2 = \sum_{(X,y) \in \mathcal{D}} [y - \text{sign}(W \cdot X)]^2 \quad (7.1)$$

Tento typ minimalizácie účelovej funkcie sa označuje aj ako *funkcia odchýlky* (z angl. *loss function*) [aggarwalNeuralNetworksDeep2018]. Problém takto formulovanej funkcie však spočíva v použití skokovej funkcie signum, ktorá nie je diferencovateľná, obsahuje skoky a na veľkej časti definičného oboru má konštantné hodnoty, čo spôsobuje nulový gradient, teda nie je vhodná pre metódu gradientného zostupu. Na odvodenie jej hladkej náhrady sa používa tzv. *perceptrónové kritérium*. Jeho princíp spočíva v prvotnom definovaní účelovej funkcie s výstupom 0/1 pre jeden príklad vstupno-výstupného páru (X, y) [aggarwalNeuralNetworksDeep2018]:

$$L^{(0/1)}(X, y) = \frac{1}{2} (y - \hat{y})^2 = 1 - y \cdot \text{sign}(W \cdot X + \theta). \quad (7.2)$$

Táto funkcia nie je diferencovateľná kvôli prítomnosti skokovej funkcie sign, preto sa na analytické účely nahrádza hladkou účelovou funkciou [aggarwalNeuralNetworksDeep2018]:

$$L(X, y) = \max \{-y(W \cdot X + \theta), 0\}. \quad (7.3)$$

Táto tzv. *hladká náhrada funkcie odchýlky* penalizuje len nesprávne klasifikované príklady a jej gradient možno využiť na aktualizáciu váh [aggarwalNeuralNetworksDeep2018]:

$$W \leftarrow W + \alpha (y - \hat{y}) X, \quad (7.4)$$

kde α je rýchlosť učenia. Váhy sa menia iba v prípade, že $y \neq \hat{y}$. Tento prístup je stochastickým gradientným zostupom (SGD), ktorý optimalizuje (aj keď len približne) uvedenú hladkú funkciu.

7.2 Spätné šírenie chyby

Optimalizačné kritérium pre SLP je ľahko definovateľné, keďže výstup siete je priamou funkciou váh. To umožňuje jednoduchý výpočet gradientu pomocou diferenciácie. Pri viacvrstvových sieťach je však odchýlka výstupu komplikovanou zloženou funkciou váh v predošlých vrstvách, ktorú môžeme zjednodušene zapísať ako $\mathcal{L} = f(o(h_r(w_r)))$. Preto sa za účelom výpočtu jej gradientu používa algoritmus *spätného šírenia chyby*. Ten využíva reťazové pravidlo diferenciálneho počtu, ktoré počíta gradienty chyby ako sumu násobkov lokálnych gradientov skrytých neurónov pozdĺž rôznych ciest od daného neurónu až po výstup. Keďže počet ciest medzi skrytým neurónom a výstupom môže rásť exponenciálne s hĺbkou a šírkou siete, priamy výpočet všetkých príspevkov by bol výpočtovo náročný. Preto sa spätné šírenie realizuje efektívne pomocou dynamického programovania, ktoré opakovane (rekurzívne) využíva už vypočítané medzivýsledky. Výpočet spätného šírenia chyby prebieha vo viacerých cykloch, tzv. *epochách*, pričom každá pozostáva z dvoch hlavných fáz:

1. *Dopredná*: Cez sieť sa v smere od vstupu k výstupu postupne prepočítavajú aktivácie všetkých neurónov pre každú tréningovú vzorku na základe aktuálneho nastavenia váh. Výstup siete je porovnaný s požadovaným výstupom tréningových dát, na základe čoho sa vypočíta odchýlka výstupu.
2. V každej vrstve v smere od výstupu k vstupu sa vypočíta lokálny gradient odchýlky voči daným váham a aktiváciám z predchádzajúcej vrstvy, na základe čoho sú prepočítané jednotlivé hodnoty váh.

Uvažujme sekvenciu skrytých neurónov $h_1 \dots h_k$, ktorá je zakončená výstupným neurónom o . Keď budeme uvažovať len jedinú cestu z neurónu h_1 do o , potom je možné

gradient váh smerujúcich do r -tého neurónu, ktoré označíme $w_{(h_{r-1}, h_r)}$, vypočítať pomocou reťazového pravidla jednej premennej [aggarwalNeuralNetworksDeep2018]:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \frac{\partial \mathcal{L}}{\partial o} \cdot \left[\frac{\partial o}{\partial h_k} \prod_{i=r}^{k-1} \frac{\partial h_{i+1}}{\partial h_i} \right] \cdot \frac{\partial h_r}{\partial w_{(h_{r-1}, h_r)}} \quad \forall r \in 1 \dots k \quad (7.5)$$

Vo všeobecnosti však bude v MLP sieti existovať exponenciálne väčšia množina prepojení neurónov h_r a o , ktorú označíme $\mathcal{P}$. Vzťah ?? je teda možné zovšeobecniť pre všetky existujúce prepojenia pomocou reťazového pravidla viacerých premenných:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \frac{\partial \mathcal{L}}{\partial o} \cdot \underbrace{\left[\sum_{[h_r, h_{r+1}, \dots, h_k, o] \in \mathcal{P}} \frac{\partial o}{\partial h_k} \prod_{i=r}^{k-1} \frac{\partial h_{i+1}}{\partial h_i} \right]}_{\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r}} \cdot \frac{\partial h_r}{\partial w_{(h_{r-1}, h_r)}} \quad (7.6)$$

Tento vzťah je logicky rozdelený na dve časti. Prvá časť, označená ako $\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r}$, predstavuje agregovaný gradient chyby vzhľadom na výstup neurónu h_r a zahŕňa vplyv všetkých ciest vedúcich z tohto neurónu až po výstup o . Nakoľko jeho veľkosť exponenciálne narastá s veľkosťou siete, jeho výpočet je komplikovanejší. Posledný činiteľ vzťahu predstavuje vplyv zmeny váh vstupujúcich do skrytého neurónu h_r na jeho výstup. Je možné ho vypočítať pomocou derivácie aktivačnej funkcie ako

$$\frac{\partial h_r}{\partial w_{(h_{r-1}, h_r)}} = h_{r-1} \cdot f'(a_{h_r}) \quad (7.7)$$

Pri výpočte už spomenutého agregovaného člena $\Delta(h_r, o)$ sa využíva fakt, že výpočtový graf siete je acyklický, preto je možné začať výpočet spätných gradientov od výstupnej vrstvy. Najskôr sa vypočíta $\Delta(h_k, o)$ pre poslednú skrytú vrstvu h_k , a následne sa gradienty šíria späť smerom k vstupným vrstvám pomocou rekurzívne definovaného vzťahu. Navyše, každý výstupný neurón je pri výpočte inicializovaný na hodnotu $\frac{\partial \mathcal{L}}{\partial o} = \Delta(o, o)$. Rekurzívny vzťah pre $\Delta(h_r, o)$ sa následne pomocou reťazového pravidla odvodí ako

$$\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r} = \sum_{h: h_r \rightarrow h} \frac{\partial \mathcal{L}}{\partial h} \frac{\partial h}{\partial h_r} = \sum_{h: h_r \rightarrow h} \frac{\partial h}{\partial h_r} \Delta(h, o), \quad (7.8)$$

kde $\Delta(h, o)$ je gradient predchádzajúcej vrstvy (bližšie k výstupu), teda je potrebné odvodiť parciálnu deriváciu $\frac{\partial h}{\partial h_r}$. Na to sa využije skutočnosť, že skryté neuróny h_r a h sú spojené váhou $w_{(h_r, h)}$ a a_h je argument aktivačnej funkcie v neuróne h . Teda pomocou reťazového pravidla jednej premennej je možné odvodiť:

$$\frac{\partial h}{\partial h_r} = \frac{\partial h}{\partial a_h} \cdot \frac{\partial a_h}{\partial h_r} = \frac{\partial f(a_h)}{\partial a_h} \cdot w_{(h_r, h)} = f'(a_h) \cdot w_{(h_r, h)} \quad (7.9)$$

Dosadením vzťahu ?? do ?? získavame konečný rekurzívny vzťah pre výpočet agregovaného gradientu chyby vzhľadom na aktiváciu neurónu h_r , ktorý umožňuje efektívny výpočet gradientov bez opakovaného prechodu rovnakých ciest v sieti. [aggarwalNeuralNetworksDeep2018]

$$\Delta(h_r, o) = \sum_{h: h_r \rightarrow h} f'(a_h) \cdot w_{(h_r, h)} \cdot \Delta(h, o). \quad (7.10)$$

Rekurzívny vzťah dynamického programovania zo vzťahu ?? je v skutočnosti možné vypočítať viacerými spôsobmi, v závislosti od toho, ktoré premenné sa použijú ako medzičlánky v reťazovom pravidle. Všetky tieto varianty výpočtu sú ekvivalentné z hľadiska výsledného gradientu získaného spätným šírením chyby. Vo vzťahu ?? sa ako premenné medzičlánku reťazového pravidla používajú výstupy skrytých vrstiev h . V literatúre sa však často uvádza alternatívna verzia, kedy sa namiesto nich použijú argumenty aktivačných funkcií neurónov a_h , teda hodnoty vypočítané po lineárnej transformácii, ale ešte pred aplikáciou aktivačnej funkcie. Preto je namiesto rovnice ?? možné použiť aj nasledovný variant reťazového pravidla [aggarwalNeuralNetworksDeep2018]:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \underbrace{\frac{\partial \mathcal{L}}{\partial o} \cdot f'(a_o) \cdot \left[\sum_{[h_r, h_{r+1}, \dots, h_k, o] \in \mathcal{P}} \frac{\partial a_o}{\partial a_{h_k}} \prod_{i=r}^{k-1} \frac{\partial a_{h_{i+1}}}{\partial a_{h_i}} \right]}_{\delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial a_{h_r}}} \cdot \underbrace{\frac{\partial a_{h_r}}{\partial w_{(h_{r-1}, h_r)}}}_{h_{r-1}}. \quad (7.11)$$

v ňom je namiesto predošlej „medzipremennej“ $\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r}$ použitá $\delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial a_{h_r}}$. Inicializácia počiatočného stupňa rekurzcie je daná ako

$$\delta(o, o) = \frac{\partial \mathcal{L}}{\partial a_o} = f'(a_o) \cdot \frac{\partial \mathcal{L}}{\partial o}. \quad (7.12)$$

Následne je možné opäť použiť reťazové pravidlo viacerých premenných na zostavenie vzťahu pre rekurziu agregovaného gradientu chyby [aggarwalNeuralNetworksDeep2018]:

$$\delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial a_{h_r}} = \sum_{h: h_r \rightarrow h} \underbrace{\frac{\partial \mathcal{L}}{\partial a_h}}_{\delta(h, o)} \underbrace{\frac{\partial a_h}{\partial a_{h_r}}}_{f'(a_{h_r}) w_{(h_r, h)}} = f'(a_{h_r}) \sum_{h: h_r \rightarrow h} w_{(h_r, h)} \cdot \delta(h, o) \quad (7.13)$$

Výsledný gradient účelovej funkcie odchýlky siete je potom vyjadrený nasledujúcim vzťahom:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \delta(h_r, o) \cdot h_{r-1} \quad (7.14)$$

Proces tréningovania UNS môže prebiehať v dvoch režimoch. Pri *vzorkovom režime* dochádza k úprave váh po privedení každej novej vstupnej vzorky. V *dávkovom režime* sa váhy korigujú až po uskutočnení celej epochy, teda po kompletnom prechode celého tréningového súboru cez sieť, s využitím globálnej chyby zo všetkých vzoriek a výstupov.

7.3 Problémy tréovania UNS

Neurónové siete poskytujú silný nástroj pri riešení komplexných a analyticky ťažko odvoditeľných úloh. Aby ich tréovanie nebolo kontraproduktívne, je treba si uvedomiť problémy, ktoré s ním môžu byť spojené. Medzi najzávažnejšie problémy patria *pretrénovanie* a *problém miznúceho gradientu*. Ťažkosti môžu nastať aj pri nedostatočnej konvergencii účelovej funkcie, uviaznutí v lokálnom alebo falošnom optime či nedostatočnom výpočtovom výkone.

7.3.1 Pretrénovanie

Podstata tréovania neurónových sietí, ktoré je príkladom *učenia s učiteľom*, spočíva v tom, že sieť je schopná sa na základe testovacích dát naučiť všeobecné závislosti medzi vstupnými a výstupnými hodnotami, ktoré má byť následne schopná rozlíšiť aj na neznámych dátach. Po ukončení tréovania siete teda vždy prebieha fáza testovania, kedy je na vstup siete privedená množina vzoriek, ktoré sú odlišné od tréovacích.

Pretrénovanie (angl. *overfitting*) je jav, ktorý môže nastať dôsledkom neskorého ukončenia procesu tréovania, nedostatočnej tréovacej množiny dát, či nevhodnej architektúry siete. Prejavuje sa tak, že neurónová sieť síce dosahuje vysokú úspešnosť pri tréovacích dátach, no jej úspešnosť výrazne klesá pri zovšeobecnení na testovacích dátach, ktoré sú odlišné. Tento problém nastáva často napríklad vtedy, keď UNS obsahuje viac neurónov a prepojení, než zodpovedá skutočnej zložitosti riešenej úlohy, či v prípade nedostatočne veľkej testovacej množiny, čo do počtu a rozsahu prvkov vstupných vzoriek. V prvom prípade je dôsledkom, že sieť sa naučí zaznamenať aj také súvislosti vo vstupných dátach, ktoré nie sú všeobecné a súvisia len s danou množinou vstupných dát. V druhom prípade je zase problém v tom, že sieť sa nestihne naučiť všetky vstupno-výstupné závislosti.

Existuje viacero prístupov, ktoré slúžia na minimalizáciu rizika vzniku pretrénovania:

1. *regularizácia* – obmedzuje zložitosť modelu (siete). Do účelovej funkcie je pridaný penalizačný člen, ktorý uprednostňuje menšie hodnoty váh. Dochádza tak k „preriedeniu siete“, keďže obsahuje menšie množstvo významnejších prepojení (s hodnotou ďalej od nuly). Je možné ju interpretovať ako formu biologicky motivovaného „zabúdania“ nepodstatných vzorov.
2. *prispôsobenie architektúry siete* – využíva známe súvislosti vo vstupných dátach. Keď pri návrhu siete berieme do úvahy osobitosti úlohy, ktorú chceme riešiť, je možné zapracovať do architektúry siete také súvislosti, o ktorých vieme, že sa vyskytujú vo vstupných dátach (napr. súvislosť susedných pixelov pri spracovaní

obrazu alebo súvislosť nasledujúcich slov pri spracovaní textu). To umožňuje použiť tie isté sady parametrov na spracovanie viacerých častí vstupu, čím sa znižuje počet neznámych parametrov a zjednodušuje model. Príkladom takýchto sietí sú *rekurentné* alebo *konvolučné* n. s.

3. *krížová validácia* (angl. *cross validation*) – zabráňuje sieti naučiť sa nevšeobecné znaky. Zo súboru testovacích vstupov je vyčlenený validačný súbor. Učenie prebieha na zvyšných tréningových dátach, ale účelová funkcia sa paralelne vyhodnocuje aj na validačných dátach. V momente, keď hodnota validačnej účelovej funkcie začne stagnovať alebo dokonca stúpať – čo indikuje, že sieť sa prestala učiť všeobecné znaky a začína sa učiť znaky špecifické pre tréningové dáta – učenie je zastavené (často už po niekoľkých epochách).
4. *výmena šírky za hĺbku* – namiesto veľkého počtu neurónov v jednej vrstve a malému počtu skrytých vrstiev sa preferuje málo neurónov a veľa skrytých vrstiev. Takáto *hlboká sieť* je schopná dosiahnuť rovnakú, a často aj lepšiu úspešnosť, a navyše môže obsahovať menšie množstvo parametrov.

7.3.2 Miznúce a explodujúce gradienty

Problém miznúcich a explodujúcich gradientov býva zvyčajne spojený s tréňovaním hlbokých neurónových sietí a súvisí s využívaním reťazového pravidla (vzťah ??) pri spätnom šírení chyby. Keďže pri výpočte celkového gradientu účelovej funkcie dochádza k početnému násobeniu lokálnych gradientov pozdĺž prepojení, zvlášť pri veľkom počte skrytých vrstiev môže spôsobiť buď exponenciálny útlm k nule alebo naopak rýchly nárast gradientu. Oba javy tak spôsobujú nestabilitu procesu tréňovania.

Častou príčinou vzniku miznúceho gradientu býva napríklad použitie aktivačnej funkcie sigmoid. Tá má v celom definičnom obore deriváciu menšiu ako 0,25. Riešením je jej náhrada funkciou ReLU. Okrem tohto riešenia existujú aj pokročilejšie prístupy, ako napríklad [aggarwalNeuralNetworksDeep2018]:

1. *Adaptívne rýchlosti učenia* – namiesto jednej globálnej rýchlosti učenia α pre celú sieť sa dynamicky prispôsobuje rýchlosť učenia každého parametra na základe historických gradientov. To zvyšuje efektivitu učenia a zlepšuje konvergenciu. Napr. *AdaGrad*, *RMSProp*, *Adam* (v súčasnosti najpoužívanejší). Ich výhodou je dobrá stabilita a rýchle učenie aj v ťažko optimalizovateľných sieťach.
2. *Metóda konjugovaných gradientov* – je vhodná pre nelineárne a veľké optimalizačné úlohy. Namiesto toho, aby sa váhy aktualizovali iba v smere gradientu, táto metóda kombinuje predchádzajúce smery gradientov, aby sa vytvoril nový, efektívnejší

smer. Výhodou je, že môže výrazne zrýchliť konvergenciu a vyhnúť sa osciláciám. Na druhej strane, pre výpočtovú náročnosť je vhodnejšia skôr pre menšie siete alebo ako súčasť učenia po dávkach.

3. *Normalizácia po dávkach* (angl. *batch normalization*) – normalizuje vstupy každej vrstvy v rámci jednej dávky tak, aby mali nulový priemer a jednotkovú varianciu. Tým sa potláča nežiaduce kolísanie rozdelenia vstupných hodnôt spôsobené priebežným menením váh vo vrstvách. Výsledkom je rýchlejšia a stabilnejšia konvergencia počas učenia, ako aj zmiernenie problémov s miznúcim gradientom. Normalizácia v rámci dávky tiež často umožňuje použiť vyššiu rýchlosť učenia a znižuje závislosť na počiatočnom nastavení váh. Je však menej účinná pri veľmi malých dávkach alebo v rekurentných sieťach.

7.3.3 Ťažkosti s konvergenciou

Zvlášť v prípade hlbokých neurónových sietí sa vyskytuje problém s konvergenciou účelovej funkcie, keďže veľký počet skrytých vrstiev spôsobuje ťažší tok gradientov cez sieť. Čiastočne tento problém súvisí s miznutím gradientov, ale má svoje osobitné špecifiká [aggarwalNeuralNetworksDeep2018].

Jedným zo spôsobov riešenia sú tzv. *bránové siete*. Využívajú špecifické neuróny (bunky), obsahujúce adaptívne riadiace mechanizmy (brány), ktoré selektívne kontrolujú tok informácie v sieti. Ich cieľom je zabezpečiť, aby sa relevantné informácie udržali a prenášali počas spracovania vstupu, zatiaľ čo menej dôležité sa potláčajú. Tento prístup je kľúčový najmä pri modelovaní sekvenčných dát (napr. spracovanie textu, videa), kde dlhodobé závislosti často bránia efektívnemu učeniu. Takéto siete sa radia medzi rekurentné neurónové siete a patria tu napr. LSTM či GRU (bližšie o nich v časti ??).

Ďalšou možnosťou sú *reziduálne siete*, ktoré zavádzajú reziduálne prepojenia, teda obchádzajúce vetvy, ktoré umožňujú prenášať informáciu aj gradient priamo naprieč viacerými vrstvami bez ich transformácie. Tým sa výrazne znižuje riziko miznutia gradientu a zlepšuje sa stabilita učenia, čo umožňuje trénovať siete s desiatkami až stovkami vrstiev. Tento prístup zároveň urýchľuje konvergenciu a vedie k lepšiemu využitiu kapacity modelu. Známy príklad takejto architektúry je ResNet [heDeepResidualLearning2016]. Princíp fungovania reziduálnych sietí spočíva v tom, že namiesto učenia sa váh, teda priamej transformácie vstupu na výstup, sa učí len rozdiel medzi vstupom a výstupom. Takéto prepojenie umožňuje gradientom efektívne pretekať aj do veľmi hlbokých vrstiev siete počas spätného šírenia chyby.

7.3.4 Lokálne a falošné optimá

Optimalizačná funkcia neurónových sietí je silne nelineárna a obsahuje veľké množstvo lokálnych extrémov. Preto je výber vhodnej inicializácie parametrov kľúčový. Nesprávne inicializačné body môžu viesť k nevhodným (lokálnym alebo falošným) minimám. Jednou z metód, ako sa tomu vyhnúť, je tzv. *predtrénovanie* (angl. *pretraining*), ktoré spočíva v postupnom tréovaní jednotlivých vrstiev siete, často pomocou učenia bez učiteľa. Tento prístup poskytuje rozumné počiatočné hodnoty váh, ktoré obchádzajú irelevantné časti parametrového priestoru. Predtrénovanie tiež pomáha znižovať riziko pretrénovania, keďže sa vyhýba minimám, ktoré sú síce vhodné pre tréovaciu množinu, no zlyhávajú na testovacích dátach – tzv. falošným optimám [aggarwalNeuralNetworksDeep2018].

7.3.5 Výpočtová náročnosť

Jednou z hlavných výziev pri návrhu neurónových sietí je dlhá doba tréovania, ktorá môže v oblastiach ako spracovanie textu či obrazu trvať aj celé týždne. Kľúčový pokrok v tomto smere priniesol vývoj výkonnejšej hardvérovej infraštruktúry, najmä grafických procesorov (GPU), ktoré sú schopné paralelne vykonávať výpočty typické pre neurónové siete. Platformy ako Torch alebo TensorFlow majú vstavanú podporu pre GPU, čo umožňuje efektívnejšie učenie aj zložitých architektúr. Hoci k pokroku v hlbokom učení prispeli aj algoritmické vylepšenia, značná časť úspechu spočíva v tom, že existujúce algoritmy dnes dokážeme lepšie využiť vďaka výkonnejšiemu hardvéru. Výhodou väčšiny neurónových sietí je, že náročné výpočty prebiehajú počas tréovania, zatiaľ čo predikčná fáza je už relatívne rýchla, čo je dôležité pri aplikáciách v reálnom čase [aggarwalNeuralNetworksDeep2018].

7.4 Súčasné prístupy k tréovaniu

Snaha o vyriešenie vyššie spomenutých problémov tréovania UNS podnietila vznik množstva variácií učiacich algoritmov, ktoré sú síce v základoch postavené na metódach gradientného zostupu a spätného šírenia chyby, ale obsahujú aj ďalšie modifikácie a vylepšenia, týkajúce sa či už len samotného procesu tréovania, alebo aj architektúry celej siete, resp. jej buniek.

Jedným z používaných vylepšení učenia je tzv. *prenos znalostí* (angl. *transfer learning*). Spočíva v tom, že sieť sa netréuje od nuly, ale vychádza sa z už predtrénovaného modelu, ktorý bol učný na rozsiahlej množine údajov. Tento model sa následne „doladuje“ (tzv. *fine-tuning*) na konkrétnu úlohu pomocou menšieho množstva nových dát. Transferové učenie výrazne znižuje nároky na dáta aj výpočtový čas a zároveň zvyšuje kvalitu výsledkov, najmä ak sa pracuje s málo rozsiahlymi alebo špecializovanými

údajmi pre konkrétnu oblasť. Táto metóda je dnes základom mnohých aplikácií – od spracovania prirodzeného jazyka (napr. BERT, GPT) až po analýzu obrazov (napr. ResNet, EfficientNet).

Ďalším riešením pre zníženie výpočtovej náročnosti je *trénovanie so zmiešanou číselnou presnosťou* (angl. *mixed precision*). V tomto prístupe prebiehajú niektoré výpočty počas tréovania s nižšou číselnou presnosťou (napr. 16-bitové čísla namiesto štandardných 32-bitových). Výsledkom je nižšia pamäťová záťaž a výrazne rýchlejšie výpočty, najmä na grafických procesoroch (GPU) a špecializovaných akcelerátoroch (TPU), ktoré sú pre takéto výpočty optimalizované. Táto technika si zachováva presnosť tréovania pomocou špeciálnych mechanizmov (napr. škálovanie gradientov) a dnes je často využívaná v priemyselnej praxi.

Trénovanie pomocou klasickej metódy gradientného zostupu býva pri zložitejších architektúrach neefektívne, pretože používa konštantnú rýchlosť učenia pre všetky parametre siete po celú dobu procesu tréovania. Veľká rýchlosť je totiž dobrá na rýchle priblíženie sa do blízkosti dobrého riešenia, avšak zväčša neumožňuje jemné doladenia sa ku optimu, teda sa môže stať, že algoritmus tréovania ostane oscilovať v okolí optimálneho bodu alebo dokonca zdiverguje do nestabilnej oblasti. Na druhej strane, voľba malej rýchlosti učenia má za následok veľmi pomalú konvergenciu učenia. To sú dôvody pre vznik tzv. adaptívnych optimalizačných algoritmov, ktoré rýchlosť učenia dynamicky prispôbujú pre každý parameter siete zvlášť počas celého procesu tréovania.

Jedným z najrozšírenejších algoritmov pre tréovanie hlbokých neurónových sietí v súčasnosti je Adam (Adaptive Moment Estimation) [kingmaAdamMethodStochastic2017]. Využíva adaptívne nastavovanie parametrov siete (váh a biasov) na základe priebežných štatistík gradientu, ich prvého momentu (priemeru), ktorý informuje o „smerovaní“ optimalizácie a druhého momentu (rozptylu). Zároveň využíva tzv. L2 regularizačný člen, ktorý má za cieľ udržiavať hodnoty váh blízke nule (angl. *weight decay*). Výsledný vzorec pre aktualizáciu i -teho parametru má tvar

$$w_i \leftarrow w_i - \frac{\alpha_t}{\sqrt{A_i}} F_i; \quad \forall i, \quad (7.15)$$

kde agregovaný člen prvého momentu F_i , agregovaný člen druhého momentu A_i a rýchlosť učenia α_t sú priebežne aktualizované na základe nasledujúcich vzťahov [aggarwalNeuralNetworksDee

$$F_i \leftarrow \rho_f F_i + (1 - \rho_f) \left(\frac{\partial \mathcal{L}}{\partial \Xi_i} \right); \forall i, \quad (7.16a)$$

$$A_i \leftarrow \rho A_i + (1 - \rho) \left(\frac{\partial \mathcal{L}}{\partial \Xi_i} \right)^2; \forall i, \quad (7.16b)$$

$$\alpha_t = \alpha \left(\frac{\sqrt{1 - \rho^t}}{1 - \rho_f^t} \right), \quad (7.16c)$$

pričom $\rho, \rho_f \in (0, 1)$ sú voliteľné parametre. Novšia verzia algoritmu, AdamW [loshchilovDecoupledW] vylepšuje pôvodný Adam v tom, že regularizačný člen nemieša s výpočtom gradientného momentu, ale počíta ho osobitne, čo vedie k stabilnejšiemu trénovaniu a lepšiemu generalizačnému výkonu siete.

8 Hlboké učenie

Hlboké učenie (angl. *deep learning*) predstavuje jednu z najdôležitejších súčasných oblastí vývoja UI. Prekonáva ťažkosti klasických perceptrónových sietí v riešení komplexnejších úloh využitím viacvrstvových neurónových architektúr, kde každá vrstva extrahuje čoraz abstraktnejšie znaky z výstupov predchádzajúcich vrstiev. Vďaka tejto hierarchickej reprezentácii je možné modelovať zložité funkcie priamo z dát bez nutnosti manuálne definovaných príznakov [lecunDeepLearning2015]. Hlboké siete tak výrazne prevyšujú tradičné MLP v schopnosti učiť sa reprezentácie priamo zo surových dát, čím umožňujú riešiť zložité úlohy ako rozpoznávanie objektov, preklad jazykov alebo predikciu dynamiky systémov.

Na rozdiel od plytkých sietí vyžaduje trénovanie hlbokých modelov pokročilejšie optimalizačné techniky. Kým MLP siete často využívali obyčajný gradientný zostup s fixnou rýchlosťou učenia, hlboké siete zvyknú používať algoritmy ako Adam, RMSProp alebo momentové metódy, ktoré zohľadňujú historické hodnoty gradientov a adaptívne upravujú parametre učenia [kingmaAdamMethodStochastic2017]. Za účelom predchádzania vyššie spomenutým problémom, ako je miznúci a vybuchujúci gradient, sa zároveň používajú metódy ako regularizácia (napr. L2 penalizácia alebo „dropout“), váhová inicializácia a plánovanie rýchlosti učenia [goodfellowDeepLearning2016].

8.1 Konvolučné neurónové siete

Konvolučné neurónové siete (CNN) sú špeciálne navrhnuté na efektívne spracovanie dát so štruktúrou v priestore. Hoci boli vynájdene ešte koncom 20. storočia, do širšieho používania sa dostali až po práci kolektívu A. Krizhevsky [krizhevskyImageNetClassificationDeep2012] a dodnes sú najúspešnejším nástrojom na rozpoznávanie a klasifikáciu obrazu z kamery. Oproti klasickým plne prepojeným sieťam majú pri rovnakom počte neurónov menej prepojení, vďaka čomu sú jednoduchšie na natrénovanie a odolnejšie voči pretrénovaniu. Princíp ich fungovania je inšpirovaný fungovaním mozgu cicavcov pri spracovaní zrakových vnemov [mehligMachineLearningNeural2021].

Vstupom do CNN je obvykle obraz vo formáte dvojrozmernej bitmapy. Pri rozpoznávaní obrazu sa v niekoľkých iteráciách opakuje postup, kedy sa na vstupnú vrstvu neurónov aplikujú konvolučné filtre, tzv. *jadrá* (angl. *kernels*), pričom každé z nich obsahuje počet neurónov rádovo nižší než je rozmer vstupnej vrstvy (napr. 3×3 , 5×5 , 8×8 , ...). Jadro postupne aplikované na celú vstupnú vrstvu, pričom sa vykonáva operácia konvolúcie. Výstup jedného vstupného neurónu tak možno vyjadriť ako

$$V(i, j) = f \left(\sum_{p=1}^P \sum_{q=1}^Q x(i+p-1, j+q-1) \cdot w(p, q) - \theta \right), \quad (8.1)$$

kde i, j sú súradnice vstupného neurónu, $w(p, q)$ je hodnota jedného neurónu jadra s rozmermi $P \times Q$ a $x(i+p, j+q)$ je vstupná hodnota v okolí daného vstupného neurónu a $f(\cdot)$ predstavuje nelineárnu aktivačnú funkciu (obvykle ReLU) [mehligMachineLearningNeural2021].

V procese učenia sú váhy jadier nastavené tak, aby rozpoznávali určité príznaky vo vstupných dátach (napr. hrany, textúry, objekty), čím vznikajú tzv. *mapy príznakov* (angl. *feature maps*). Vlastnosťou tejto techniky je invariantnosť voči posunu, zmene mierky alebo iným formám skreslenia, vďaka čomu je použitím jedného malého jadra možné detegovať ten istý príznak vo viacerých častiach vstupu bez zmeny jeho hodnôt. Významne sa tak redukuje počet parametrov potrebných na natrénovanie takejto siete oproti plnému prepojeniu. Tento proces sa opakuje vo viacerých po sebe nasledujúcich *konvolučných vrstvách*, pričom platí, že čím viac vrstiev sa použije, tým komplexnejšie príznaky je možné rozpoznávať. Na učenie konvolučných vrstiev sa používa algoritmus spätného šírenia chyby [mehligMachineLearningNeural2021].

Medzi jednotlivé konvolučné vrstvy sa umiestňujú tzv. *zhlukovacie vrstvy* (angl. *pooling layers*). Ich vstupom sú výstupy z viacerých susedných máp príznakov a redukuje ich na jediné číslo. Tieto vrstvy neobsahuje žiadne parametre, ktoré by boli predmetom tréningu. Úlohou je podvzorkovanie mapy príznakov, na čo sa obvykle využíva funkcia maxima alebo priemeru. Výstup zo zhlukovacích vrstiev slúži ako vstup pre nasledujúce konvolučné vrstvy. Napokon, výsledná klasifikácia CNN môže byť vykonaná pomocou *plne prepojených vrstiev*.

Medzi najvyužívanejšie implementácie patria TensorFlow a PyTorch, ktoré ponúkajú predpripravené moduly na tvorbu a tréning CNN, ako aj množstvo predtrénovaných modelov (napr. VGG, ResNet, MobileNet či EfficientNet) vhodných na prenos znalostí. Tieto knižnice podporujú aj hardvérovú akceleráciu (napr. pomocou GPU), čo umožňuje efektívne tréningovanie rozsiahlych sietí. V praxi sa CNN implementácie uplatňujú v prostrediach ako OpenCV, ktoré ponúka jednoduché rozhranie na inferenciu CNN modelov v reálnom čase a je často využívaný vo vnorených systémoch a robotike. Vďaka týmto nástrojom je dnes práca s CNN prístupná aj bez potreby vlastnej implementácie architektúr od základu.

8.2 Rekurentné neurónové siete

Rekurentné neurónové siete (RNN) tvoria triedu architektúr umelých neurónových sietí navrhnutých špecificky na spracovanie sekvenčných dát. Na rozdiel od bežných dopredných sietí, ktoré spracúvajú vstupy ako nezávislé a nemajú vnútornú pamäť, RNN obsahujú mechanizmus *rekurencie*, ktorý im umožňuje uchovávať informácie o predchádzajúcich vstupoch v tzv. *skrytom stave*. Táto schopnosť ich predurčuje na

úlohy, v ktorých poradie alebo časový kontext zohráva rozhodujúcu úlohu – napríklad pri spracovaní textu, zvuku, signálov zo senzorov či trajektórií v priestore.

Tento typ neurónových sietí neobsahuje iba dopredné väzby, teda zľava doprava, ale obsahujú tiež spätné väzby a pamäťové informácie o stave buniek. Zásadným rozdielom RNN oproti klasickým dopredným sieťam je tiež to, že vstupy nie sú pripojené priamo na prvú skrytú vrstvu, ale interagujú so skrytými stavmi, ktoré boli vypočítané na základe predošlých vstupov. Skrytý stav siete sa mení v čase a je reprezentovaný vektorom h_t , ktorého výpočet je funkciou aktuálneho vstupného vektora X_t a predošlého skrytého stavu h_{t-1} :

$$H_t = \sigma(W_{xh} X_t + W_{hh} H_{t-1} + b_h), \quad (8.2)$$

kde W_{xh} a W_{hh} sú váhové matice pre vstup a skrytý stav, b_h je bias a σ je aktivačná funkcia (najčastejšie hyperbolický tangens alebo ReLU). Na výpočet výstupu siete sa potom väčšinu používa aktivačná funkcia softmax alebo sigmoid. Výstup siete môže byť generovaný za každou vstupnou vzorkou alebo až po ukončení jednej dávky. Aktivačné funkcie sú rovnaké pre každú vstupnú vzorku.

Vďaka schopnosti modelovať dlhodobé závislosti v čase sú RNN vhodné na spracovanie senzorických dát, kde každé meranie tvorí súčasť väčšej sekvencie. Môžu slúžiť aj ako časový filter, nakoľko dokážu integrovať informácie z predchádzajúcich meraní a korigovať neistotu v aktuálnych pozorovaniach. K ich výhodám patrí aj prispôsobivosť a univerzálnosť, keďže tá istá architektúra sa dá použiť na rôzne typy sekvencií. Sú však náročné na tréningovanie a citlivé na dĺžku a kvalitu sekvencie. Medzi najčastejšie používané implementácie RNN patria tieto architektúry:

- *Dlhá krátkodobá pamäť (LSTM)* [hochreiterLongShortTermMemory1997] – (obr. ??) zavádza vnútorný pamäťový stav bunky a sústavu brán, ktoré regulujú tok informácií: vstupná brána rozhoduje, čo nové si zapamätať, výstupná brána rozhoduje, ktorú informáciu z pamäte použiť ako výstup a zabúdacia brána rozhoduje, čo z pamäte vyhodíť. Prináša teda schopnosť udržať si informáciu z minulosti bez toho, aby došlo k miznutiu gradientu.
- *Rekurentná jednotka s bránou (GRU)* [chungEmpiricalEvaluationGated2014] – (obr. ??) ide o zjednodušenú verziu LSTM, ktorá obsahuje len dve brány: aktualizácia – riadi, koľko z predchádzajúceho stavu sa preniesie ďalej – a resetovacia – rozhoduje, koľko informácie z minulosti ignorovať. Je výpočtovo efektívnejšia než LSTM, no výkonovo porovnateľná.

9 Fúzia lokalizácie pomocou UNS

Presná znalosť polohy v prostredí – lokalizácia – predstavuje jeden zo základných predpokladov pre spoľahlivú prevádzku a efektívne plnenie úloh mobilného robota. Na tento účel sa bežne využíva viacero typov senzorov, ako napríklad GNSS, INS, vizuálne systémy alebo laserové snímače. Každý z týchto senzorov však podlieha určitým obmedzeniam a v praxi neposkytuje dokonale presné ani spoľahlivé údaje. Na zníženie neistoty a zvýšenie robustnosti odhadu aktuálnej polohy sa preto využíva fúzia údajov, t. j. inteligentná integrácia viacerých dátových tokov do jedného spoločného odhadu, ktorý je spravidla presnejší a konzistentnejší než jednotlivé zdroje samostatne.

Tradičné prístupy k fúzii údajov sú založené prevažne na pravdepodobnostných modeloch (napr. Bayesovská filtrácia, Kalmanove filtre, časticové filtre) alebo metódach intervalového odhadu. Najväčšou výzvou pri použití týchto metód je však získanie presného modelu systému. V prípade komplexných a vysoko dynamických systémov môže byť odvodenie presného modelu zvlášť náročné. Navyše, senzorické dáta bývajú sprevádzané vlastnou nepresnosťou a neistotou, ktorých zapracovanie do modelu je problematické. Vo výsledku tak nepresný model systému môže vážne obmedziť úspešnosť analytických metód fúzie [fayyadDeepLearningSensor2020].

S nástupom moderných techník umelej inteligencie – predovšetkým umelých neurónových sietí a hlbokého učenia – sa postupne presadzuje aj ich uplatnenie v tejto oblasti. Tieto modely sú schopné spracovávať veľké objemy vysoko dimenzionálnych dát, učiť sa zložené nelineárne vzťahy medzi jednotlivými vstupmi a zohľadňovať aj ich časové závislosti bez hlbokej analytickej znalosti modelu, čo z nich robí atraktívny nástroj pre riešenie úloh lokalizácie prostredníctvom senzorickej fúzie.

Príkladom využitia štandardnej, plne prepojenej DFFN siete na fúziu lokalizácie môže byť práca Barreto-Cuberto a kol [barreto-cuberoSensorDataFusion2022]. Využíva sa tu kombinácia troch typov senzorov: 360-stupňový 2D lidar, stereokamera a ultrazvukové senzory. Úlohou neurónovej siete bolo zlepšiť schopnosť mobilného robota detegovať rôzne druhy prekážok vrátane sklenených povrchov, ktoré sú pre lidar často neviditeľné. Každý z týchto senzorov má iné výhody: ultrazvuk vie spoľahlivo detegovať sklo, stereo kamera zachytáva trojrozmernú hĺbkovú štruktúru a lidar poskytuje vysoké rozlíšenie v 2D rovine. Pred fúziou sa surové senzorické dáta upravujú – aplikujú sa filtre (napr. Kalmanov filter na ultrazvuk), transformácie do spoločného súradnicového systému a projekcia mračien bodov na 2D rovinu. Neurónová sieť bola trénovaná na predikciu spoľahlivých vzdialeností k prekážkam spojením vstupov zo všetkých troch senzorov. Používa Adam optimalizátor, aktivačnú funkciu ReLU a ďalšie osvedčené techniky pre nelineárne dáta. Výsledkom fúzie je jednotná metrika vzdialeností, ktorú

systém využíva na tvorbu 2D okupačnej mapy (angl. Occupancy Grid Map). Experimentálne porovnanie viacerých stratégií (lidar-sólo, lidar+sonar, lidar+kamera+sonar) ukázalo, že fúzia pomocou UNS výrazne znižuje strednú kvadratickú chybu (RMSE) (až pod 3 cm), pričom samotný lidar mal chybu cez 2 metre pri prítomnosti skla. Navyše, kombinácia kamery a sonaru umožňuje rozpoznať aj objekty pod úrovňou skenovania lidar, čím sa zvyšuje bezpečnosť a spoľahlivosť navigácie.

9.1 CNN fúzia

Nakoľko je architektúra CNN sietí prispôbená na spracovanie dvojrozmerných dát, v súvislosti s fúziou sa ich využitie objavuje najčastejšie pri spracovaní kamerového obrazu, príp. máp.

Jednou z prvých implementácií metód hlbokého učenia na účely fúzie odometrie vôbec je práca autorov Valente a kol. z roku 2019 [**valenteDeepSensorFusion2019**], ktorí sa zaoberali fúziou monokamery a 2D laserového skenera. Cieľom bolo eliminovať závislosť od presnej kalibrácie medzi senzormi a zložitosť návrhu ručne definovaných fúzných pravidiel. Navrhnutý prístup transformuje klasický regresný problém odometrie (odhadu vzdialenosti a natočenia medzi snímkami) na problém ordinálnej klasifikácie, čím zjednodušuje učenie siete. Vstupom do siete sú vždy dvojice po sebe idúcich 360° laserových skenov a obrázkov z kamery, pričom sieť predikuje transformáciu $(\Delta d, \Delta \theta)^T$ – teda prejdenú vzdialenosť a rotačný uhol medzi dvoma časovými krokmi. Akumuláciou týchto lokálnych odhadov je možné rekurzívne rekonštruovať globálnu trajektóriu robota. Architektúra pozostáva z dvoch vetiev (CNN pre laser, CNN pre kameru), ktorých výstupy sú zlúčené a prevedené na odhad translácie a rotácie. Výsledky na reálnych dátach z KITTI datasetu ukazujú, že konvolučné siete dokážu efektívne fúzovať heterogénne senzorické údaje pre účely lokalizácie v reálnom čase. Tento prístup je preto vhodný najmä v situáciách, kde nie sú dostupné kinematické dáta (napr. z enkodérov) alebo GNSS.

Efektívne využitie CNN technológie je predstavené v článku [**xiaoDynamicSLAMSemanticMono**], kde autori predstavujú systém Dynamic-SLAM, ktorý rozširuje klasické vizuálne SLAM riešenia tak, aby dokázali spoľahlivo pracovať v dynamickom prostredí. Kým tradičné SLAM metódy predpokladajú, že všetky pozorované prvky sú statické, tento prístup využíva sémantickú segmentáciu pomocou SSD konvolučnej neurónovej siete na rozpoznanie dynamických objektov v obraze. Tieto objekty sa detegujú v samostatnom vlákne a na základe toho sa ich zodpovedajúce obrazové prvky (napr. rohové body) vylúčia z odhadu pohybu robota, čím sa výrazne znižuje chyba lokalizácie. Keďže SSD môže niektoré objekty vynechať, autori navrhujú kompenzačný algoritmus, ktorý využíva fakt, že pohyb objektov medzi po sebe idúcimi snímkami býva plynulý – tzv. rýchlostnú

invariantnosť – a na základe toho spätne identifikuje nedetekované objekty. Následne sa v sledovacom vlákne aplikuje selektívne sledovanie, ktoré spracúva len spoľahlivé statické prvky. Výsledný systém je robustnejší voči narušeniu dynamikou prostredia, funguje v reálnom čase, a experimentálne preukazuje vyššiu presnosť a úspešnosť lokalizácie než existujúce riešenia ako ORB-SLAM2 či DynaSLAM, a to nielen v simulovaných testoch, ale aj na mobilnej robotickej platforme v reálnom svete.

DeepFusion je riešenie predstavené v práci [laidlowDeepFusionRealTimeDense2022], ktoré systém pre hustú 3D rekonštrukciu z monokulárneho videa. Kombinuje výhody geometrických metód a hlbokého učenia. Motiváciou je prekonanie obmedzení existujúcich metód, ako je obmedzený dosah hĺbkových kamier a nejednoznačnosť mierky pri rekonštrukcii z fotometrických chýb, čo je kľúčové pre robotické úlohy. Na rozdiel od klasických SLAM systémov, ktoré vytvárajú len riedke mapy na základe kľúčových bodov, DeepFusion generuje husté hĺbkové mapy v mierke pomocou CNN, ktorá predikuje nielen hĺbku z jedného obrazu, ale aj jej gradienty a neistoty. Tieto výstupy sa potom pravdepodobnostne spájajú so čiastočne hustou rekonštrukciou z viacerých pohľadov, čím sa zachováva globálna konzistencia aj absolútna mierka. Optimalizácia prebieha priebežne počas prechodu novými snímkami, ale sieť sa spúšťa len raz pre každý kľúčový snímok, čím sa zachováva reálny čas spracovania na GPU. Tento hybridný prístup využíva prednosti učenia (presnosť vo vnútri objektov) aj geometrie (ostré hrany) a podľa experimentov dosahuje porovnateľné alebo lepšie výsledky ako iné existujúce systémy.

9.2 RNN fúzia

Ako už bolo spomenuté v časti ??, silnou stránkou RNN sietí je schopnosť spracúvať časovo-závislé dáta a pamätať si z nich vzniknuté závislosti. Vďaka tomu je táto architektúra vhodná na spracovanie meraní z GNSS a IMU.

Autori článku [daiINSGNSSIntegrated2020] reagujú na obmedzenia tradičných metód integrovanej navigácie INS/GNSS, najmä rozšíreného Kalmanovho filtra (EKF), ktorý si vyžaduje presný model chýb senzorov a trpí zníženou presnosťou pri dlhodobom výpadku GNSS signálu v silne nelineárnych alebo rušených prostrediach. Na rozdiel od statických neurónových sietí, ktoré nedokážu zachytiť časové závislosti chýb INS, navrhujú autori využitie RNN schopnej modelovať dynamické väzby medzi aktuálnymi a minulými chybami INS. RNN sa trénuje na dátach z obdobia, keď je GNSS dostupné, a následne dokáže počas výpadku GNSS predikovať chyby polohy a rýchlosti INS na základe vlastnej „pamäte“ a údajov o dynamike vozidla (napr. zmeny rýchlosti a orientácie). Tento prístup umožňuje kontinuálne a presné určovanie polohy bez potreby zložitého modelovania alebo ladenia parametrov ako v prípade EKF. Výsledky

zo simulácií aj reálnych experimentov (napr. počas 10-hodinovej plavby lode) ukázali, že navrhovaná metóda dosahuje výrazné zníženie chýb v porovnaní s EKF (až o 61 % v polohe a 40 % v rýchlosti) aj s ELM, čo potvrdzuje jej potenciál pre navigáciu v prostredíach s nedostupným alebo rušeným GNSS signálom.

Podobný problém súvisiaci s potenciálnym obmedzením dostupnosti a presnosti GNSS signálu v zastavaných mestských oblastiach či tuneloch sa rozhodli riešiť aj autori práce [kimDeepLearningBasedGNSS2019]. Na preklopenie výpadkov GNSS meraní sa rozhodli zapojiť do kombinácie aj údaje z IMU a kolesovej odometrie, no v snahe vyhnúť sa potrebe komplexného odhadu modelu jednotlivých senzorov využili LSTM sieť. Model predikuje aktuálnu polohu na základe predchádzajúcich meraní zo všetkých spomenutých senzorov. Autori uvádzajú 40%-tné zmenšenie chyby odhadu v porovnaní so samostatnou GNSS navigáciou v zjednodušených testovacích podmienkach. Napriek ukázanému potenciálu metód hlbokého učenia v podobe obídenia procesu kalibrácie a modelovania, riešenie by ešte potrebovalo validáciu v náročnejších reálnych podmienkach.

Rekurzívne neurónové siete je možné využiť nie len na nahradenie analytických prístupov fúzie, ale aj na ich doplnenie, resp. riešenie problémov, na ktoré štandardné metódy nie sú stavané. Príkladom je nedávno publikovaná práca [huangApplicationMultisensorFusion2025] v ktorej je fúzia pomocou EKF doplnená o RNN sieť za účelom riešenia asynchrónnych frekvencií jednotlivých senzorov, akumulácie driftu a šumu merania. Algoritmus prebieha v troch krokoch. V prvom je fúzia údajov z IMU a kolesovej odometrie zabezpečená pomocou EKF, následne je použitá RNN sieť na modelovanie časových závislostí, čo umožňuje vyhladzovanie dát a redukciu driftu a šumu, ktoré EKF sám o sebe nedokáže dobre potlačiť, najmä pri nelineárnych dynamikách alebo asynchrónnom snímaní. RNN tak vystupuje ako korekčný mechanizmus, ktorý spracúva už EKF-fúzované dáta a zohľadňuje dlhodobé závislosti v signáli. Následne sa výsledok koriguje pomocou komplementárnej fúzie s lidarom pre zvýšenie robustnosti a spoľahlivosti. Vďaka tejto architektúre algoritmus dosahuje lokalizačnú chybu do 8 cm a prekračuje výkon metód ako časticový filter alebo SLAM založený na grafovej optimalizácii polôh (tzv. Graph SLAM) pri zachovaní výpočtovej efektivity, čím je vhodný aj pre reálne aplikácie v autonómnej navigácii.

10 Pravdepodobnostné metódy odhadu stavu

10.1 Bayesov filter


10.2 Gaussovské filtre

10.2.1 Kalmanov filter


10.2.2 Rozšírený Kalmanov filter

10.2.3 “Unscented Kalman filter”


10.2.4 Informačný filter




Obr. 3.4: Principiálna schéma gyroskopu Systron Donner Gyro-Chip [duchonSnimaceMobilnejRobotike2012]




Obr. 3.5: Štruktúra a princíp merania rôznych typov akcelerometrov [duchonSnimaceMobilnejRobotike2012]




Obr. 5.1: McCulloch-Pittsov model neurónu. x_i sú vstupy neurónu, w_i váhy synaptických spojení, θ je prah neurónu, $f(a)$ predstavuje aktivačnú funkciu, a vnútornú aktivitu, y je výstup z neurónu.




(a) skoková




(b) lineárna




(c) sigmoid



(d) hyperbolický tangens




(e) ReLU




(f) Hard Tanh


Obr. 5.2: Vybrané aktivačné funkcie.



Obr. 6.1: Geometrické riešenie klasifikácie.




(a) Kojunkcia (AND) – lineárne separovateľná




(b) Exkluzívna disjunkcia (XOR) – lineárne neseparovateľná

Obr. 6.2: Lineárna separovateľnosť vybraných logických funkcií. ● pre pravd. hodnotu „TRUE“ ($y = 1$), ○ pre pravd. hodnotu „FALSE“ ($y = -1$).




Obr. 6.3: Viacvrstvový perceptrón s jednou skrytou vrstvou so vstupnými terminálmi x_k , skrytými neurónmi h_j , výstupným neurónom y_1 , a váhami prepojení medzi vrstvami w_{jk} a w_{1j} . [mehligMachineLearningNeural2021]




(a) Lineárne separovateľný problém klasifikovaný pomocou SLP.

(b) Lineárne neseparovateľný problém klasifikovaný pomocou MLP, tvoriacej po častiach lineárnu rozhodovaciu hranicu.


Obr. 6.4: Porovnanie klasifikácie pomocou SLP a MLP.




Obr. 7.1: Základná schéma algoritmov tréningovania UNS.




Obr. 8.1: Schéma architektúry konvolučnej neurónovej siete. [mehligMachineLearningNeural2021]



Obr. 8.2: Rekurentná neurónová sieť – znázornenie toku informácií v čase.



Obr. 8.3: Porovnanie štruktúr LSTM a GRU rekurentných neurónových sietí. [jiangMixedDeepRecurrent2019]



Obr. 9.1: Fúzia senzorov pomocou DFFN [barreto-cuberoSensorDataFusion2022]