

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Snímače pre lokalizáciu mobilných robotov

Seminárna práca

Študijný program:	Robotika a kybernetika
Študijný odbor:	kybernetika
Školiace pracovisko:	Ústav robotiky a kybernetiky
Predmet:	D-PS1-RK – Predmet špecializácie Robotika a Kybernetika I
Školiteľ:	prof. Ing. František Duchoň, PhD.
Konzultant:	Ing. Martin Dekan, PhD.

Obsah

1	Charakteristika a delenie snímačov	7
2	Interné senzorické systémy	10
2.1	Odometria	10
2.1.1	Kolesová odometria	10
2.2	Vizuálna odometria	11
2.2.1	Rekonštrukcia pohybu	12
2.2.2	Nelineárna optimalizácia	13
2.2.3	Párovanie textúr	15
2.2.4	Rekonštrukcia hĺbky	15
2.2.5	Aktualizácia stavu	16
2.2.6	Prehľad súčasných riešení	17
2.2.7	Vizuálny SLAM	18
2.3	Lidarová odometria	20
2.3.1	LiDAR technológia	20
2.3.2	Prehľad metód lidarovej odometrie	21
2.3.3	Iteratívny algoritmus najbližších bodov (ICP)	22
2.4	Inerčné snímače	27
2.4.1	Gyroskopy	27
2.4.2	Akcelerometre	30
2.4.3	Magnetometre	32
2.4.4	IMU	32
3	Externé lokalizačné systémy	34
3.1	GNSS systémy	34
3.1.1	Princíp činnosti	35
3.1.2	Chyby GPS	35
3.1.3	Augmentačné systémy	36
3.2	UWB systémy	37
3.2.1	Modulácia signálu	38
3.2.2	Metódy UWB lokalizácie	39
3.3	Systémy na snímanie pohybu	40
	Literatúra	41

Zoznam obrázkov a tabuliek

Obrázok 1	Princíp textúrnej vizuálnej odometrie [30].	11
Obrázok 2	Dierkový model kamery	13
Obrázok 3	Gyroskop – ilustrácia	28
Obrázok 4	Principiálna schéma gyroskopu Systron Donner GyroChip [11]	29
Obrázok 5	Štruktúra a princíp merania rôznych typov akcelerometrov [11]	31

Zoznam značiek a skratiek

AGV	Autonomous Ground Vehicle
AMCW	Amplitude-Modulated Continuous Wave
AOA	Angle Of Arrival
BPSK	Binary Phase Shift Keying
BRIEF	Binary Robust Independent Elementary
CLINS	Continuous-time LiDAR-Inertial Navigation System
DGPS	Differential GPS
DL	Deep Learning
DLT	Direct Linear Transform
DoF	Degree of Freedom
DoG	Difference of Gaussians
DOP	Dilution Of Precision
EGNOS	European Geostationary Navigation Overlay Service
EKF	Extended Kalman Filter
EPnP	Efficient PnP
FAST	Features From Accelerated Segment Test
FMCW	Frequency-Modulated Continuous Wave
FOV	Field Of View
GLONASS	Globalnaja Navigacionnaja Sputnikovaja Sis- tema
GNSS	Global Navigation Satellite Systems
GPS	Global Positioning System
ICP	Iterative Closest Point
IMU	Inertial Measurement Unit
INS	Inertial Navigation System
IRC	Incremental rotary encoder
IRNSS	Indian Regional Navigation Satellite System
KISS-ICP	Keep It Small and Simple
LiDAR	Light Detection and Ranging
LIO	LiDAR-Inertial Odometry
LIO-SAM	LiDAR-Inertial Odometry Smoothing and Mapping

LIOR	LiDAR Odometry with Intensity and Occlusion Removal
LO	LiDAR Odometry
LO-Net	Lidar Odometry Network
LOAM	LiDAR Odometry and Mapping
LodoNet	LiDAR Odometry Deep Neural Network
MEMS	Micro-Electro-Mechanical Systems
MKP	Matched Keypoint Pair
MLE	maximum-likelihood estimation
MoCap	motion capture
NAS	National Airspace System (USA)
NDT-ICP	Normal Distribution Transform ICP
OOK	On-OFF Keying
OPA	Optical Phased Array
ORB	Oriented FAST and rotated BRIEF
ORB-SLAM	ORB-SLAM
PAM	Pulse Amplitude Modulation
PnP	Perspective-n-Point
PPM	Pulse Position Modulation
PSK	Phase Shift Keying
PWM	Pulse Width Modulation
QZSS	Quasi-Zenith Satellite System
RANSAC	Random Sample Consensus
RPE	reprojecition error
RSS	Received Signal Strength
RTK	Real-Time Kinematic
SBAS	Satellite-based Augmentation Systems
SIFT	Scale-Invariant Feature Transform
SLAM	Simultaneous Localization and Mapping
SuMa	Surfel-based Mapping
SURF	Speeded-Up Robust Features
TDOA	Time Difference Of Arrival
TH	Time Hopping
TOA	Time Of Arrival
ToF	Time of Flight
UAV	Unmanned Aerial Vehicle
UWB	Ultra-Wideband

VO	Visual odometry
WAAS	Wide Area Augmentation System
WeatherNet	Weather-Robust Deep LiDAR Odometry Network
WGS	World Geodetic System
WiMAX	Worldwide Interoperability for Microwave Access
WMS	Wide Area Master Stations
WRS	Wide Area Reference Stations

1 Charakteristika a delenie snímačov

V súvislosti so snímačmi používanými v mobilnej robotike treba mať na pamäti tri zásadné faktory [11]:

1. Meranie skutočnými snímačmi je zašumené;
2. Skutočné snímače poskytujú nekompletný opis prostredia;
3. Skutočné snímače nemôžu byť úplne modelované.

Vlastnosti a miera použiteľnosti snímačov sú dané mnohými parametrami, ktoré ich vzájomne odlišujú. Z nich medzi najvýznamnejšie môžeme zaradiť [11]:

- *Zorné (detekčné) pole (FOV)* – šírka záberu snímača, zvyčajne vyjadrená v stupňoch. Niektoré typy snímačov majú definované vertikálne aj horizontálne zorné pole;
- *Merací rozsah* – pracovný rozsah snímání vrátane obmedzenia hĺbky (môže byť minimálne aj maximálne);
- *Dynamický rozsah* – pomer medzi maximálnou a minimálnou vstupnou hodnotou snímača. Hodnota býva vyjadrená v decibeloch;
- *Rozlíšenie* – minimálny rozdiel medzi dvoma hodnotami, ktoré snímač dokáže detegovať;
- *Lineárnosť* – ak je gradient vstupno-výstupnej závislosti konštantný, snímač je lineárny;
- *Šírka pásma/frekvencia* – rýchlosť merania snímača. Zvyčajne býva vyjadrená v hertzoch;
- *Citlivosť* – miera zmeny výstupného signálu vzhľadom na mieru zmeny vstupného signálu. Môže byť ovplyvnená aj prostredím;
- *Chyba* – odchýlka výstupnej hodnoty od skutočnej. Vo všeobecnosti rozlišujeme medzi dvomi typmi chýb:
 - *systematická (deterministická)* – sústavná (konštantná) odchýlka meraní od skutočnosti. Môže byť spôsobená faktormi alebo procesmi, ktoré je možné modelovať;

- *náhodná (stochastická)* – premenlivá odchýlka meraní od skutočnosti. Je možné ju vyjadriť pravdepodobnostnými metrikami;
- *Presnosť* – miera systematickej chyby. Vyjadrená býva v pomere k skutočnej hodnote;
- *Opakovateľnosť* – miera náhodnej chyby. Je nezávislá od presnosti snímača;
- *Drift* – postupný odklon meraní od reálnych hodnôt, vzniká kumuláciou chýb merania;
- *Latencia* – oneskorenie medzi momentom výskytu fyzikálneho javu a momentom poskytnutia informácie o ňom senzorom. Môže byť spôsobená viacerými faktormi, vrátane fyzikálnych vlastností senzora, spôsobu spracovania signálu či času potrebného na odoslanie údajov.

Snímače a systémové komponenty využívané na lokalizáciu mobilných robotov možno klasifikovať viacerými spôsobmi podľa rôznych hľadísk, vo všeobecnosti podľa toho čo a akým spôsobom snímajú. Každé z týchto hľadísk zvyrazňuje iný aspekt senzorov. Medzi najčastejšie kritériá delenia snímačov patria:

1. Podľa spôsobu interakcie so snímaným prostredím [19]:
 - *aktívne* – senzory, ktoré samy vysielajú energiu do prostredia (napr. LiDAR, ultrazvuk),
 - *pasívne* – senzory, ktoré len pasívne prijímajú signály (napr. kamery, magnetometre),
2. Podľa typu meranej veličiny [39, 40]:
 - *inerciálne veličiny* – gyroskopy, akcelerometre,
 - *vzdialenosť* – LiDAR, ultrazvuk,
 - *elektromagnetické signály* – GNSS, magnetometre;
3. Podľa referenčného rámca výstupu [2]:
 - *lokálne* – poskytujú odhad polohy vzhľadom na predchádzajúci stav robota (napr. odometria),
 - *globálne* – poskytujú polohu vzhľadom na externý (globálny) rámec (napr. GNSS, MoCap systémy);
4. Podľa spôsobu vnímania [39]:

- *proprioceptívne* – merajú vnútorný stav robota samotného (napr. IMU),
- *exteroceptívne* – merajú informácie o vonkajšom prostredí (napr. LiDAR, kamera);

5. Podľa potreby infraštruktúry [13]:

- *interné* („*on-board*“) – schopné fungovať samostatne ako súčasť robota (napr. kamera, LiDAR, IMU),
- *externé* („*off-board*“) – vyžadujú externú inštaláciu alebo systém (napr. GPS, MoCap, UWB);

V tejto práci použijeme na systematizáciu predstavenia senzorov používaných na lokalizáciu mobilných robotov práve posledné spomenuté delenie.

2 Interné senzorické systémy

2.1 Odometria

Jedným zo spôsobov lokalizácie objektov je hrubé stanovenie polohy. Aktuálna poloha je odvodená na základe informácií o predošliých polohách a aktuálnom smere a rýchlosti pohybu. Najjednoduchšou implementáciou takéhoto prístupu je odometria. Využíva odometer – snímač, ktorý je schopný zaznamenať zmenu kinematiky – umiestnený na palube mobilného zariadenia (robota). Na základe uplynutého času, prejdenej dráhy vypočítanej z odometrie a orientácie, ktorá musí byť získaná iným spôsobom, je následne odvodený odhad aktuálnej polohy [11].

V prípade kolesových robotov je obvykle snímaný pohyb kolies, tzv. kolesová odometria, a to najčastejšie pomocou inkrementálnych snímačov polohy [11]. Princíp odometrie je však možné využiť aj pri spracovaní údajov z iných snímačov. V súčasnosti už dobre zaužívanou metódou je vizuálna odometria, ktorá využíva obraz z kamery, a pomerne nedávnou oblasťou je spracovanie meraní z LiDAR-u – lidarová odometria.

2.1.1 Kolesová odometria

Kolesová odometria využíva snímanie otáčok kolies, resp. motora pomocou optického inkrementálneho snímaču (IRC). Ten je schopný zaznamenávať otáčanie hriadeľa pomocou prerušovania svetelného lúča cez mriežku na rotujúcom disku. Pri jeho otáčaní vznikajú impulzy – sínusové alebo pravouhlé – ktoré reprezentujú zmenu uhla. Rozlíšenie snímača sa vyjadruje ako počet impulzov (cyklov) na jednu otáčku. Základný typ snímača však nevie určiť smer pohybu, preto sa v mobilnej robotike používa tzv. kvadrátúry inkrementálny snímač. Ten má dva optické kanály posunuté o 90° fázovo, čo umožňuje určiť nielen uhol, ale aj smer otáčania. Navyše, každý impulz možno ďalej interpolovať, čím sa zvyšuje presnosť merania [11].

Výhodou IRC je ich jednoduchosť, nízka cena a vysoká presnosť v rámci vnútornej štruktúry robota – chyby priamo v snímači sú spravidla zanedbateľné v porovnaní s chybami v mechanickom prenose (napr. v hriadeľi). Najväčším problémom IRC je však akumulácia chýb – spôsobená napríklad pretáčaním kolies, nepresným priemerom kolies alebo nerovným povrchom. Preto sú odometrické merania pomocou inkrementálnych snímačov síce veľmi presné v krátkom časovom horizonte, ale dlhodobo sa ich chyba zväčšuje. Na kompenzáciu sa preto bežne používajú korekčné algoritmy, ako je napríklad Kalmanov filter, ktorý kombinuje výstupy z viacerých senzorov [11].

2.2 Vizuálna odometria

Vizuálna odometria (VO) je technika odhadu polohy na základe vstupného obrazu z jednej alebo viacerých kamier. Na rozdiel od kolesovej odometrie, zaznamenáva posunutie obrazu medzi za sebou nasledujúcimi snímkami. Funguje v reálnom čase, v porovnaní s kolesovou odometriou má podstatne vyššiu spoľahlivosť a je vhodná v prostrediach bez dostupnosti signálu GPS.

Podľa počtu použitých kamier sa rozlišujú tri typy vizuálnej odometrie [22]:

1. *monokulárna* – využíva jednu kameru, meria posuny obrazu medzi snímkami a odhaduje pohyb, jej nevýhodou je faktor neurčitej mierky, ktorý je nutné kompenzovať prídavnými senzormi;
2. *stereovízna* – kombinuje dve synchronizované kamery, získava hĺbku priamo pomocou stereo triangulácie, čím odstraňuje problém neurčitej mierky;
3. *všesmerová* – pozostáva z komplexného systému viacerých mono- alebo stereo-kamier. Poskytuje veľmi široké zorné pole (až do 360°), vďaka čomu je rotačne invariantná. Vyžaduje však presnú kalibráciu a synchronizáciu medzi kamerami a je nákladnejšia [3].

Existuje viacero spôsobov určovania pohybu na základe obrazu z kamier. Medzi dominujúce prístupy VO patria [22]:

- *textúrna* – (obr. 1) pracuje s detekciou a sledovaním výrazných obrazových prvkov – textúr (napr. rohy, línie, krivky, ...). Je presná v dobre štruktúrovanom prostredí,



(a) vstupný obraz



(b) výstup zo sledovača textúr – krúžky reprezentujú aktuálne pozície textúr, čiary sú znázorňujú ich pohyb po obrázku

Obr. 1: Princíp textúrnej vizuálnej odometrie [30].

avšak jej robustnosť klesá pri monotónnych scénach. Na kompenzáciu driftu sa často požíva v kombinácii s metódami optimalizácie pozičného grafu.

- *priama* - pracuje priamo s intenzitami všetkých pixelov snímku, bez predchádzajúcej extrakcie, a to za účelom minimalizácie fotometrickej chyby. Je preto výpočtovo náročnejšia a pomalšia než textúrna vizuálna odometria. Je tiež citlivejšia na svetelné zmeny.
- *hybridná* – využíva kombináciu dvoch predošlých typov na rekonštrukciu trojrozmerného prostredia. V prvom slede sa použije textúrna VO na získanie hrubého odhadu polohy, ktorý je neskôr spresnený pomocou priamej VO.
- *vizuálno-inerciálna* – kombinuje kameru s IMU, čo zlepšuje metriku aj stabilitu: IMU poskytuje rýchlo-časové odhady a pomáha pri rýchlych pohyboch či nízkej textúre. Niektoré takéto systémy dosahujú centimetrovú presnosť a robustnosť v náročných prostrediach [32].

Vďaka efektívnejšiemu výkonu sú v súčasnosti rozšírenejšie skôr textúrne než priame metódy VO. Základné problémy, ktoré musí riešiť každý algoritmus textúrnej VO sú rekonštrukcia pohybu, nelineárna optimalizácia, párovanie textúr, rekonštrukcia hĺbky a aktualizácia stavu. Ich princíp vysvetlíme v nasledujúcich častiach podľa [18].

2.2.1 Rekonštrukcia pohybu

Pre rekonštrukciu pohybu kamery je potrebné získať 3D súradnice bodu na obraze z kamery. To je možné na základe tzv. *dierkového modelu kamery* (angl. *pinhole camera model*, viď obr. 2). Pre bod v priestore $\mathbf{P} = (x, y, z)^\top$ a jeho projekciu v rovine obrazu $\mathbf{p} = (u, v)^\top$ je projekčný model definovaný takto:


$$\begin{bmatrix} \mathbf{p} \\ 1 \end{bmatrix} \sim \begin{bmatrix} f_u & 0 & u_c & 0 \\ 0 & f_v & v_c & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{0} \end{bmatrix} \mathbf{P}, \quad (2.1)$$

kde $\mathbf{K}$ je tzv. *matica kamery*, ktorá obsahuje vnútorné parametre kamery: fokálne vzdialenosti f_u, f_v a súradnice stredu optickej osi (u_c, v_c) .

Za predpokladu, že $\mathbf{P}$ je stacionárny bod v priestore, jeho projekcia v nasledujúcej snímke z kamery sa dá vyjadriť ako

$$\begin{bmatrix} \mathbf{p}' \\ 1 \end{bmatrix} \sim \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix} \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix}, \quad (2.2)$$

kde rotačná matica $\mathbf{R} \in SO(3)$ a translačný vektor $\mathbf{t} \in \mathbb{R}^3$ predstavujú Euklidovskú transformáciu danú pohybom kamery.



Obr. 2: Dierkový model kamery – projekcia 3D bodu do 2D obrazu kamery (podľa [10])

V kontexte problému odhadu pohybu je transformácia $\begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}$ riešenou neznámou, ktorú je potrebné určiť na základe množiny 3D–2D korešpondencií $(x, y, z) \leftrightarrow (u', v')$. Tento problém je známy ako úloha *perspective-from-n-points* (PnP). Ak sa na celú projekčnú maticu $\mathbf{P} = \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}$ pozeráme ako na problém čiernej skrinky (t. j. bez znalosti vnútorných závislostí), riešenie je možné získať jednoducho vyriešením homogénneho lineárneho systému. Takýto prístup je známy ako metóda *priamej lineárnej transformácie* (DLT) [18]. Rotácia určená týmto spôsobom však nemusí byť platným prvkom špeciálnej ortogonálnej skupiny $SO(3)$ kvôli nadbytočnej parametrizácii. Preto sa na nájdenie riešenia rovnice 2.2 v praxi často používa algoritmus *Efficient PnP* (EPnP) [24], ktorý ponúka výpočtovo efektívne a stabilné riešenie úlohy PnP. Jeho hlavnou výhodou je, že reprezentuje 3D body ako lineárnu kombináciu štyroch kontrolných bodov, čím znižuje počet neznámych a dosahuje lineárnu výpočtovú zložitosť vzhľadom na počet korešpondencií. Táto vlastnosť robí EPnP obzvlášť vhodným pre použitie v reálnom čase a v systémoch, kde sa pracuje s veľkým množstvom bodov, ako je tomu aj v tomto prípade.

2.2.2 Nelineárna optimalizácia

Pohyb kamery odhadnutý pomocou lineárnych metód (napr. DLT alebo EPnP), poskytuje len suboptimálne riešenie. Na dosiahnutie riešenia *metódou maximálnej vierohodnosti* (MLE) je potrebná nelineárna optimalizácia. Za predpokladu, že šum v meraniach má Gaussovské rozdelenie, možno odhad MLE pre N sledovaných textúr dosiahnuť minimalizáciou sumy štvorcov reprojekčnej chyby:

$$\phi_{\text{RPE}}(\mathbf{R}, \mathbf{t}) = \sum_{i=1}^N \|\mathbf{p}'_i - \pi_{\mathbf{K}}(\mathbf{R} \cdot \mathbf{P}_i + \mathbf{t})\|_{\Sigma_i}^2, \quad (2.3)$$

kde $\pi_{\mathbf{K}} : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ je projekčná funkcia, ktorá zobrazuje 3D bod do projekčného priestoru P^2 pomocou matice kamery $\mathbf{K}$ a následne prevádza homogénne súradnice na karteziánske. Symbol $|\cdot|_{\Sigma}$ označuje Mahalanobisovu vzdialenosť vzhľadom na kovariančnú maticu Σ .

Na zvýšenie stability optimalizácie sa okrem korešpondencií 3D–2D zohľadňujú aj korešpondencie 2D–2D, t. j. $(u, v) \leftrightarrow (u', v')$, pre ktoré sa definuje epipolárna chybová funkcia:

$$\phi_{\text{EPI}}(\mathbf{R}, \mathbf{t}) = \sum_{i=1}^N \delta(\mathbf{p}_i, \mathbf{p}'_i; \mathbf{F}), \quad (2.4)$$

kde δ označuje Sampsonovu vzdialenosť [37] medzi dvojicou bodov vzhľadom na fundamentálnu maticu $\mathbf{F}$:

$$\delta(\mathbf{p}, \mathbf{p}'; \mathbf{F}) = \frac{(\mathbf{p}'^\top \mathbf{F} \mathbf{p})^2}{(\mathbf{F} \mathbf{p})_0^2 + (\mathbf{F} \mathbf{p})_1^2 + (\mathbf{F}^\top \mathbf{p}')_0^2 + (\mathbf{F}^\top \mathbf{p}')_1^2} \quad (2.5)$$

Fundamentálna matica $\mathbf{F}$ je definovaná ako:

$$\mathbf{F} = \mathbf{K}^{-\top} [\mathbf{t}]_{\times} \mathbf{R} \mathbf{K}^{-1}, \quad (2.6)$$

kde $[\mathbf{t}]_{\times}$ je antisymetrická matica odvodená z translačného vektora $\mathbf{t} = (t_x, t_y, t_z)^\top$:

$$[\mathbf{t}]_{\times} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix} \quad (2.7)$$

Optimalizovaná funkcia energie, ktorá kombinuje reprojekčnú aj epipolárnu chybu, je definovaná ako:

$$\Phi(\mathbf{R}, \mathbf{t}) = (1 - \alpha) \cdot \phi_{\text{RPE}}(\mathbf{R}, \mathbf{t}) + \alpha \cdot \phi_{\text{EPI}}(\mathbf{R}, \mathbf{t}), \quad (2.8)$$

kde $\alpha \in [0, 1]$ je regulačný parameter určujúci váhu epipolárneho člena. Aby boli členy porovnateľné, hodnota α je normalizovaná vzhľadom na počet zodpovedajúcich bodov. Nech $\beta \in [0, 1]$ je požadovaný pomer váh, N_{RPE} počet 3D–2D korešpondencií a N_{EPI} počet 2D–2D korešpondencií. Potom sa α vypočíta nasledovne:

$$\alpha = \left(1 + \frac{N_{\text{EPI}}}{N_{\text{RPE}}} \cdot \frac{1 - \beta}{\beta} \right)^{-1} \quad (2.9)$$

Rovnicu (2.8) nie je možné vyriešiť v uzavretom tvare, a preto sa na jej minimalizáciu používa nelineárna optimalizačná metóda najmenších štvorcov, napríklad algoritmus Levenberg-Marquardt, pričom sa vychádza z lineárneho počiatočného odhadu.

2.2.3 Párovanie textúr

Párovanie obrazových textúr (angl. *feature matching*) sa bežne využíva na určenie 2D–2D pixelových korešpondencií, ktoré sú potrebné na výpočet členov vo vzťahu (2.4). Po vyriešení relatívneho pohybu aktuálneho snímku sa tieto korešpondencie znova využívajú na získanie 3D–2D korešpondencií požadovaných vo vzťahu (2.3), a to pomocou prístupu opísaného v nasledujúcej časti.

Príznamy sa spočiatku zladujú v príznakovom priestore. Nech $\mathcal{F}$ a $\mathcal{F}'$ označujú množiny príznakov (textúr) extrahovaných v dvoch po sebe idúcich snímkach. Príznak $\chi \in \mathcal{F}$ sa priradí k $\chi' \in \mathcal{F}'$ podľa pravidla:

$$\chi' = \arg \min_{\chi' \in \mathcal{F}'} d(\chi, \chi'), \quad (2.10)$$

kde $d : \mathcal{F} \times \mathcal{F}' \rightarrow \mathbb{R}$ je zvolená metrika podobnosti medzi dvoma príznakmi.

Nejednoznačné zhody sa identifikujú pomocou rozdielového pomeru. Nech $\tilde{\chi}' \in \mathcal{F}'$ označuje druhú najlepšiu zhodu pre príznak χ . Korešpondencia $\chi \rightarrow \chi'$ je považovaná za nejednoznačnú, ak platí:

$$\frac{d(\chi, \chi')}{d(\chi, \tilde{\chi}')} < r, \quad (2.11)$$

kde $r \in (0, 1)$ je vopred určený prah.

Nejednoznačné korešpondencie sa následne odstránia spätným overením z množiny $\mathcal{F}'$ do $\mathcal{F}$. Korešpondencia $\chi \rightarrow \chi'$ je považovaná za nekonzistentnú, ak:

$$\arg \min_{\tilde{\chi} \in \mathcal{F}} d(\tilde{\chi}, \chi') \neq \chi \quad (2.12)$$

Po aplikovaní podmienok (2.11) a (2.12) získame množinu jednoznačných a symetrických korešpondencií $\chi \leftrightarrow \chi'$.

Tieto korešpondencie sa ďalej rozširujú pomocou sledovania príznakov KLT [41] aplikovaného na príznaky z $\mathcal{F}$, ktoré sa nepodarilo spojiť s prvkami z $\mathcal{F}'$.

Na rozšírenej množine príznakov sa následne vykonáva eliminácia odľahlých bodov pomocou robustnej metódy RANSAC [14]. V každej iterácii sa náhodne vyberie päť korešpondencií, na základe ktorých sa odhadne esenciálna matica $\mathbf{E}$ pomocou päťbodového algoritmu [29]. Následne sa pre všetky zhody vypočítajú Sampsonove vzdialenosti vzhľadom na $\mathbf{E}$. Tento proces sa opakuje, kým sa nenájde dostatočný počet prilahlých bodov, ktoré súhlasia s esenciálnou maticou v rámci tolerovanej vzdialenosti, napríklad 0,5 pixelu.

2.2.4 Rekonštrukcia hĺbky

Na odhad pohybu kamery v konzistentnej mierke je potrebné pracovať v Euklidovských súradniciach. V prípade monokulárneho systému však absolútnu mierku nie je možné

určiť iba na základe projekcie. Pohyb medzi prvým a druhým snímkom sa preto zvyčajne určuje pomocou dekompozície esenciálnej matice, ktorá následne slúži na rekonštrukciu 3D súradníc príznakov. Takto inicializovaný proces vizuálnej odometrie potom umožňuje určovať relatívny pohyb kamery v konzistentnej mierke počas celej sekvencie snímok.

Nech (u, v) a (u', v') označujú obrazové súradnice zodpovedajúceho príznaku $\chi \leftrightarrow \chi'$ v dvoch po sebe idúcich snímkach. Pri danom pohybe kamery $[\mathbf{R} \ \mathbf{t}]$ možno 3D súradnice príznaku χ rekonštruovať minimalizáciou nasledujúcej vzdialenosti vzhľadom na voľné parametre $k, k' \in \mathbb{R}^+$:

$$\delta_{\text{mid}}(k, k') = \|k \mathbf{a} - (k' \mathbf{a}' + \mathbf{c}')\|^2, \quad (2.13)$$

kde $\mathbf{a} = \mathbf{K}^{-1}(u, v, 1)^\top$ a $\mathbf{a}' = \mathbf{R}^\top \mathbf{K}^{-1}(u', v', 1)^\top$ sú smerové vektory spätných projekcií lúčov v prvom a druhom snímku. Vektor $\mathbf{c}' = -\mathbf{R}^\top \mathbf{t}$ predstavuje nový stred kamery (t. j. pozíciu kamery po pohybe).

Minimum vo výraze (2.13) možno nájsť ako riešenie metódy najmenších štvorcov pre nasledujúcu lineárnu sústavu:

$$\begin{bmatrix} \mathbf{a} & -\mathbf{a}' \end{bmatrix} \begin{bmatrix} k \\ k' \end{bmatrix} = \mathbf{A} \begin{bmatrix} k \\ k' \end{bmatrix} = \mathbf{c}' \quad (2.14)$$

Výsledné hodnoty k a k' určujú dva body na príslušných spätných lúčoch (zodpovedajúcich príznaku χ v oboch snímkach), ktoré sú v priestore k sebe najbližšie.

Stred týchto dvoch bodov, ktorý predstavuje 3D odhad súradníc príznaku, sa potom vypočíta ako:

$$(x, y, z)^\top = \frac{1}{2} \left(\begin{bmatrix} \mathbf{a} & \mathbf{a}' \end{bmatrix} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top + \mathbf{I} \right) \mathbf{c}' \quad (2.15)$$

Týmto spôsobom sa získa odhad 3D súradníc príznaku, pričom tento postup je známy ako *triangulácia pomocou stredového bodu* (angl. *mid-point triangulation*).

2.2.5 Aktualizácia stavu

Na zlepšenie stability procesu vizuálnej odometrie sa stavy sledovaných príznakov uchovávaajú počas celej sekvencie. Nech $\mathbf{m}_{i,k}$ je pozorovaný stavový vektor príznaku i v snímke k a $\omega_{i,k} \in \langle 0, 1 \rangle$ je váha vyjadrujúca mieru dôvery, že pozorovanie zodpovedá skutočnému stavu. Odhad skutočného stavu sa potom vypočíta ako:

$$\hat{\mathbf{m}}_{i,k} = \frac{\hat{\omega}_{i,k-1} \cdot f_{k-1,k}(\hat{\mathbf{m}}_{i,k-1}) + \omega_{i,k} \cdot \mathbf{m}_{i,k}}{\hat{\omega}_{i,k}}, \quad (2.16)$$

kde $\hat{\omega}_{i,k} = \hat{\omega}_{i,k-1} + \omega_{i,k}$ predstavuje kumulatívnu váhu a $f_{k-1,k}$ je prechodová funkcia, ktorá transformuje stav z predchádzajúceho snímku $k-1$ do aktuálneho snímku k .

Na dočasné zlepšenie odhadov hĺbok sledovaných príznakov možno vektor $\mathbf{m}$ interpretovať ako 3D súradnice príznaku a následne aplikovať aktualizčný vzťah (2.16). V tomto prípade je $f_{k-1,k}$ Euklidovská transformácia určená odhadnutým relatívnym pohybom kamery $\begin{bmatrix} \mathbf{R}_k & \mathbf{t}_k \end{bmatrix}$, a váha sa nastavuje ako:

$$\omega_{i,k} = \frac{1}{1 + \delta_{i,k}}, \quad (2.17)$$

kde $\delta_{i,k}$ je odhadnutá chyba triangulácie. V prípade použitia metódy triangulácie pomocou stredového bodu sa $\delta_{i,k}$ definuje ako súčet najkratších vzdialeností triangulovaného bodu od oboch spätných projekčných lúčov.

2.2.6 Prehľad súčasných riešení

Jedným z prvých algoritmov na extrakciu textúr bol algoritmus SIFT, v súčasnosti sa skôr využívajú jeho alternatívy SURF a ORB, ktoré popisujeme nižšie.

SIFT

Algoritmus SIFT, ktorý predstavil Lowe v roku 1999 [25], patrí medzi najskoršie komplexné metódy detekcie kľúčových bodov a extrakcie deskriptorov príznakov. Na zabezpečenie mierkovej invariance buduje SIFT viacúrovňovú pyramídu z rozmazaných verzií vstupného obrazu a aplikuje operátory rozdielu Gaussov (DoG) na detekciu lokálnych extrémov v mierkovom priestore. Lokálnosť je definovaná oknom veľkosti $3 \times 3 \times 3$. Vybrané sú iba extrémy s vysokým lokálnym kontrastom, ktoré neležia na hranách – tie sa označujú ako kľúčové body.

V okolí každého kľúčového bodu sa v okne 16×16 počítajú gradienty obrazu, ktoré sa následne zoskupia do 4×4 podoblastí. V každej podoblasti sa gradienty kvantizujú do osem-prvkového histogramu smerov. Spojením všetkých histogramov (16 oblastí $\times 8$ binov) vzniká vektor deskriptora dĺžky 128 prvkov.

SURF

Šesť rokov po zavedení SIFT predstavili autori Bay a kol. algoritmus SURF [6], ktorý mal byť rýchlejší a robustnejší. Namiesto DoG operátorov využíva SURF aproximované druhé derivácie výpočtom pomocou filtrov s rovnomerným váhovaním, ktoré možno efektívne aplikovať pomocou integrálneho obrazu. To umožňuje výrazné zrýchlenie oproti SIFT.

Robustnosť SURF príznakov spočíva v určení dominantného smeru oblasti okolo kľúčového bodu ešte pred výpočtom deskriptora. Tento smer sa odhaduje na základe Gaussovsky vážených odpovedí na horizontálne a vertikálne Haarove vlnenia v kruhovej oblasti okolo kľúčového bodu. Odpovede sa prevedú do polárnych súradníc, rozdelia do uhlových segmentov a v každom sa spočítajú vektorové odpovede. Smer segmentu

s najdlhším súčtovým vektorom je určený ako dominantný smer lokálneho okolia. Na základe tohto smeru sa potom oblasť rotuje a extrahuje sa Gaussovsky vážený deskriptor z odpovedí na Haarove vlnenia.

ORB

Algoritmus ORB, ktorý v roku 2011 navrhli autori Rublee a kol. [35], predstavuje rýchlu a výpočtovo nenáročnú alternatívu k SIFT a SURF. Kombinuje modifikovaný detektor FAST [33] s rotačne invariantnou verziou binárneho deskriptora BRIEF [9].

Pre dosiahnutie mierkovej invariance sa FAST detekcia opakuje na každej úrovni mierkovej pyramídy. Výber príznakov je ďalej filtrovaný pomocou Harrisovej miery [17], ktorá odstraňuje body, ktoré nie sú rohmi.

Deskriptory sa tvoria ako binárne reťazce dĺžky n porovnávaním jasov vopred určených dvojíc pixelov v okolí príznaku. Keďže pôvodný BRIEF nie je rotačne invariantný, ORB najprv určí smer každého príznaku pomocou metódy obrazových momentov [21]. Smer príznaku je určený vektorom spájajúcim jeho stred s centroidom príslušnej obrazovej oblasti. Tento smer sa následne použije na rotáciu testovacej masky pred extrakciou binárneho deskriptora, čím sa dosahuje rotačná invariantnosť.

2.2.7 Vizualný SLAM

Kým vizuálna odometria sa zameriava predovšetkým na lokálny odhad pohybu kamery medzi po sebe idúcimi snímkami, cieľom vizuálneho SLAM-u je súčasne odhadovať trajektóriu kamery aj rekonštruovať štruktúru pozorovaného prostredia. To si vyžaduje riešiť zložitejšie problémy, ako je uzatváranie slučiek, správa globálnej konzistentnej mapy či eliminácia chýb akumulovaných počas lokalizácie.

Kľúčovou súčasťou väčšiny moderných SLAM systémov je nelineárna optimalizácia známa ako „bundle adjustment“, ktorá umožňuje spresniť odhady pozícií kamery aj 3D súradníc pozorovaných bodov (tzv. mapových bodov) tak, aby čo najlepšie zodpovedali skutočným pozorovaniam. Hoci je táto technika výpočtovo náročná, vývoj efektívnych algoritmov a organizačných princípov umožnil jej využitie aj v reálnom čase.

Aby bol vizuálny SLAM efektívny a zároveň presný, systém musí zabezpečiť:

1. výber tzv. *klúčových snímkok* (angl. *keyframes*), ktoré reprezentujú rôzne pohľady na scénu a poskytujú dostatočnú paralaxu pre rekonštrukciu hĺbky,
2. sledovanie spoločných prvkov scény medzi kľúčovými snímkami, čo vytvára dobre prepojenú sieť pozorovaní (tzv. *graf snímkok*),
3. dobrý počiatočný odhad pozícií snímkok aj 3D bodov, ktorý slúži ako vstup pre optimalizáciu,

4. lokálne obmedzenú optimalizáciu, ktorá znižuje výpočtové nároky a umožňuje škálovateľnosť,
5. globálne optimalizačné kroky – napríklad optimalizáciu grafu pozícií snímok – ktoré umožňujú uzatváranie slučiek v reálnom čase.

Jednou z najznámejších a široko používaných implementácií vizuálneho SLAM-u, ktorá úspešne spája všetky vyššie uvedené aspekty, je algoritmus ORB-SLAM [28].

ORB-SLAM

ORB-SLAM je komplexný systém vizuálneho SLAM-u, prvýkrát predstavený v roku 2015, ktorý využíva len jednu monokulárnu, stereo alebo RGB-D kameru a je schopný pracovať v reálnom čase. Systém je postavený na ORB detekcii príznakov, pričom tá istá sada príznakov je využívaná na všetky úlohy: sledovanie pohybu, mapovanie aj uzavretie slučky. ORB-SLAM spája klasickú odometriu s mapovaním a optimalizáciou, čím umožňuje presnú a konzistentnú lokalizáciu aj pri dlhodobom sledovaní scény. Pozostáva z troch základných modulov, ktoré spolupracujú paralelne v reálnom čase:

1. Sledovanie (Tracking)

Tento modul sa stará o spracovanie prichádzajúcich snímok a odhad pohybu kamery vzhľadom na mapu. Ak mapa ešte nie je inicializovaná, vykoná sa monokulárna triangulácia medzi prvými dvoma kľúčovými snímkami. V ďalších krokoch modul odhaduje pozíciu novej snímky pomocou zodpovedajúcich ORB príznakov a porovnaním s aktuálnou mapou. V prípade výraznej zmeny scény alebo straty sledovania môže byť iniciovaný relokalizáciou pomocou databázy kľúčových snímok.

2. Správa mapy (Local Mapping)

Body v mape sa triangulujú zo zodpovedajúcich príznakov v rôznych snímkach. Počas spracovania sa vyberajú nové kľúčové snímky, ktoré rozširujú mapu a umožňujú jej lokálnu optimalizáciu pomocou lokálnej *balíkovej optimalizácie* (angl. *bundle adjustment*). Výber kľúčových snímok je optimalizovaný tak, aby zachytili dostatočný pohyb a nový pohľad na scénu, ale zároveň nezahltili systém nadbytočnými údajmi.

3. Uzatváranie slučiek (Loop Closing)

Na odstránenie akumulovaných chýb a dosiahnutie globálnej konzistencie systému využíva ORB-SLAM detekciu slučiek, t. j. opätovného návratu kamery do už navštívených oblastí. Po detekcii slučky sa vykoná globálna optimalizácia grafu pozícií snímok (angl. *pose graph*), ktorá opraví globálnu trajektóriu a prispôsobí mapu.

Pre efektívne porovnávanie snímok a detekciu slučiek používa ORB-SLAM prístup tzv. *zásobníka slov* (angl. *Bag of Words*), ktorý umožňuje rýchle vyhľadávanie vizuálne podobných snímok na základe ORB deskriptorov.

System poskytuje ako výstup trajektóriu kamery a riedku trojrozmernú rekonštrukciu scény – s dostatočnou presnosťou pre potreby lokalizácie, ale zároveň s dôrazom na výpočtovú efektivitu.

2.3 Lidarová odometria

Téma lidarovej odometrie (LO) zaznamenala v posledných niekoľkých rokoch veľký rozmach, keďže prináša nové možnosti aplikácie zvlášť v prostrediach a podmienkach, kde sú iné spôsoby lokalizácie nedostatočné. Neustále pribúdajú nové riešenia, ktoré využívajú lidar spolu s ďalšími modernými prístupmi a technológiami za účelom získania čo najpresnejšej polohy.

2.3.1 LiDAR technológia

Light Detection and Ranging (LiDAR) je technológia diaľkového snímania založená na meraní času, za ktorý sa laserový impulz odrazí späť od objektu. Výsledkom sú vysoko presné 3D reprezentácie prostredia vo forme mračien bodov (z angl. *point clouds*). Lidar je nezávislý od osvetlenia a stal sa kľúčovým senzorom v oblasti autonómnej navigácie a mapovania [23].

Lidary možno klasifikovať podľa dvoch hlavných kritérií [23]:

1. Mechanizmus snímania:

- *mechanický* – využíva rotujúce časti na rozptyl lúčov. Ponúka široké zorné pole, dobrú kvalitu meraní, ale tá môže časom degradovať vplyvom opotrebovania mechanických prvkov;
- *polovodičový (angl. solid-state)* – nepohyblivé systémy (napr. MEMS, OPA), ktoré sú kompaktnjšie a menej poruchové. Využívajú sa technológie MEMS, ktorá rozptyľuje stacionárny lúč pomocou elektromechanických zrkadiel alebo OPA, ktorá využíva moduláciu tvaru svetelných vln;
- *s plošným osvetlením (angl. flash)* – osvetľuje celé zorné pole naraz, veľmi rýchly, no menej používaný v odometrii.

2. Princíp merania:

- *čas letu (ToF)* – meria vzdialenosť na základe rýchlosti svetla a doby letu laserového impulzu, za ktorú sa odrazí od objektu a vráti naspäť. Je jednoduchý a presný, no môže byť náchylný na rušenie externými svetelnými zdrojmi.

- *frekvenčne modulovaná spojité vlna (FMCW)* – vysielajú súvislé svetelné vlny s premenlivou frekvenciou a analyzuje frekvenčný posun odrazeného svetla, ktorý je priamo úmerný vzdialenosti objektu. Poskytuje navyše aj informácie o relatívnej rýchlosti. Je rezistentný voči interferencii a viaccestnému šíreniu, ale zložitejší a zvyčajne drahší než ToF.
- *amplitúdovo modulovaná spojité vlna (AMCW)* – meria čas odrazu pomocou vysielania vln s variabilnou amplitúdou.

2.3.2 Prehľad metód lidarovej odometrie

Cieľom LO je odhadnúť trajektóriu robota na základe údajov z lidar. Kľúčom k tomu je princíp odometrie, spočívajúci vo vyhodnotení posunu od predošlému stavu k súčasnemu, čo je však prípade lidarového mračna bodov podstatne komplexnejšie úloha než v prípade kolesovej odometrie. Prístupov k riešeniu tohto problému je mnoho, ponúkame teda najvýznamnejšie z nich podľa zdroja [23].

Odometria založená výlučne na lidare (angl. LiDAR-only odometry)

Využíva výhradne údaje z jedného lidar, pričom porovnáva rozdiel medzi predošlým a súčasným skenom. Jej výhodou je nezávislosť od iných senzorov, nevýhodou nižšia robustnosť v degenerovaných prostrediach. Delí sa na:

- *Metódy priamej zhody (angl. direct matching)* – sú založené na odhade transformačnej matice medzi po sebe nasledujúcimi skenmi, najčastejšie pomocou ICP algoritmu (viac v kap. 2.3.3).
- *Textúrne zamerané prístupy (angl. feature-based)* – sú založené na extrakcii významných bodov z mračna bodov a ich použití na odhad transformačného pohybu medzi skenmi, vďaka čomu sú výpočtovo efektívnejšie a odolnejšie voči šumu. Kľúčovou úlohou je však výber vhodných príznakov. Príkladmi implementácie je LOAM, ktorý rozlišuje medzi hranovými a rovinnými bodmi podľa lokálnej hladkosti povrchu či SuMa, resp. SuMa++, ktoré využívajú normálové mapy povrchu a zohľadňujú aj sémantické informácie, čo zvyšuje robustnosť voči chybám registrácie.
- *Metódy hlbokého učenia (angl. deep learning-based)* – pokúšajú sa zlepšiť nachádzanie zhody medzi skenmi pomocou DL prístupov. Túto triedu zastupujú algoritmy ako LO-Net, ktorý predvída dynamiku jednotlivých regiónov a LodoNet, kde sa využíva proces spätnej projekcie zhodných párov kľúčových bodov (MKP).

Lidarovo-inerciálna odometria (LIO)

Ide o kombináciu dát z lidarů a IMU. Prináša vyššiu presnosť a stabilitu. Existujú dve jej variácie podľa toho, akým spôsobom sú spracúvané údaje z IMU:

- *voľne previazaná (angl. loosely coupled)* – spracovanie údajov prebieha samostatne, následne sú fúzované na základe pridelených váh, napr. pomocou EKF.
- *tesne previazaná (angl. tightly coupled)* – optimalizuje všetky merania v spoločnom grafe (napr. LIO-SAM, CLINS). Je výpočtovo náročnejšia a môže byť zraniteľná v prípade, že jeden zo senzorov poskytuje nekvalitné údaje.

Fúzia viacerých senzorov

S cieľom zvýšiť kvalitu merania celého systému (zorné pole, presnosť, robustnosť, ...) sa často využíva kombinácia viacerých senzorov, pričom treba rozlišovať dva základné typy:

- *kombinácia viacerých lidarů* – predchádza dôsledkom výpadku meraní pri použití jediného lidarů, zároveň však kladie vyššie nároky na synchronizáciu a výpočty (napr.);
- *kombinácia lidarů a iných senzorů* – fúzia s kamerami, radarmi, termálnymi senzormi či IMU kompenzuje nedostatky lidarů v nevhodných prostrediach akými sú nepriaznivé poveternostné podmienky či monotónne štruktúry (napr. tunely či diaľnice).

Predmetom výskumu LO sú viaceré pretrvávajúce nedostatky riešení. Spracovanie veľkého množstva údajů si vyžaduje využitie efektívnych dátových štruktúr (napr. ikd-Tree [8], iVox [5]). Pri pohybe lidarů dochádza k skresleniu nameraných dát, čo sa rieši zavádzaním vyrovnávacích korekcií a modelov trajektórie. Spoľahlivosť LO stále ovplyvňuje aj povaha okolitého prostredia. V monotónnych prostrediach je preto nevyhnutné aj využitie intenzity merania, Dopplerovho efektu či fúzie s kamerou. Pri fúzii s inými senzormi sú však výzvami faktory ako presná kalibrácia a synchronizácia, ale aj výpočtová náročnosť. Z povahy princípu fungovania lidarů sú problémové najmä daždivé, hmlisté či reflexné prostredia; pre tieto prípady už vznikli viaceré riešenia, napr. WeatherNet alebo LIOR [23].

2.3.3 Iteratívny algoritmus najbližších bodů (ICP)

Jedným z najpoužívanějších súčasných prístupů pre geometrické zarovnanie pri registrácii trojrozmerných povrchů je Iteratívny algoritmus najbližších bodů (ICP). Jeho pôvodná verzia bola vytvorená autormi Besl a kol. [7] v roku 1992, no modifikácie sú vyvíjané dodnes. Trojrozmerná registrácia povrchu je proces, ktorý zarovnáva 3D

mračno bodov (napr. z hĺbkovej kamery alebo z lidar) z rôznych uhlov pohľadu za účelom získania úplnejšej reprezentácie prostredia a určenia pohybu senzora. V prípade, že vstupné dáta sú asociované, t. j. je známa korešpondencia $\mathcal{C}(\mathbf{s}_i) = \{(i, j)\}$ medzi zdrojovým mračnom $\mathcal{S} = \{\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_I\}$ a cieľovým mračnom $\mathcal{D} = \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_J\}$, je možné ich vzájomnú transláciu $\mathbf{t}$ a rotáciu $\mathbf{R}$ určiť minimalizáciou sumy štvorcov odchýlok ako

$$\mathcal{F}(\mathcal{C}(\mathcal{S}), \mathcal{S}, \mathcal{D}) = \min_{\mathbf{R}, \mathbf{t}} \sum_{i=1}^I \sum_{j=1}^J \|\mathbf{d}_i - \mathbf{R} \cdot \mathbf{s}_j - \mathbf{t}\|_2^2 \quad (2.18)$$

Avšak v prípadoch, kedy korešpondencia známa nie je, asociáciu medzi mračnami bodov je potrebné získať heuristicky. Na to existuje viacero metód, napr. numerická Newtonova metóda či dynamický genetický algoritmus, no najčastejšie sa na tento účel využívajú práve variácie ICP algoritmu [4].

Podstata algoritmu spočíva v troch základných krokoch:

1. počiatočný odhad možných asociácií na základe vstupných dát,
2. iteratívne transformovanie cieľového mračna bodov k zdrojovému tak, aby sa minimalizovala celková odchýlka, až kým sa nedosiahne prahová hodnota konvergenzie,
3. výpočet výslednej translácie a rotácie.

Podrobnejšie je celý proces znázornený v algoritme 1, kde je sú vstupmi zdrojové mračno bodov $\mathcal{S}$, cieľové mračno bodov $\mathcal{D}$ a prah konvergenzie θ . Ďalej v ňom vystupuje operátor výpočtu ťažiska $\mathcal{M}$, operátor registrácie povrchov pri známych korešponden-

Algoritmus 1 Základný ICP algoritmus podľa [4]

Require: $\mathcal{S} = \{\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_I\}$, $\mathcal{D} = \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_J\}$, θ

Ensure: $\mathbf{T}_{R,t}$, $\varepsilon_k \leq \theta$

$\mathcal{T}(\mathcal{S} \rightarrow \mathcal{D})$ s.t. $\mathcal{M}(\mathcal{S}) = \mathcal{M}(\mathcal{D})$

$\varepsilon_0 \leftarrow \infty$

while $(\varepsilon_k > \theta \wedge \varepsilon_k < \varepsilon_{k-1}) \vee \varepsilon_k = \infty$ **do**

for $\mathbf{s}_i \in \mathcal{S}$ **do**

$\mathcal{C}(\mathbf{s}_i) \leftarrow (\mathbf{d}_j, \mathbf{s}_i)$ s.t. $\|(\mathbf{d}_j, \mathbf{s}_i)\|^2 \rightarrow \min$

end for

$\mathbf{T}_{R,t} \leftarrow \mathcal{F}(\mathcal{C}(\mathcal{S}), \mathcal{S}, \mathcal{D})$

$\varepsilon_{k+1} \leftarrow \frac{1}{|I|} \sum_{i=1}^I (\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_j)^2$

end while

return $\mathbf{T}_{R,t}$

ciách $\mathcal{F}$, odchýlku ε vypočítanú pre danú iteráciu, množinu korešpondencií $\mathcal{C} = \{(i, j)\}$, operátor tuhého transformačného odhadu $\mathcal{T}$ a operátor aplikácie transformácie $\mathbf{T}_{\mathbf{R}, \mathbf{t}}$.

Ako už bolo spomenuté, existuje viacero variantov ICP algoritmu, ktoré je možné rozdeliť na základe viacerých kritérií [36]:

1. Podľa typu minimalizačnej metriky:

- *bod na bod* – najjednoduchšia verzia, minimalizuje euklidovskú vzdialenosť medzi korešpondujúcimi bodmi, vhodná pri povrchoch bez výraznej štruktúry

$$\min_{\mathbf{R}, \mathbf{t}} \sum_i \|\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_i\|^2$$

- *bod na plochu* – minimalizuje vzdialenosť od bodu k rovine určenej normálou cieľového bodu, rýchlejšie konverguje, vhodný pre hladké povrchy

$$\min_{\mathbf{R}, \mathbf{t}} \sum_i [(\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_i) \cdot \mathbf{n}_i]^2$$

- *plocha na plochu* – predpokladá, že oba body majú definované normály a minimalizuje vzdialenosť medzi dotyčnými rovinami. Používa sa napr. v NDT-ICP alebo pokročilých SLAM systémoch.

2. Podľa stratégie výberu korešpondencií:

- *Brute-force nearest neighbor* – každý bod zo zdrojového mračna sa spáruje s najbližším bodom v cieľovom;
- *Mutual nearest neighbor* – korešpondencia sa akceptuje iba vtedy, ak si oba body navzájom zodpovedajú ako najbližší sused;
- *Color ICP* – pri výbere korešpondencií sa berie do úvahy aj podobnosť farby alebo intenzity;
- *Feature-based ICP* – body sú doplnené o deskriptory a párujú sa na základe ich podobnosti.

3. Podľa robustnosti a rýchlosti:

- *Generalized ICP (G-ICP)* – spája metódy *bod na bod* a *bod na plochu* pomocou modelovania pravdepodobnostného rozloženia bodov ako Gaussových distribúcií, vhodný pre zarovnávanie s neistotou alebo nehomogenitou;
- *Sparse ICP* – používa len podmnožinu bodov, čo šetrí výpočtový čas;
- *Robust ICP* – používa robustné funkcie na potlačenie vplyvu odľahlých bodov.

- *Color/Photometric ICP* – rozširuje ICP o intenzitné alebo farebné informácie (vhodné pri RGB-D údajoch).

4. Iné pokročilé varianty:

- *Normal Distributions Transform (NDT)* – Mračná bodov sa reprezentujú ako hustotné mapy (napr. v bunkách), nie ako explicitné body;
- *Iterative Closest Line/Keypoint (ICLK)* – rozšírenia pre špecifické geometrie (čiary, body, hrany);
- *KISS-ICP* – minimalistický robustný point-to-point ICP s adaptívnym prahom a robustným jadrom.

KISS ICP

KISS-ICP predstavuje odľahčený variant klasického ICP algoritmu typu *bod na bod* pre LO. Cieľom autorov bolo preukázať, že dobre navrhnuté jednoduché komponenty dokážu prekonať zložité metódy. Systém má rádovo menej parametrov než iné metódy a väčšinou nevyžaduje žiadne špecifické ladenie pre rôzne typy lidarov či prostredia [42].

Algoritmus prebieha v štyroch základných krokoch. Najskôr sa vykonáva predikcia a kompenzácia pohybu (angl. *deskewing*), ktorej cieľom je kompenzovať rozptyl meraných bodov spôsobený pohybom lidarů počas skenovania a predpovedať aktuálnu pozíciu registrovaných bodov. Namiesto fúzie s kolesovou odometriou či IMU sa v tomto prípade používa model konštantnej rýchlosti, a to práve pre jeho jednoduchosť a nezávislosť od ďalších senzorov či časovej synchronizácie. Model konštantnej rýchlosti predikuje aktuálnu polohu $\mathbf{T}_{pred,t}$ v čase t na základe rozdielu dvoch predošlých polôh definovaných pomocou translačného vektora a rotačnej matice $\mathbf{T}_{t-1} = (\mathbf{R}_{t-1}, \mathbf{t}_{t-1})$, $\mathbf{T}_{t-2} = (\mathbf{R}_{t-2}, \mathbf{t}_{t-2})$, pričom sa predpokladá, že translačná $\mathbf{v}_t$ a rotačná rýchlosť $\boldsymbol{\omega}_t$ sa nemení.

Predikovaná poloha a z toho odvodené rýchlosti sa vypočítajú ako

$$\mathbf{T}_{pred,t} = \begin{bmatrix} \mathbf{R}_{t-2}^\top \mathbf{R}_{t-1} & \mathbf{R}_{t-2}^\top (\mathbf{t}_{t-1} - \mathbf{t}_{t-2}) \\ \mathbf{0} & 1 \end{bmatrix}, \quad (2.19)$$

$$\mathbf{v}_t = \frac{\mathbf{R}_{t-2}^\top (\mathbf{t}_{t-1} - \mathbf{t}_{t-2})}{\Delta t}, \quad (2.20)$$

$$\boldsymbol{\omega}_t = \frac{\text{Log}(\mathbf{R}_{t-2}^\top \mathbf{R}_{t-1})}{\Delta t}, \quad (2.21)$$

kde Δt je čas akvizície lidarového snímku a $\text{Log} : SO(3) \rightarrow \mathbb{R}^3$ extrahuje osovo-uhlovú reprezentáciu rotácie. Ďalej sa predpokladá, že každý zosnímaný bod v jednom skene $\mathbf{p}_i \in \mathcal{P}$ má relatívnu časovú značku v rozmedzí $s_i \in \langle 0, \Delta t \rangle$, predstavujúcu uplynutý

čas od začiatku snímania daného skenu. Korekcia pozície nameraných bodov je potom počítaná ako

$$\mathbf{p}_i^* = \text{Exp}(s_i \boldsymbol{\omega}_t) \mathbf{p}_i + s_i \mathbf{v}_t, \quad (2.22)$$

kde $\text{Exp} : \mathbb{R}^3 \rightarrow SO(3)$ počíta rotačnú maticu z osovo-uhlovej reprezentácie.

Následne prebieha podvzorkovanie skenu pre zefektívnenie registrácie mračien. Mnohé iné prístupy vyhľadávajú význačné body, čo však pridáva ďalšiu vrstvu komplexnosti. KISS-ICP namiesto toho pracuje s dvojkrokovým podvzorkovaním pomocou tvz. *voxelov*, teda trojrozmerných buniek. Kým lokálna mapa je reprezentovaná voxelovou mriežkou s rozlíšením $v \times v \times v$, v prvom kroku je vstupné mračno $\mathcal{P}^*$ podvzorkované na voxely veľkosti αv – čím vzniká mračno $\mathcal{P}_{\text{merge}}^*$ ktoré je neskôr použité na aktualizáciu mapy – a v druhom kroku na voxely veľkosti βv za vzniku mračna $\hat{\mathcal{P}}^*$, ktoré sa použije na registráciu, platí $\alpha \in (0, 1)$ a $\beta \in \langle 1, 2 \rangle$. Na rozdiel od iných metód, v ktorých sa súradnice voxelu určujú ako priemer všetkých bodov, ktoré obsahuje, v tomto prípade sa použijú súradnice prvého bodu spadajúceho pod daný voxel, čím sa zamedzí vzniku diskretizačnej odchýlky, a teda platí $\hat{\mathcal{P}}^* \subseteq \mathcal{P}^*$

Ďalším krokom je určenie korešpondencií. Oproti klasickému ICP, kde sa porovnávajú dva po sebe nasledujúce snímky, KISS-ICP registruje vstupný snímok na celú lokálnu mapu, teda množinu všetkých v minulosti registrovaných bodov. Následne sa voxelová mriežka mapy doplní o novo registrované body s tou podmienkou, že každý voxel má obmedzenú kapacitu, čo opäť cieli na celkovú efektivitu algoritmu. Na nastavenie prahovej hodnoty τ_t pre filtráciu odľahlých bodov sa využíva adaptívny výpočet. Ten zohľadňuje veľkosť zrýchlenia, ktoré spôsobuje nepresnosť predikcie v predchádzajúcich krokoch.

Proces získania globálneho odhadu polohy $\mathbf{T}_t$ začína transformáciou vstupného mračna pomocou predošlej polohy $\mathbf{T}_{t-1}$ a predikcie $\mathbf{T}_{\text{pred},t}$:

$$\mathcal{S} = \{s_i = \mathbf{T}_{t-1} \mathbf{T}_{\text{pred},t} \mathbf{p} \mid \mathbf{p} \in \hat{\mathcal{P}}^*\} \quad (2.23)$$

V každej iterácii j sa získa množina korešpondencií medzi mračnom $\mathcal{S}$ a lokálnou mapou $\mathcal{L} = \{\mathbf{q}_i \mid \mathbf{q}_i \in \mathbb{R}^3\}$ pomocou metódy najbližšieho suseda s prahovou hodnotou τ_t . Odhad korekcie polohy sa potom počíta takto:

$$\Delta \mathbf{T}_{\text{est},j} = \underset{\mathbf{T}}{\text{argmin}} \sum_{(s,q) \in \mathcal{C}(\tau_t)} \rho(\|\mathbf{T} \mathbf{s} - \mathbf{q}\|_2), \quad (2.24)$$

kde $\mathcal{C}(\tau_t)$ je množina korešpondencií najbližších susedov, ktorých vzdialenosť je menšia ako τ_t a ρ je Geman-McClure-ova robustná účelová funkcia. Vstupné body sú potom aktualizované pomocou vypočítanej korekcie, pričom celý postup sa opakuje až kým nie je splnená podmienka konvergenzie, ktorou je $\Delta \mathbf{T}_{\text{est},j} < \gamma$:

$$\{s_i \leftarrow \Delta \mathbf{T}_{\text{est},j} s_i \mid s_i \in \mathcal{S}\} \quad (2.25)$$

Výsledkom je tak transformácia $\mathbf{T}_t = \Delta \mathbf{T}_{icp,t} \mathbf{T}_{t-1} \mathbf{T}_{pred,t}$. Napokon, korekcia je aplikovaná na mračno $\mathcal{P}_{merge}^*$, ktoré je následne integrované do lokálnej mapy.

2.4 Inerčné snímače

Inerčné snímače, resp. snímače zotrvačnosti slúžia na meranie vlastných stavových veličín – lineárnych a uhlových rýchlostí a zrýchlení robota. Nemerajú polohu priamo, ale v kombinácii s inými meraniami polohy môžu prispieť k spresneniu odhadu polohy a korekcii chýb iných meraní. Zaraďujeme tu gyroskopy, akcelerometre a tiež magnetometre.

2.4.1 Gyroskopy

Gyroskopy zaznamenávajú zmeny v natočení objektu, pričom poskytujú informáciu o orientácii, príp. jej zmene vo všetkých osiach. Ich výstupom sú hodnoty vzťahnuté na pevný referenčný rámec. Väčšinou nie sú citlivé na elektromagnetické a feromagnetické anomálie, takže na rozdiel od magnetických kompasov je ich využitie možné aj v prostrediach bez prítomnosti geomagnetického poľa [11].

Gyroskopy je možné podľa technológie merania rozdeliť na mechanické a optické. Podľa typu výstupných dát sa delia na derivačné a integračné. Výstup derivačných gyroskopov je úmerný rotácii. Integračné gyroskopy sú schopné poskytnúť aj informáciu o absolútnej polohe pomocou integrovania relatívnych hodnôt vzťahnutých na globálnu referenciu. Podobne ako u odometrických snímačov, aj v tomto prípade dochádza driftu. Na jeho potlačenie je možné využiť niektorú z techník [11]:

- potlačenie šumu odstránením odľahlých hodnôt,
- potlačenie šumu aplikáciou metódy kľzavého priemeru,
- aplikácia mierky na zmenu absolútnych uhlov,
- recalibrácia gyroskopu vzorkovaním na strednú hodnotu,
- recalibrácia gyroskopu vzorkovaním na minimálnu a maximálnu hodnotu.

Mechanické gyroskopy

Fungujú na princípe zákona zachovania hybnosti, pričom sa delia podľa toho, aký typ hybnosti využívajú [11]:

1. *spojitá uhlová hybnosť* – gyroskopy so zotrvačníkom, čiastkové gyroskopy,
2. *kmitajúca uhlová rýchlosť* – gyroskopy s torznou závesnou hmotou kmitajúcou na vlastnej frekvencii,


3. *spojitá lineárna hybnosť* – gyroskopy so stabilným tokom tekutiny, plazmy alebo elektrónov, ktoré majú tendenciu udržiavať vektor svojej rýchlosti pri otáčaní meracej platformy,
4. *kmitajúca lineárna hybnosť* – gyroskopy používajúce množinu kmitajúcej diskretnéj hmoty, pričom kmity sú vyvolané pozdĺž rovných čiar.

Mechanický gyroskop na báze zotrvačníka pozostáva s rýchlo rotujúceho kotúča alebo gule, ktorej väčšina hmoty je sústredená na vonkajšej periférii, a to pre dosiahnutie vyššieho momentu zotrvačnosti. Rotujúce teleso je upevnené na dvoch na seba kolmých voľne rotujúcich osiach. Rotácia kotúča okolo prvej osi spôsobuje vznik momentu hybnosti L . Pri vzniknutí krútiaceho momentu τ na kolmú os (vplyvom vonkajších síl) dochádza k zmene smeru momentu hybnosti prvej osi


$$d\vec{L} = \vec{\tau} dt. \quad (2.26)$$

Tejto jav sa nazýva *precesia gyroskopu* [26]. Na obr. 3a je bez straty na všeobecnosti znázornená situácia s klasickým zotrvačníkom, v ktorej je moment τ spôsobený tiažovým zrýchlením. Zo vzťahu 2.26 je možné následne odvodiť, že veľkosť precesie ω_P je priamo úmerná krútiacemu momentu τ [11]:

$$\tau = J\omega\Omega, \quad (2.27)$$



(a) Precesia gyroskopu so znázornením všetkých pôsobiacich síl a momentov [26]



(b) Dvojosý mechanický gyroskop so zotrvačníkom [11]

Obr. 3: Gyroskop – ilustrácia

kde J je moment zotrvačnosti rotačného objektu a ω je jeho uhlová rýchlosť, pričom platí $\omega_P \ll \omega$ [26]. Typický príklad mechanického dvojsového gyroskopu je na obr. 3b.

Zvyškové trenie v ložiskách gyroskopu, vonkajšie vplyvy a malé nerovnováhy v konštrukcii spôsobujú malú odchýlku v zmysle dlhotrvajúcej stability, ktorá sa u vysoko-kvalitných produktov pohybuje na úrovni okolo $0,1^\circ$ za 6 hodín prevádzky [11].

Derivačné mechanické gyroskopy

Fungujú na princípe mechanickej ladičky, ktorej vidlice vibrujú k sebe a od seba s pevnou amplitúdou. Takýto snímač pozostáva z páru vidlíc – riadenej a snímacej. Rotácia okolo vertikálnej (torznej) osi vyvoláva vznik Coriolisových síl, pričom na každú z vidlíc pôsobí sila


$$F = 2m\Omega v_r, \quad (2.28)$$

kde F je Coriolisova sila pôsobiaca na vidlicu, m je hmotnosť vidlice, Ω je vstupná rýchlosť otáčania a v_r je okamžitá uhlová rýchlosť vidlice. Coriolisove sily generujú rotačný moment, ktorý je priamo úmerný vstupnej uhlovej rýchlosti a spôsobuje kmitanie snímacej vidlice, ktorá tak generuje signál [11]. Schematický náčrt takéhoto typu gyroskopu sa nachádza na obr. 4.

Optické gyroskopy

Uhlová rýchlosť je snímaná pomocou dvoch monochromatických svetelných lúčov, ktoré sú vysielané z rovnakého zdroja do opačného smeru v uzavretom kruhovom optickom vlákne. Lúče vytvárajú vo vnútri vlákna stojaté vlnenie s kmitňami a uzlami. Teoreticky by mal detektor s každou otočkou laserového kruhu zaznamenať počet uzlov rovný dvojnásobku dráhy lúčov vydeleného ich vlnovou dĺžkou. V skutočnosti však dosiahnutie takéhoto riešenia nie je možné kvôli vplyvu konštrukčných nedokonalostí [11].

Optické gyroskopy sa používajú v nasledujúcich základných konfiguráciách [11]:



Obr. 4: Principiálna schéma gyroskopu Syston Donner GyroChip [11]

- *Aktívne optické rezonátory* – využívajú tzv. Sagnacov efekt. Laserové lúče sú vysielané oproti sebe v cyklickej dráhe. Pri rotácii dochádza k predĺženiu dráhy jedného lúča a skráteniu dráhy druhého. Rozdiel je priamoúmerný rotačnej rýchlosti. Ich nevýhodou je jav uzamknutia frekvencie pri nízkych rýchlostiach, ktorí súvisí s periodickou moduláciou lasera v spojení s malým množstvom odrazov na reflexných plochách. Výsledkom je pásmo necitlivosti.
- *Pasívne optické rezonátory* – používajú externý laser, čo zabraňuje vzniku uzamknutia frekvencie. Klasické implementácie používajú zrkadlové optické rezonátory. V porovnaní s aktívnymi majú menšie rozmery, vyššiu citlivosť aj robustnosť a nižšiu cenu.
- *Neradené interferometrické gyroskopy z optických vlákien (analog)* – vďaka využitiu optických vlákien je možné zmenšenie rozmerov a predĺženie dráhy lúčov, z čoho vyplýva zvýšenie rozlíšenia a znížené výrobné náklady. Medzi výhody tiež patrí vysoká tolerancia na vibrácie a otrasy, necitlivosť na gravitačné efekty, rýchly štart a dobrá citlivosť. Nevýhodami sú veľká dĺžka optického vlákna, obmedzený dynamický rozsah a odchýlky kvôli použitým analógovým komponentom. Používajú sa zväčša v jednoduchších aplikáciách vyžadujúcich strednú presnosť.
- *Riadené interferometrické gyroskopy z optických vlákien (digitál)* – citlivý prvok merajúci fázový posun nevyužíva Sagnacov efekt, ale pracujú s fázovým posunom lúčov $\Delta\phi = 0$. Ich výhodou je veľká presnosť, nezávislosť od intenzity svetla vysielaného v gyroskope, nezávislosť od zosilnení jednotlivých komponentov gyroskopu a lineárnosť a stabilita závislá len od nerecipročného fázového vysieláča. Drift tohto typu gyroskopov sa pohybuje v rozmedzí 0,0001–0,01°/hod.
- *Rezonančné gyroskopy s optickými vláknami* – princíp ich činnosti bol odvodený od pasívnych optických rezonátorov. Výhodami sú vysoká spoľahlivosť, dlhá životnosť, rýchly štart a malá hmotnosť. Nevýhodou je nutnosť použitia vysoko koherentného zdroja svetla a extrémne bezstratových komponentov optického vlákna.


2.4.2 Akcelerometre

Zrýchlenie je vektorová fyzikálna veličina popisujúca zmenu vektoru rýchlosti – jeho veľkosti alebo smeru. Z Newtonových pohybových zákonov je známe, že teleso mení rýchlosť len keď na neho pôsobí sila (I. zákon) a táto sila spôsobuje jej úmerné zrýchlenie (II. zákon). Akcelerometre sú snímače vyvinuté na zaznamenanie síl na nich pôsobiacich, teda výstupom z nich je signál priamo úmerný akcelerácii.

Na zaznamenanie rôznych fyzikálnych síl sa v akcelerometroch využívajú rôzne citlivé elementy. Podľa toho sa akcelerometre delia na[11]:

- *mechanické* – (obr. 5a) merajú zrýchlenie pomocou pružiny, pričom využívajú Newtonov druhý pohybový zákon a Hookov zákon opisujúci tuhosť pružiny. Zrýchlenie spôsobuje deformáciu pružiny, ktorá je úmerná zrýchleniu;
- *piezoelektrické* – (obr. 5b) využívajú piezoelektrický efekt – pri deformácii keramického kryštálu sa pôsobením zrýchlenia generuje elektrický náboj, ktorý je úmerný sile. Pracujú najlepšie v stredných a vysokých frekvenciách;
- *piezorezistívne* – sú založené na zmene elektrického odporu pri mechanickom namáhaní piezorezistívneho materiálu. Umožňujú merať aj konštantné zrýchlenie (0 Hz), čo ich odlišuje od piezoelektrického typu;
- *tepelné* – (obr. 5c) merajú zrýchlenie na základe zmien rozloženia teploty v plyne ohrievanom výhrevným telesom. Neobsahujú pohyblivé časti a sú veľmi odolné, ale citlivé na zmeny okolitej teploty;
- *elektromechanické* – obsahujú pohyblivý mechanický prvok spojený s elektrickou časťou (napr. kondenzátorom). Zrýchlenie spôsobuje pohyb prvku, čo vedie k zmene elektrickej veličiny – najčastejšie kapacity.

Akcelerometre sú schopné zaznamenať zrýchlenie len v jednej osi. Pre meranie trojrozmerného zrýchlenia sa používajú systémy zložené z kombinácie troch vzájomne kolmých akcelerometrov. Ich najväčšou nevýhodou je vysoká citlivosť na vibrácie mechanických častí robota ako aj na rôzne parazitné zrýchlenia. Tento problém sa obvykle rieši zvýšením pomeru dĺžky citlivého elementu k jeho šírke v požadovanom smere [11].



Obr. 5: Štruktúra a princíp merania rôznych typov akcelerometrov [11]

2.4.3 Magnetometre

Magnetometre (magnetické kompas) sú prístroje, ktoré sú schopné zaznamenať magnetické pole Zeme. Na základe ich meraní je možné stanoviť orientáciu robota. Magnetické kompasy využívané v mobilnej robotike sa delia na [11]:

- *mechanické magnetické kompas* – tradičné kompas s otočným diskom v kvapaline, často upevnené na guľovom závесе na kompenzáciu pohybu. Okolité magnetické anomálie sa potláčajú pomocou nastaviteľných permanentných magnetov. Sú náchylné na odchýlky z externých zdrojov.
- *kompas s magnetickou indukčnou sondou* – používajú dvojicu navzájom kolmých cievok s feritovým jadrom. Merajú horizontálnu zložku magnetického poľa pomocou sínusových výstupov. Ich výhodou je nízka spotreba, odolnosť voči otrasom a rýchly štart. Nevýhodou je citlivosť na magnetické anomálie, ktorú možno potlačiť spojením s gyroskopom.
- *magneticko-indukčné kompas* – využívajú solenoid ako súčasť L/R oscilátora, kde frekvencia závisí od indukcie ovplyvnenej magnetickým poľom. Elektronika je jednoduchšia a spotreba energie nižšia ako pri kompasoch na báze magnetickej indukčnej sondy. Výstup má digitálny charakter.
- *kompas na báze Hallovho efektu* – merajú rozdiely napätí v polovodiči so stálym prúdom pri prítomnosti magnetického poľa. Dvojica kolmých senzorov umožňuje výpočet uhla natočenia. Sú lacné, ale s nízkym rozlíšením a silným vplyvom vnútorných chýb, čo vyžaduje filtrovanie a znižuje šírku pásma.
- *magneticko-rezistívne kompas* – Využívajú zmenu odporu anizotropného materiálu pri zmene smeru magnetizácie. Umožňujú veľmi citlivé meranie natočenia, sú vhodnú najmä pre aplikácie vyžadujúce vysokú presnosť.
- *magneticko-elastické kompas* – sú založené na zmene Youngovho modulu magneticko-striktívnych materiálov pri pôsobení magnetického poľa. Meranie je založené na detekcii deformácie materiálu vyžaduje zliatiny s vysokou magnetostrikciou.

2.4.4 IMU

Inerčná meracia jednotka (niekedy nazývaná aj inerčná referenčná jednotka alebo pohybová referenčná jednotka, skr. IMU, alebo tiež inerčný navigačný systém, skr. INS) je zväčša elektromechanické alebo polovodičové zariadenie, ktoré obsahuje kombináciu viacerých senzorov (zvyčajne akcelerometrov a gyroskopov, ale tiež magnetometrov

a tlakových senzorov) schopných merať pohyb, teda lineárne a uhlové zrýchlenia, uhlové rýchlosti, príp. aj orientáciu, a to vo všetkých troch osiach. Je schopná zaznamenať zotrvačné sily a transformovať ich na výstupné údaje, ktoré opisujú pohyb objektu [20].

Najpoužívanejšou konštrukčnou technológiou pre IMU je MEMS. Sú to miniatúrne zariadenia s veľkosťou rádovo v mikrometroch, ktoré sú tvorené kombináciou elektrických a mechanických prvkov tvorených z rôznych materiálov (napr. kremík, polyméry, kov). Existujú rôzne typy MEMS komponentov, od jednoduchých prepínačov až po mimoriadne zložené elektromechanické systémy s viacerými integrovanými snímačmi a mikroelektronikou [20].

Výhody použitia MEMS technológie spočívajú najmä v mimoriadne malej veľkosti a hmotnosti komponentov v kombinácii s nízkou spotrebou energie. Vďaka tomu je možné takéto snímače umiestniť na malých plošných spojoch do kompaktných puzdier a sú vhodné na umiestnenie v mobilných robotoch, ktoré majú obvykle značné priestorové aj napájacie obmedzenia. Jednotlivé komponenty, materiály a konštrukčné techniky zabezpečujú vysokú spoľahlivosť a dlhú životnosť, pričom tieto parametre sú stále predmetom neustáleho zdokonaľovania sa [20].

Na druhú stranu, pre správnu interpretáciu výstupných dát z IMU je potrebné ďalšie spracovanie, a to za účelom odstránenia tiažového zrýchlenia a tiež filtrácie šumu meraní, ktorý pri vysokej citlivosti snímačov môže spôsobiť vznik drift odhadu polohy. Vzhľadom na vysokú mieru šumu meraní sa IMU senzory väčšinou nepoužívajú samostatne, ale vo fúzii s inými senzormi. Vďaka skutočnosti, že meria reálne fyzikálne veličiny na základe priameho vplyvu zotrvačných síl, údaje z nej sú nápomocné v kombinácii so snímačmi, ktoré merajú polohu na základe rôznych metód odhadu (kamera, lidar, GPS, a i.) a u ktorých zvykne dochádzať napríklad ku skokovým zmenám odhadu, ktoré fyzikálne nie sú možné. Algoritmy, ktoré sa zaoberajú fúziou dát z viacerých snímačov budeme bližšie rozoberať v ďalších častiach práce.

Open GINS

3 Externé lokalizačné systémy

3.1 GNSS systémy

Globálne navigačné satelitné systémy (GNSS) sú systémy slúžiace na určenie polohy, rýchlosti a času [11]. Pozostávajú zo zoskupení satelitov, ktoré neustále vysielajú informáciu o svojej polohe a čase, zo siete pozemných staníc a z prijímačov, ktoré vypočítavajú polohu na zemi pomocou trilaterácie. Používajú sa vo všetkých formách dopravy: na vesmírnych staniciach, v letectve, námornej doprave, železničnej doprave, cestnej doprave a hromadnej doprave [16].

V súčasnosti existuje niekoľko globálnych systémov [43]:

- GPS (Spojené štáty americké),
- GLONASS (Ruská federácia),
- GALILEO (Európska Únia),
- COMPASS/Bei-Dou (Čína).

Okrem nich sú v priebežnom vývoji aj ďalšie regionálne systémy, ako napríklad indický IRNSS a japonský QZSS. V momente dokončenia všetkých týchto systémov bude pre užívateľov k dispozícii dokopy viac než sto satelitov. Jednou z najaktuálnejších tém v rámci oblasti GNSS je zabezpečenie interoperability medzi globálnymi systémami, čo by umožnilo užívateľom prijímať a spracúvať signál z viacerých satelitných systémov pomocou jedného zariadenia [16].

Výkonnosť GNSS sa hodnotí podľa štyroch kritérií [43]:

1. *presnosť* – rozdiel medzi nameranou a skutočnou polohou, rýchlosťou alebo časom prijímača,
2. *integrita* – schopnosť systému poskytnúť určenú mieru spoľahlivosti a v prípade poruchy v údajoch o polohe vydať varovanie,
3. *kontinuita* – schopnosť systému fungovať bez prerušenia,
4. *dostupnosť* – percentuálny podiel času, počas ktorého signál spĺňa uvedené kritériá presnosti, integrity a kontinuity.

Túto výkonnosť je možné zlepšiť pomocou regionálnych satelitných augmentačných systémov (SBAS). Ich kombinácia s overenými pozemnými technológiami, ako je inerciálna navigácia, prináša možnosti novým aplikáciám, ktoré nevyžadujú len presnosť, ale predovšetkým spoľahlivosť a integritu.

Medzi hlavné výhody GNSS patria vysoká presnosť, údaje v jednotnom svetovom súradnicovom systéme WGS a nezávislosť na počasi či fáze dňa. Nevýhodami sú nemožnosť využitia v podzemí, vo vode aj v interiéroch s hrubými či početnými stenami, horšia presnosť v prostrediach s menšou viditeľnosťou na oblohu (napr. oblasti husto zastavané vysokými budovami, lesy, údolia) či možnosť rušenia signálu externým zdrojom [11].

3.1.1 Princíp činnosti

Princíp určovania polohy pomocou GNSS spočíva v meraní času letu rádiového signálu z družíc. Každý satelit vysiela svoje identifikačné údaje, polohu a časovú značku. Prijímač vypočíta odhad vzdialenosti družice na základe rozdielu medzi časom vyslania a prijatia signálu. Polohu meraného bodu je možné určiť vyhodnotením takéhoto signálu z viacerých satelitov. Z geometrického hľadiska by na určenie trojrozmernej polohy mal stačiť prienik vzdialeností troch družíc. Keďže ale nie je možné zaručiť presnú synchronizáciu hodín prijímača, je potrebný údaj z ešte aspoň jedného satelitu, čím vznikne viacero bodov prieniku. Čas prijímača je následne posúvaný tak, aby tieto body splynuli do jediného, čím vzniká výsledné meranie polohy. Pre dosiahnutie vyššej presnosti potrebné poznať polohy čo najväčšieho počtu vhodne rozložených družíc [11].

3.1.2 Chyby GPS

Merania GPS sú sprevádzané niekoľkými typmi chýb [11]:

- *Geometria rozloženia satelitov* – pokiaľ aktuálne viditeľné satelity nie sú rovnomerne rozložené po celej oblohe, môže dôjsť k nepresnej triangulácii, a teda aj k chybe odhadu polohy. Viditeľnosť satelitov negatívne ovplyvňuje aj meranie vnútri vozidla, v blízkosti vysokých budov či v členitom teréne. Tento typ chyby vyjadruje parameter zníženia presnosti (DOP).
- *Atmosférické efekty* – zemská atmosféra ovplyvňuje GPS signály dvomi hlavnými vrstvami: troposférou a ionosférou. Troposféra ako elektricky neutrálne prostredie spôsobuje nedisperzné odchýlky závislé od teploty, tlaku a vlhkosti, ktoré rovnomerne postihujú fázové aj kódové GPS merania. Ionosféra je elektricky aktívna vrstva s voľnými elektrónmi a iónmi, kde dochádza k odrazu a útlmu rádiových vln, najmä v dôsledku interakcie s neutrálnymi molekulami. Jej účinky závisia od slnečnej aktivity a polohy v atmosfére a spôsobujú spomalenie elektromagnetických vln úmerné k prevrátenej hodnote kvadrátu ich frekvencie. Vplyv ionosféry možno čiastočne eliminovať porovnaním signálov na rôznych frekvenciách, čo využívajú napríklad vojenské GPS prijímače pracujúce.

- *Efekt viaccestného šírenia sa signálu (angl. multipath)* – nastáva, keď sa GPS signál odrazí od objektov v okolí prijímača a dorazí k nemu oneskorene. Tieto odrazené signály predlžujú dráhu, ktorú signál prejde, čo vedie k chybám v určení polohy – typicky v rozsahu niekoľkých metrov. GPS satelity vysielajú signál v širokom kuželi, takže odrazy sú bežné najmä v mestskom alebo členitom prostredí. Na zníženie tohto efektu sa používajú antény so špeciálnou konštrukciou (napr. s ochranným tanierom), pokročilé technológie v prijímači a efektívne metódy spracovania signálu. Tieto opatrenia znižujú príjem odrazených signálov, čím zlepšujú presnosť určenia polohy.
- *Relativistické efekty* – zohrávajú významnú úlohu pri určovaní polohy pomocou GPS, najmä kvôli veľkej rýchlosti a výške družíc. Zmeny frekvencie signálu v dôsledku rýchlosti pohybu družíc (Dopplerov jav) a rozdiely v priebehu času spôsobené gravitáciou (dilatácia času) ovplyvňujú presnosť meraní. Tieto efekty sú dôsledkom špeciálnej aj všeobecnej teórie relativity a musia byť zahrnuté do výpočtov polohy. Bez ich korekcie by chyba v určovaní času spôsobila výrazné chyby v polohe, až rádovo kilometre denne. Preto sú súčasťou rovníc používaných v GPS prijímačoch aj korekcie na relativistické poruchy dráh družíc a šírenia signálu.
- *Ďalšie chyby GPS*
 - nepresnosť hodín v GPS prijímači (prijímač nemôže obsahovať atómové hodiny, odstránenie chyby sa rieši použitím signálu z viacerých satelitov),
 - nepresné určenie parametrov dráhy družice (tzv. ephemeris error),
 - počet viditeľných satelitov (pre väčšiu presnosť merania je potrebné mať väčší počet viditeľných satelitov).

3.1.3 Augmentačné systémy

Spomenuté chyby GPS meraní je možné v rôznej miere potlačiť pomocou systémov so zvýšenou presnosťou. Tie bývajú častou voľbou aj v prípade mnohých robotických aplikácií, pre potreby ktorých je presnosť meraní pomocou GNSS nedostatočná [11].

Inertial Navigation System (INS)

Pridaním INS ku GPS je možné dosiahnuť presnosť v rozsahu približne jedného metra. Výstup z oboch systémov býva porovnávaný obvykle pomocou Kalmanovho filtra, ktorý poskytuje najviac pravdepodobné meranie;

Differential GPS (DGPS)

Potrebné sú dva GPS prijímače, z ktorých jeden sa nachádza na geodeticky vymeranej polohe. Využíva sa skutočnosť, že blízke prijímače majú vysokú koreláciu chýb. Referenčná stanica vypočítava a vysiela korekcie na základe rozdielov medzi očakávanými a nameranými údajmi zo všetkých viditeľných družíc. V prijímači užívateľa DGPS je korekčný údaj využitý na opravu merania. Použitím DGPS môže užívateľ získať presnosť určovania polohy v reálnom čase na úrovni desiatok centimetrov až metrov, v závislosti od vzdialenosti od referenčnej stanice.

Real-Time Kinematic (RTK) GPS

RTK je vysoko presná technológia pre lokalizáciu a navigáciu, využívaná v širokom spektre aplikácií od prieskumu a mapovania, cez poľnohospodárstvo až po stavebníctvo. Funguje, podobne než DGPS, na kombinácii referenčnej stanice a užívateľského prijímača. Na rozdiel od DGPS však referenčná stanica uskutočňuje aj meranie nosnej fázy signálu. Prijímač potom odlišnosti v nosnej fáze vyhodnocuje, čo dramaticky zvyšuje presnosť merania polohy [34].

Wide Area Augmentation System (WAAS)

Systém WAAS poskytuje extrémne vysokú presnosť lokalizácie, využiteľnú najmä v leteckej doprave. Pozostáva z 38 referenčných staníc (WRS), 3 hlavných staníc (WMS), 3 geostacionárnych družíc a 6 pozemných vysielačích staníc. Referenčné stanice slúžia na prijímanie signálu GPS. Ich polohy sú zvolené tak, aby bolo možné zachytiť akékoľvek chyby v signáloch GPS. Informácie z WRS sa posielajú do WMS, ktoré vysielaajú správy pre užívateľov s frekvenciou 1 Hz. Tieto správy umožňujú významnú korekciu GPS meraní na strane užívateľa. WMS vysiela správy aj na pozemné vysielačie stanice, odkiaľ sú prenášané k navigačným zariadeniam na geostacionárnych komunikačných satelitoch. Tie následne vysielaajú signál podobný GPS, ktorý môžu prijímače využiť spolu s korekčnými údajmi na spresnenie lokalizácie. Systém WAAS je dostupný v rámci NAS [38]. V Európe funguje na podobnom princípe systém **EGNOS** [12].

3.2 UWB systémy

Ultra-širokopásmové (UWB) systémy predstavujú modernú bezdrôtovú technológiu využívajúcu veľmi krátke rádiové impulzy (rádovo v nanosekundách) v širokom frekvenčnom pásme (typicky 3,1 – 10,6 GHz) s nízkou spektrálnou hustotou výkonu, vďaka čomu má malú spotrebu energie. Je schopná prenášať dáta vysokou rýchlosťou (do 100 Mb/s) na krátku vzdialenosť. Používanie krátkych impulzných vĺn namiesto kontinuálneho šírenia signálu znižuje riziko vzniku „multipath“ efektu (spomínaného v časti 3.1.2) a zjednodušuje určenie času príchodu signálu (TOA) pri dávkovom prenose dát medzi

vysielačom a prijímačom, čo dáva UWB výhodu vo vnútornom prostredí oproti iným technológiám. Navyše, nízka frekvencia pulzov umožňuje prienik signálu cez iné objekty alebo steny. Vďaka tomu je technológia UWB okrem iných využití vhodná aj pre lokalizáciu a sledovanie objektov, a to zvlášť vo vnútornom prostredí, kde iné technológie zlyhávajú kvôli potrebe priamej viditeľnosti alebo vysokému rušeniu. Odchýlka UWB lokalizácie sa pohybuje rádovo v jednotkách centimetrov a jej dosah je približne 30 – 50 m. [1].

Systémy UWB lokalizácie tvoria dva základné prvky: kotvy (z angl. anchors) a značky (z angl. tags). Anchory sú vo väčšine topológií využívané ako prijímače signálov vysielaných tagmi, na základe ktorých určujú vzdialenosť (príp. uhol) medzi daným anchorom a tagom. Túto informáciu odosielaajú do výpočtového systému, kde sa na základe informácií z viacerých anchorov a ich známych polôh vypočíta poloha sledovaného objektu. Na pokrytie prostredia sa používajú viaceré anchory v rôznych typoch rozložení v závislosti od použitej metódy lokalizácie [31].

3.2.1 Modulácia signálu

Nakoľko prenos UWB signálov prebieha zvyčajne v prostredí, kde sa vyskytujú aj iné typy signálov, kľúčovou zložkou technológie je *modulácia signálu*. Je to proces, ktorým sa na impulzný signál (nosnú vlnu) prenáša informácia zmenou jednej alebo viacerých jeho vlastností. V UWB systémoch zohráva modulácia zásadnú úlohu nielen pri prenose dát, ale aj pri samotnej lokalizácii, pretože ovplyvňuje schopnosť presne identifikovať impulzy aj v prítomnosti šumu, rušenia či odrazených signálov. Pre tento prípad sa využívajú viaceré variácie modulácie signálov, ktoré môžeme kategorizovať nasledovne [1]:

1. Podľa počtu stavov signálu

- *Binárna modulácia* – dva možné stavy signálu (napr. logická 0 a 1),
- *Ternárna modulácia* – tri úrovne (napr. záporná, nulová a kladná amplitúda),
- *M-árna modulácia* – viacero stavov (napr. 4-PSK, 8-PPM);

2. Podľa modifikovanej vlastnosti signálu

- Základné:
 - *Amplitúdová (PAM)* – mení sa amplitúda impulzu,
 - *Frekvenčná* – zriedkavá pri UWB,
 - *Fázová (PSK)* – mení sa fáza impulzu,
 - *Šírková (PWM)* – mení sa dĺžka impulzu,
 - *Časová (PPM)* – mení sa poloha impulzu v časovom okne,

- Rozšírené:
 - *Binárne fázové kódovanie (BPSK)* – impulz mení fázu o 180° ; vhodná pri vyšších dátových prenosoch a odolná voči šumu,
 - „*On-Off*“ *kódovanie (OOK)* – informácia sa kóduje prítomnosťou alebo neprítomnosťou impulzu; jednoduchá, no citlivá na šum,
 - *Skoky času (TH-PPM/TH-BPSK)* – impulzy sa vysielajú v náhodne vybraných časových oknách podľa kľúča, čo zvyšuje odolnosť voči rušeniu a umožňuje viacerým zariadeniam zdieľať pásmo.

Správna voľba modulácie je dôležitá pre presnosť lokalizácie, robustnosť voči viaccestnému šíreniu, energetickú efektivitu vysielача, ale aj výpočtovú náročnosť prijímača.

3.2.2 Metódy UWB lokalizácie

Za účelom získania informácií o polohe objektu z rádiových signálov bolo vyvinutých viacero algoritmov, ktoré je možné principiálne rozdeliť do nasledujúcich kategórií [1]:

1. *Čas príchodu signálu (TOA)* – meria sa čas šírenia signálu medzi vysielateľom a prijímačom. Na základe známej rýchlosti šírenia signálu (pre rádiové vlny je to rýchlosť svetla) je možné priamo vypočítať vzdialenosť. Výsledná poloha sa odhaduje ako priesečník kružníc so stredmi v jednotlivých anchoroch a polomerami určenými odhadom vzdialenosti (podobne ako pri GNSS);
2. *Uhol príchodu signálu (AOA)* – vyžaduje informáciu o uhle príchodu signálu od minimálne dvoch, optimálne aspoň troch prijímačov; poloha objektu je určená prienikom uhlových priamok. Je citlivý na rôzne faktory spôsobujúce odchýlku, zásadný vplyv na presnosť má aj vzdialenosť objektu od antény. Je navyše zložitejší než iné algoritmy;
3. *Intenzita prijatého signálu (RSS)* – odvodzuje vzdialenosť na základe útlmu signálu. Hoci je implementačne jednoduchá, trpí vysokou neistotou v prostredí s odrazmi, čím je menej vhodná pre UWB;
4. *Časový rozdiel príchodzieho signálu (TDOA)* – využíva sa rozdiel časov príchodu signálu do viacerých anchorov. Prijímače musia byť navzájom zosynchronizované. Výsledná poloha sa odhaduje ako priesečník hyperbol, čo umožňuje získať polohu bez potreby synchronizácie mobilného uzla;
5. *Hybridné algoritmy* – Kombinujú viacero vyššie uvedených prístupov (napr. TDOA+AOA) s cieľom zlepšiť presnosť a robustnosť voči rušeniu a „multipath“ efektom.

Technológia UWB je sprevádzaná aj viacerými nevýhodami a výzvami. Nakoľko je frekvenčné pásmo zdieľané aj s inými bezdrôtovými technológiami (napr. WiMAX, 3G), môže dochádzať k rušeniu signálu. V prípade lokalizácie viacerých objektov môže taktiež dochádzať k problémom s prístupom na kanál. Spracovanie impulzov z tagov si vyžaduje komplexný hardvér a pre presnú lokalizáciu je potrebná presná časová synchronizácia zariadení. Na korekciu chýb spôsobených nedostatočnou synchronizáciou sa používajú rôzne filtračné a optimalizačné metódy a algoritmy, napr. metóda najmenších štvorcov, Kalmanove filtre či časticové filtre [31].

3.3 Systémy na snímanie pohybu

Systémy na snímanie pohybu (MoCap) boli vyvinuté na zaznamenávanie pohybu objektov alebo ľudí, pôvodne za účelom analýzy chôdze [15]. Technológia sa však postupne rozšírila aj do ďalších oblastí vrátane robotiky.

Najpoužívanejšími prístupmi k MoCap v posledných rokoch sú [15]:

1. *opticko-pasívny* – najpraktickejší a najpoužívanejší spôsob v súčasnosti; sledovaný objekt je označený retroreflexnými značkami (markermi), ktoré sú zaznamenávané viacerými infračervenými kamerami. Každý marker musí byť zachytený viacerými kamerami, jeho polohu je potom možné určiť trianguláciou s chybou pod 1 mm;
2. *opticko-aktívny* – sledovaný objekt je označený infračervenými LED diódami, ktoré sú snímané infračervenými kamerami. Princíp určovania polohy je rovnaký ako v predošlom prípade, hlavná nevýhoda však spočíva v nutnosti napájania aktívnych markerov;
3. *video* – každá snímka je spracúvaná softvérom na detekciu objektov. Dosahuje menšiu presnosť než riešenia využívajúce markery;
4. *inerciálny* – je nezávislý od kamier, využíva inerčné snímače. Slabou stránkou je krátkodobá presnosť.

Súčasným lídrom v oblasti MoCap je opticko-pasívny systém OptiTrack. Predstavuje jedno z najmodernejších riešení lokalizácie objektov, vyznačujúce sa nízkou latenciou, vysokou presnosťou, relatívne jednoduchým používaním a schopnosťou zaznamenať všetkých 6 stupňov voľnosti (DoF) ako u pozemných (AGV), tak u lietajúcich (UAV) autonómnych vozidiel [27]. Často sa využíva na validáciu počítačového videnia či ako referencia pre iné metódy lokalizácie. Praktický je hlavne vo vnútorných laboratórnych podmienkach [15]. Medzi jeho hlavné nevýhody patrí potreba priamej viditeľnosti medzi kamerami a značkami, výrazný pokles presnosti mimo optimálnej oblasti, vysoké náklady, inštalačná náročnosť a tiež nevhodnosť použitia v exteriéri.

Literatúra

1. ALARIFI, A. et al. Ultra Wideband Indoor Positioning Technologies: Analysis and Recent Advances. *Sensors* [online]. 2016, **16**(5), 707 [cit. 2025-07-01]. ISSN 1424-8220. Dostupné z DOI: 10.3390/s16050707.
2. ALENCASTRE-MIRANDA, M.; MUNOZ-GOMEZ, L.; MURRIETA-CID, R.; MONROY, R. Local Reference Frames vs. Global Reference Frame for Mobile Robot Localization and Path Planning. In: 2006, s. 309–318. Proceedings - Fifth Mexican International Conference on Artificial Intelligence, MICAI 2006. Dostupné z DOI: 10.1109/MICAI.2006.27.
3. AQEL, M. O. A.; MARHABAN, M. H.; SARIPAN, M. I.; ISMAIL, N. B. Review of Visual Odometry: Types, Approaches, Challenges, and Applications. *SpringerPlus* [online]. 2016, **5**(1), 1897 [cit. 2025-07-02]. ISSN 2193-1801. Dostupné z DOI: 10.1186/s40064-016-3573-7.
4. BAI, H. ICP Algorithm: Theory, Practice And Its SLAM-oriented Taxonomy. *Applied and Computational Engineering* [online]. 2023, **2**(1), 451–462 [cit. 2025-07-27]. ISSN 2755-2721, ISSN 2755-273X. Dostupné z DOI: 10.54254/2755-2721/2/20220512. Comment: Accepted by CONF-CDS'22.
5. BAI, C. et al. Faster-LIO: Lightweight Tightly Coupled Lidar-Inertial Odometry Using Parallel Sparse Incremental Voxels. *IEEE Robotics and Automation Letters* [online]. 2022, **7**(2), 4861–4868 [cit. 2025-07-03]. ISSN 2377-3766. Dostupné z DOI: 10.1109/LRA.2022.3152830.
6. BAY, H.; TUYTELAARS, T.; VAN GOOL, L. SURF: Speeded Up Robust Features. In: LEONARDIS, A.; BISCHOF, H.; PINZ, A. (eds.). *Computer Vision – ECCV 2006*. Berlin, Heidelberg: Springer, 2006, s. 404–417. ISBN 978-3-540-33833-8. Dostupné z DOI: 10.1007/11744023_32.
7. BESL, P.; MCKAY, N. D. A Method for Registration of 3-D Shapes. *IEEE Transactions on Pattern Analysis and Machine Intelligence* [online]. 1992, **14**(2), 239–256 [cit. 2025-07-27]. ISSN 1939-3539. Dostupné z DOI: 10.1109/34.121791.
8. CAI, Y.; XU, W.; ZHANG, F. *Ikd-Tree: An Incremental K-D Tree for Robotic Applications* [online]. 2021-02-22. [cit. 2025-07-03]. Dostupné z DOI: 10.48550/arXiv.2102.10808.

9. CALONDER, M.; LEPETIT, V.; STRECHA, C.; FUA, P. BRIEF: Binary Robust Independent Elementary Features. In: DANIILIDIS, K.; MARAGOS, P.; PARAGIOS, N. (eds.). *Computer Vision – ECCV 2010*. Berlin, Heidelberg: Springer, 2010, s. 778–792. ISBN 978-3-642-15561-1. Dostupné z DOI: 10.1007/978-3-642-15561-1_56.
10. *Camera Calibration and 3D Reconstruction — OpenCV 2.4.13.7 Documentation* [online]. [cit. 2025-07-26]. Dostupné z: https://docs.opencv.org/2.4/modules/calib3d/doc/camera_calibration_and_3d_reconstruction.html.
11. DUCHOŇ, F. *Snímače v mobilnej robotike*. 1. vyd. Bratislava: Nakladateľstvo STU, 2012. ISBN 978-80-227-3801-9.
12. *EGNOS* [online]. EU Agency for the Space Programme. [cit. 2025-06-26]. Dostupné z: <https://www.euspa.europa.eu/eu-space-programme/egnoss>.
13. FERREIRA, J.; VALE, A.; VENTURA, R. Vehicle Localization System Using Offboard Range Sensor Network. *IFAC Proceedings Volumes* [online]. 2013, **46**(10), 102–107 [cit. 2025-06-29]. ISSN 1474-6670. Dostupné z DOI: 10.3182/20130626-3-AU-2035.00032.
14. FISCHLER, M. A.; BOLLES, R. C. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. *Commun. ACM* [online]. 1981, **24**(6), 381–395 [cit. 2025-07-26]. ISSN 0001-0782. Dostupné z DOI: 10.1145/358669.358692.
15. FURTADO, J.; LIU, H.; LAI, G.; LACHERAY, H.; DESOUSA-COELHO, J. Comparative Analysis Of Optitrack Motion Capture Systems [online]. 0018 [cit. 2025-06-29]. ISSN 978-1-77355-023-7. Dostupné z HDL: 10315/35247.
16. *GNSS* [online]. United Nations Office for Outer Space Affairs. [cit. 2025-06-26]. Dostupné z: <https://www.unoosa.org/oosa/de/ourwork/psa/gnss/gnss.html>.
17. HARRIS, C.; STEPHENS, M. A Combined Corner and Edge Detector. In: Manchester, UK, 1988, s. 147–151.
18. CHIEN, H.-J.; CHUANG, C.-C.; CHEN, C.-Y.; KLETTE, R. When to Use What Feature? SIFT, SURF, ORB, or A-KAZE Features for Monocular Visual Odometry. In: *2016 International Conference on Image and Vision Computing New Zealand (IVCNZ)* [online]. 2016, s. 1–6 [cit. 2025-07-25]. ISSN 2151-2205. Dostupné z DOI: 10.1109/IVCNZ.2016.7804434.

19. CHRISTENSEN, H. I.; HAGER, G. D. Sensing and Estimation. In: SICILIANO, B.; KHATIB, O. (eds.). *Springer Handbook of Robotics* [online]. 2nd ed. Cham: Springer International Publishing, 2016, s. 91–112 [cit. 2025-06-29]. ISBN 978-3-319-32552-1. Dostupné z DOI: 10.1007/978-3-319-32552-1_5.
20. *Inertial Measurement Unit (IMU) – An Introduction* [online]. Advanced Navigation, 2023-02-13. [cit. 2025-06-29]. Dostupné z: <https://www.advancednavigation.com/tech-articles/inertial-measurement-unit-imu-an-introduction/>.
21. KLETTE, R. *Concise Computer Vision: An Introduction into Theory and Algorithms* [online]. London: Springer, 2014 [cit. 2025-07-26]. Undergraduate Topics in Computer Science. ISBN 978-1-4471-6319-0 978-1-4471-6320-6. ISSN 1863-7310, ISSN 2197-1781. Dostupné z DOI: 10.1007/978-1-4471-6320-6.
22. KROMBACH, N.; DROESCHEL, D.; BEHNKE, S. Combining Feature-Based and Direct Methods for Semi-dense Real-Time Stereo Visual Odometry. In: CHEN, W.; HOSODA, K.; MENEGATTI, E.; SHIMIZU, M.; WANG, H. (eds.). *Intelligent Autonomous Systems 14* [online]. Cham: Springer International Publishing, 2017, vol. 531, s. 855–868 [cit. 2025-06-28]. ISBN 978-3-319-48035-0. Dostupné z DOI: 10.1007/978-3-319-48036-7_62.
23. LEE, D.; JUNG, M.; YANG, W.; KIM, A. LiDAR Odometry Survey: Recent Advancements and Remaining Challenges. *Intelligent Service Robotics* [online]. 2024, **17**(2), 95–118 [cit. 2025-06-28]. ISSN 1861-2784. Dostupné z DOI: 10.1007/s11370-024-00515-8.
24. LEPETIT, V.; MORENO-NOGUER, F.; FUA, P. EPnP: An Accurate $O(n)$ Solution to the PnP Problem. *International Journal of Computer Vision* [online]. 2009, **81**(2), 155–166 [cit. 2025-07-26]. ISSN 1573-1405. Dostupné z DOI: 10.1007/s11263-008-0152-6.
25. LOWE, D. Object Recognition from Local Scale-Invariant Features. In: *Proceedings of the Seventh IEEE International Conference on Computer Vision* [online]. 1999, zv. 2, 1150–1157 vol.2 [cit. 2025-07-26]. Dostupné z DOI: 10.1109/ICCV.1999.790410.
26. MOEBS, W.; LING, S. J.; SANNY, J. *University Physics*. Vol. 1 [online]. Houston: OpenStax, 2016 [cit. 2025-06-27]. UCF Pressbooks. 3 vols. ISBN 978-1-938168-27-7. Dostupné z: <https://pressbooks.online.ucf.edu/osuniversityphysics/>.
27. *Motion Capture for Robotics* [online]. OptiTrack. [cit. 2025-06-28]. Dostupné z: <http://optitrack.com/applications/robotics/index.html>.

28. MUR-ARTAL, R.; MONTIEL, J. M. M.; TARDOS, J. D. ORB-SLAM: A Versatile and Accurate Monocular SLAM System. *IEEE Transactions on Robotics* [online]. 2015, **31**(5), 1147–1163 [cit. 2025-07-26]. ISSN 1552-3098, ISSN 1941-0468. Dostupné z DOI: 10.1109/TR0.2015.2463671. Comment: 17 pages. 13 figures. IEEE Transactions on Robotics, 2015. Project webpage (videos, code): <http://webdiis.unizar.es/~raulmur/orbslam/>.
29. NISTER, D. An Efficient Solution to the Five-Point Relative Pose Problem. *IEEE Transactions on Pattern Analysis and Machine Intelligence* [online]. 2004, **26**(6), 756–770 [cit. 2025-07-26]. ISSN 1939-3539. Dostupné z DOI: 10.1109/TPAMI.2004.17.
30. NISTER, D.; NARODITSKY, O.; BERGEN, J. Visual Odometry. In: *Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2004. CVPR 2004.* [online]. 2004, zv. 1, s. I–I [cit. 2025-06-28]. ISSN 1063-6919. Dostupné z DOI: 10.1109/CVPR.2004.1315094.
31. AL-OKBY, M. F. R.; JUNGINGER, S.; RODDELKOPF, T.; THUROW, K. UWB-Based Real-Time Indoor Positioning Systems: A Comprehensive Review. *Applied Sciences* [online]. 2024, **14**(23), 11005 [cit. 2025-07-02]. ISSN 2076-3417. Dostupné z DOI: 10.3390/app142311005.
32. QIN, T.; LI, P.; SHEN, S. VINS-Mono: A Robust and Versatile Monocular Visual-Inertial State Estimator. *IEEE Transactions on Robotics* [online]. 2018, **34**(4), 1004–1020 [cit. 2025-06-28]. ISSN 1552-3098, ISSN 1941-0468. Dostupné z DOI: 10.1109/TR0.2018.2853729. Comment: journal paper.
33. ROSTEN, E.; DRUMMOND, T. Machine Learning for High-Speed Corner Detection. In: LEONARDIS, A.; BISCHOF, H.; PINZ, A. (eds.). *Computer Vision – ECCV 2006*. Berlin, Heidelberg: Springer, 2006, s. 430–443. ISBN 978-3-540-33833-8. Dostupné z DOI: 10.1007/11744023_34.
34. *RTK-GPS Technology for Precise Positioning* [online]. RTLS Alliance. [cit. 2025-06-26]. Dostupné z: <https://rtlsalliance.com/rtls-digital-twin/technologies/rtk-gps>.
35. RUBLEE, E.; RABAUD, V.; KONOLIGE, K.; BRADSKI, G. ORB: An Efficient Alternative to SIFT or SURF. In: *2011 International Conference on Computer Vision* [online]. 2011, s. 2564–2571 [cit. 2025-07-26]. ISSN 2380-7504. Dostupné z DOI: 10.1109/ICCV.2011.6126544.

36. RUSINKIEWICZ, S.; LEVOY, M. Efficient Variants of the ICP Algorithm. In: *Proceedings Third International Conference on 3-D Digital Imaging and Modeling* [online]. Quebec City, Que., Canada: IEEE Comput. Soc, [n.d.], s. 145–152 [cit. 2025-07-27]. Dostupné z DOI: 10.1109/im.2001.924423.
37. SAMPSON, P. D. Fitting Conic Sections to “Very Scattered” Data: An Iterative Refinement of the Bookstein Algorithm. *Computer Graphics and Image Processing* [online]. 1982, **18**(1), 97–108 [cit. 2025-07-26]. ISSN 0146-664X. Dostupné z DOI: 10.1016/0146-664X(82)90101-0.
38. *Satellite Navigation - WAAS - How It Works / Federal Aviation Administration* [online]. [cit. 2025-06-26]. Dostupné z: https://www.faa.gov/about/office_org/headquarters_offices/ato/service_units/techops/navservices/gnss/waas/howitworks.
39. SIEGWART, R. *Introduction to Autonomous Mobile Robots* [online]. 2nd ed. Cambridge, MA: MIT Press, 2011 [cit. 2025-06-29]. Intelligent Robots and Autonomous Agents. ISBN 978-0-262-01535-6. Dostupné z: <https://mitpress.mit.edu/9780262015356/introduction-to-autonomous-mobile-robots/>.
40. THRUN, S.; BURGARD, W.; FOX, D. *Probabilistic Robotics*. Cambridge, Mass.: The MIT Press, 2005. ISBN 978-0-262-20162-9. Dostupné tiež z: <https://docs.ufpr.br/~danielsantos/ProbabilisticRobotics.pdf>.
41. TOMASI, C.; KANADE, T. *Detection and Tracking of Point Features*. Pittsburgh, PA, 1991-04. Technical Report, CMU-CS-91-132. Carnegie Mellon University, School of Computer Science.
42. VIZZO, I. et al. KISS-ICP: In Defense of Point-to-Point ICP – Simple, Accurate, and Robust Registration If Done the Right Way. *IEEE Robotics and Automation Letters* [online]. 2023, **8**(2), 1029–1036 [cit. 2025-06-30]. ISSN 2377-3766, ISSN 2377-3774. Dostupné z DOI: 10.1109/LRA.2023.3236571.
43. *What Is GNSS* [online]. EU Agency for the Space Programme. [cit. 2025-06-26]. Dostupné z: <https://www.euspa.europa.eu/eu-space-programme/galileo/what-gnss>.