

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104364-104252

**Fúzia dát zo snímačov pre zlepšenie
spoľahlivosti lokalizácie mobilného robota**

Písomná práca k dizertačnej skúške

SLOVENSKÁ TECHNICKÁ UNIVERZITA V BRATISLAVE

Fakulta elektrotechniky a informatiky

Evidenčné číslo: FEI-104364-104252

Fúzia dát zo snímačov pre zlepšenie spoľahlivosti lokalizácie mobilného robota

Písomná práca k dizertačnej skúške

Študijný program:	Robotika a kybernetika
Študijný odbor:	kybernetika
Školiace pracovisko:	Ústav robotiky a kybernetiky
Školiteľ:	prof. Ing. František Duchoň, PhD.

Podakovanie

Moje podakovanie patrí predovšetkým vedúcemu práce, ktorým bol prof. Ing. František Duchoň, PhD., za odborné vedenie a pripomienky, ktoré mi pomohli pri vypracovaní tejto písomnej práce k dizertačnej skúške. Ďakujem aj Ing. Martinovi Dekanovi, PhD. za motiváciu a cenné rady pri písaní práce. V poslednom rade sa chcem poďakovať mojej manželke Adriane za podporu, porozumenie a trpezlivosť napriek nezriedkavým nadčasom stráveným v priestoroch fakulty.

Abstrakt

Spolehlivá lokalizácia predstavuje jeden zo základných predpokladov pre úspešnú autonómnú navigáciu mobilných robotov v reálnom prostredí. Vzhľadom na obmedzenia a neistoty jednotlivých snímačov, ako aj potenciálne výpadky v reálnych aplikáciách, sa fúzia údajov zo snímačov javí ako kľúčový nástroj na zvýšenie presnosti a robustnosti odhadu polohy. Táto práca poskytuje systematický prehľad dostupných senzorických technológií, ktoré sa využívajú na určenie polohy mobilných robotov a analyzuje ich z hľadiska princípov fungovania, vlastností a možností aplikácie. Opísané sú tiež zaužívané pravdepodobnostné metódy senzorickej fúzie, ako aj súčasné trendy smerujúce k využitiu techník umelej inteligencie pri spracovaní a integrácii senzorických údajov. Výsledky analytickej časti práce tvoria teoretický základ pre návrh nových postupov zvyšujúcich spoľahlivosť lokalizačných systémov bez potreby externej kalibračnej infraštruktúry, čím prispievajú k ďalšiemu rozvoju autonómnych robotických technológií v širokej škále odvetví vrátane priemyslu či logistiky.

Kľúčové slová

senzor, fúzia senzorických údajov, lokalizácia, mobilný robot, Kalmanov filter, umelé neurónové siete, hlboké učenie

Abstract

Reliable localization is one of the fundamental prerequisites for successful autonomous navigation of mobile robots in real-world environments. Due to the limitations and uncertainties of individual sensors, as well as potential outages in practical applications, sensor data fusion emerges as a key tool for improving the accuracy and robustness of position estimation. This thesis provides a systematic overview of available sensing technologies used for mobile robot localization, analyzing them in terms of operational principles, characteristics, and application potential. It also describes established probabilistic methods for sensor fusion, along with current trends toward the use of artificial intelligence techniques for processing and integrating sensor data. The results of the analytical part of the work form a theoretical foundation for the design of new approaches that increase the reliability of localization systems without requiring external calibration infrastructure, thus contributing to the further development of autonomous robotic technologies across a wide range of fields, including industry and logistics.

Keywords

sensor, sensor data fusion, localization, mobile robot, Kalman filter, artificial neural networks, deep learning

Obsah

Úvod	1
1 Vymedzenie pojmov a úvod do problematiky	2
1.1 Taxonómia fúzie	2
1.2 Význam fúzie	3
1.3 Vlastnosti a taxonómia snímačov	4
2 Charakteristika a delenie snímačov	8
3 Interné senzorické systémy	11
3.1 Odometria	11
3.1.1 Kolesová odometria	11
3.2 Vizuálna odometria	12
3.2.1 Rekonštrukcia pohybu	13
3.2.2 Nelineárna optimalizácia	14
3.2.3 Párovanie textúr	16
3.2.4 Rekonštrukcia hĺbky	16
3.2.5 Aktualizácia stavu	17
3.2.6 Prehľad súčasných riešení	18
3.2.7 Vizuálny SLAM	19
3.3 Lidarová odometria	21
3.3.1 LiDAR technológia	21
3.3.2 Prehľad metód lidarovej odometrie	22
3.3.3 Iteratívny algoritmus najbližších bodov (ICP)	23
3.4 Inerčné snímače	28
3.4.1 Gyroskopy	28
3.4.2 Akcelerometre	31
3.4.3 Magnetometre	32
3.4.4 IMU	33
4 Externé lokalizačné systémy	35
4.1 GNSS systémy	35
4.1.1 Princíp činnosti	36
4.1.2 Chyby GPS	36
4.1.3 Augmentačné systémy	37
4.2 UWB systémy	38
4.2.1 Modulácia signálu	39

4.2.2	Metódy UWB lokalizácie	40
4.3	Systémy na snímanie pohybu	41
5	Pravdepodobnostné metódy fúzie údajov zo snímačov	42
5.1	Pojmy a označenia v pravdepodobnostnej robotike	42
5.1.1	Od pravdepodobnosti k Bayesovej vete	42
5.1.2	Pravdepodobnostná reprezentácia stavu	44
5.2	Bayesov filter	45
5.3	Gaussove filtre	46
5.3.1	Lineárny Kalmanov filter	47
5.3.2	Rozšírený Kalmanov filter	49
5.4	Využitie Kalmanových filtrov pre fúziu snímačov	52
6	Čo sú umelé neurónové siete	54
6.1	Aktivačná funkcia	56
7	Perceptróny	58
7.1	Jednovrstvové perceptróny	58
7.2	Lineárna separovateľnosť – problém klasifikácie	59
7.3	Viacvrstvové perceptróny	60
8	Trénovanie UNS	63
8.1	Perceptrónové kritérium	63
8.2	Spätné šírenie chyby	64
8.3	Problémy trénovania UNS	67
8.3.1	Pretrénovanie	67
8.3.2	Miznúce a explodujúce gradienty	68
8.3.3	Ťažkosti s konvergenciou	69
8.3.4	Lokálne a falošné optimá	70
8.3.5	Výpočtová náročnosť	70
8.4	Súčasný prístup k trénovaniu	70
9	Hlboké učenie	73
9.1	Konvolučné neurónové siete	73
9.2	Rekurentné neurónové siete	75
10	Fúzia lokalizácie pomocou UNS	77
10.1	Fúzia vnímania prostredia s využitím DFFN	77
10.2	Fúzia odometrie s využitím DL a CNN	81

10.3 Fúzia GNSS a INS s využitím RNN	85
Záver	89
Tézy dizertačnej práce	90
Literatúra	91

Zoznam obrázkov a tabuliek

Obrázok 1.1	Diagram porovnania vybraných snímačov podľa vlastností	5
Obrázok 3.1	Princíp textúrnej vizuálnej odometrie [53].	12
Obrázok 3.2	Dierkový model kamery	14
Obrázok 3.3	Gyroskop – ilustrácia	29
Obrázok 3.4	Principiálna schéma gyroskopu Systron Donner GyroChip [16]	30
Obrázok 3.5	Štruktúra a princíp merania rôznych typov akcelerometrov [16]	32
Obrázok 6.1	McCulloch-Pittsov model neurónu.	54
Obrázok 6.2	Vybrané aktivačné funkcie.	57
Obrázok 7.1	Geometrické riešenie klasifikácie.	59
Obrázok 7.2	Lineárna separovateľnosť vybraných logických funkcií.	60
Obrázok 7.3	Viacvrstvový perceptrón.	61
Obrázok 7.4	Porovnanie klasifikácie pomocou SLP a MLP.	62
Obrázok 8.1	Základná schéma algoritmov tréningu UNS.	63
Obrázok 9.1	Schéma architektúry konvolučnej neurónovej siete. [47]	74
Obrázok 9.2	Rekurentná neurónová sieť – znázornenie toku informácií v čase.	75
Obrázok 9.3	Porovnanie štruktúr LSTM a GRU rekurentných neurónových sietí. [33]	76
Obrázok 10.1	Rozloženie senzorov na mobilnom robote	78
Obrázok 10.2	Fúzia senzorov pomocou DFFN	79
Obrázok 10.3	Výsledky experimentov	80
Obrázok 10.4	Návrh systému fúzie kamery a lidarů pomocou CNN	82
Obrázok 10.5	Architektúra CNN sietí pre fúziu odometrie	83
Obrázok 10.6	Výsledky experimentov na testovacích sekvenciách z KITTI datasetu.	85
Obrázok 10.7	Rozbor RNN z hľadiska toku informácií v čase	87
Obrázok 10.8	Architektúra systému s RNN na predikciu odchýlky INS	87
Obrázok 10.9	Priebeh simulovaného experimentu pre fúziu GNSS/INS s využitím RNN	88

Zoznam značiek a skratiek

AGV	Autonomous Ground Vehicle
AMCW	Amplitude-Modulated Continuous Wave
AOA	Angle Of Arrival
BCE	Binary Cross Entropy
BF	Bayessov filter
BPSK	Binary Phase Shift Keying
BRIEF	Binary Robust Independent Elementary
CLINS	Continuous-time LiDAR-Inertial Navigation System
CNN	Convolutional Neural Network
DFFN	Deep Feed-Forward Network
DGPS	Differential GPS
DL	Deep Learning
DLT	Direct Linear Transform
DoF	Degree of Freedom
DoG	Difference of Gaussians
DOP	Dilution Of Precision
EGNOS	European Geostationary Navigation Overlay Service
EKF	Extended Kalman Filter
ELM	Extreme Learning Machine
EPnP	Efficient PnP
FAST	Features From Accelerated Segment Test
FMCW	Frequency-Modulated Continuous Wave
FOV	Field Of View
GLONASS	Globalnaja Navigacionnaja Sputnikovaja Sistema
GNSS	Global Navigation Satellite Systems
GPS	Global Positioning System
GPU	Graphical Processing Unit
GRU	Gated Recurrent Unit
ICP	Iterative Closest Point
IMU	Inertial Measurement Unit
INS	Inertial Navigation System
IRC	Incremental rotary encoder
IRNSS	Indian Regional Navigation Satellite System
KISS-ICP	Keep It Small and Simple ICP
LiDAR	Light Detection and Ranging

LIO	LiDAR-Inertial Odometry
LIO-SAM	LiDAR-Inertial Odometry Smoothing and Mapping
LIOR	LiDAR Odometry with Intensity and Occlusion Removal
LKF	Lineárny Kalmanov filter
LO	LiDAR Odometry
LO-Net	Lidar Odometry Network
LOAM	LiDAR Odometry and Mapping
LodoNet	LiDAR Odometry Deep Neural Network
LSTM	Long Short-Term Memory
MEMS	Micro-Electro-Mechanical Systems
MKP	Matched Keypoint Pair
MLE	maximum-likelihood estimation
MLP	Multi-Layer Perceptron
MoCap	motion capture
n. p.	náhodná premenná
NAS	National Airspace System (USA)
NDT-ICP	Normal Distribution Transform ICP
OOK	On-OFF Keying
OPA	Optical Phased Array
ORB	Oriented FAST and rotated BRIEF
ORB-SLAM	ORB-SLAM
PAM	Pulse Amplitude Modulation
PnP	Perspective-n-Point
PPM	Pulse Position Modulation
PSK	Phase Shift Keying
PWM	Pulse Width Modulation
QZSS	Quasi-Zenith Satellite System
RANSAC	Random Sample Consensus
ReLU	Rectified Linear Unit
RMSE	Root Mean Square Error
RNN	Recurrent Neural Network
RPE	reprojecition error
RSS	Received Signal Strength
RTK	Real-Time Kinematic
SBAS	Satellite-based Augmentation Systems
SGD	Stochastic Gradient Descent
SIFT	Scale-Invariant Feature Transform

SLAM	Simultaneous Localization and Mapping
SLP	Single-Layer Perceptron
SuMa	Surfel-based Mapping
SURF	Speeded-Up Robust Features
TDOA	Time Difference Of Arrival
TH	Time Hopping
TOA	Time Of Arrival
ToF	Time of Flight
UAV	Unmanned Aerial Vehicle
UI	Umelá inteligencia
UNS	Umelá neurónová sieť
UWB	Ultra-Wideband
VO	Visual odometry
WAAS	Wide Area Augmentation System
WeatherNet	Weather-Robust Deep LiDAR Odometry Network
WGS	World Geodetic System
WiMAX	Worldwide Interoperability for Microwave Access
WMS	Wide Area Master Stations
WRS	Wide Area Reference Stations

Zoznam algoritmov

1	Základný ICP algoritmus podľa [5]	24
2	Bayesov filter	46
3	Lineárny Kalmanov filter	48
4	Rozšírený Kalmanov filter	51

Úvod

Miera nasadenia mobilných robotov v priemysle, logistike a ďalších inteligentných systémoch sa každým rokom zvyšuje. Kľúčovým predpokladom pre autonómnu navigáciu robota a jeho interakciu s prostredím je spoľahlivá lokalizácia. Informácie o vlastnom stave ako aj o stave okolitého prostredia dostáva robot prostredníctvom snímačov. Vzhľadom na súčasné trendy, ktoré sa zameriavajú na inteligentné systémy a autonómne riadenie, je dôležité riešiť problematiku fúzie dát z viacerých snímačov, ktoré často podliehajú rušivým vplyvom či výpadkom a vyznačujú sa rôznymi vlastnosťami. Cieľom fúzie je vyťažiť maximum z kombinácie údajov zo senzorov a dosiahnuť väčšiu odolnosť systému voči systematickým aj náhlym nepresnostiam niektorého zo senzorov.

Táto práca sa zameriava na komplexný prehľad a analýzu dostupných prostriedkov, používaných na určenie polohy mobilných robotov, ktorý má slúžiť ako báza poznania pre ďalší výskum v danej téme. V prvej časti práce zavádzame definície dôležitých pojmov, vysvetľujeme opodstatnenie zaoberania sa problematikou fúzie a pomenúvame rôzne prístupy k jej implementácii. Uvádzame tiež dôležité vlastnosti snímačov, ktoré predstavujú základ pre ich taxonómiu a spôsob ich využitia pre lokalizáciu mobilných robotov.

Nasleduje podrobný opis snímačov, ktoré sa v súčasnosti používajú na lokalizáciu mobilných robotov. Pre prehľadnosť sme ich rozdelili podľa toho, či na určenie polohy využívajú externú infraštruktúru prostredia. Cieľom týchto dvoch častí bolo poskytnúť komplexný prehľad síce nie všetkých, no za to najvýznamnejších senzorických systémov.

Ďalšia časť je venovaná pravdepodobnostným metódam fúzie údajov zo snímačov, ktoré predstavujú tradičný spôsob riešenia tejto problematiky. Keďže nejde o novú oblasť výskumu, uvádzame najmä základné predpoklady a princípy, z ktorých vychádzajú všetky súčasné variácie týchto metód. V kontraste s dobre zaužívanými pravdepodobnostnými prístupmi sa v poslednej časti práce zaoberáme využitím aktuálnej témy umelej inteligencie. Samotná technológia síce už tiež nie je najnovšia, no v súčasnosti zažíva rozmach vďaka výraznému pokroku vo výkone výpočtových zariadení. V oblasti riešenia senzorickej fúzie však ešte nemá celkom zaužívané miesto a jej inkorporácia do inteligentných systémov je aktuálnym predmetom výskumu mnohých autorov.

1 Vymedzenie pojmov úvod do problematiky

Senzor je elektronické zariadenie, ktoré sníma okolie z fyzikálneho hľadiska, pričom jeho výstupom sú digitálne spracovateľné údaje. Poskytuje priame vnímanie prostredia, v ktorom je zasadený. Na zvýšenie kompletnosti a presnosti informácií o prostredí sa obvykle používa viacero snímačov súčasne [36]. Pojmy *senzor* a *snímač* v tejto práci používame zameniteľne.

Fúzia údajov je proces zlučovania dát z viacerých snímačov za účelom zníženia neistoty, ktorá vzniká pri navigácii a pohybe vozidla prostredím [71]. Fúzia pomáha vytvoriť presnejší model prostredia na spoľahlivejšie navigovanie a správanie vozidla.

Inak povedané, fúzia dát zo snímačov je kombinácia senzorických dát alebo dát odvodených zo senzorických dát, pričom výsledná informácia je v istom zmysle lepšia než by bola v prípade použitia týchto zdrojov samostatne [18].

Pojmy *fúzia dát (zo snímačov)*, *fúzia údajov (zo snímačov)*, *fúzia snímačov*, apod. používame v tejto práci zameniteľne.

Lokalizácia označuje odhad polohy (pozície a orientácie) robota vzhľadom na referenčný súradnicový systém. Môže byť buď absolútna (vzhľadom na mapu prostredia) alebo relatívna (vzhľadom na predošlú polohu) [68]. V tejto práci budeme používať pojmy *lokalizácia* a *odhad/určenie polohy* zameniteľne.

1.1 Taxonómia fúzie

Podľa [71] existujú tri základné typy viacsenzorovej architektúry:

- *Redundantná* – všetky senzory poskytujú rovnaké informácie o prostredí,
- *Doplňková* – senzory poskytujú nezávislé typy informácií o prostredí,
- *Koordinovaná* – senzory zbierajú informácie o prostredí sekvenčne.

Tri základné komunikačné schémy medzi senzormi sú [71]:

- *Decentralizovaná* – medzi uzlami senzorov neprebíha žiadna komunikácia,
- *Centralizovaná* – všetky senzory poskytujú merania ústrednému uzlu,
- *Distribúovaná* – uzly si vzájomne vymieňajú informácie danou frekvenciou (napr. každých 5 meraní, t. j. $\frac{1}{5}$ snímacej frekvencie).

Centralizovaná schéma sa dá považovať za špeciálny prípad distribuovanej, keď senzory spolu komunikujú po každom meraní.

Fúziu údajov z viacerých snímačov je možné vykonávať na rôznych úrovniach [18]:

- *Fúzia nízkej úrovne* (angl. *low-level fusion, raw data fusion*) – spočíva v zlúčení surových dát z viacerých zariadení za účelom produkovania nových dát obsahujúcich širšie spektrum informácií;
- *Fúzia strednej úrovne* (angl. *intermediate-level fusion, feature level fusion*) – kombinuje rôzne príznaky, ako napríklad hrany, rohy, línie, textúry alebo pozície do mapy príznakov, ktorá môže byť následne využitá na segmentáciu a detekciu;
- *Fúzia vysokej úrovne* (angl. *high-level fusion, decision fusion*) – kombinuje rozhodnutia viacerých expertných algoritmov. Medzi používané metódy rozhodovania patria hlasovanie (angl. *voting*), fuzzy logika či štatistické metódy.

Spoločným predpokladom na fúziu údajov z viacerých snímačov je časová synchronizácia dát a reprezentácia v spoločnom súradnicovom systéme [40].

1.2 Význam fúzie

Presnosť každého snímača je limitovaná určitými faktormi. Individuálne použitie akéhokoľvek snímača bez porovnania s podobnými informáciami z iných snímačov môže ovplyvniť celý systém, v ktorom je implementovaný, pričom nie je možné odhaliť odchýlku alebo neplatnosť merania. Vo všeobecnosti sa pri senzorických meraniach môžeme stretnúť s týmito nedostatkami [18]:

- *výpadok senzora* – porucha senzora spôsobuje stratu vnímania objektu,
- *obmedzené pokrytie priestoru* – jediný senzor obvykle poskytuje informácie len z určitého regiónu,
- *obmedzené časové pokrytie* – na vykonanie merania a sprenesenia informácie je potrebný určitý čas, čo limituje maximálnu frekvenciu meraní,
- *nepresnosť* – merania sú limitované presnosťou snímača.
- *neistota* – na rozdiel od nepresnosti závisí skôr od snímaného objektu než od snímača. Narastá keď senzor nedokáže zaznamenať všetky vlastnosti objektu alebo keď je meranie nejednoznačné. Systém s jediným senzorom nedokáže znížiť neistotu vnímania kvôli obmedzenému pohľadu na objekt.

Naproti tomu, od fúzie dát zo snímačov si sľubujeme najmä tieto výhody [18]:

- *robustnosť a spoľahlivosť* – pre systémy s viacerými senzormi je prirodzená redundancia, ktorá umožňuje poskytovanie informácií aj v prípade čiastočnej poruchy;
- *rozšírené pokrytie priestoru a času* – jeden senzor sa môže pozerať tam, kde (resp. v čase, v ktorom) iné nemôžu;
- *zvýšenie presnosti a opakovateľnosti* – meranie jedného senzora je porovnávané s meraniami ostatných, snímajúcich tú istú veličinu;
- *zníženie nejednoznačnosti a neistoty* – zjednotené informácie znižujú množstvo nejednoznačných interpretácií meranej hodnoty;
- *odolnosť voči rušeniu* – rozšírením dimenzie meraného priestoru sa systém stáva menej náchylným voči rušivým faktorom.

Keďže lokalizácia predstavuje kľúčovú úlohu v každom autonómne riadenom mobilnom systéme, je nevhodné sa pre jej odvodenie spoliehať len na jediný zdroj informácie. Nepresná lokalizácia totiž môže veľmi rýchlo viesť ku kumulácii chyby v mape prostredia a celkovej neschopnosti robota orientovať sa v prostredí. Metóda fúzie údajov z viacerých snímačov musí zohľadňovať ich chybové či meracie vlastnosti. Prehľad dôležitých parametrov, ktoré definujú vlastnosti snímačov, ako aj ich zatriedenie podľa rôznych kritérií prinášame v nasledujúcej kapitole. V neposlednom rade, zo softvérového hľadiska slúži fúzia ako rozhranie pre nasledujúce úlohy, tie sa tak stávajú nezávislé od zdroja meraní.


1.3 Vlastnosti a taxonómia snímačov

Pokiaľ je našou snahou fúzia senzorických dát, musíme v prvom rade poznať parametre týchto senzorov, ich silné a slabé stránky, pretože to sú faktory, ktoré je pri fúzii potrebné zohľadniť.

V súvislosti so snímačmi používanými v mobilnej robotike treba mať na pamäti tri zásadné skutočnosti [16]:

1. Meranie skutočnými snímačmi je zašumené;
2. Skutočné snímače poskytujú nekompletný opis prostredia;
3. Skutočné snímače nemôžu byť úplne modelované.

Vlastnosti a miera použiteľnosti snímačov sú dané mnohými parametrami, ktoré ich vzájomne odlišujú. Porovnanie vlastností vybraných typov snímačov je znázornené na obr. 1.1. Medzi najvýznamnejšie parametre snímačov môžeme zaradiť [16]:



Obr. 1.1: Diagram porovnania vybraných snímačov podľa dosahu, rozlíšenia, schopnosti klasifikácie, určovania rýchlosti a odolnosti pri rôznych vonkajších podmienkach [78].

- *Zorné (detekčné) pole (FOV)* – šírka záberu snímača, zvyčajne vyjadrená v stupňoch. Niektoré typy snímačov majú definované vertikálne aj horizontálne zorné pole;
- *Merací rozsah* – pracovný rozsah snímania vrátane obmedzenia hĺbky (môže byť minimálne aj maximálne);
- *Dynamický rozsah* – pomer medzi maximálnou a minimálnou vstupnou hodnotou snímača. Hodnota býva vyjadrená v decibeloch;
- *Rozlíšenie* – minimálny rozdiel medzi dvoma hodnotami, ktoré snímač dokáže detegovať;
- *Lineárnosť* – ak je gradient vstupno-výstupnej závislosti konštantný, snímač je lineárny;
- *Šírka pásma/frekvencia* – rýchlosť merania snímača. Zvyčajne býva vyjadrená v hertzoch;

- *Citlivosť* – miera zmeny výstupného signálu vzhľadom na mieru zmeny vstupného signálu. Môže byť ovplyvnená aj prostredím;
- *Chyba* – odchýlka výstupnej hodnoty od skutočnej. Vo všeobecnosti rozlišujeme medzi dvomi typmi chýb:
 - *systematická (deterministická)* – sústavná (konštantná) odchýlka meraní od skutočnosti. Môže byť spôsobená faktormi alebo procesmi, ktoré je možné modelovať;
 - *náhodná (stochastická)* – premenlivá odchýlka meraní od skutočnosti. Je možné ju vyjadriť pravdepodobnostnými metrikami;
- *Presnosť* – miera systematickej chyby. Vyjadrená býva v pomere k skutočnej hodnote;
- *Opakovateľnosť* – miera náhodnej chyby. Je nezávislá od presnosti snímača;
- *Drift* – postupný odklon meraní od reálnych hodnôt, vzniká kumuláciou chýb merania;
- *Latencia* – oneskorenie medzi momentom výskytu fyzikálneho javu a momentom poskytnutia informácie o ňom senzorom. Môže byť spôsobená viacerými faktormi, vrátane fyzikálnych vlastností senzora, spôsobu spracovania signálu či času potrebného na odoslanie údajov.

Snímače a systémové komponenty využívané na lokalizáciu mobilných robotov možno klasifikovať viacerými spôsobmi podľa rôznych hľadísk, vo všeobecnosti podľa toho čo a akým spôsobom snímajú. Každé z týchto hľadísk zvýrazňuje iný aspekt senzorov. Medzi najčastejšie kritériá taxonómie snímačov patria:

1. Podľa spôsobu interakcie so snímaným prostredím [30]:
 - *Aktívne* – senzory, ktoré samy vysielajú energiu do prostredia (napr. LiDAR, ultrazvuk),
 - *Pasívne* – senzory, ktoré len pasívne prijímajú signály (napr. kamery, magnetometre),
2. Podľa typu meranej veličiny [67, 68]:
 - *inerciálne veličiny* – gyroskopy, akcelerometre,
 - *vzdialenosť* – LiDAR, ultrazvuk,

- *elektromagnetické signály* – GNSS, magnetometre;

3. Podľa referenčného rámca výstupu [3]:

- *Lokálne* – poskytujú odhad polohy vzhľadom na predchádzajúci stav robota (napr. odometria),
- *Globálne* – poskytujú polohu vzhľadom na externý (globálny) rámec (napr. GNSS, MoCap systémy);

4. Podľa spôsobu vnímania [67]:

- *Proprioreceptívne* – merajú vnútorný stav robota samotného (napr. IMU),
- *Exteroreceptívne* – merajú informácie o vonkajšom prostredí (napr. LiDAR, kamera);

5. Podľa požiadaviek na infraštruktúru [20]:

- *Interné („on-board“)* – schopné fungovať samostatne ako súčasť robota, bez potreby externej infraštruktúry (napr. kamera, LiDAR, IMU),
- *Externé („off-board“)* – vyžadujú vopred pripravené externé prvky poskytujúce referenčné informácie (napr. GPS, MoCap, UWB);

Pri návrhu senzorického vybavenia pre lokalizáciu mobilného robota je potrebné vychádzať z možností, ktoré poskytuje daná aplikácia. Pred voľbou konkrétnych snímačov si musí dizajnér položiť niekoľko rozhodujúcich otázok. Bude sa robot pohybovať v exteriéri alebo interiéri? Ak v interiéri, pôjde o vopred známe prostredie s možnosťou prispôsobenia infraštruktúry, alebo to bude neznáme prostredie, v ktorom musí byť robot schopný operovať s vlastnou výbavou? Ak v exteriéri, bude sa robot pohybovať v prostrediach s dobrým pokrytím GNSS, alebo skôr v lesnatých či zastavaných oblastiach? Akú časť z celkovej hmotnosti robota je možné rezervovať pre senzory pri zohľadnení dynamických požiadaviek aplikácie? S akým rizikom kolízie či poškodenia robota sa pri danej aplikácii počíta a akú časť celkovej ceny robota môžu tvoriť práve senzory?

Odpovede na tieto otázky je možné premietnuť na jednu škálu ohraničenú práve voľbou medzi použitím interných alebo externých senzorov. V tejto práci sa preto na systematizáciu predstavenia senzorov používaných na lokalizáciu mobilných robotov použijeme práve poslednú spomenutú taxonómiu.

2 Charakteristika a delenie snímačov

V súvislosti so snímačmi používanými v mobilnej robotike treba mať na pamäti tri zásadné faktory [16]:

1. Meranie skutočnými snímačmi je zašumené;
2. Skutočné snímače poskytujú nekompletný opis prostredia;
3. Skutočné snímače nemôžu byť úplne modelované.

Vlastnosti a miera použiteľnosti snímačov sú dané mnohými parametrami, ktoré ich vzájomne odlišujú. Z nich medzi najvýznamnejšie môžeme zaradiť [16]:

- *Zorné (detekčné) pole (FOV)* – šírka záberu snímača, zvyčajne vyjadrená v stupňoch. Niektoré typy snímačov majú definované vertikálne aj horizontálne zorné pole;
- *Merací rozsah* – pracovný rozsah snímania vrátane obmedzenia hĺbky (môže byť minimálne aj maximálne);
- *Dynamický rozsah* – pomer medzi maximálnou a minimálnou vstupnou hodnotou snímača. Hodnota býva vyjadrená v decibeloch;
- *Rozlíšenie* – minimálny rozdiel medzi dvoma hodnotami, ktoré snímač dokáže detegovať;
- *Lineárnosť* – ak je gradient vstupno-výstupnej závislosti konštantný, snímač je lineárny;
- *Šírka pásma/frekvencia* – rýchlosť merania snímača. Zvyčajne býva vyjadrená v hertzoch;
- *Citlivosť* – miera zmeny výstupného signálu vzhľadom na mieru zmeny vstupného signálu. Môže byť ovplyvnená aj prostredím;
- *Chyba* – odchýlka výstupnej hodnoty od skutočnej. Vo všeobecnosti rozlišujeme medzi dvomi typmi chýb:
 - *systematická (deterministická)* – sústavná (konštantná) odchýlka meraní od skutočnosti. Môže byť spôsobená faktormi alebo procesmi, ktoré je možné modelovať;

- *náhodná (stochastická)* – premenlivá odchýlka meraní od skutočnosti. Je možné ju vyjadriť pravdepodobnostnými metrikami;
- *Presnosť* – miera systematickej chyby. Vyjadrená býva v pomere k skutočnej hodnote;
- *Opakovateľnosť* – miera náhodnej chyby. Je nezávislá od presnosti snímača;
- *Drift* – postupný odklon meraní od reálnych hodnôt, vzniká kumuláciou chýb merania;
- *Latencia* – oneskorenie medzi momentom výskytu fyzikálneho javu a momentom poskytnutia informácie o ňom senzorom. Môže byť spôsobená viacerými faktormi, vrátane fyzikálnych vlastností senzora, spôsobu spracovania signálu či času potrebného na odoslanie údajov.

Snímače a systémové komponenty využívané na lokalizáciu mobilných robotov možno klasifikovať viacerými spôsobmi podľa rôznych hľadísk, vo všeobecnosti podľa toho čo a akým spôsobom snímajú. Každé z týchto hľadísk zvyrazňuje iný aspekt senzorov. Medzi najčastejšie kritériá delenia snímačov patria:

1. Podľa spôsobu interakcie so snímaným prostredím [30]:
 - *aktívne* – senzory, ktoré samy vysielajú energiu do prostredia (napr. LiDAR, ultrazvuk),
 - *pasívne* – senzory, ktoré len pasívne prijímajú signály (napr. kamery, magnetometre),
2. Podľa typu meranej veličiny [67, 68]:
 - *inerciálne veličiny* – gyroskopy, akcelerometre,
 - *vzdialenosť* – LiDAR, ultrazvuk,
 - *elektromagnetické signály* – GNSS, magnetometre;
3. Podľa referenčného rámca výstupu [3]:
 - *lokálne* – poskytujú odhad polohy vzhľadom na predchádzajúci stav robota (napr. odometria),
 - *globálne* – poskytujú polohu vzhľadom na externý (globálny) rámec (napr. GNSS, MoCap systémy);
4. Podľa spôsobu vnímania [67]:

- *proprioceptívne* – merajú vnútorný stav robota samotného (napr. IMU),
- *exteroceptívne* – merajú informácie o vonkajšom prostredí (napr. LiDAR, kamera);

5. Podľa potreby infraštruktúry [20]:

- *interné* („*on-board*“) – schopné fungovať samostatne ako súčasť robota (napr. kamera, LiDAR, IMU),
- *externé* („*off-board*“) – vyžadujú externú inštaláciu alebo systém (napr. GPS, MoCap, UWB);

V tejto práci použijeme na systematizáciu predstavenia senzorov používaných na lokalizáciu mobilných robotov práve posledné spomenuté delenie.

3 Interné senzorické systémy

3.1 Odometria

Jedným zo spôsobov lokalizácie objektov je hrubé stanovenie polohy. Aktuálna poloha je odvodená na základe informácií o predošliých polohách a aktuálnom smere a rýchlosti pohybu. Najjednoduchšou implementáciou takéhoto prístupu je odometria. Využíva odometer – snímač, ktorý je schopný zaznamenať zmenu kinematiky – umiestnený na palube mobilného zariadenia (robota). Na základe uplynutého času, prejdenej dráhy vypočítanej z odometrie a orientácie, ktorá musí byť získaná iným spôsobom, je následne odvodený odhad aktuálnej polohy [16].

V prípade kolesových robotov je obvykle snímaný pohyb kolies, tzv. kolesová odometria, a to najčastejšie pomocou inkrementálnych snímačov polohy [16]. Princíp odometrie je však možné využiť aj pri spracovaní údajov z iných snímačov. V súčasnosti už dobre zaužívanou metódou je vizuálna odometria, ktorá využíva obraz z kamery, a pomerne nedávnou oblasťou je spracovanie meraní z LiDAR-u – lidarová odometria.

3.1.1 Kolesová odometria

Kolesová odometria využíva snímanie otáčok kolies, resp. motora pomocou optického inkrementálneho snímaču (IRC). Ten je schopný zaznamenávať otáčanie hriadeľa pomocou prerušovania svetelného lúča cez mriežku na rotujúcom disku. Pri jeho otáčaní vznikajú impulzy – sínusové alebo pravouhlé – ktoré reprezentujú zmenu uhla. Rozlíšenie snímača sa vyjadruje ako počet impulzov (cyklov) na jednu otáčku. Základný typ snímača však nevie určiť smer pohybu, preto sa v mobilnej robotike používa tzv. kvadrátúrny inkrementálny snímač. Ten má dva optické kanály posunuté o 90° fázovo, čo umožňuje určiť nielen uhol, ale aj smer otáčania. Navyše, každý impulz možno ďalej interpolovať, čím sa zvyšuje presnosť merania [16].

Výhodou IRC je ich jednoduchosť, nízka cena a vysoká presnosť v rámci vnútornej štruktúry robota – chyby priamo v snímači sú spravidla zanedbateľné v porovnaní s chybami v mechanickom prenose (napr. v hriadeľi). Najväčším problémom IRC je však akumulácia chýb – spôsobená napríklad pretáčaním kolies, nepresným priemerom kolies alebo nerovným povrchom. Preto sú odometrické merania pomocou inkrementálnych snímačov síce veľmi presné v krátkom časovom horizonte, ale dlhodobo sa ich chyba zväčšuje. Na kompenzáciu sa preto bežne používajú korekčné algoritmy, ako je napríklad Kalmanov filter, ktorý kombinuje výstupy z viacerých senzorov [16].

3.2 Vizuálna odometria

Vizuálna odometria (VO) je technika odhadu polohy na základe vstupného obrazu z jednej alebo viacerých kamier. Na rozdiel od kolesovej odometrie, zaznamenáva posunutie obrazu medzi za sebou nasledujúcimi snímkami. Funguje v reálnom čase, v porovnaní s kolesovou odometriou má podstatne vyššiu spoľahlivosť a je vhodná v prostrediach bez dostupnosti signálu GPS.

Podľa počtu použitých kamier sa rozlišujú tri typy vizuálnej odometrie [39]:

1. *monokulárna* – využíva jednu kameru, meria posuny obrazu medzi snímkami a odhaduje pohyb, jej nevýhodou je faktor neurčitej mierky, ktorý je nutné kompenzovať prídavnými senzormi;
2. *stereovízna* – kombinuje dve synchronizované kamery, získava hĺbku priamo pomocou stereo triangulácie, čím odstraňuje problém neurčitej mierky;
3. *všesmerová* – pozostáva z komplexného systému viacerých mono- alebo stereo-kamier. Poskytuje veľmi široké zorné pole (až do 360°), vďaka čomu je rotačne invariantná. Vyžaduje však presnú kalibráciu a synchronizáciu medzi kamerami a je nákladnejšia [4].

Existuje viacero spôsobov určovania pohybu na základe obrazu z kamier. Medzi dominujúce prístupy VO patria [39]:

- *textúrna* – (obr. 3.1) pracuje s detekciou a sledovaním výrazných obrazových prvkov – textúr (napr. rohy, línie, krivky, ...). Je presná v dobre štruktúrovanom



(a) vstupný obraz



(b) výstup zo sledovača textúr – krúžky reprezentujú aktuálne pozície textúr, čiary sú znázorňujú ich pohyb po obrázku

Obr. 3.1: Princíp textúrnej vizuálnej odometrie [53].

prostredí, avšak jej robustnosť klesá pri monotónnych scénach. Na kompenzáciu driftu sa často požíva v kombinácii s metódami optimalizácie pozičného grafu.

- *priama* - pracuje priamo s intenzitami všetkých pixelov snímku, bez predchádzajúcej extrakcie, a to za účelom minimalizácie fotometrickej chyby. Je preto výpočtovo náročnejšia a pomalšia než textúrna vizuálna odometria. Je tiež citlivejšia na svetelné zmeny.
- *hybridná* – využíva kombináciu dvoch predošlých typov na rekonštrukciu trojrozmerného prostredia. V prvom slede sa použije textúrna VO na získanie hrubého odhadu polohy, ktorý je neskôr spresnený pomocou priamej VO.
- *vizuálno-inerciálna* – kombinuje kameru s IMU, čo zlepšuje metriku aj stabilitu: IMU poskytuje rýchlo-časové odhady a pomáha pri rýchlych pohyboch či nízkej textúre. Niektoré takéto systémy dosahujú centimetrovú presnosť a robustnosť v náročných prostrediach [55].

Vďaka efektívnejšiemu výkonu sú v súčasnosti rozšírenejšie skôr textúrne než priame metódy VO. Základné problémy, ktoré musí riešiť každý algoritmus textúrnej VO sú rekonštrukcia pohybu, nelineárna optimalizácia, párovanie textúr, rekonštrukcia hĺbky a aktualizácia stavu. Ich princíp vysvetlíme v nasledujúcich častiach podľa [29].

3.2.1 Rekonštrukcia pohybu

Pre rekonštrukciu pohybu kamery je potrebné získať 3D súradnice bodu na obraze z kamery. To je možné na základe tzv. *dierkového modelu kamery* (angl. *pinhole camera model*, viď obr. 3.2). Pre bod v priestore $\mathbf{P} = (x, y, z)^\top$ a jeho projekciu v rovine obrazu $\mathbf{p} = (u, v)^\top$ je projekčný model definovaný takto:


$$\begin{bmatrix} \mathbf{p} \\ 1 \end{bmatrix} \sim \begin{bmatrix} f_u & 0 & u_c & 0 \\ 0 & f_v & v_c & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{I} & \mathbf{0} \end{bmatrix} \mathbf{P}, \quad (3.1)$$

kde $\mathbf{K}$ je tzv. *matica kamery*, ktorá obsahuje vnútorné parametre kamery: fokálne vzdialenosti f_u, f_v a súradnice stredu optickej osi (u_c, v_c) .

Za predpokladu, že $\mathbf{P}$ je stacionárny bod v priestore, jeho projekcia v nasledujúcej snímke z kamery sa dá vyjadriť ako

$$\begin{bmatrix} \mathbf{p}' \\ 1 \end{bmatrix} \sim \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix} \begin{bmatrix} \mathbf{P} \\ 1 \end{bmatrix}, \quad (3.2)$$

kde rotačná matica $\mathbf{R} \in SO(3)$ a translačný vektor $\mathbf{t} \in \mathbb{R}^3$ predstavujú Euklidovskú transformáciu danú pohybom kamery.



Obr. 3.2: Dierkový model kamery – projekcia 3D bodu do 2D obrazu kamery (podľa [13])

V kontexte problému odhadu pohybu je transformácia $\begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}$ riešenou neznámou, ktorú je potrebné určiť na základe množiny 3D–2D korešpondencií $(x, y, z) \leftrightarrow (u', v')$. Tento problém je známy ako úloha *perspective-from-n-points* (PnP). Ak sa na celú projekčnú maticu $\mathbf{P} = \mathbf{K} \begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}$ pozeráme ako na problém čiernej skrinky (t. j. bez znalosti vnútorných závislostí), riešenie je možné získať jednoducho vyriešením homogénneho lineárneho systému. Takýto prístup je známy ako metóda *priamej lineárnej transformácie* (DLT) [29]. Rotácia určená týmto spôsobom však nemusí byť platným prvkom špeciálnej ortogonálnej skupiny $SO(3)$ kvôli nadbytočnej parametrizácii. Preto sa na nájdenie riešenia rovnice 3.2 v praxi často používa algoritmus *Efficient PnP* (EPnP) [43], ktorý ponúka výpočtovo efektívne a stabilné riešenie úlohy PnP. Jeho hlavnou výhodou je, že reprezentuje 3D body ako lineárnu kombináciu štyroch kontrolných bodov, čím znižuje počet neznámych a dosahuje lineárnu výpočtovú zložitosť vzhľadom na počet korešpondencií. Táto vlastnosť robí EPnP obzvlášť vhodným pre použitie v reálnom čase a v systémoch, kde sa pracuje s veľkým množstvom bodov, ako je tomu aj v tomto prípade.

3.2.2 Nelineárna optimalizácia

Pohyb kamery odhadnutý pomocou lineárnych metód (napr. DLT alebo EPnP), poskytuje len suboptimálne riešenie. Na dosiahnutie riešenia *metódou maximálnej vierohodnosti* (MLE) je potrebná nelineárna optimalizácia. Za predpokladu, že šum v meraniach má Gaussovské rozdelenie, možno odhad MLE pre N sledovaných textúr dosiahnuť minimalizáciou sumy štvorcov reprojekčnej chyby:

$$\phi_{\text{RPE}}(\mathbf{R}, \mathbf{t}) = \sum_{i=1}^N \|\mathbf{p}'_i - \pi_{\mathbf{K}}(\mathbf{R} \cdot \mathbf{P}_i + \mathbf{t})\|_{\Sigma_i}^2, \quad (3.3)$$

kde $\pi_{\mathbf{K}} : \mathbb{R}^3 \rightarrow \mathbb{R}^2$ je projekčná funkcia, ktorá zobrazuje 3D bod do projekčného priestoru P^2 pomocou matice kamery $\mathbf{K}$ a následne prevádza homogénne súradnice na karteziánske. Symbol $|\cdot|_{\Sigma}$ označuje Mahalanobisovu vzdialenosť vzhľadom na kovariančnú maticu Σ .

Na zvýšenie stability optimalizácie sa okrem korešpondencií 3D–2D zohľadňujú aj korešpondencie 2D–2D, t. j. $(u, v) \leftrightarrow (u', v')$, pre ktoré sa definuje epipolárna chybová funkcia:

$$\phi_{\text{EPI}}(\mathbf{R}, \mathbf{t}) = \sum_{i=1}^N \delta(\mathbf{p}_i, \mathbf{p}'_i; \mathbf{F}), \quad (3.4)$$

kde δ označuje Sampsonovu vzdialenosť [63] medzi dvojicou bodov vzhľadom na fundamentálnu maticu $\mathbf{F}$:

$$\delta(\mathbf{p}, \mathbf{p}'; \mathbf{F}) = \frac{(\mathbf{p}'^\top \mathbf{F} \mathbf{p})^2}{(\mathbf{F} \mathbf{p})_0^2 + (\mathbf{F} \mathbf{p})_1^2 + (\mathbf{F}^\top \mathbf{p}')_0^2 + (\mathbf{F}^\top \mathbf{p}')_1^2} \quad (3.5)$$

Fundamentálna matica $\mathbf{F}$ je definovaná ako:

$$\mathbf{F} = \mathbf{K}^{-\top} [\mathbf{t}]_{\times} \mathbf{R} \mathbf{K}^{-1}, \quad (3.6)$$

kde $[\mathbf{t}]_{\times}$ je antisymetrická matica odvodená z translačného vektora $\mathbf{t} = (t_x, t_y, t_z)^\top$:

$$[\mathbf{t}]_{\times} = \begin{bmatrix} 0 & -t_z & t_y \\ t_z & 0 & -t_x \\ -t_y & t_x & 0 \end{bmatrix} \quad (3.7)$$

Optimalizovaná funkcia energie, ktorá kombinuje reprojekčnú aj epipolárnu chybu, je definovaná ako:

$$\Phi(\mathbf{R}, \mathbf{t}) = (1 - \alpha) \cdot \phi_{\text{RPE}}(\mathbf{R}, \mathbf{t}) + \alpha \cdot \phi_{\text{EPI}}(\mathbf{R}, \mathbf{t}), \quad (3.8)$$

kde $\alpha \in [0, 1]$ je regulačný parameter určujúci váhu epipolárneho člena. Aby boli členy porovnateľné, hodnota α je normalizovaná vzhľadom na počet zodpovedajúcich bodov. Nech $\beta \in [0, 1]$ je požadovaný pomer váh, N_{RPE} počet 3D–2D korešpondencií a N_{EPI} počet 2D–2D korešpondencií. Potom sa α vypočíta nasledovne:

$$\alpha = \left(1 + \frac{N_{\text{EPI}}}{N_{\text{RPE}}} \cdot \frac{1 - \beta}{\beta} \right)^{-1} \quad (3.9)$$

Rovnicu (3.8) nie je možné vyriešiť v uzavretom tvare, a preto sa na jej minimalizáciu používa nelineárna optimalizačná metóda najmenších štvorcov, napríklad algoritmus Levenberg-Marquardt, pričom sa vychádza z lineárneho počiatočného odhadu.

3.2.3 Párovanie textúr

Párovanie obrazových textúr (angl. *feature matching*) sa bežne využíva na určenie 2D–2D pixelových korešpondencií, ktoré sú potrebné na výpočet členov vo vzťahu (3.4). Po vyriešení relatívneho pohybu aktuálneho snímku sa tieto korešpondencie znova využívajú na získanie 3D–2D korešpondencií požadovaných vo vzťahu (3.3), a to pomocou prístupu opísaného v nasledujúcej časti.

Príznačky sa spočiatku zladujú v príznakovom priestore. Nech $\mathcal{F}$ a $\mathcal{F}'$ označujú množiny príznakov (textúr) extrahovaných v dvoch po sebe idúcich snímkach. Príznak $\chi \in \mathcal{F}$ sa priradí k $\chi' \in \mathcal{F}'$ podľa pravidla:

$$\chi' = \arg \min_{\chi' \in \mathcal{F}'} d(\chi, \chi'), \quad (3.10)$$

kde $d : \mathcal{F} \times \mathcal{F}' \rightarrow \mathbb{R}$ je zvolená metrika podobnosti medzi dvoma príznakmi.

Nejednoznačné zhody sa identifikujú pomocou rozdielového pomeru. Nech $\tilde{\chi}' \in \mathcal{F}'$ označuje druhú najlepšiu zhodu pre príznak χ . Korešpondencia $\chi \rightarrow \chi'$ je považovaná za nejednoznačnú, ak platí:

$$\frac{d(\chi, \chi')}{d(\chi, \tilde{\chi}')} < r, \quad (3.11)$$

kde $r \in (0, 1)$ je vopred určený prah.

Nejednoznačné korešpondencie sa následne odstránia spätným overením z množiny $\mathcal{F}'$ do $\mathcal{F}$. Korešpondencia $\chi \rightarrow \chi'$ je považovaná za nekonzistentnú, ak:

$$\arg \min_{\tilde{\chi} \in \mathcal{F}} d(\tilde{\chi}, \chi') \neq \chi \quad (3.12)$$

Po aplikovaní podmienok (3.11) a (3.12) získame množinu jednoznačných a symetrických korešpondencií $\chi \leftrightarrow \chi'$.

Tieto korešpondencie sa ďalej rozširujú pomocou sledovania príznakov KLT [69] aplikovaného na príznaky z $\mathcal{F}$, ktoré sa nepodarilo spojiť s prvkami z $\mathcal{F}'$.

Na rozšírenej množine príznakov sa následne vykonáva eliminácia odľahlých bodov pomocou robustnej metódy RANSAC [21]. V každej iterácii sa náhodne vyberie päť korešpondencií, na základe ktorých sa odhadne esenciálna matica $\mathbf{E}$ pomocou päťbodového algoritmu [52]. Následne sa pre všetky zhody vypočítajú Sampsonove vzdialenosti vzhľadom na $\mathbf{E}$. Tento proces sa opakuje, kým sa nenájde dostatočný počet prilahlých bodov, ktoré súhlasia s esenciálnou maticou v rámci tolerovanej vzdialenosti, napríklad 0,5 pixelu.

3.2.4 Rekonštrukcia hĺbkky

Na odhad pohybu kamery v konzistentnej mierke je potrebné pracovať v Euklidovských súradniciach. V prípade monokulárneho systému však absolútnu mierku nie je možné

určiť iba na základe projekcie. Pohyb medzi prvým a druhým snímkom sa preto zvyčajne určuje pomocou dekompozície esenciálnej matice, ktorá následne slúži na rekonštrukciu 3D súradníc príznakov. Takto inicializovaný proces vizuálnej odometrie potom umožňuje určovať relatívny pohyb kamery v konzistentnej mierke počas celej sekvencie snímok.

Nech (u, v) a (u', v') označujú obrazové súradnice zodpovedajúceho príznaku $\chi \leftrightarrow \chi'$ v dvoch po sebe idúcich snímkach. Pri danom pohybe kamery $[\mathbf{R} \ \mathbf{t}]$ možno 3D súradnice príznaku χ rekonštruovať minimalizáciou nasledujúcej vzdialenosti vzhľadom na voľné parametre $k, k' \in \mathbb{R}^+$:

$$\delta_{\text{mid}}(k, k') = \|k \mathbf{a} - (k' \mathbf{a}' + \mathbf{c}')\|^2, \quad (3.13)$$

kde $\mathbf{a} = \mathbf{K}^{-1}(u, v, 1)^\top$ a $\mathbf{a}' = \mathbf{R}^\top \mathbf{K}^{-1}(u', v', 1)^\top$ sú smerové vektory spätných projekcií lúčov v prvom a druhom snímku. Vektor $\mathbf{c}' = -\mathbf{R}^\top \mathbf{t}$ predstavuje nový stred kamery (t. j. pozíciu kamery po pohybe).

Minimum vo výraze (3.13) možno nájsť ako riešenie metódy najmenších štvorcov pre nasledujúcu lineárnu sústavu:

$$\begin{bmatrix} \mathbf{a} & -\mathbf{a}' \end{bmatrix} \begin{bmatrix} k \\ k' \end{bmatrix} = \mathbf{A} \begin{bmatrix} k \\ k' \end{bmatrix} = \mathbf{c}' \quad (3.14)$$

Výsledné hodnoty k a k' určujú dva body na príslušných spätných lúčoch (zodpovedajúcich príznaku χ v oboch snímkach), ktoré sú v priestore k sebe najbližšie.

Stred týchto dvoch bodov, ktorý predstavuje 3D odhad súradníc príznaku, sa potom vypočíta ako:

$$(x, y, z)^\top = \frac{1}{2} \left(\begin{bmatrix} \mathbf{a} & \mathbf{a}' \end{bmatrix} (\mathbf{A}^\top \mathbf{A})^{-1} \mathbf{A}^\top + \mathbf{I} \right) \mathbf{c}' \quad (3.15)$$

Týmto spôsobom sa získa odhad 3D súradníc príznaku, pričom tento postup je známy ako *triangulácia pomocou stredového bodu* (angl. *mid-point triangulation*).

3.2.5 Aktualizácia stavu

Na zlepšenie stability procesu vizuálnej odometrie sa stavy sledovaných príznakov uchovávaajú počas celej sekvencie. Nech $\mathbf{m}_{i,k}$ je pozorovaný stavový vektor príznaku i v snímke k a $\omega_{i,k} \in \langle 0, 1 \rangle$ je váha vyjadrujúca mieru dôvery, že pozorovanie zodpovedá skutočnému stavu. Odhad skutočného stavu sa potom vypočíta ako:

$$\hat{\mathbf{m}}_{i,k} = \frac{\hat{\omega}_{i,k-1} \cdot f_{k-1,k}(\hat{\mathbf{m}}_{i,k-1}) + \omega_{i,k} \cdot \mathbf{m}_{i,k}}{\hat{\omega}_{i,k}}, \quad (3.16)$$

kde $\hat{\omega}_{i,k} = \hat{\omega}_{i,k-1} + \omega_{i,k}$ predstavuje kumulatívnu váhu a $f_{k-1,k}$ je prechodová funkcia, ktorá transformuje stav z predchádzajúceho snímku $k-1$ do aktuálneho snímku k .

Na dočasné zlepšenie odhadov hĺbok sledovaných príznakov možno vektor $\mathbf{m}$ interpretovať ako 3D súradnice príznaku a následne aplikovať aktualizčný vzťah (3.16). V tomto prípade je $f_{k-1,k}$ Euklidovská transformácia určená odhadnutým relatívnym pohybom kamery $\begin{bmatrix} \mathbf{R}_k & \mathbf{t}_k \end{bmatrix}$, a váha sa nastavuje ako:

$$\omega_{i,k} = \frac{1}{1 + \delta_{i,k}}, \quad (3.17)$$

kde $\delta_{i,k}$ je odhadnutá chyba triangulácie. V prípade použitia metódy triangulácie pomocou stredového bodu sa $\delta_{i,k}$ definuje ako súčet najkratších vzdialeností triangulovaného bodu od oboch spätných projekčných lúčov.

3.2.6 Prehľad súčasných riešení

Jedným z prvých algoritmov na extrakciu textúr bol algoritmus SIFT, v súčasnosti sa skôr využívajú jeho alternatívy SURF a ORB, ktoré popisujeme nižšie.

SIFT

Algoritmus SIFT, ktorý predstavil Lowe v roku 1999 [45], patrí medzi najskoršie komplexné metódy detekcie kľúčových bodov a extrakcie deskriptorov príznakov. Na zabezpečenie mierkovej invariance buduje SIFT viacúrovňovú pyramídu z rozmazaných verzií vstupného obrazu a aplikuje operátory rozdielu Gaussov (DoG) na detekciu lokálnych extrémov v mierkovom priestore. Lokálnosť je definovaná oknom veľkosti $3 \times 3 \times 3$. Vybrané sú iba extrémy s vysokým lokálnym kontrastom, ktoré neležia na hranách – tie sa označujú ako kľúčové body.

V okolí každého kľúčového bodu sa v okne 16×16 počítajú gradienty obrazu, ktoré sa následne zoskupia do 4×4 podoblastí. V každej podoblasti sa gradienty kvantizujú do osem-prvkového histogramu smerov. Spojením všetkých histogramov (16 oblastí $\times 8$ binov) vzniká vektor deskriptora dĺžky 128 prvkov.

SURF

Šesť rokov po zavedení SIFT predstavili autori Bay a kol. algoritmus SURF [9], ktorý mal byť rýchlejší a robustnejší. Namiesto DoG operátorov využíva SURF aproximované druhé derivácie výpočtom pomocou filtrov s rovnomerným váhovaním, ktoré možno efektívne aplikovať pomocou integrálneho obrazu. To umožňuje výrazné zrýchlenie oproti SIFT.

Robustnosť SURF príznakov spočíva v určení dominantného smeru oblasti okolo kľúčového bodu ešte pred výpočtom deskriptora. Tento smer sa odhaduje na základe Gaussovsky vážených odpovedí na horizontálne a vertikálne Haarove vlnenia v kruhovej oblasti okolo kľúčového bodu. Odpovede sa prevedú do polárnych súradníc, rozdelia do uhlových segmentov a v každom sa spočítajú vektorové odpovede. Smer segmentu

s najdlhším súčtovým vektorom je určený ako dominantný smer lokálneho okolia. Na základe tohto smeru sa potom oblasť rotuje a extrahuje sa Gaussovsky vážený deskriptor z odpovedí na Haarove vlnenia.

ORB

Algoritmus ORB, ktorý v roku 2011 navrhli autori Rublee a kol. [59], predstavuje rýchlu a výpočtovo nenáročnú alternatívu k SIFT a SURF. Kombinuje modifikovaný detektor FAST [57] s rotačne invariantnou verziou binárneho deskriptora BRIEF [12].

Pre dosiahnutie mierkovej invariance sa FAST detekcia opakuje na každej úrovni mierkovej pyramídy. Výber príznakov je ďalej filtrovaný pomocou Harrisovej miery [26], ktorá odstraňuje body, ktoré nie sú rohmi.

Deskriptory sa tvoria ako binárne reťazce dĺžky n porovnávaním jasov vopred určených dvojíc pixelov v okolí príznaku. Keďže pôvodný BRIEF nie je rotačne invariantný, ORB najprv určí smer každého príznaku pomocou metódy obrazových momentov [35]. Smer príznaku je určený vektorom spájajúcim jeho stred s centroidom príslušnej obrazovej oblasti. Tento smer sa následne použije na rotáciu testovacej masky pred extrakciou binárneho deskriptora, čím sa dosahuje rotačná invariantnosť.

3.2.7 Vizualný SLAM

Kým vizuálna odometria sa zameriava predovšetkým na lokálny odhad pohybu kamery medzi po sebe idúcimi snímkami, cieľom vizuálneho SLAM-u je súčasne odhadovať trajektóriu kamery aj rekonštruovať štruktúru pozorovaného prostredia. To si vyžaduje riešiť zložitejšie problémy, ako je uzatváranie slučiek, správa globálnej konzistentnej mapy či eliminácia chýb akumulovaných počas lokalizácie.

Kľúčovou súčasťou väčšiny moderných SLAM systémov je nelineárna optimalizácia známa ako „bundle adjustment“, ktorá umožňuje spresniť odhady pozícií kamery aj 3D súradníc pozorovaných bodov (tzv. mapových bodov) tak, aby čo najlepšie zodpovedali skutočným pozorovaniam. Hoci je táto technika výpočtovo náročná, vývoj efektívnych algoritmov a organizačných princípov umožnil jej využitie aj v reálnom čase.

Aby bol vizuálny SLAM efektívny a zároveň presný, systém musí zabezpečiť:

1. výber tzv. *klúčových snímkok* (angl. *keyframes*), ktoré reprezentujú rôzne pohľady na scénu a poskytujú dostatočnú paralaxu pre rekonštrukciu hĺbky,
2. sledovanie spoločných prvkov scény medzi kľúčovými snímkami, čo vytvára dobre prepojenú sieť pozorovaní (tzv. *graf snímkok*),
3. dobrý počiatočný odhad pozícií snímkok aj 3D bodov, ktorý slúži ako vstup pre optimalizáciu,

4. lokálne obmedzenú optimalizáciu, ktorá znižuje výpočtové nároky a umožňuje škálovateľnosť,
5. globálne optimalizačné kroky – napríklad optimalizáciu grafu pozícií snímok – ktoré umožňujú uzatváranie slučiek v reálnom čase.

Jednou z najznámejších a široko používaných implementácií vizuálneho SLAM-u, ktorá úspešne spája všetky vyššie uvedené aspekty, je algoritmus ORB-SLAM [51].

ORB-SLAM

ORB-SLAM je komplexný systém vizuálneho SLAM-u, prvýkrát predstavený v roku 2015, ktorý využíva len jednu monokulárnu, stereo alebo RGB-D kameru a je schopný pracovať v reálnom čase. Systém je postavený na ORB detekcii príznakov, pričom tá istá sada príznakov je využívaná na všetky úlohy: sledovanie pohybu, mapovanie aj uzavretie slučky. ORB-SLAM spája klasickú odometriu s mapovaním a optimalizáciou, čím umožňuje presnú a konzistentnú lokalizáciu aj pri dlhodobom sledovaní scény. Pozostáva z troch základných modulov, ktoré spolupracujú paralelne v reálnom čase:

1. Sledovanie (Tracking)

Tento modul sa stará o spracovanie prichádzajúcich snímok a odhad pohybu kamery vzhľadom na mapu. Ak mapa ešte nie je inicializovaná, vykoná sa monokulárna triangulácia medzi prvými dvoma kľúčovými snímkami. V ďalších krokoch modul odhaduje pozíciu novej snímky pomocou zodpovedajúcich ORB príznakov a porovnaním s aktuálnou mapou. V prípade výraznej zmeny scény alebo straty sledovania môže byť iniciovaný relokalizáciou pomocou databázy kľúčových snímok.

2. Správa mapy (Local Mapping)

Body v mape sa triangulujú zo zodpovedajúcich príznakov v rôznych snímkach. Počas spracovania sa vyberajú nové kľúčové snímky, ktoré rozširujú mapu a umožňujú jej lokálnu optimalizáciu pomocou lokálnej *balíkovej optimalizácie* (angl. *bundle adjustment*). Výber kľúčových snímok je optimalizovaný tak, aby zachytili dostatočný pohyb a nový pohľad na scénu, ale zároveň nezahltili systém nadbytočnými údajmi.

3. Uzatváranie slučiek (Loop Closing)

Na odstránenie akumulovaných chýb a dosiahnutie globálnej konzistencie systému využíva ORB-SLAM detekciu slučiek, t. j. opätovného návratu kamery do už navštívených oblastí. Po detekcii slučky sa vykoná globálna optimalizácia grafu pozícií snímok (angl. *pose graph*), ktorá opraví globálnu trajektóriu a prispôsobí mapu.

Pre efektívne porovnávanie snímok a detekciu slučiek používa ORB-SLAM prístup tzv. *zásobníka slov* (angl. *Bag of Words*), ktorý umožňuje rýchle vyhľadávanie vizuálne podobných snímok na základe ORB deskriptorov.

System poskytuje ako výstup trajektóriu kamery a riedku trojrozmernú rekonštrukciu scény – s dostatočnou presnosťou pre potreby lokalizácie, ale zároveň s dôrazom na výpočtovú efektivitu.

3.3 Lidarová odometria

Téma lidarovej odometrie (LO) zaznamenala v posledných niekoľkých rokoch veľký rozmach, keďže prináša nové možnosti aplikácie zvlášť v prostrediach a podmienkach, kde sú iné spôsoby lokalizácie nedostatočné. Neustále pribúdajú nové riešenia, ktoré využívajú lidar spolu s ďalšími modernými prístupmi a technológiami za účelom získania čo najpresnejšej polohy.

3.3.1 LiDAR technológia

Light Detection and Ranging (LiDAR) je technológia diaľkového snímania založená na meraní času, za ktorý sa laserový impulz odrazí späť od objektu. Výsledkom sú vysoko presné 3D reprezentácie prostredia vo forme mračien bodov (z angl. *point clouds*). Lidar je nezávislý od osvetlenia a stal sa kľúčovým senzorom v oblasti autonómnej navigácie a mapovania [42].

Lidary možno klasifikovať podľa dvoch hlavných kritérií [42]:

1. Mechanizmus snímania:

- *mechanický* – využíva rotujúce časti na rozptyl lúčov. Ponúka široké zorné pole, dobrú kvalitu meraní, ale tá môže časom degradovať vplyvom opotrebovania mechanických prvkov;
- *polovodičový (angl. solid-state)* – nepohyblivé systémy (napr. MEMS, OPA), ktoré sú kompaktnjšie a menej poruchové. Využívajú sa technológie MEMS, ktorá rozptyľuje stacionárny lúč pomocou elektromechanických zrkadiel alebo OPA, ktorá využíva moduláciu tvaru svetelných vln;
- *s plošným osvetlením (angl. flash)* – osvetľuje celé zorné pole naraz, veľmi rýchly, no menej používaný v odometrii.

2. Princíp merania:

- *čas letu (ToF)* – meria vzdialenosť na základe rýchlosti svetla a doby letu laserového impulzu, za ktorú sa odrazí od objektu a vráti naspäť. Je jednoduchý a presný, no môže byť náchylný na rušenie externými svetelnými zdrojmi.

- *frekvenčne modulovaná spojité vlna (FMCW)* – vysiela súvislé svetelné vlny s premenlivou frekvenciou a analyzuje frekvenčný posun odrazeného svetla, ktorý je priamo úmerný vzdialenosti objektu. Poskytuje navyše aj informácie o relatívnej rýchlosti. Je rezistentný voči interferencii a viaccestnému šíreniu, ale zložitejší a zvyčajne drahší než ToF.
- *amplitúdovo modulovaná spojité vlna (AMCW)* – meria čas odrazu pomocou vysielania vln s variabilnou amplitúdou.

3.3.2 Prehľad metód lidarovej odometrie

Cieľom LO je odhadnúť trajektóriu robota na základe údajov z lidar. Kľúčom k tomu je princíp odometrie, spočívajúci vo vyhodnotení posunu od predošlému stavu k súčasnemu, čo je však prípade lidarového mračna bodov podstatne komplexnejšie úloha než v prípade kolesovej odometrie. Prístupov k riešeniu tohto problému je mnoho, ponúkame teda najvýznamnejšie z nich podľa zdroja [42].

Odometria založená výlučne na lidare (angl. LiDAR-only odometry)

Využíva výhradne údaje z jedného lidar, pričom porovnáva rozdiel medzi predošlým a súčasným skenom. Jej výhodou je nezávislosť od iných senzorov, nevýhodou nižšia robustnosť v degenerovaných prostrediach. Delí sa na:

- *Metódy priamej zhody (angl. direct matching)* – sú založené na odhade transformačnej matice medzi po sebe nasledujúcimi skenmi, najčastejšie pomocou ICP algoritmu (viac v kap. 3.3.3).
- *Textúrne zamerané prístupy (angl. feature-based)* – sú založené na extrakcii významných bodov z mračna bodov a ich použití na odhad transformačného pohybu medzi skenmi, vďaka čomu sú výpočtovo efektívnejšie a odolnejšie voči šumu. Kľúčovou úlohou je však výber vhodných príznakov. Príkladmi implementácie je LOAM, ktorý rozlišuje medzi hranovými a rovinnými bodmi podľa lokálnej hladkosti povrchu či SuMa, resp. SuMa++, ktoré využívajú normálové mapy povrchu a zohľadňujú aj sémantické informácie, čo zvyšuje robustnosť voči chybám registrácie.
- *Metódy hlbokého učenia (angl. deep learning-based)* – pokúšajú sa zlepšiť nachádzanie zhody medzi skenmi pomocou DL prístupov. Túto triedu zastupujú algoritmy ako LO-Net, ktorý predvída dynamiku jednotlivých regiónov a LodoNet, kde sa využíva proces spätnej projekcie zhodných párov kľúčových bodov (MKP).

Lidarovo-inerciálna odometria (LIO)

Ide o kombináciu dát z lidarů a IMU. Prináša vyššiu presnosť a stabilitu. Existujú dve jej variácie podľa toho, akým spôsobom sú spracúvané údaje z IMU:

- *voľne previazaná (angl. loosely coupled)* – spracovanie údajov prebieha samostatne, následne sú fúzované na základe pridelených váh, napr. pomocou EKF.
- *tesne previazaná (angl. tightly coupled)* – optimalizuje všetky merania v spoločnom grafe (napr. LIO-SAM, CLINS). Je výpočtovo náročnejšia a môže byť zraniteľná v prípade, že jeden zo senzorov poskytuje nekvalitné údaje.

Fúzia viacerých senzorov

S cieľom zvýšiť kvalitu merania celého systému (zorné pole, presnosť, robustnosť, ...) sa často využíva kombinácia viacerých senzorov, pričom treba rozlišovať dva základné typy:

- *kombinácia viacerých lidarů* – predchádza dôsledkom výpadku meraní pri použití jediného lidarů, zároveň však kladie vyššie nároky na synchronizáciu a výpočty (napr.);
- *kombinácia lidarů a iných senzorů* – fúzia s kamerami, radarimi, termálnymi senzormi či IMU kompenzuje nedostatky lidarů v nevhodných prostrediach akými sú nepriaznivé poveternostné podmienky či monotónne štruktúry (napr. tunely či diaľnice).

Predmetom výskumu LO sú viaceré pretrvávajúce nedostatky riešení. Spracovanie veľkého množstva údajů si vyžaduje využitie efektívnych dátových štruktúr (napr. ikd-Tree [11], iVox [6]). Pri pohybe lidarů dochádza k skresleniu nameraných dát, čo sa rieši zavádzaním vyrovnávacích korekcií a modelov trajektórie. Spoľahlivosť LO stále ovplyvňuje aj povaha okolitého prostredia. V monotónnych prostrediach je preto nevyhnutné aj využitie intenzity merania, Dopplerovho efektu či fúzie s kamerou. Pri fúzii s inými senzormi sú však výzvami faktory ako presná kalibrácia a synchronizácia, ale aj výpočtová náročnosť. Z povahy princípu fungovania lidarů sú problémové najmä daždivé, hmlisté či reflexné prostredia; pre tieto prípady už vznikli viaceré riešenia, napr. WeatherNet alebo LIOR [42].

3.3.3 Iteratívny algoritmus najbližších bodů (ICP)

Jedným z najpoužívanějších súčasných prístupů pre geometrické zarovnanie pri registrácii trojrozmerných povrchů je Iteratívny algoritmus najbližších bodů (ICP). Jeho pôvodná verzia bola vytvorená autormi Besl a kol. [10] v roku 1992, no modifikácie sú vyvíjané dodnes. Trojrozmerná registrácia povrchu je proces, ktorý zarovnáva 3D

mračno bodov (napr. z hĺbkovej kamery alebo z lidar) z rôznych uhlov pohľadu za účelom získania úplnejšej reprezentácie prostredia a určenia pohybu senzora. V prípade, že vstupné dáta sú asociované, t. j. je známa korešpondencia $\mathcal{C}(\mathbf{s}_i) = \{(i, j)\}$ medzi zdrojovým mračnom $\mathcal{S} = \{\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_I\}$ a cieľovým mračnom $\mathcal{D} = \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_J\}$, je možné ich vzájomnú transláciu $\mathbf{t}$ a rotáciu $\mathbf{R}$ určiť minimalizáciou sumy štvorcov odchýlok ako

$$\mathcal{F}(\mathcal{C}(\mathcal{S}), \mathcal{S}, \mathcal{D}) = \min_{\mathbf{R}, \mathbf{t}} \sum_{i=1}^I \sum_{j=1}^J \|\mathbf{d}_i - \mathbf{R} \cdot \mathbf{s}_j - \mathbf{t}\|_2^2 \quad (3.18)$$

Avšak v prípadoch, kedy korešpondencia známa nie je, asociáciu medzi mračnami bodov je potrebné získať heuristicky. Na to existuje viacero metód, napr. numerická Newtonova metóda či dynamický genetický algoritmus, no najčastejšie sa na tento účel využívajú práve variácie ICP algoritmu [5].

Podstata algoritmu spočíva v troch základných krokoch:

1. počiatočný odhad možných asociácií na základe vstupných dát,
2. iteratívne transformovanie cieľového mračna bodov k zdrojovému tak, aby sa minimalizovala celková odchýlka, až kým sa nedosiahne prahová hodnota konvergenzie,
3. výpočet výslednej translácie a rotácie.

Podrobnejšie je celý proces znázornený v algoritme 1, kde je sú vstupmi zdrojové mračno bodov $\mathcal{S}$, cieľové mračno bodov $\mathcal{D}$ a prah konvergenzie θ . Ďalej v ňom vystupuje operátor výpočtu ťažiska $\mathcal{M}$, operátor registrácie povrchov pri známych korešpondenciách $\mathcal{F}$, odchýlku ε vypočítanú pre danú iteráciu, množinu korešpondencií $\mathcal{C} = \{(i, j)\}$, operátor tuhého transformačného odhadu $\mathcal{T}$ a operátor aplikácie transformácie $\mathbf{T}_{\mathbf{R}, \mathbf{t}}$.

Algoritmus 1 Základný ICP algoritmus podľa [5]

Require: $\mathcal{S} = \{\mathbf{s}_1, \mathbf{s}_2, \dots, \mathbf{s}_I\}$, $\mathcal{D} = \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_J\}$, θ

Ensure: $\mathbf{T}_{\mathbf{R}, \mathbf{t}}$, $\varepsilon_k \leq \theta$

- 1: $\mathcal{T}(\mathcal{S} \rightarrow \mathcal{D})$ s.t. $\mathcal{M}(\mathcal{S}) = \mathcal{M}(\mathcal{D})$
 - 2: $\varepsilon_0 \leftarrow \infty$
 - 3: **while** $(\varepsilon_k > \theta \wedge \varepsilon_k < \varepsilon_{k-1}) \vee \varepsilon_k = \infty$ **do**
 - 4: **for** $\mathbf{s}_i \in \mathcal{S}$ **do**
 - 5: $\mathcal{C}(\mathbf{s}_i) \leftarrow (\mathbf{d}_j, \mathbf{s}_i)$ s.t. $\|(\mathbf{d}_j, \mathbf{s}_i)\|^2 \rightarrow \min$
 - 6: **end for**
 - 7: $\mathbf{T}_{\mathbf{R}, \mathbf{t}} \leftarrow \mathcal{F}(\mathcal{C}(\mathcal{S}), \mathcal{S}, \mathcal{D})$
 - 8: $\varepsilon_{k+1} \leftarrow \frac{1}{|I|} \sum_{i=1}^I (\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_j)^2$
 - 9: **end while return** $\mathbf{T}_{\mathbf{R}, \mathbf{t}}$
-

Ako už bolo spomenuté, existuje viacero variantov ICP algoritmu, ktoré je možné rozdeliť na základe viacerých kritérií [61]:

1. Podľa typu minimalizačnej metriky:

- *bod na bod* – najjednoduchšia verzia, minimalizuje euklidovskú vzdialenosť medzi korešpondujúcimi bodmi, vhodná pri povrchoch bez výraznej štruktúry

$$\min_{\mathbf{R}, \mathbf{t}} \sum_i \|\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_i\|^2$$

- *bod na plochu* – minimalizuje vzdialenosť od bodu k rovine určenej normálou cieľového bodu, rýchlejšie konverguje, vhodný pre hladké povrchy

$$\min_{\mathbf{R}, \mathbf{t}} \sum_i [(\mathbf{R} \mathbf{s}_i + \mathbf{t} - \mathbf{d}_i) \cdot \mathbf{n}_i]^2$$

- *plocha na plochu* – predpokladá, že oba body majú definované normály a minimalizuje vzdialenosť medzi dotyčnými rovinami. Používa sa napr. v NDT-ICP alebo pokročilých SLAM systémoch.

2. Podľa stratégie výberu korešpondencií:

- *Brute-force nearest neighbor* – každý bod zo zdrojového mračna sa spáruje s najbližším bodom v cieľovom;
- *Mutual nearest neighbor* – korešpondencia sa akceptuje iba vtedy, ak si oba body navzájom zodpovedajú ako najbližší sused;
- *Color ICP* – pri výbere korešpondencií sa berie do úvahy aj podobnosť farby alebo intenzity;
- *Feature-based ICP* – body sú doplnené o deskriptory a párujú sa na základe ich podobnosti.

3. Podľa robustnosti a rýchlosti:

- *Generalized ICP (G-ICP)* – spája metódy *bod na bod* a *bod na plochu* pomocou modelovania pravdepodobnostného rozloženia bodov ako Gaussových distribúcií, vhodný pre zarovnávanie s neistotou alebo nehomogenitou;
- *Sparse ICP* – používa len podmnožinu bodov, čo šetrí výpočtový čas;
- *Robust ICP* – používa robustné funkcie na potlačenie vplyvu odľahlých bodov.
- *Color/Photometric ICP* – rozširuje ICP o intenzitné alebo farebné informácie (vhodné pri RGB-D údajoch).

4. Iné pokročilé varianty:

- *Normal Distributions Transform (NDT)* – Mračná bodov sa reprezentujú ako hustotné mapy (napr. v bunkách), nie ako explicitné body;
- *Iterative Closest Line/Keypoint (ICLK)* – rozšírenia pre špecifické geometrie (čiary, body, hrany);
- *KISS-ICP* – minimalistický robustný point-to-point ICP s adaptívnym prahom a robustným jadrom.

KISS ICP

KISS-ICP predstavuje odľahčený variant klasického ICP algoritmu typu *bod na bod* pre LO. Cieľom autorov bolo preukázať, že dobre navrhnuté jednoduché komponenty dokážu prekonať zložité metódy. Systém má rádovo menej parametrov než iné metódy a väčšinou nevyžaduje žiadne špecifické ladenie pre rôzne typy lidarov či prostredia [74].

Algoritmus prebieha v štyroch základných krokoch. Najskôr sa vykonáva predikcia a kompenzácia pohybu (angl. *deskewing*), ktorej cieľom je kompenzovať rozptyl mieraných bodov spôsobený pohybom lidarů počas skenovania a predpovedať aktuálnu pozíciu registrovaných bodov. Namiesto fúzie s kolesovou odometriou či IMU sa v tomto prípade používa model konštantnej rýchlosti, a to práve pre jeho jednoduchosť a nezávislosť od ďalších senzorov či časovej synchronizácie. Model konštantnej rýchlosti predikuje aktuálnu polohu $\mathbf{T}_{pred,t}$ v čase t na základe rozdielu dvoch predošlých polôh definovaných pomocou translačného vektora a rotačnej matice $\mathbf{T}_{t-1} = (\mathbf{R}_{t-1}, \mathbf{t}_{t-1})$, $\mathbf{T}_{t-2} = (\mathbf{R}_{t-2}, \mathbf{t}_{t-2})$, pričom sa predpokladá, že translačná $\mathbf{v}_t$ a rotačná rýchlosť $\boldsymbol{\omega}_t$ sa nemení.

Predikovaná poloha a z toho odvodené rýchlosti sa vypočítajú ako

$$\mathbf{T}_{pred,t} = \begin{bmatrix} \mathbf{R}_{t-2}^\top \mathbf{R}_{t-1} & \mathbf{R}_{t-2}^\top (\mathbf{t}_{t-1} - \mathbf{t}_{t-2}) \\ \mathbf{0} & 1 \end{bmatrix}, \quad (3.19)$$

$$\mathbf{v}_t = \frac{\mathbf{R}_{t-2}^\top (\mathbf{t}_{t-1} - \mathbf{t}_{t-2})}{\Delta t}, \quad (3.20)$$

$$\boldsymbol{\omega}_t = \frac{\text{Log}(\mathbf{R}_{t-2}^\top \mathbf{R}_{t-1})}{\Delta t}, \quad (3.21)$$

kde Δt je čas akvizície lidarového snímku a $\text{Log} : SO(3) \rightarrow \mathbb{R}^3$ extrahuje osovo-uhlovú reprezentáciu rotácie. Ďalej sa predpokladá, že každý zosnímaný bod v jednom skene $\mathbf{p}_i \in \mathcal{P}$ má relatívnu časovú značku v rozmedzí $s_i \in \langle 0, \Delta t \rangle$, predstavujúcu uplynutý čas od začiatku snímania daného skenu. Korekcia pozície nameraných bodov je potom počítaná ako

$$\mathbf{p}_i^* = \text{Exp}(s_i \boldsymbol{\omega}_t) \mathbf{p}_i + s_i \mathbf{v}_t, \quad (3.22)$$

kde $\text{Exp} : \mathbb{R}^3 \rightarrow SO(3)$ počíta rotačnú maticu z osovo-uhlovej reprezentácie.

Následne prebieha podvzorkovanie skenu pre zefektívnenie registrácie mračien. Mnohé iné prístupy vyhľadávajú význačné body, čo však pridáva ďalšiu vrstvu komplexnosti. KISS-ICP namiesto toho pracuje s dvojkrokovým podvzorkovaním pomocou tvz. *voxelov*, teda trojrozmerných buniek. Kým lokálna mapa je reprezentovaná voxelovou mriežkou s rozlíšením $v \times v \times v$, v prvom kroku je vstupné mračno $\mathcal{P}^*$ podvzorkované na voxely veľkosti αv – čím vzniká mračno $\mathcal{P}_{\text{merge}}^*$ ktoré je neskôr použité na aktualizáciu mapy – a v druhom kroku na voxely veľkosti βv za vzniku mračna $\hat{\mathcal{P}}^*$, ktoré sa použije na registráciu, platí $\alpha \in (0, 1)$ a $\beta \in \langle 1, 2 \rangle$. Na rozdiel od iných metód, v ktorých sa súradnice voxelu určujú ako priemer všetkých bodov, ktoré obsahuje, v tomto prípade sa použijú súradnice prvého bodu spadajúceho pod daný voxel, čím sa zamedzí vzniku diskretizačnej odchýlky, a teda platí $\hat{\mathcal{P}}^* \subseteq \mathcal{P}^*$

Ďalším krokom je určenie korešpondencií. Oproti klasickému ICP, kde sa porovnávajú dva po sebe nasledujúce snímky, KISS-ICP registruje vstupný snímok na celú lokálnu mapu, teda množinu všetkých v minulosti registrovaných bodov. Následne sa voxelová mriežka mapy doplní o novo registrované body s tou podmienkou, že každý voxel má obmedzenú kapacitu, čo opäť cieľi na celkovú efektivitu algoritmu. Na nastavenie prahovej hodnoty τ_t pre filtráciu odlahľých bodov sa využíva adaptívny výpočet. Ten zohľadňuje veľkosť zrýchlenia, ktoré spôsobuje nepresnosť predikcie v predchádzajúcich krokoch.

Proces získania globálneho odhadu polohy $\mathbf{T}_t$ začína transformáciou vstupného mračna pomocou predošlej polohy $\mathbf{T}_{t-1}$ a predikcie $\mathbf{T}_{\text{pred},t}$:

$$\mathcal{S} = \{\mathbf{s}_i = \mathbf{T}_{t-1} \mathbf{T}_{\text{pred},t} \mathbf{p} \mid \mathbf{p} \in \hat{\mathcal{P}}^*\} \quad (3.23)$$

V každej iterácii j sa získa množina korešpondencií medzi mračnom $\mathcal{S}$ a lokálnou mapou $\mathcal{L} = \{\mathbf{q}_i \mid \mathbf{q}_i \in \mathbb{R}^3\}$ pomocou metódy najbližšieho suseda s prahovou hodnotou τ_t . Odhad korekcie polohy sa potom počíta takto:

$$\Delta \mathbf{T}_{\text{est},j} = \underset{\mathbf{T}}{\text{argmin}} \sum_{(s,q) \in \mathcal{C}(\tau_t)} \rho(\|\mathbf{T}\mathbf{s} - \mathbf{q}\|_2), \quad (3.24)$$

kde $\mathcal{C}(\tau_t)$ je množina korešpondencií najbližších susedov, ktorých vzdialenosť je menšia ako τ_t a ρ je Geman-McClure-ova robustná účelová funkcia. Vstupné body sú potom aktualizované pomocou vypočítanej korekcie, pričom celý postup sa opakuje až kým nie je splnená podmienka konverencie, ktorou je $\Delta \mathbf{T}_{\text{est},j} < \gamma$:

$$\{\mathbf{s}_i \leftarrow \Delta \mathbf{T}_{\text{est},j} \mathbf{s}_i \mid \mathbf{s}_i \in \mathcal{S}\} \quad (3.25)$$

Výsledkom je tak transformácia $\mathbf{T}_t = \Delta \mathbf{T}_{\text{icp},t} \mathbf{T}_{t-1} \mathbf{T}_{\text{pred},t}$. Napokon, korekcia je aplikovaná na mračno $\mathcal{P}_{\text{merge}}^*$, ktoré je následne integrované do lokálnej mapy.

3.4 Inerčné snímače

Inerčné snímače, resp. snímače zotrvačnosti slúžia na meranie vlastných stavových veličín – lineárnych a uhlových rýchlostí a zrýchlení robota. Nemerajú polohu priamo, ale v kombinácii s inými meraniami polohy môžu prispieť k spresneniu odhadu polohy a korekcii chýb iných meraní. Zaraďujeme tu gyroskopy, akcelerometre a tiež magnetometre.

3.4.1 Gyroskopy

Gyroskopy zaznamenávajú zmeny v natočení objektu, pričom poskytujú informáciu o orientácii, príp. jej zmene vo všetkých osiach. Ich výstupom sú hodnoty vzťahnuté na pevný referenčný rámec. Väčšinou nie sú citlivé na elektromagnetické a feromagnetické anomálie, takže na rozdiel od magnetických kompasov je ich využitie možné aj v prostrediach bez prítomnosti geomagnetického poľa [16].

Gyroskopy je možné podľa technológie merania rozdeliť na mechanické a optické. Podľa typu výstupných dát sa delia na derivačné a integračné. Výstup derivačných gyroskopov je úmerný rotácii. Integračné gyroskopy sú schopné poskytnúť aj informáciu o absolútnej polohe pomocou integrovania relatívnych hodnôt vzťahnutých na globálnu referenciu. Podobne ako u odometrických snímačov, aj v tomto prípade dochádza driftu. Na jeho potlačenie je možné využiť niektorú z techník [16]:

- potlačenie šumu odstránením odľahlých hodnôt,
- potlačenie šumu aplikáciou metódy klzavého priemeru,
- aplikácia mierky na zmenu absolútnych uhlov,
- recalibrácia gyroskopu vzorkovaním na strednú hodnotu,
- recalibrácia gyroskopu vzorkovaním na minimálnu a maximálnu hodnotu.

Mechanické gyroskopy

Fungujú na princípe zákona zachovania hybnosti, pričom sa delia podľa toho, aký typ hybnosti využívajú [16]:

1. *spojitá uhlová hybnosť* – gyroskopy so zotrvačníkom, čiastkové gyroskopy,
2. *kmitajúca uhlová rýchlosť* – gyroskopy s torznou závesnou hmotou kmitajúcou na vlastnej frekvencii,
3. *spojitá lineárna hybnosť* – gyroskopy so stabilným tokom tekutiny, plazmy alebo elektrónov, ktoré majú tendenciu udržiavať vektor svojej rýchlosti pri otáčaní meracej platformy,

4. *kmitajúca lineárna hybnosť* – gyroskopy používajúce množinu kmitajúcej diskretnéj hmoty, pričom kmity sú vyvolané pozdĺž rovných čiar.


Mechanický gyroskop na báze zotrvačníka pozostáva s rýchlo rotujúceho kotúča alebo gule, ktorej väčšina hmoty je sústredená na vonkajšej periférii, a to pre dosiahnutie vyššieho momentu zotrvačnosti. Rotujúce teleso je upevnené na dvoch na seba kolmých voľne rotujúcich osiach. Rotácia kotúča okolo prvej osi spôsobuje vznik momentu hybnosti L . Pri vzniknutí krútiaceho momentu τ na kolmú os (vplyvom vonkajších síl) dochádza k zmene smeru momentu hybnosti prvej osi

$$d\vec{L} = \vec{\tau} dt. \quad (3.26)$$

Tejto jav sa nazýva *precesia gyroskopu* [49]. Na obr. 3.3a je bez straty na všeobecnosti znázornená situácia s klasickým zotrvačníkom, v ktorej je moment τ spôsobený tiažovým zrýchlením. Zo vzťahu 3.26 je možné následne odvodiť, že veľkosť precesie ω_P je priamo úmerná krútiacemu momentu τ [16]:

$$\tau = J\omega_P\Omega, \quad (3.27)$$

kde J je moment zotrvačnosti rotačného objektu a ω je jeho uhlová rýchlosť, pričom platí $\omega_P \ll \omega$ [49]. Typický príklad mechanického dvojsoseho gyroskopu je na obr. 3.3b.



(a) Precesia gyroskopu so znázornením všetkých pôsobiacich síl a momentov [49]

(b) Dvojsoý mechanický gyroskop so zotrvačníkom [16]

Obr. 3.3: Gyroskop – ilustrácia

Zvyškové trenie v ložiskách gyroskopu, vonkajšie vplyvy a malé nerovnováhy v konštrukcii spôsobujú malú odchýlku v zmysle dlhotrvajúcej stability, ktorá sa u vysoko-kvalitných produktov pohybuje na úrovni okolo $0,1^\circ$ za 6 hodín prevádzky [16].

Derivačné mechanické gyroskopy

Fungujú na princípe mechanickej ladičky, ktorej vidlice vibrujú k sebe a od seba s pevnou amplitúdou. Takýto snímač pozostáva z páru vidlíc – riadenej a snímacej. Rotácia okolo vertikálnej (torznej) osi vyvoláva vznik Coriolisových síl, pričom na každú z vidlíc pôsobí sila

$$F = 2m\Omega v_r, \quad (3.28)$$


kde F je Coriolisova sila pôsobiaca na vidlicu, m je hmotnosť vidlice, Ω je vstupná rýchlosť otáčania a v_r je okamžitá uhlová rýchlosť vidlice. Coriolisove sily generujú rotačný moment, ktorý je priamo úmerný vstupnej uhlovej rýchlosti a spôsobuje kmitanie snímacej vidlice, ktorá tak generuje signál [16]. Schematický náčrt takéhoto typu gyroskopu sa nachádza na obr. 3.4.

Optické gyroskopy

Uhlová rýchlosť je snímaná pomocou dvoch monochromatických svetelných lúčov, ktoré sú vysielané z rovnakého zdroja do opačného smeru v uzavretom kruhovom optickom vlákne. Lúče vytvárajú vo vnútri vlákna stojaté vlnenie s kmitňami a uzlami. Teoreticky by mal detektor s každou otočkou laserového kruhu zaznamenať počet uzlov rovný dvojnásobku dráhy lúčov vydelenej ich vlnovou dĺžkou. V skutočnosti však dosiahnutie takéhoto riešenia nie je možné kvôli vplyvu konštrukčných nedokonalostí [16].

Optické gyroskopy sa používajú v nasledujúcich základných konfiguráciách [16]:

- *Aktívne optické rezonátory* – využívajú tzv. Sagnacov efekt. Laserové lúče sú vysielané oproti sebe v cyklickej dráhe. Pri rotácii dochádza k predĺženiu dráhy



Obr. 3.4: Principiálna schéma gyroskopu Syston Donner GyroChip [16]

jedného lúča a skráteniu dráhy druhého. Rozdiel je priamoúmerný rotačnej rýchlosti. Ich nevýhodou je jav uzamknutia frekvencie pri nízkych rýchlostiach, ktorí súvisí s periodickou moduláciou lasera v spojení s malým množstvom odrazov na reflexných plochách. Výsledkom je pásmo necitlivosti.

- *Pasívne optické rezonátory* – používajú externý laser, čo zabraňuje vzniku uzamknutia frekvencie. Klasické implementácie používajú zrkadlové optické rezonátory. V porovnaní s aktívnymi majú menšie rozmery, vyššiu citlivosť aj robustnosť a nižšiu cenu.
- *Neradené interferometrické gyroskopy z optických vlákien (analog)* – vďaka využitiu optických vlákien je možné zmenšenie rozmerov a predĺženie dráhy lúčov, z čoho vyplýva zvýšenie rozlíšenia a znížené výrobné náklady. Medzi výhody tiež patrí vysoká tolerancia na vibrácie a otrasy, necitlivosť na gravitačné efekty, rýchly štart a dobrá citlivosť. Nevýhodami sú veľká dĺžka optického vlákna, obmedzený dynamický rozsah a odchýlky kvôli použitým analógovým komponentom. Používajú sa zväčša v jednoduchších aplikáciách vyžadujúcich strednú presnosť.
- *Riadené interferometrické gyroskopy z optických vlákien (digitál)* – citlivý prvok merajúci fázový posun nevyužíva Sagnacov efekt, ale pracujú s fázovým posunom lúčov $\Delta\phi = 0$. Ich výhodou je veľká presnosť, nezávislosť od intenzity svetla vysielaného v gyroskope, nezávislosť od zosilnení jednotlivých komponentov gyroskopu a lineárnosť a stabilita závislá len od nerecipročného fázového vysielateľa. Drift tohto typu gyroskopov sa pohybuje v rozmedzí 0,0001–0,01°/hod.
- *Rezonančné gyroskopy s optickými vláknami* – princíp ich činnosti bol odvodený od pasívnych optických rezonátorov. Výhodami sú vysoká spoľahlivosť, dlhá životnosť, rýchly štart a malá hmotnosť. Nevýhodou je nutnosť použitia vysoko koherentného zdroja svetla a extrémne bezstratových komponentov optického vlákna.

3.4.2 Akcelerometre

Zrýchlenie je vektorová fyzikálna veličina popisujúca zmenu vektoru rýchlosti – jeho veľkosti alebo smeru. Z Newtonových pohybových zákonov je známe, že teleso mení rýchlosť len keď na neho pôsobí sila (I. zákon) a táto sila spôsobuje jej úmerné zrýchlenie (II. zákon). Akcelerometre sú snímače vyvinuté na zaznamenanie síl na nich pôsobiacich, teda výstupom z nich je signál priamo úmerný akcelerácii.


Na zaznamenanie rôznych fyzikálnych síl sa v akcelerometroch využívajú rôzne citlivé elementy. Podľa toho sa akcelerometre delia na[16]:

- *mechanické* – (obr. 3.5a) merajú zrýchlenie pomocou pružiny, pričom využívajú Newtonov druhý pohybový zákon a Hookov zákon opisujúci tuhosť pružiny. Zrýchlenie spôsobuje deformáciu pružiny, ktorá je úmerná zrýchleniu;
- *piezoelektrické* – (obr. 3.5b) využívajú piezoelektrický efekt – pri deformácii keramického kryštálu sa pôsobením zrýchlenia generuje elektrický náboj, ktorý je úmerný sile. Pracujú najlepšie v stredných a vysokých frekvenciách;
- *piezorezistívne* – sú založené na zmene elektrického odporu pri mechanickom namáhaní piezorezistívneho materiálu. Umožňujú merať aj konštantné zrýchlenie (0 Hz), čo ich odlišuje od piezoelektrického typu;
- *tepelné* – (obr. 3.5c) merajú zrýchlenie na základe zmien rozloženia teploty v plyne ohrievanom výhrevným telesom. Neobsahujú pohyblivé časti a sú veľmi odolné, ale citlivé na zmeny okolitej teploty;
- *elektromechanické* – obsahujú pohyblivý mechanický prvok spojený s elektrickou časťou (napr. kondenzátorom). Zrýchlenie spôsobuje pohyb prvku, čo vedie k zmene elektrickej veličiny – najčastejšie kapacity.

Akcelerometre sú schopné zaznamenať zrýchlenie len v jednej osi. Pre meranie trojrozmerného zrýchlenia sa používajú systémy zložené z kombinácie troch vzájomne kolmých akcelerometrov. Ich najväčšou nevýhodou je vysoká citlivosť na vibrácie mechanických častí robota ako aj na rôzne parazitné zrýchlenia. Tento problém sa obvykle rieši zvýšením pomeru dĺžky citlivého elementu k jeho šírke v požadovanom smere [16].

3.4.3 Magnetometre

Magnetometre (magnetické kompas) sú prístroje, ktoré sú schopné zaznamenať magnetické pole Zeme. Na základe ich meraní je možné stanoviť orientáciu robota. Magnetické kompasy využívané v mobilnej robotike sa delia na [16]:



Obr. 3.5: Štruktúra a princíp merania rôznych typov akcelerometrov [16]

- *mechanické magnetické kompas*y – tradičné kompas y s otočným diskom v kvapaline, často upevnené na guľovom závесе na kompenzáciu pohybu. Okolité magnetické anomálie sa potláčajú pomocou nastaviteľných permanentných magnetov. Sú náchylné na odchýlky z externých zdrojov.
- *kompas y s magnetickou indukčnou sondou* – používajú dvojicu navzájom kolmých cievok s feritovým jadrom. Merajú horizontálnu zložku magnetického poľa pomocou sínusových výstupov. Ich výhodou je nízka spotreba, odolnosť voči otrasom a rýchly štart. Nevýhodou je citlivosť na magnetické anomálie, ktorú možno potlačiť spojením s gyroskopom.
- *magneticko-indukčné kompas y* – využívajú solenoid ako súčasť L/R oscilátora, kde frekvencia závisí od indukcie ovplyvnenej magnetickým poľom. Elektronika je jednoduchšia a spotreba energie nižšia ako pri kompasoch na báze magnetickej indukčnej sondy. Výstup má digitálny charakter.
- *kompas y na báze Hallovho efektu* – merajú rozdiely napätí v polovodiči so stálym prúdom pri prítomnosti magnetického poľa. Dvojica kolmých senzorov umožňuje výpočet uhla natočenia. Sú lacné, ale s nízkym rozlíšením a silným vplyvom vnútorných chýb, čo vyžaduje filtrovanie a znižuje šírku pásma.
- *magneticko-rezistívne kompas y* – Využívajú zmenu odporu anizotropného materiálu pri zmene smeru magnetizácie. Umožňujú veľmi citlivé meranie natočenia, sú vhodnú najmä pre aplikácie vyžadujúce vysokú presnosť.
- *magneticko-elastické kompas y* – sú založené na zmene Youngovho modulu magneticko-striktívnych materiálov pri pôsobení magnetického poľa. Meranie je založené na detekcii deformácie materiálu vyžaduje zliatiny s vysokou magnetostrikciou.

3.4.4 IMU

Inerčná meracia jednotka (niekedy nazývaná aj inerčná referenčná jednotka alebo pohybová referenčná jednotka, skr. IMU, alebo tiež inerčný navigačný systém, skr. INS) je zväčša elektromechanické alebo polovodičové zariadenie, ktoré obsahuje kombináciu viacerých senzorov (zvyčajne akcelerometrov a gyroskopov, ale tiež magnetometrov a tlakových senzorov) schopných merať pohyb, teda lineárne a uhlové zrýchlenia, uhlové rýchlosti, príp. aj orientáciu, a to vo všetkých troch osiach. Je schopná zaznamenať zotrvačné sily a transformovať ich na výstupné údaje, ktoré opisujú pohyb objektu [32].

Najpoužívanejšou konštrukčnou technológiou pre IMU je MEMS. Sú to miniatúrne zariadenia s veľkosťou rádovo v mikrometroch, ktoré sú tvorené kombináciou elektrických a mechanických prvkov tvorených z rôznych materiálov (napr. kremík, polyméry,

kov). Existujú rôzne typy MEMS komponentov, od jednoduchých prepínačov až po mimoriadne zložité elektromechanické systémy s viacerými integrovanými snímačmi a mikroelektronikou [32].

Výhody použitia MEMS technológie spočívajú najmä v mimoriadne malej veľkosti a hmotnosti komponentov v kombinácii s nízkou spotrebou energie. Vďaka tomu je možné takéto snímače umiestniť na malých plošných spojoch do kompaktných puzdier a sú vhodné na umiestnenie v mobilných robotoch, ktoré majú obvykle značné priestorové aj napájacie obmedzenia. Jednotlivé komponenty, materiály a konštrukčné techniky zabezpečujú vysokú spoľahlivosť a dlhú životnosť, pričom tieto parametre sú stále predmetom neustáleho zdokonaľovania sa [32].

Na druhú stranu, pre správnu interpretáciu výstupných dát z IMU je potrebné ďalšie spracovanie, a to za účelom odstránenia tiažového zrýchlenia a tiež filtrácie šumu meraní, ktorý pri vysokej citlivosti snímačov môže spôsobiť vznik drift odhadu polohy. Vzhľadom na vysokú mieru šumu meraní sa IMU senzory väčšinou nepoužívajú samostatne, ale vo fúzii s inými senzormi. Vďaka skutočnosti, že meria reálne fyzikálne veličiny na základe priameho vplyvu zotrvačných síl, údaje z nej sú nápomocné v kombinácii so snímačmi, ktoré merajú polohu na základe rôznych metód odhadu (kamera, lidar, GPS, a i.) a u ktorých zvykne dochádzať napríklad ku skokovým zmenám odhadu, ktoré fyzikálne nie sú možné. Algoritmy, ktoré sa zaoberajú fúziou dát z viacerých snímačov budeme bližšie rozoberať v ďalších častiach práce.

Open GINS

4 Externé lokalizačné systémy

4.1 GNSS systémy

Globálne navigačné satelitné systémy (GNSS) sú systémy slúžiace na určenie polohy, rýchlosti a času [16]. Pozostávajú zo zoskupení satelitov, ktoré neustále vysielajú informáciu o svojej polohe a čase, zo siete pozemných staníc a z prijímačov, ktoré vypočítavajú polohu na zemi pomocou trilaterácie. Používajú sa vo všetkých formách dopravy: na vesmírnych staniciach, v letectve, námornej doprave, železničnej doprave, cestnej doprave a hromadnej doprave [24].

V súčasnosti existuje niekoľko globálnych systémov [77]:

- GPS (Spojené štáty americké),
- GLONASS (Ruská federácia),
- GALILEO (Európska Únia),
- COMPASS/Bei-Dou (Čína).

Okrem nich sú v priebežnom vývoji aj ďalšie regionálne systémy, ako napríklad indický IRNSS a japonský QZSS. V momente dokončenia všetkých týchto systémov bude pre užívateľov k dispozícii dokopy viac než sto satelitov. Jednou z najaktuálnejších tém v rámci oblasti GNSS je zabezpečenie interoperability medzi globálnymi systémami, čo by umožnilo užívateľom prijímať a spracúvať signál z viacerých satelitných systémov pomocou jedného zariadenia [24].

Výkonnosť GNSS sa hodnotí podľa štyroch kritérií [77]:

1. *presnosť* – rozdiel medzi nameranou a skutočnou polohou, rýchlosťou alebo časom prijímača,
2. *integrita* – schopnosť systému poskytnúť určenú mieru spoľahlivosti a v prípade poruchy v údajoch o polohe vydať varovanie,
3. *kontinuita* – schopnosť systému fungovať bez prerušenia,
4. *dostupnosť* – percentuálny podiel času, počas ktorého signál spĺňa uvedené kritériá presnosti, integrity a kontinuity.

Túto výkonnosť je možné zlepšiť pomocou regionálnych satelitných augmentačných systémov (SBAS). Ich kombinácia s overenými pozemnými technológiami, ako je inerciálna navigácia, prináša možnosti novým aplikáciám, ktoré nevyžadujú len presnosť, ale predovšetkým spoľahlivosť a integritu.

Medzi hlavné výhody GNSS patria vysoká presnosť, údaje v jednotnom svetovom súradnicovom systéme WGS a nezávislosť na počasi či fáze dňa. Nevýhodami sú nemožnosť využitia v podzemí, vo vode aj v interiéroch s hrubými či početnými stenami, horšia presnosť v prostrediach s menšou viditeľnosťou na oblohu (napr. oblasti husto zastavané vysokými budovami, lesy, údolia) či možnosť rušenia signálu externým zdrojom [16].

4.1.1 Princíp činnosti

Princíp určovania polohy pomocou GNSS spočíva v meraní času letu rádiového signálu z družíc. Každý satelit vysiela svoje identifikačné údaje, polohu a časovú značku. Prijímač vypočíta odhad vzdialenosti družice na základe rozdielu medzi časom vyslania a prijatia signálu. Polohu meraného bodu je možné určiť vyhodnotením takéhoto signálu z viacerých satelitov. Z geometrického hľadiska by na určenie trojrozmernej polohy mal stačiť prienik vzdialeností troch družíc. Keďže ale nie je možné zaručiť presnú synchronizáciu hodín prijímača, je potrebný údaj z ešte aspoň jedného satelitu, čím vznikne viacero bodov prieniku. Čas prijímača je následne posúvaný tak, aby tieto body splynuli do jediného, čím vzniká výsledné meranie polohy. Pre dosiahnutie vyššej presnosti potrebné poznať polohy čo najväčšieho počtu vhodne rozložených družíc [16].

4.1.2 Chyby GPS

Merania GPS sú sprevádzané niekoľkými typmi chýb [16]:

- *Geometria rozloženia satelitov* – pokiaľ aktuálne viditeľné satelity nie sú rovnomerne rozložené po celej oblohe, môže dojsť k nepresnej triangulácii, a teda aj k chybe odhadu polohy. Viditeľnosť satelitov negatívne ovplyvňuje aj meranie vnútri vozidla, v blízkosti vysokých budov či v členitom teréne. Tento typ chyby vyjadruje parameter zníženia presnosti (DOP).
- *Atmosférické efekty* – zemská atmosféra ovplyvňuje GPS signály dvomi hlavnými vrstvami: troposférou a ionosférou. Troposféra ako elektricky neutrálne prostredie spôsobuje nedisperzné odchýlky závislé od teploty, tlaku a vlhkosti, ktoré rovnomerne postihujú fázové aj kódové GPS merania. Ionosféra je elektricky aktívna vrstva s voľnými elektrónmi a iónmi, kde dochádza k odrazu a útlmu rádiových vln, najmä v dôsledku interakcie s neutrálnymi molekulami. Jej účinky závisia od slnečnej aktivity a polohy v atmosfére a spôsobujú spomalenie elektromagnetických vln úmerné k prevrátenej hodnote kvadrátu ich frekvencie. Vplyv ionosféry možno čiastočne eliminovať porovnaním signálov na rôznych frekvenciách, čo využívajú napríklad vojenské GPS prijímače pracujúce.

- *Efekt viaccestného šírenia sa signálu (angl. multipath)* – nastáva, keď sa GPS signál odrazí od objektov v okolí prijímača a dorazí k nemu oneskorene. Tieto odrazené signály predlžujú dráhu, ktorú signál prejde, čo vedie k chybám v určení polohy – typicky v rozsahu niekoľkých metrov. GPS satelity vysielajú signál v širokom kuželi, takže odrazy sú bežné najmä v mestskom alebo členitom prostredí. Na zníženie tohto efektu sa používajú antény so špeciálnou konštrukciou (napr. s ochranným tanierom), pokročilé technológie v prijímači a efektívne metódy spracovania signálu. Tieto opatrenia znižujú príjem odrazených signálov, čím zlepšujú presnosť určenia polohy.
- *Relativistické efekty* – zohrávajú významnú úlohu pri určovaní polohy pomocou GPS, najmä kvôli veľkej rýchlosti a výške družíc. Zmeny frekvencie signálu v dôsledku rýchlosti pohybu družíc (Dopplerov jav) a rozdiely v priebehu času spôsobené gravitáciou (dilatácia času) ovplyvňujú presnosť meraní. Tieto efekty sú dôsledkom špeciálnej aj všeobecnej teórie relativity a musia byť zahrnuté do výpočtov polohy. Bez ich korekcie by chyba v určovaní času spôsobila výrazné chyby v polohe, až rádovo kilometre denne. Preto sú súčasťou rovníc používaných v GPS prijímačoch aj korekcie na relativistické poruchy dráh družíc a šírenia signálu.
- *Ďalšie chyby GPS*
 - nepresnosť hodín v GPS prijímači (prijímač nemôže obsahovať atómové hodiny, odstránenie chyby sa rieši použitím signálu z viacerých satelitov),
 - nepresné určenie parametrov dráhy družice (tzv. ephemeris error),
 - počet viditeľných satelitov (pre väčšiu presnosť merania je potrebné mať väčší počet viditeľných satelitov).

4.1.3 Augmentačné systémy

Spomenuté chyby GPS meraní je možné v rôznej miere potlačiť pomocou systémov so zvýšenou presnosťou. Tie bývajú častou voľbou aj v prípade mnohých robotických aplikácií, pre potreby ktorých je presnosť meraní pomocou GNSS nedostatočná [16].

Inertial Navigation System (INS)

Pridaním INS ku GPS je možné dosiahnuť presnosť v rozsahu približne jedného metra. Výstup z oboch systémov býva porovnávaný obvykle pomocou Kalmanovho filtra, ktorý poskytuje najviac pravdepodobné meranie;

Differential GPS (DGPS)

Potrebné sú dva GPS prijímače, z ktorých jeden sa nachádza na geodeticky vymeranej polohe. Využíva sa skutočnosť, že blízke prijímače majú vysokú koreláciu chýb. Referenčná stanica vypočítava a vysiela korekcie na základe rozdielov medzi očakávanými a nameranými údajmi zo všetkých viditeľných družíc. V prijímači užívateľa DGPS je korekčný údaj využitý na opravu merania. Použitím DGPS môže užívateľ získať presnosť určovania polohy v reálnom čase na úrovni desiatok centimetrov až metrov, v závislosti od vzdialenosti od referenčnej stanice.

Real-Time Kinematic (RTK) GPS

RTK je vysoko presná technológia pre lokalizáciu a navigáciu, využívaná v širokom spektre aplikácií od prieskumu a mapovania, cez poľnohospodárstvo až po stavebníctvo. Funguje, podobne než DGPS, na kombinácii referenčnej stanice a užívateľského prijímača. Na rozdiel od DGPS však referenčná stanica uskutočňuje aj meranie nosnej fázy signálu. Prijímač potom odlišnosti v nosnej fáze vyhodnocuje, čo dramaticky zvyšuje presnosť merania polohy [58].

Wide Area Augmentation System (WAAS)

Systém WAAS poskytuje extrémne vysokú presnosť lokalizácie, využiteľnú najmä v leteckej doprave. Pozostáva z 38 referenčných staníc (WRS), 3 hlavných staníc (WMS), 3 geostacionárnych družíc a 6 pozemných vysielačích staníc. Referenčné stanice slúžia na prijímanie signálu GPS. Ich polohy sú zvolené tak, aby bolo možné zachytiť akékoľvek chyby v signáloch GPS. Informácie z WRS sa posielajú do WMS, ktoré vysielaajú správy pre užívateľov s frekvenciou 1 Hz. Tieto správy umožňujú významnú korekciu GPS meraní na strane užívateľa. WMS vysiela správy aj na pozemné vysielačie stanice, odkiaľ sú prenášané k navigačným zariadeniam na geostacionárnych komunikačných satelitoch. Tie následne vysielaajú signál podobný GPS, ktorý môžu prijímače využiť spolu s korekčnými údajmi na spresnenie lokalizácie. Systém WAAS je dostupný v rámci NAS [64]. V Európe funguje na podobnom princípe systém **EGNOS** [17].

4.2 UWB systémy

Ultra-širokopásmové (UWB) systémy predstavujú modernú bezdrôtovú technológiu využívajúcu veľmi krátke rádiové impulzy (rádovo v nanosekundách) v širokom frekvenčnom pásme (typicky 3,1 – 10,6 GHz) s nízkou spektrálnou hustotou výkonu, vďaka čomu má malú spotrebu energie. Je schopná prenášať dáta vysokou rýchlosťou (do 100 Mb/s) na krátku vzdialenosť. Používanie krátkych impulzných vĺn namiesto kontinuálneho šírenia signálu znižuje riziko vzniku „multipath“ efektu (spomínaného v časti 4.1.2) a zjednodušuje určenie času príchodu signálu (TOA) pri dávkovom prenose dát medzi

vysielačom a prijímačom, čo dáva UWB výhodu vo vnútornom prostredí oproti iným technológiám. Navyše, nízka frekvencia pulzov umožňuje prienik signálu cez iné objekty alebo steny. Vďaka tomu je technológia UWB okrem iných využití vhodná aj pre lokalizáciu a sledovanie objektov, a to zvlášť vo vnútornom prostredí, kde iné technológie zlyhávajú kvôli potrebe priamej viditeľnosti alebo vysokému rušeniu. Odchýlka UWB lokalizácie sa pohybuje rádovo v jednotkách centimetrov a jej dosah je približne 30 – 50 m. [2].

Systémy UWB lokalizácie tvoria dva základné prvky: kotvy (z angl. anchors) a značky (z angl. tags). Anchory sú vo väčšine topológií využívané ako prijímače signálov vysielaných tagmi, na základe ktorých určujú vzdialenosť (príp. uhol) medzi daným anchorom a tagom. Túto informáciu odosielaajú do výpočtového systému, kde sa na základe informácií z viacerých anchorov a ich známych polôh vypočíta poloha sledovaného objektu. Na pokrytie prostredia sa používajú viaceré anchory v rôznych typoch rozložení v závislosti od použitej metódy lokalizácie [54].

4.2.1 Modulácia signálu

Nakoľko prenos UWB signálov prebieha zvyčajne v prostredí, kde sa vyskytujú aj iné typy signálov, kľúčovou zložkou technológie je *modulácia signálu*. Je to proces, ktorým sa na impulzný signál (nosnú vlnu) prenáša informácia zmenou jednej alebo viacerých jeho vlastností. V UWB systémoch zohráva modulácia zásadnú úlohu nielen pri prenose dát, ale aj pri samotnej lokalizácii, pretože ovplyvňuje schopnosť presne identifikovať impulzy aj v prítomnosti šumu, rušenia či odrazených signálov. Pre tento prípad sa využívajú viaceré variácie modulácie signálov, ktoré môžeme kategorizovať nasledovne [2]:

1. Podľa počtu stavov signálu

- *Binárna modulácia* – dva možné stavy signálu (napr. logická 0 a 1),
- *Ternárna modulácia* – tri úrovne (napr. záporná, nulová a kladná amplitúda),
- *M-árna modulácia* – viacero stavov (napr. 4-PSK, 8-PPM);

2. Podľa modifikovanej vlastnosti signálu

- Základné:
 - *Amplitúdová (PAM)* – mení sa amplitúda impulzu,
 - *Frekvenčná* – zriedkavá pri UWB,
 - *Fázová (PSK)* – mení sa fáza impulzu,
 - *Šírková (PWM)* – mení sa dĺžka impulzu,
 - *Časová (PPM)* – mení sa poloha impulzu v časovom okne,

- Rozšírené:
 - *Binárne fázové kódovanie (BPSK)* – impulz mení fázu o 180° ; vhodná pri vyšších dátových prenosoch a odolná voči šumu,
 - „*On-Off*“ *kódovanie (OOK)* – informácia sa kóduje prítomnosťou alebo neprítomnosťou impulzu; jednoduchá, no citlivá na šum,
 - *Skoky času (TH-PPM/TH-BPSK)* – impulzy sa vysielajú v náhodne vybraných časových oknách podľa kľúča, čo zvyšuje odolnosť voči rušeniu a umožňuje viacerým zariadeniam zdieľať pásmo.

Správna voľba modulácie je dôležitá pre presnosť lokalizácie, robustnosť voči viaccestnému šíreniu, energetickú efektivitu vysielача, ale aj výpočtovú náročnosť prijímača.

4.2.2 Metódy UWB lokalizácie

Za účelom získania informácií o polohe objektu z rádiových signálov bolo vyvinutých viacero algoritmov, ktoré je možné principiálne rozdeliť do nasledujúcich kategórií [2]:

1. *Čas príchodu signálu (TOA)* – meria sa čas šírenia signálu medzi vysielateľom a prijímačom. Na základe známej rýchlosti šírenia signálu (pre rádiové vlny je to rýchlosť svetla) je možné priamo vypočítať vzdialenosť. Výsledná poloha sa odhaduje ako priesečník kružníc so stredmi v jednotlivých anchoroch a polomerami určenými odhadom vzdialenosti (podobne ako pri GNSS);
2. *Uhol príchodu signálu (AOA)* – vyžaduje informáciu o uhle príchodu signálu od minimálne dvoch, optimálne aspoň troch prijímačov; poloha objektu je určená prienikom uhlových priamok. Je citlivý na rôzne faktory spôsobujúce odchýlku, zásadný vplyv na presnosť má aj vzdialenosť objektu od antény. Je navyše zložitejší než iné algoritmy;
3. *Intenzita prijatého signálu (RSS)* – odvodzuje vzdialenosť na základe útlmu signálu. Hoci je implementačne jednoduchá, trpí vysokou neistotou v prostredí s odrazmi, čím je menej vhodná pre UWB;
4. *Časový rozdiel príchodzieho signálu (TDOA)* – využíva sa rozdiel časov príchodu signálu do viacerých anchorov. Prijímače musia byť navzájom zosynchronizované. Výsledná poloha sa odhaduje ako priesečník hyperbol, čo umožňuje získať polohu bez potreby synchronizácie mobilného uzla;
5. *Hybridné algoritmy* – Kombinujú viacero vyššie uvedených prístupov (napr. TDOA+AOA) s cieľom zlepšiť presnosť a robustnosť voči rušeniu a „multipath“ efektom.

Technológia UWB je sprevádzaná aj viacerými nevýhodami a výzvami. Nakoľko je frekvenčné pásmo zdieľané aj s inými bezdrôtovými technológiami (napr. WiMAX, 3G), môže dochádzať k rušeniu signálu. V prípade lokalizácie viacerých objektov môže taktiež dochádzať k problémom s prístupom na kanál. Spracovanie impulzov z tagov si vyžaduje komplexný hardvér a pre presnú lokalizáciu je potrebná presná časová synchronizácia zariadení. Na korekciu chýb spôsobených nedostatočnou synchronizáciou sa používajú rôzne filtračné a optimalizačné metódy a algoritmy, napr. metóda najmenších štvorcov, Kalmanove filtre či časticové filtre [54].

4.3 Systémy na snímanie pohybu

Systémy na snímanie pohybu (MoCap) boli vyvinuté na zaznamenávanie pohybu objektov alebo ľudí, pôvodne za účelom analýzy chôdze [22]. Technológia sa však postupne rozšírila aj do ďalších oblastí vrátane robotiky.

Najpoužívanejšími prístupmi k MoCap v posledných rokoch sú [22]:

1. *opticko-pasívny* – najpraktickejší a najpoužívanejší spôsob v súčasnosti; sledovaný objekt je označený retroreflexnými značkami (markermi), ktoré sú zaznamenávané viacerými infračervenými kamerami. Každý marker musí byť zachytený viacerými kamerami, jeho polohu je potom možné určiť trianguláciou s chybou pod 1 mm;
2. *opticko-aktívny* – sledovaný objekt je označený infračervenými LED diódami, ktoré sú snímané infračervenými kamerami. Princíp určovania polohy je rovnaký ako v predošlom prípade, hlavná nevýhoda však spočíva v nutnosti napájania aktívnych markerov;
3. *video* – každá snímka je spracúvaná softvérom na detekciu objektov. Dosahuje menšiu presnosť než riešenia využívajúce markery;
4. *inerciálny* – je nezávislý od kamier, využíva inerčné snímače. Slabou stránkou je krátkodobá presnosť.

Súčasným lídrom v oblasti MoCap je opticko-pasívny systém OptiTrack. Predstavuje jedno z najmodernejších riešení lokalizácie objektov, vyznačujúce sa nízkou latenciou, vysokou presnosťou, relatívne jednoduchým používaním a schopnosťou zaznamenať všetkých 6 stupňov voľnosti (DoF) ako u pozemných (AGV), tak u lietajúcich (UAV) autonómnych vozidiel [50]. Často sa využíva na validáciu počítačového videnia či ako referencia pre iné metódy lokalizácie. Praktický je hlavne vo vnútorných laboratórnych podmienkach [22]. Medzi jeho hlavné nevýhody patrí potreba priamej viditeľnosti medzi kamerami a značkami, výrazný pokles presnosti mimo optimálnej oblasti, vysoké náklady, inštalácia náročnosť a tiež nevhodnosť použitia v exteriéri.

5 Pravdepodobnostné metódy fúzie údajov zo snímačov

Odhad aktuálneho stavu robota a prostredia, v ktorom sa nachádza, je vždy sprevádzaný neistotou. Tá je súčasťou každej informácie o systéme či merania senzora. Pri fúzii viacerých senzorov musíme zohľadniť skutočnosť, že každý z nich dosahuje rôzne úrovne presnosti a šumu jednotlivých meraní, preto je vhodné uplatniť metódy, ktoré umožňujú systematicky zohľadniť neistotu merania a neúplnosť informácií. Pravdepodobnostné prístupy k senzorickej fúzii používajú na reprezentáciu odhadov stavov a šumu teóriu pravdepodobnosti.

5.1 Pojmy a označenia v pravdepodobnostnej robotike

Skôr než sa dostaneme k pravdepodobnostným metódam, uvedieme základné princípy, pojmy a označenia pravdepodobnostnej robotiky. Tá vyjadruje veličiny, merania snímačov, akčné zásahy a stavy robota a prostredia, v ktorom sa nachádza, ako náhodné premenné (n. p.).

5.1.1 Od pravdepodobnosti k Bayesovej vete

Pravdepodobnosť, že diskretná n. p. X nadobúda hodnotu x sa označuje pomocou pravdepodobnostnej funkcie:

$$P(X = x) \equiv p(x); p(x) \in (0, 1); \sum_x p(x) = 1 \quad (5.1)$$

V prípade spojitých n. p. hovoríme v rovnakom kontexte o pravdepodobnosti, že $X \in \langle a, b \rangle$, nazývanej (pravdepodobnostná) funkcia hustoty:

$$P(a \leq X \leq b) = \int_a^b p(x) dx; \int p(x) dx = 1 \quad (5.2)$$

Pravdepodobnostné metódy, ktoré budeme opisovať v tejto kapitole, sú založené na tzv. *normálnom*, resp. *Gaussovom rozdelení pravdepodobnosti*, ktoré sa označuje $\mathcal{N}(x; \mu, \sigma^2)$ a definované je ako

$$p(x) = (2\pi\sigma)^{-\frac{1}{2}} \exp\left(-\frac{1}{2} \frac{(x - \mu)^2}{\sigma^2}\right) \quad (5.3)$$

kde μ je stredná hodnota a σ rozptyl pravdepodobnosti pre skalárnu n. p.. Pre viacrozmerné veličiny so stredom μ a kovariančnou maticou Σ má Gaussovská pravdepodobnostná funkcia tvar

$$p(x) = \det(2\pi\Sigma)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x - \mu)^\top \Sigma^{-1}(x - \mu)\right) \quad (5.4)$$

Súčasný výskyt dvoch n. p. sa nazýva *združená pravdepodobnosť* a označuje sa takto:

$$p(x, y) \equiv p(y, x) \equiv p(X = x \wedge Y = y) = p(x) p(y) \quad (5.5)$$

Posledná rovnosť vo vzťahu (5.5) platí len v prípade, že premenné X a Y sú *nezávislé*. Naopak, jav, kedy hodnota jednej n. p. ovplyvňuje hodnotu druhej, sa nazýva *podmienená pravdepodobnosť* a označuje sa takto:

$$p(x | y) = p(X = x | Y = y) = \frac{p(x, y)}{p(y)} \quad (5.6)$$

Z uvedeného vyplýva dôležitá súvislosť, nazývaná aj ako *veta o úplnej pravdepodobnosti*, ktorú je možné vyjadriť ako pre diskkrétne ((5.7a)) tak pre spojité ((5.7b)) n. p.:

$$p(x) = \sum_y p(x | y) p(y) \quad (5.7a)$$

$$p(x) = \int p(x | y) p(y) dy \quad (5.7b)$$

Vzťahy (5.5), (5.6) a (5.7) je možné využiť na nasledujúce odvodenie:

$$\begin{aligned} p(x, y) &= p(y, x) \\ p(x | y) p(y) &= p(y | x) p(x) \\ p(x | y) &= \frac{p(y | x) p(x)}{p(y)} = \frac{p(y | x) p(x)}{\int p(y | x') p(x') dx'} = \eta p(y | x) p(x) \end{aligned} \quad (5.8)$$

Vzťah (5.8) sa nazýva *Bayesova veta* a zohráva kľúčovú rolu (nielen) v pravdepodobnostnej robotike. Keď x je veličina, ktorej hodnotu odvádzame z údajov y (napr. meranie senzora), $p(x)$ sa označuje ako *apriórna pravdepodobnosť* a predstavuje naše poznanie o hodnote X pred zapracovaním y . Pravdepodobnosť $p(x | y)$ sa nazýva *aposteriórne rozdelenie pravdepodobnosti* premennej X . Substitúciu menovateľa pomocou normalizačnej premennej η je možné zaviesť nakoľko menovateľ nezávisí od hodnoty x . Bayesova veta teda poskytuje nástroj pre odvodenie aposteriórneho odhadu veličiny x na základe údajov zo senzora y , a to pomocou inverznej pravdepodobnosti. Tá sa v robotike často nazýva aj „generatívny model“, nakoľko popisuje ako stavové premenné X spôsobujú senzorické merania Y [68].

Ak použijeme Bayesovu vetu na odvodenie závislosti aj od tretej premennej Z , jej tvar sa zmení takto:

$$p(x | y, z) = \frac{p(y | x, z) p(x | z)}{p(y | z)} \quad (5.9)$$

Podobne je možné podmieniť združenie pravdepodobnosti dvoch premenných tretou, čo sa nazýva *podmienená nezávislosť*:

$$p(x, y \mid z) = p(x \mid z)p(y \mid z) \quad (5.10)$$

Podmienená nezávislosť má pre robotiku ten význam, že hovorí o nepotrebnosti informácie y pri znalosti informácie z . Avšak podmienená nezávislosť neimplikuje úplnú nezávislosť, ako ani absolútna nezávislosť neimplikuje existenciu podmienenej nezávislosti, hoci sa tieto javy môžu v špeciálnych prípadoch zhodovať [68].

5.1.2 Pravdepodobnostná reprezentácia stavu

Súhrn informácií o riadenom systéme a prostredí, v ktorom sa nachádza, vyplývajúci na jeho budúce správanie, nazývame *stav*. Pre prípad mobilného robota stav typicky zahŕňa veličiny ako sú poloha, rýchlosť, pozícia statických prvkov prostredia, príp. pozícia a rýchlosť pohyblivých objektov či informácie o jeho vnútorných prvkoch. Stav robota v čase t sa označuje x_t . Za *úplnú reprezentáciu stavu* považujeme takú, ktorú už nie je možné spresniť ďalšími informáciami o predošlom stave, akčných zásahoch či meraniach snímačov. Keďže v reálnom svete je nemožné obsiahnuť všetky veličiny, ktoré vplyvajú na robot, v praxi sa stav reprezentuje len malou podmnožinou najrelevantnejších veličín. Takúto reprezentáciu voláme *neúplný stav*. Procesy, ktoré spĺňajú kritérium, že žiadne veličiny pred časom t nemôžu ovplyvniť stochastický vývoj budúcich stavov bez toho, aby sa táto závislosť preniesla prostredníctvom aktuálneho stavu x_t , sa nazývajú *Markovove reťazce* [68].

Vo všeobecnosti môžeme uvažovať o dvoch druhoch interakcie robota s prostredím. Prvým je vnímanie prostredia pomocou senzorov, nazývané tiež *percepčia*. Druhým typom sú akčné zásahy, ktorými robot mení stav svojho okolia. Na základe týchto dvoch druhov interakcie s prostredím rozlišujeme dva typy údajov, ktoré môže robot prijímať: merané údaje z_t , ktoré popisujú aktuálny stav prostredia a riadiace signály u_t , ktoré hovoria o zmene stavu v prostredí. Je dôležité poznamenať, že k riadiacim signálom sa zaraďujú aj údaje z odometrie, keďže popisujú zmenu stavu [68].

Pravdepodobnostný stavový model odvodzuje stav pomocou podmienených pravdepodobností vyššie spomenutých veličín [65, 68]:

$$\begin{aligned} x_t &\sim p(x_t \mid x_{t-1}, u_t) \\ z_t &\sim p(z_t \mid x_t), \end{aligned}$$

kde $p(x_t \mid x_{t-1}, u_t)$ je *prechodový model stavu*, ktorý reprezentuje stochastickú dynamiku systému a $p(z_t \mid x_t)$ je *model merania*, ktorá predstavuje distribúciu meraní pri danom stave.

Keďže všetky údaje, ktoré má robot k dispozícii, či už merania alebo riadiace údaje, sú zafaržené neistotou, súčasný stav robota je potrebné odhadnúť na základe všetkých dostupných informácií. Takýto sa nazýva *aposteriórny odhad stavu* a budeme rozlišovať dve jeho variácie podľa toho, či vznikne po zapracovaní aktuálneho merania ((5.11b)) alebo ešte pred ním ((5.11a)):

$$\hat{x}_t = p(x_t \mid z_{1:t}, u_{1:t}) \quad (5.11a)$$

$$\bar{x}_t = p(x_t \mid z_{1:t-1}, u_{1:t}) \quad (5.11b)$$

5.2 Bayesov filter

Bayesov filter (BF) je najvšeobecnejší algoritmus na výpočet odhadov. Jeho cieľom je vypočítať aposteriórny odhad stavu na základe dostupných meraní a riadiacich signálov. Jeho odvodenie podľa [68] je postavené na troch počiatočných predpokladoch:

1. $\bar{x}_0$ je počiatočný odhad stavu v čase $t = 0$,
2. x_t je úplný odhad stavu x v čase t
3. riadiace signály u_t sú vykonávané náhodne.

Sformulovaním Bayesovej vety pre aposteriórny odhad stavu $\bar{x}_t$ dostávame:

$$p(x_t \mid z_{1:t}, u_{1:t}) = \eta p(z_t \mid x_t, z_{1:t-1}, u_{1:t}) p(x_t \mid z_{1:t-1}, u_{1:t}) \quad (5.12)$$

Za využitia predpokladu, že máme úplnú reprezentáciu stavu však môžeme pri odhade súčasného merania zanedbať predošlé merania $z_{1:t-1}$ aj riadiace signály $u_{1:t}$, keďže všetky potrebné informácie sú obsiahnuté v súčasnom stave x_t , teda môžeme predchádzajúci vzťah zjednodušiť a odvodiť:

$$p(x_t \mid z_{1:t-1}, u_{1:t}) = \eta p(z_t \mid x_t) p(x_t \mid z_{1:t-1}, u_{1:t}) \quad (5.13)$$

$$\bar{x}_t = \eta p(z_t \mid x_t) \hat{x}_t \quad (5.14)$$

Ďalej je možné pre $\hat{x}_t$ využitím vzťahu (5.7b) odvodiť:

$$\hat{x}_t = p(x_t \mid z_{1:t-1}, u_{1:t}) \quad (5.15)$$

$$= \int p(x_t \mid x_{t-1}, z_{1:t-1}, u_{1:t}) p(x_{t-1} \mid z_{1:t-1}, u_{1:t}) dx_{t-1} \quad (5.16)$$

Aj v tomto prípade je za predpokladu úplného odhadu stavu možné vylúčiť podmienenosť predošlými meraniami a riadiacimi signálmi:

$$p(x_t \mid x_{t-1}, z_{1:t-1}, u_{1:t}) = p(x_t \mid x_{t-1}, u_t) \quad (5.17)$$

Algoritmus 2 Bayesov filter podľa [68]

Require: $\bar{x}_{t-1}, u_t, z_t$

Ensure: $\bar{x}_t$

1: **for** $\forall x_t$ **do**

 Prediction:

2: $\hat{x}_t \leftarrow \int p(x_t \mid u_t, x_{t-1}) \bar{x}_{t-1} dx_{t-1}$

 Update:

3: $\bar{x}_t \leftarrow \eta p(z_t \mid x_t) \hat{x}_t$

4: **end for**

5: **return** $\bar{x}_t$

Napokon je zanedbaná hodnota u_t z výrazu $p(x_{t-1} \mid z_{1:t-1}, u_{1:t})$, keďže predpokladáme, že je volená náhodne. Tak získavame výsledný rekurzívny vzťah pre aposteriórny odhad stavu:

$$\hat{x}_t = \int p(x_t \mid x_{t-1}, u_t) p(x_{t-1} \mid z_{1:t-1}, u_{1:t-1}) dx_{t-1} \quad (5.18)$$

$$= \int p(x_t \mid x_{t-1}, u_t) \bar{x}_{t-1} dx_{t-1} \quad (5.19)$$

Algoritmus BF teda pozostáva z troch krokov. Stanovenie počiatocného odhadu stavu $\bar{x}_0$ tvorí prvý krok, *inicializáciu*. Nasleduje periodické opakovanie *predikcie* ((5.19)) a *aktualizácie* ((5.14)) (viď alg. 2). Akákoľvek konkrétna implementácia tohto algoritmu vyžaduje definíciu troch pravdepodobnostných funkcií: počiatocného odhadu stavu $p(x_0)$, pravdepodobnostného modelu merania $p(z_t \mid x_t)$ a prechodového modelu stavu $p(u_t, x_{t-1})$. Ďalej je tiež potrebné definovať predikčný model odhadu stavu $\hat{x}_t$.

Ako vyplýva z uvedeného, toto odvodenie platí pre úplný odhad stavu, ktorý je však v reálnych podmienkach nedosiahnuteľný. Použitie čiastočnej stavovej reprezentácie a voľba pravdepodobnostných modelov sú faktory, ktoré určujú, do akej miery sa výsledok filtrácie odkloní od skutočnosti. V praxi sa však Bayesove filtre osvedčili ako mimoriadne robustné aj pri týchto zjednodušeníach [68].

Existuje viacero algoritmov odvodených od BF, ktoré sa líšia práve prístupom k reprezentácii pravdepodobnostných funkcií a počiatocného odhadu, na základe čoho získavajú isté špecifiká. My sa budeme v ďalšej kapitole zaoberať len jednou množinou týchto implementácií, a to Gaussovými filtrami.

5.3 Gaussove filtre

Gussove filtre sú najstaršou a zároveň aj najpopulárnejšou skupinou algoritmov odvodených z Bayesovho filtra. Sú založené na základnej myšlienke, že všetky pravdepodob-

nostné odhady sú reprezentované viacrozmernými normálnymi rozdeleniami $\mathcal{N}(x; \mu, \sigma^2)$ (vzťah (5.4)). Rozmer strednej hodnoty μ je zhodný s rozmerom stavového vektora x a kovariančná matica Σ je symetrická a kladne semidefinitná. Počet jej prvkov je kvadraticky závislý od rozmeru stavu.

Gaussovská reprezentácia pravdepodobnosti má niekoľko dôsledkov. Najzávažnejším z nich je unimodálnosť, teda má jediné maximum. Kvôli tomu nedokáže dobre reprezentovať systémy, kde existuje viacero odlišných hypotéz o aposteriórnom odhade stavu [68].

5.3.1 Lineárny Kalmanov filter

Najzákladnejšou implementáciou Bayesoveho filtra je Lineárny Kalmanov filter (LKF). Je využiteľný iba pre lineárne spojité systémy. Popri Markovových predpokladoch majú ďalšie tri základné podmienky.

Po prvé, pravdepodobnostná funkcia nasledujúceho stavu $p(x_t | u_t, x_{t-1})$ musí byť *lineárna*, čo vyjadruje tento vzťah:

$$x_t = A_t x_{t-1} + B_t u_t + \varepsilon_t, \quad (5.20)$$

kde x_t, x_{t-1} sú stavové vektory rozmeru $n \times 1$, u_t je vektor riadiacich signálov rozmeru $m \times 1$, A_t je prechodová matica stavu rozmeru $n \times n$, B_t je riadiaca matica rozmeru $n \times m$ a vektor $\varepsilon_t \sim \mathcal{N}(0, Q_t)$ rozmeru $n \times 1$ slúži na modelovanie náhodných javov v prechodových dejoch systému. Dosadením do vzťahu (5.7b) tak vzniká vzťah pre pravdepodobnostnú funkciu prechodu stavu:

$$\begin{aligned} p(x_t | u_t, x_{t-1}) &= \\ &= \det(2\pi Q_t)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x_t - A_t x_{t-1} - B_t u_t)^\top Q_t^{-1}(x_t - A_t x_{t-1} - B_t u_t)\right), \end{aligned} \quad (5.21)$$

kde Q_t je tzv. *procesná matica šumu*, ktorá má rozmer $n \times n$ a vyjadruje mieru zhody predikčného modelu systému s realitou. Predstavuje jeden z hlavných konfiguračných prvkov filtra, keďže ovplyvňuje do akej miery bude výsledok filtra ovplyvnený predikciou modelu a do akej miery sa vezme do úvahy meranie. Keďže musí byť symetrická a kladne definitná, v praxi má väčšinou diagonálny charakter, ktorý umožňuje nezávislé nastavenie pre každý prvok stavového vektora.

Po druhé, aj pravdepodobnostná funkcia merania $p(z_t | x_t)$ musí byť lineárna:

$$z_t = C_t x_t + \delta_t, \quad (5.22)$$

kde z_t je vektor merania s rozmerom $k \times 1$, C_t je matica merania s rozmerom $k \times n$ a $\delta_t \sim \mathcal{N}(0, Q_t)$ predstavuje šum merania. Pravdepodobnostná funkcia merania je tak

definovaná ako:

$$p(z_t | x_t) = \det(2\pi R_t)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(z_t - C_t x_t)^\top R_t^{-1}(z_t - C_t x_t)\right), \quad (5.23)$$

kde R_t je matica rozmeru $k \times k$, ktorá vyjadruje lineárny merací model snímača.

Po tretie, počiatočný odhad stavu $\bar{x}_t$ má normálne rozdelenie pravdepodobnosti so stredom μ_0 a kovarianciou Σ_0 . Jeho pravdepodobnostná funkcia má takýto tvar:

$$\bar{x}_0 = p(x_0) = \det(2\pi \Sigma_0)^{-\frac{1}{2}} \exp\left(-\frac{1}{2}(x_0 - \mu_0)^\top \Sigma_0^{-1}(x_0 - \mu_0)\right) \quad (5.24)$$

Vďaka týmto trom podmienkam bude mať aposteriórny odhad stavu $\bar{x}_t$ normálne rozdelenie pravdepodobnosti $\mathcal{N}(x; \mu, \sigma^2)$ v ľubovoľnom čase t , a teda môže byť reprezentovaný vektorom strednej hodnoty μ_t a kovariančnou maticou Σ_t . Vstupom do algoritmu je odhad stavu v čase $t - 1$ reprezentovaný pomocou μ_{t-1} a Σ_{t-1} . Aktualizácia týchto parametrov je zabezpečená zapracovaním akčných zásahov u_t a meraní z_t .

Prehľad postupnosti výpočtov LKF je zobrazený v algoritme 3. Na riadkoch 1 – 2 sa počíta predikcia stavu, a to ešte pred zapracovaním aktuálneho merania. Výpočet vychádza zo znalosti dynamického modelu reprezentovaného maticami A_t, B_t a akčného zásahu u_t . K odhadu kovariancie sa pričítava už spomínaná procesná matica šumu Q_t , čím je potenciálne zvýšená neistota tohto odhadu (v závislosti od veľkosti prvkov v tejto matici). V korekčnej časti algoritmu je najskôr počítané tzv. *Kalmanovo zosilnenie* K_t (angl. *Kalman gain*, riadok 3 algoritmu 3). Predstavuje mieru zapracovania merania do odhadu stavu, pričom dôležitým parametrom v jeho výpočte je merací model reprezentovaný kovariančnou maticou R_t . Čím väčší je predpoklad neistoty merania, tým menšie Kalmanovo zosilnenie a teda aj menší vplyv merania z_t na odhad stavu, čo je vidieť na nasledujúcom riadku algoritmu. Napokon je opätovným využitím Kalmanovho

Algoritmus 3 Lineárny Kalmanov filter podľa [68]

Require: $\mu_{t-1}, \Sigma_{t-1}, u_t, z_t, A_t, B_t, Q_t, C_t, R_t$

Ensure: μ_t, Σ_t

Prediction:

- 1: $\hat{\mu}_t \leftarrow A_t \mu_{t-1} + B_t u_t$
- 2: $\hat{\Sigma}_t \leftarrow A_t \Sigma_{t-1} A_t^\top + Q_t$

Correction:

- 3: $K_t \leftarrow \hat{\Sigma}_t C_t^\top (C_t \hat{\Sigma}_t C_t^\top + R_t)^{-1}$
 - 4: $\mu_t \leftarrow \hat{\mu}_t + K_t (z_t - C_t \hat{\mu}_t)$
 - 5: $\Sigma_t \leftarrow (I - K_t C_t) \hat{\Sigma}_t$
 - 6: **return** μ_t, Σ_t
-

zosilnenia proporčne k zmene odhadu stavu aktualizovaný odhad kovariancie. Podrobné odvodenie LKF môžeme nájsť napríklad v [68, kap. 3.2.4].

5.3.2 Rozšírený Kalmanov filter

Predpoklady LKF, že systém má lineárne prechodové deje a lineárne merania s Gaussovým šumom limitujú jeho využitie len na tie najtriviálnejšie prípady. Už len obyčajný dvojrozmerný kinematický model mobilného robota s diferenciálnym podvozkom totiž musí byť opísaný nelineárnymi vzťahmi. Jeho stav je sa dá zapísať ako $x_t = (x \ y \ \theta)^\top$, kde x, y sú jeho pozičné súradnice a θ vyjadruje orientáciu. Akčný zásah má podobu $u_t = (v \ \omega)^\top$, kde v predstavuje lineárnu (tangenciálnu) a ω uhlovú rýchlosť vzťažného bodu. Ak uvažujeme konštantné hodnoty rýchlostí v, ω počas časového úseku Δt , robot sa bude vo všeobecnosti pohybovať po oblúku s polomerom r (priamočiary pohyb je pohyb po oblúku s nekonečným polomerom), pričom platí:

$$r = \left| \frac{v}{\omega} \right|. \quad (5.25)$$

Z toho je možné odvodiť, že nový stav $x_{t+1} = (x' \ y' \ \theta')^\top$ sa dá zapísať v tvare podľa [68, kap. 5.3.3]:

$$\begin{pmatrix} x' \\ y' \\ \theta' \end{pmatrix} = \begin{pmatrix} x \\ y \\ \theta \end{pmatrix} + \begin{pmatrix} -\frac{v_t}{\omega_t} \sin \theta + \frac{v_t}{\omega_t} \sin(\theta + \omega \Delta t) \\ \frac{v_t}{\omega_t} \cos \theta - \frac{v_t}{\omega_t} \cos(\theta + \omega_t \Delta t) \\ \omega_t \Delta t \end{pmatrix}. \quad (5.26)$$

Nelineárne funkcie sú často potrebné nie len na zápis stavového modelu, ale aj modelu merania. Keď uvažujeme senzor merajúci vzdialenosť k určitým objektom, ktoré sú lokalizované, resp. na základe ktorých sa má spresniť odhad polohy robota, takýto senzor (napr. lidar alebo kamera) prirodzene poskytuje meranie v tzv. *polárnych súradniciach*, teda v tvare $z_t = (r_t \ \varphi_t)^\top$, kde r_t je veľkosť a φ_t uhol smerového vektora merania v čase t . Polohu objektu vzhľadom na polohu robota je tak možné vyjadriť v tvare [14]:

$$\begin{pmatrix} m_x \\ m_y \end{pmatrix} = \begin{pmatrix} x \\ y \end{pmatrix} + \begin{pmatrix} r_t \cos(\varphi_t + \theta) \\ r_t \sin(\varphi_t + \theta) \end{pmatrix}. \quad (5.27)$$

V praxi je preto oveľa častejšie využívaný *Rozšírený Kalmanov filter (EKF)*, ktorý zovšeobecňuje modely pre odvodenie nasledujúcich stavov a meraní pomocou nelineárnych funkcií g (namiesto A_t a B_t) a h (namiesto C_t) [68]:

$$x_t = g(u_t, x_{t-1}) + \varepsilon_t, \quad (5.28)$$

$$z_t = h(x_t) + \delta_t. \quad (5.29)$$

Výsledkom použitia nelineárnych funkcií je, že pravdepodobnostné rozdelenie odhadu stavu už nie je Gaussovo. EKF počíta len aproximáciu skutočného pravdepodobnostného

rozdelenia stavu, ktorú ale reprezentuje opäť pomocou Gaussovho rozdelenia. Konkrétne, odhad stavu v čase t je reprezentovaný strednou hodnotou μ_t a kovariančnou maticou Σ_t . EKF tak preberá základnú reprezentáciu odhadu stavu z lineárneho Kalmanovho filtra, avšak na rozdiel od neho je tento odhad len približný, nie presný ako v prípade LKF [68].

Kľúčovým aspektom pri EKF je *linearizácia*. Keďže projekcia Gaussovej distribučnej funkcie cez nelineárne funkcie g a h by viedla k ne-Gaussovej distribúcii, nahrádzajú sa tieto funkcie lineárnymi, ktoré sú ich dotýčnice v strednej hodnote Gaussovej funkcie. Na linearizáciu sa v EKF používajú prvé dva členy *Taylorovho radu*. Funkcia g sa linearizuje v bode poslednej najpravdepodobnejšej hodnoty x_{t-1} , ktorou je stredná hodnota predchádzajúceho aposteriórneho odhadu μ_{t-1} a aktuálnej hodnoty riadiaceho signálu u_t . Jej sklon sa vypočíta ako parciálna derivácia v tomto bode:

$$g'(u_t, x_{t-1}) := \left. \frac{\partial g(u_t, x_{t-1})}{\partial x_{t-1}} \right|_{x_{t-1}=\mu_{t-1}} = G_t, \quad (5.30)$$

kde G_t je matica rozmeru $n \times n$ nazývaná *Jakobián*. Na lineárnu extrapoláciu funkcie g sa následne použijú prvé dva členy Taylorovho rozvoja:

$$g(u_t, x_{t-1}) \approx g(u_t, \mu_{t-1}) + G_t(x_{t-1} - \mu_{t-1}) \quad (5.31)$$

Pravdepodobnostnú funkciu nasledujúceho stavu je potom aproximovať takto:

$$\begin{aligned} p(x_t | u_t, x_{t-1}) &\approx \det(2\pi Q_t)^{-\frac{1}{2}} \\ &\exp \left(-\frac{1}{2} [x_t - g(u_t, \mu_{t-1}) - G_t(x_{t-1} - \mu_{t-1})]^\top \right. \\ &\quad \left. Q_t^{-1} [x_t - g(u_t, \mu_{t-1}) - G_t(x_{t-1} - \mu_{t-1})] \right) \end{aligned} \quad (5.32)$$

Rovnaký spôsob linearizácie je použitý aj pre prechodovú funkciu merania h , ktorá je aproximovaná v bode $\hat{\mu}_t$:

$$h(x_t) \approx h(\hat{\mu}_t) + H_t(x_t - \hat{\mu}_t) ; \quad H_t = \left. \frac{\partial h(x_t)}{\partial x_t} \right|_{x_t=\hat{\mu}_t} \quad (5.33)$$

Pravdepodobnostná funkcia merania je v tvare:

$$\begin{aligned} p(z_t | x_t) &\approx \det(2\pi R_t)^{-\frac{1}{2}} \\ &\exp \left(-\frac{1}{2} [z_t - h(\hat{\mu}_t) - H_t(x_t - \hat{\mu}_t)]^\top \right. \\ &\quad \left. R_t^{-1} [z_t - h(\hat{\mu}_t) - H_t(x_t - \hat{\mu}_t)] \right) \end{aligned} \quad (5.34)$$

Jednotlivé výpočty EKF sú znázornené v algoritme 4. V princípe je algoritmus veľmi podobný lineárnej verzii, avšak zásadný rozdiel je v tom, že lineárne predikcie

Algoritmus 4 Rozšírený Kalmanov filter podľa [68]

Require: $\mu_{t-1}, \Sigma_{t-1}, u_t, z_t, g, h, G_t, H_t, R_t, Q_t$

Ensure: μ_t, Σ_t

Prediction:

- 1: $\hat{\mu}_t \leftarrow g(u_t, \mu_{t-1})$
- 2: $\hat{\Sigma}_t \leftarrow G_t \Sigma_{t-1} G_t^\top + Q_t$

Correction:

- 3: $K_t \leftarrow \hat{\Sigma}_t H_t^\top (H_t \hat{\Sigma}_t H_t^\top + R_t)^{-1}$
 - 4: $\mu_t \leftarrow \hat{\mu}_t + K_t(z_t - h(\hat{\mu}_t))$
 - 5: $\Sigma_t \leftarrow (I - K_t H_t) \hat{\Sigma}_t$
 - 6: **return** μ_t, Σ_t
-

sú nahradené všeobecnejšími nelineárnymi funkciami. Odvodenie vzťahov pre EKF je možné nájsť v [68, kap. 3.3.3].

Implementáciu EKF si môžeme priblížiť na vyššie spomenutom prípade mobilného robota s diferenciálnym podvozkom. Kľúčové je pritom odvodiť Jakobiány G_t a H_t . Maticu G_t získame parciálnou deriváciou funkcie $g(x)$, ktorá je reprezentovaná vzťahom (5.26) [14]:

$$\begin{aligned} G_t &= \frac{\partial}{\partial(x, y, \theta)^\top} \left[\begin{pmatrix} x \\ y \\ \theta \end{pmatrix} + \begin{pmatrix} -\frac{v_t}{\omega_t} \sin \theta + \frac{v_t}{\omega_t} \sin(\theta + \omega \Delta t) \\ \frac{v_t}{\omega_t} \cos \theta - \frac{v_t}{\omega_t} \cos(\theta + \omega_t \Delta t) \\ \omega_t \Delta t \end{pmatrix} \right] \\ &= I + \frac{\partial}{\partial(x, y, \theta)^\top} + \begin{pmatrix} -\frac{v_t}{\omega_t} \sin \theta + \frac{v_t}{\omega_t} \sin(\theta + \omega \Delta t) \\ \frac{v_t}{\omega_t} \cos \theta - \frac{v_t}{\omega_t} \cos(\theta + \omega_t \Delta t) \\ \omega_t \Delta t \end{pmatrix} \\ &= I + \begin{pmatrix} 0 & 0 & -\frac{v_t}{\omega_t} \cos \theta + \frac{v_t}{\omega_t} \cos(\theta + \omega \Delta t) \\ 0 & 0 & -\frac{v_t}{\omega_t} \sin \theta + \frac{v_t}{\omega_t} \sin(\theta + \omega_t \Delta t) \\ 0 & 0 & 0 \end{pmatrix} \\ G_t &= \begin{pmatrix} 1 & 0 & -\frac{v_t}{\omega_t} \cos \theta + \frac{v_t}{\omega_t} \cos(\theta + \omega \Delta t) \\ 0 & 1 & -\frac{v_t}{\omega_t} \sin \theta + \frac{v_t}{\omega_t} \sin(\theta + \omega_t \Delta t) \\ 0 & 0 & 1 \end{pmatrix} \end{aligned} \quad (5.35)$$

Na výpočet Jakobiánu H_t je potrebné si najskôr zadať funkciu $h(x)$ na základe vzťahu (5.27) a za predpokladu, že odhad stavu je reprezentovaný $\hat{\mu}_t$ a odhad polohy

meraného objektu je μ_m [14, text]:

$$\begin{aligned}\delta &= \begin{pmatrix} \delta_x \\ \delta_y \end{pmatrix} = \begin{pmatrix} \hat{\mu}_{m,x} - \hat{\mu}_{t,x} \\ \hat{\mu}_{m,y} - \mu_{t,y} \end{pmatrix} \\ q &= \theta^\top \theta \\ \hat{z}_t &= \begin{pmatrix} \sqrt{q} \\ \text{atan2}(\delta_y, \delta_x) - \hat{\mu}_{t,\theta} \end{pmatrix} = h(\hat{\mu}_t).\end{aligned}\tag{5.36}$$

Derivovaním predošlého vzťahu s využitím reťazového pravidla pre stavový vektor rozšírený o súradnice objektu $\mu_t = (x \ y \ \theta \ m_x \ m_y)^\top$ je následne možné odvodiť [14]:

$$\begin{aligned}H_t &= \frac{\partial h(\hat{\mu}_t)}{\partial \hat{\mu}_t} \\ &= \frac{1}{q} \begin{pmatrix} -\sqrt{q}\delta_x & -\sqrt{q}\delta_y & 0 & \sqrt{q}\delta_x & \sqrt{q}\delta_y \\ \delta_y & -\delta_x & -q & -\delta_y & \delta_x \end{pmatrix}\end{aligned}\tag{5.37}$$

5.4 Využitie Kalmanových filtrov pre fúziu snímačov

Dizajn Kalmanových filtrov, ktorý umožňuje rekurzívne spracovanie sekvenčných údajov a zohľadnenie chybových charakteristík týchto dátových tokov ako aj znalostí o správaní systému, ich predurčuje byť jedným z najvhodnejších a najpoužívanějších nástrojov na fúziu snímačov. Keďže však väčšina reálnych problémov je opísaná nelineárnymi modelmi, v praxi sa najčastejšie stretávame s využitím Rozšíreného Kalmanovho filtra a jeho komplexnejších variácií. Ich popularita v robotickej lokalizácii vychádza z kompromisu medzi výpočtovou efektivitou, schopnosťou pracovať v reálnom čase a dostatočne presným odhadom stavu systému.

Kľúčovými parametrami pri implementácii EKF sú:

1. model stavu,
2. merací model,
3. procesný šum a merací šum,
4. lineárne aproximácie nelineárnych funkcií pomocou Jakobiánov.

Súčasný prístup k EKF sa líši hlavne tým, ako tieto modely zostavujú, ladia a využívajú v špecifických aplikáciách, ako je senzorická fúzia, lokalizácia robotov, alebo navigácia v reálnom čase.

V základnej formulácii EKF predpokladá, že pohyb robota je opísaný nelineárnym stavovým modelom, často odvodeným z kinematiky diferenciálneho pohonu alebo unicykla, pričom merania pochádzajú z rôznych senzorov ako LiDAR, INS, GNSS alebo

odometria. Tieto senzory typicky poskytujú komplementárne informácie – napríklad INS zachytáva krátkodobú dynamiku, zatiaľ čo GNSS poskytuje pomalé, ale globálne ukotvené merania. EKF zabezpečuje ich optimálne zlúčenie na základe štatistického modelu nepresností a korelácií medzi odhadmi a meraniami [68].

Jedným z hlavných výskumných smerov je presné modelovanie procesného šumu (matica Q_t) a meracieho šumu (matica R_t), ktoré významne ovplyvňujú kvalitu lokalizačného odhadu. V pokročilejších implementáciách sa tieto matice nenastavujú staticky, ale adaptívne upravujú počas prevádzky na základe štatistických ukazovateľov – napríklad pomocou analýzy inovačných rezíduí. Takéto adaptívne EKF riešenia nachádzajú uplatnenie v lokalizácii autonómnych vozidiel v dynamickom prostredí [75].

Ďalšou významnou oblasťou vývoja je robustnosť voči odľahlým meraniam, napríklad pri dočasnom výpadku GPS signálu alebo prechodom senzora cez oblasť s nízkym kontrastom. V takýchto prípadoch sa do EKF integrujú techniky detekcie odľahlých údajov a filtračné mechanizmy s inovačným obmedzením (angl. *gating*), prípadne sa používajú robustné varianty EKF s nelineárnym zaobchádzaním s neistotou (Fang et al., 2019).

Pri odhade orientácie zo sensorov ako IMU je vhodné aplikovať multiplikatívny EKF (MEKF), ktorý rešpektuje nelineárnu štruktúru priestorovej rotácie ($SO(3)$) a zachováva normu kvaternionov. Tento prístup sa často používa v kombinácii s lokalizačnými systémami GNSS/INS, kde dochádza k fúzii globálneho a inerciálneho odhadu polohy [70].

V posledných rokoch sa do popredia dostáva aj invariantný EKF (IEKF), ktorý pri fúzii údajov z vizuálnych a inerciálnych sensorov zohľadňuje symetrickú štruktúru systému (napr. $SE(2)$ alebo $SE(3)$), čím sa zlepšuje konzistentnosť filtra a eliminujú kumulatívne chyby spôsobené chybnou linearizáciou. Tieto prístupy sa ukazujú ako veľmi efektívne pri vizuálno-inerciálnych lokalizačných systémoch v interiéri aj exteriéri [7].

Nové trendy tiež zahŕňajú hybridné prístupy, kde sú niektoré časti modelu (napr. dynamika robota alebo sensorový model) aproximované neurónovými sieťami. Takto vznikajú tzv. *learned EKF*, kde sa časť odhadu odovzdáva trénovateľnému modulu, čo umožňuje modelovať aj komplexné nelinearity a kompenzovať senzorické chyby bez explicitného modelovania [37].

6 Čo sú umelé neurónové siete


Cieľom umelých neurónových sietí (UNS) je napodobniť štruktúru a spôsob fungovania ľudského mozgu. Ten je na vonkajšej strane pokrytý mozgovou kôrou, ktorá obsahuje obrovské množstvo neurónov (v literatúre sa uvádza číslo približne 10^{10} [47]), ktoré sú vzájomne prepojené axónmi cez spojenia tvorené synapsami na jednej strane a dendridmi na druhej, vďaka čomu dochádza k prenosu informácií v podobe elektrického signálu. Jeden ľudský neurón môže byť prepojený s tisíckami iných [47]. Centrálna nervová sústava je schopná paralelne spracúvať veľké množstvo informácií z receptorov, pracovať s pamäťou a učiť sa z poznatkov, názorných aj analogických príkladov, zovšeobecňovať, konkretizovať a v konečnom dôsledku generovať riadiace pokyny pre ostatné časti tela.

Elementárnym prvkom UNS je *umelý neurón*. Zjednodušený model umelého neurónu, používaný v podstate dodnes, bol predstavený ešte v roku 1943 v práci McCullocha a Pittsa [46]. Jeho grafické znázornenie môžeme vidieť na obrázku 6.1. Matematicky je možné vyjadriť vstupno-výstupnú závislosť umelého neurónu ako

$$y = f\left(\sum_{i=1}^n w_i x_i - \theta\right) = f(a), \quad (6.1)$$

kde x_i sú vstupy do neurónu, w_i váhy synaptických prepojení smerujúcich do neurónu, θ je prah neurónu (nazývaný tiež *bias*), a predstavuje vnútornú aktivitu, $f(a)$ aktivačnú funkciu a y je výstup z neurónu.

UNS sa skladajú z množstva neurónov, ktoré sú usporiadané do vrstiev. Prvá vrstva sa nazýva vstupná, neuróny v nej prijímajú vstupné informácie a posielajú ich ďalej. Posledná vrstva neurónovej siete, ktorá poskytuje výsledok, sa nazýva výstupná. Medzi vstupnou a výstupnou vrstvou sa môžu vyskytovať tzv. skryté vrstvy, ktoré slúžia na vykonávanie medzivýpočtov, čím umožňujú riešenie komplexnejších úloh. Výpočtový



Obr. 6.1: McCulloch-Pittsov model neurónu. x_i sú vstupy neurónu, w_i váhy synaptických spojení, θ je prah neurónu, $f(a)$ predstavuje aktivačnú funkciu, a vnútornú aktivitu, y je výstup z neurónu.

výkon siete je daný práve schopnosťou skrytých vrstiev modelovať nelineárne vzťahy medzi vstupmi a výstupmi. UNS je možné rozdeliť do viacerých kategórií:

1. Podľa architektúry usporiadania neurónov do vrstiev:

- (a) *Jednovrstvové siete – perceptróny (SLP)* – skladajú sa len zo vstupnej (nevykonávajúcej výpočty) a výstupnej vrstvy; využíva sa úplné prepojenie, teda každý vstupný neurón je prepojený s každým výstupným; obvykle využívajú skokové aktivačné funkcie a ich účelom je klasifikácia do tried;
- (b) *Viacvrstvové siete – viacvrstvové perceptróny (MLP)* – obsahujú aspoň jednu skrytú vrstvu; vstupná vrstva slúži iba na distribúciu vstupných informácií, výkonnú funkciu majú iba skryté vrstvy a výstupná vrstva. Umožňujú riešenie lineárne neseparovateľných problémov.
- (c) *Hlboké neurónové siete* – majú vyšší počet skrytých vrstiev, umožňujú modelovanie komplexnejších závislostí. Medzi najznámejšie architektúry patria hlboké dopredné neurónové siete (DFFN), konvolučné neurónové siete (CNN), používané v oblasti spracovania obrazu, a rekurentné neurónové siete (RNN), vhodné na spracovanie sekvenčných dát [41, 66].

2. Podľa spôsobu šírenia informácií v rámci siete:

- (a) *Dopredné siete* – (angl. *feed-forward*) obsahujú iba väzby v smere od vstupov k výstupom,
- (b) *Rekurentné siete* – obsahujú aspoň jednu spätnú väzbu v rámci tej istej vrstvy alebo v rámci rôznych vrstiev,

Kľúčom k úspešnosti neurónových sietí vo vykonávaní učenej úlohy je proces ich učenia. Učenie je možné definovať ako proces zlepšovania výkonu na základe pozorovania okolitého prostredia [62]. Proces učenia neurónovej siete zahŕňa úpravu váh w_i na základe chyby medzi predikovaným a skutočným výstupom. Najčastejšie sa používa algoritmus *gradientného zostupu* v kombinácii s technikou *spätného šírenia* (angl. *backpropagation*) [60]. Cieľom je minimalizovať hodnotu funkcie odchýlky, napr. strednej kvadratickej chyby:

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2, \quad (6.2)$$


kde y_i je skutočný a $\hat{y}_i$ predikovaný výstup.

6.1 Aktivačná funkcia

Aktivačná funkcia zabezpečuje nelinearitu neurónu, vďaka čomu je UNS schopná riešiť zložitejšie problémy. Výber vhodnej aktivačnej funkcie je jednou z kritických častí návrhu UNS a musí byť prispôsobený typu úlohy, ktorú má neurónová sieť vykonávať. V pôvodnom modeli [46] sa používala len binárna (skoková) funkcia $f(a) = \text{sgn}(a)$. Tá je stále používaná v perceptrónových neurónových sieťach, ktoré vykonávajú klasifikáciu. V mnohých prípadoch sa však vyžaduje spojitý výstup siete, preto sa používajú viaceré typy spojitých aktivačných funkcií [1]:

- *lineárna funkcia*: $f(a) = a$ – používa sa v prípade, že výstupná premenná je reálne číslo; v takom prípade rieši sieť regresiu najmenších štvorcov $\hat{y} = \sum_{i=1}^n w_i x_i$;
- *sigmoida*: $f(a) = S(a) = \frac{1}{1+e^{-\beta a}}$ – vhodná pre prípad odhadu pravdepodobnosti binárnej triedy, účelová funkcia má tvar $\hat{y} = -\log \left| \frac{y}{2} - 0,5 + \hat{y} \right|$ za predpokladu $y \in \{-1, 1\}$;
- *hyperbolický tangens*: $f(a) = \tanh\left(\frac{a}{2}\right) = \frac{1-e^{-a}}{1+e^{-a}} = 2S(2a) - 1$ – ide v podstate o preškálovaný a transformovaný sigmoid tak, že pripomína skokovú funkciu, avšak na rozdiel od nej je diferencovateľná. Je vhodná v prípade, že výstup môže nadobúdať kladné aj záporné hodnoty. Navyše, jej gradient je viac koncentrovaný okolo nuly, vďaka čomu sa trénuje jednoduchšie než sigmoid. Tento efekt sa zvykne ešte zosilniť modifikáciami, ako napr. $f(a) = \tanh(3a)$;
- *upravená lineárna jednotka (ReLU)*: $f(a) = \max\{a, 0\}$ – patrí k novším typom aktivačných funkcií; je výhodná pri trénovaní viacvrstvových sietí s množstvom neurónov, a to najmä vďaka rýchlejšiemu výpočtu gradientu, ale tiež pre nižšie riziko výskytu *efektu miznúceho gradientu* a zabránenie saturácii. Nevýhodou je strata informácie zo záporných vstupov a riziko vzniku tzv. *mŕtveho neurónu*: keď sa raz váhy neurónu natrénujú na záporné hodnoty, jeho výstup bude vždy nulový;
- „*Hard Tanh*“: $f(a) = \max\{\min[v, 1], -1\}$ – je to po častiach lineárna aproximácia hyperbolického tangensu; výpočtovo menej náročná, zachováva saturáciu, čo býva žiaduce napríklad pri výstupných neurónoch; podobne ako ReLU má v citlivej časti konštantný nenulový gradient, čo má význam pri spätnom šírení gradientu.

Aktivačné funkcie ReLU a Hard Tanh v poslednej dobe zväčša nahrádzajú klasické typy, ako sú sigmoid a hyperbolický tangens, a to pre zjednodušenie trénovania viacvrstvových neurónových sietí s týmito funkciami [1]. Grafické znázornenia aktivačných funkcií sa nachádzajú na obr. 6.2.



Obr. 6.2: Vybrané aktivačné funkcie.

V MLP sieťach sa v neurónoch výstupnej vrstvy často využíva aj aktivačná funkcia *softmax*. Jej úlohou je prepočítať výstupy poslednej skrytej vrstvy na pravdepodobnostné hodnoty, teda musí platiť $y_i \in \langle 0; 1 \rangle$ a zároveň $\sum_i y_i = 1$. To je zabezpečené predpisom funkcie

$$f(y_i) = \frac{\exp(h_i)}{\sum_{j=1}^k \exp(h_j)} ; \forall i \in \{1, \dots, k\}, \quad (6.3)$$

kde $H = (h_1, \dots, h_k)^\top$ je vektor výstupov poslednej skrytej vrstvy a k je počet výstupných neurónov aj neurónov poslednej skrytej vrstvy. Tento typ aktivačnej funkcie je výhodné použiť na klasifikáciu väčšieho množstva tried [1].

7 Perceptróny

Základným typom neurónových sietí sú perceptróny. Slúžia na klasifikáciu vstupných údajov a pôvodne boli predstavené predstavené Rosenblattom v roku 1958 [56], ktorý ich architektúru rozdelil na tri vrstvy: senzorickú, asociačnú a výstupnú. Senzorická vrstva sa namiesto plnohodnotných neurónov skladá len zo vstupných terminálov, ktorých počet zodpovedá rozmeru vstupného vektora a ich úlohou je preposielanie vstupných hodnôt ďalej (príp. normalizácia vstupných hodnôt). Za ňou môže nasledovať asociačná, teda skrytá vrstva, v ktorej neuróny slúžia na vykonávanie medzivýpočtov a umožňujú riešenie lineárne neseparovateľných problémov (viac v časti 7.2). Výstupy skrytej vrstvy nie sú čitateľné, slúžia ako vstupy pre neuróny poslednej, výstupnej vrstvy. V pôvodnej architektúre váhy skrytej vrstvy nepodliehali učeniu. Napokon, výstupná vrstva slúži na výsledné výpočty siete. Počet neurónov v nej zodpovedá počtu tried, ktoré sa v rámci úlohy klasifikácie rozlišujú. Neuróny v takejto sieti sú pospájané v doprednom smere (angl. *feed-forward*), teda zľava doprava. Všetky prepojenia perceptrónu sú jednosmerné, informácie sa posielajú len v smere dopredu k neurónom susediacim sprava. Nenachádzajú sa v ňom žiadne spätné prepojenia ani prepojenia preskakujúce vrstvu [47].

Počas nasledujúceho vývoju v oblasti UNS však došlo z didaktických dôvodov k ustáleniu termínu *perceptrón* iba na jednovrstvovú lineárne separovateľnú architektúru, *jednovrstvový perceptrón (SLP)*. Klasifikačné siete s menej ako štyrmi skrytými vrstvami sa zvyknú označovať aj *viacvrstvové perceptróny (MLP)*.

7.1 Jednovrstvové perceptróny

Vstupná vrstva jednovrstvého perceptrónu obsahuje d vstupných terminálov pre vstupný vektor $X = (x_1, x_2, \dots, x_d)^\top$, ku ktorým je priradený vektor váh $W = (w_1, w_2, \dots, w_d)^\top$. Výstupná jednotka vypočíta vážený súčet vstupov a výsledok spracuje pomocou skokovej funkcie, ktorá určuje výstupnú triedu [1]:

$$\hat{y} = \text{sign}(W \cdot X + \theta) = \text{sign} \left(\sum_{j=1}^d w_j x_j + \theta \right), \quad (7.1)$$

kde θ predstavuje tzv. *bias* – prahovú hodnotu, ktorá umožňuje posun rozhodovacej hranice. V implementáciách sa často reprezentuje ako špeciálny vstup s hodnotou 1 a vlastnou váhou.

Perceptrón funguje ako lineárny klasifikátor: rozhodovaciu hranicu tvorí hyper-rovina $W \cdot X + \theta = 0$, ktorá rozdeľuje vstupný priestor na dve triedy. Tento prístup je účinný v prípadoch, keď sú dáta *lineárne separovateľné*.

7.2 Lineárna separovateľnosť – problém klasifikácie

Problém lineárnej separovateľnosti je možné priblížiť na jednoduchom príklade. Majme klasifikačnú úlohu pre dvojrozmerné reálne vstupné vektory $X = (x_1, x_2)^\top$, ktoré majú byť rozdelené do cieľových skupín, teda tried $y \in \{-1, 1\}$. Na riešenie teoreticky stačí použiť jeden neurón so skokovou aktivačnou funkciou, teda výstup neurónu je počítaný ako skalárny súčin vstupov a váh:

$$\hat{y} = \text{sgn}(w_1x_1 + w_2x_2 - \theta) = \text{sgn}(W \cdot X - \theta), \quad (7.2)$$


kde $W = (w_1, w_2)$ je vektor váh, ktoré pripájajú vstupy neurónu [47]. Skalárny súčin, ktorý vystupuje vo vzťahu (7.2), je možné riešiť aj geometricky po úprave:

$$\begin{aligned} W &= |W| \begin{bmatrix} \cos \alpha \\ \sin \alpha \end{bmatrix} ; |W| = \sqrt{w_1^2 + w_2^2}, \\ X &= |X| \begin{bmatrix} \cos \beta \\ \sin \beta \end{bmatrix} ; |X| = \sqrt{x_1^2 + x_2^2}, \\ W \cdot X &= |W||X| \cos(\alpha - \beta) = |W||X| \cos \varphi, \end{aligned} \quad (7.3)$$


kde α a β sú uhly, ktoré zvierajú vektor váh, resp. vstupov s osou x_1 a φ je uhol medzi nimi. Z toho je zrejmé, že výsledok skalárneho súčinu bude kladný pre $\varphi \in (-\frac{\pi}{2}, \frac{\pi}{2})$, inak bude záporný. Dôsledkom toho je zabezpečená správna klasifikácia vtedy, keď je vektor váh kolmý na rozhodovaciu hranicu, ktorá vymedzuje jednotlivé triedy. Situácia je graficky znázornená na obr. 7.1.

V uvedenom príklade sme pre zjednodušenie neuvažovali s biasom neurónu θ . Jeho vplyv na rozhodovaciu hranicu je však zrejmý keď položíme argument zo vzťahu (7.2) rovný nule a odvodíme

$$x_2 = -\frac{w_1}{w_2}x_1 + \frac{\theta}{w_2}, \quad (7.4)$$



Obr. 7.1: Geometrické riešenie klasifikácie.



(a) Kojunkcia (AND) – lineárne separovateľná

(b) Exkluzívna disjunkcia (XOR) – lineárne neseparovateľná

Obr. 7.2: Lineárna separovateľnosť vybraných logických funkcií. ● pre pravd. hodnotu „TRUE“ ($y = 1$), ○ pre pravd. hodnotu „FALSE“ ($y = -1$).

z čoho vyplýva, že bias má vplyv na priesečník rozhodovacej hranice s osou x_2 [47].

Ak existuje taká lineárna hranica (napr. priamka v 2D, rovina v 3D, hyper-rovina vo vyšších dimenziách), ktorá dokáže oddeliť všetky vstupné prvky jednej triedy od druhej bez chyby, takúto množinu vstupov nazývame *lineárne separovateľná* a jej klasifikácia je zvládnuteľná pomocou jediného jediného neurónu.

Dobрым príkladom na demonštráciu lineárnej separovateľnosti sú aj logické funkcie. Na obr. 7.2 je porovnanie funkcií konjunkcie, ktorá je lineárne separovateľná a exkluzívnej disjunkcie, ktorá nie je.

7.3 Viacvrstvové perceptróny

V prípade SLP je jediná výpočtová vrstva výstupná, keďže vstupná vrstva nevykonáva žiadne výpočty. Viacvrstvové perceptróny (MLP) obsahujú viacero výpočtových vrstiev. Keďže ale výsledky vrstiev pridaných medzi vstupnú a výstupnú vrstvu nie sú viditeľné pre užívateľa, označujú sa ako *skryté vrstvy*.

Pridanie skrytej vrstvy umožňuje MLP riešiť lineárne neseparovateľné problémy, nakoľko rozdeľuje klasifikačný priestor na viac než len dva segmenty. Jednoduchý príklad takejto siete, ktorá klasifikuje dvojrozmerný vstupný vektor pomocou troch skrytých a jedného výstupného neurónu, môžeme vidieť na obr. 7.3. Neuróny vypočítavajú výstupné hodnoty pomocou skokovej aktivačnej funkcie v tvare

$$h_j = f \left(\sum_k w_{jk} x_k - \theta_j \right), \quad (7.5a)$$

$$\hat{y}_i = f \left(\sum_j W_{ij} h_j - \theta_i \right), \quad (7.5b)$$


pričom výsledok môže nadobúdať hodnoty $y_i = \{-1, +1\}$ [47]. Každý z neurónov v skrytej vrstve má vlastnú rozhodovaciu hranicu. Cieľom je teda nájsť také hodnoty w_{jk} a θ_j , aby rozhodovacie hranice rozdelili vstupnú rovinu (keďže máme dvojrozmerný vstup, môžeme si ho predstaviť ako súradnice bodov v rovine) na také segmenty, ktoré budú obsahovať len prvky jednej triedy. Situácia je znázornená na obr. 7.4.

Mechanizmus klasifikácie je možné si predstaviť tak, že každý zo vstupných bodov obdrží množinu výstupných hodnôt skrytých neurónov $\{h_1, h_2, h_3\}$. Každý zo segmentov je potom charakterizovaný unikátnou kombináciou výstupov skrytej vrstvy. Váhy w_{1j} a prahové hodnoty θ_j musia byť nastavené tak, aby každému vzniknutému segmentu vstupnej roviny pridelil výstupný neurón správnu triedu y_i , čo už opäť predstavuje lineárne separovateľný problém. To prebieha v tomto konkrétnom prípade na základe vzťahu


$$\hat{y}_1 = \text{sgn}(h_1 + h_2 + h_3). \quad (7.6)$$

Je potrebné si uvedomiť, že neexistuje jedinečné riešenie takéhoto problému; sú možné viaceré kombinácie váh a prahových hodnôt neurónov, ktoré by spĺňali požiadavky klasifikácie, ako aj viaceré rozloženia siete. Vo všeobecnosti však platí, že pre zložitejšie problémy klasifikácie je potrebných viac skrytých neurónov [47]. V práci autorov Minsky a Papert z roku 1969 [48] bolo preukázané, že všetky logické operácie je možné vyriešiť pomocou MLP za podmienky, že aspoň jeden zo skrytých neurónov je pripojený ku všetkým vstupným terminálom.

Pri základnej architektúre dopredných sietí sa predpokladá, že všetky neuróny jednej vrstvy sú pripojené ku všetkým neurónom nasledujúcej vrstvy. V prípade, že sieť obsahuje len jednu skrytú vrstvu, hovoríme o tzv. *plytkej sieti*. MLP však môže obsahovať viac než len jednu skrytú vrstvu. Je matematicky dokázané, že UNS s tromi vrstvami



Obr. 7.3: Viacvrstvový perceptrón s jednou skrytou vrstvou so vstupnými terminálmi x_k , skrytými neurónmi h_j , výstupným neurónom y_1 , a váhami prepojení medzi vrstvami w_{jk} a w_{1j} . [47]



(a) Lineárne separovateľný problém klasifikovaný pomocou SLP. (b) Lineárne neseparovateľný problém klasifikovaný pomocou MLP, tvoriacej po častiach lineárnu rozhodovaciu hranicu.

Obr. 7.4: Porovnanie klasifikácie pomocou SLP a MLP.

sú schopné aproximovať ľubovoľnú spojitú nelineárnu funkciu a siete so štyrmi vrstvami stačia na aproximáciu ľubovoľnej nespojitej nelineárnej funkcie. Ak sieť obsahuje viac ako tri skryté vrstvy, zvykne sa nazývať *hlboká (dopredná) sieť (DFFN)*.

Pre praktický zápis matematických operácií vnútri siete sa na označenie jednotlivých prvkov používa vektorová, resp. maticová forma. MLP obsahuje vstupnú vrstvu označenú vektorom X veľkosti $d \times 1$, kde d je rozmer vstupných dát, k skrytých vrstiev o veľkosti $p_1 \dots p_k$, ktorých výstupy označujú vektory $H_1 \dots H_k$. Vstupná vrstva je na prvú skrytú vrstvu pripojená váhami označenými maticou W_1 veľkosti $d \times p_1$, zatiaľ čo r -tá skrytá vrstva je prepojená s $(r+1)$ -ou maticou W_r veľkosti $p_r \times p_{r+1}$. Za predpokladu, že máme vektor výstupných neurónov $O = (o_1, \dots, o_m)^\top$, tie sa pripájajú k poslednej skrytej vrstve pomocou váh označených maticou W_{k+1} s veľkosťou $p_k \times m$. Vstupno-výstupný výpočet MLP je potom možné zapísať pomocou nasledujúcich rekurzívnych vzťahov [1]:

$$H_1 = f(W_1^\top X) \quad (7.7a)$$

$$H_{p+1} = f(W_{p+1}^\top H_p) \quad \forall p \in (1 \dots k-1) \quad (7.7b)$$

$$o = f(W_{k+1}^\top H_k). \quad (7.7c)$$

Základnými parametrami pri návrhu siete sú teda počet skrytých vrstiev, počty skrytých vrstiev a neurónov v jednotlivých vrstvách, a tiež výber aktivačných funkcií neurónov. V neposlednom rade, úspešnosť trénovania neurónovej siete závisí od výberu optimalizačnej funkcie odchýlky.

8 Trénovanie UNS


Trénovanie umelých neurónových sietí predstavuje kľúčový proces, prostredníctvom ktorého sa model učí z dostupných dát optimalizáciou svojich parametrov, najmä váh a prahov neurónov. Cieľom trénovania je minimalizovať odchýlku medzi výstupom siete $\hat{y}$ a požadovaným výstupom y , čo sa dosahuje iteratívnym prispôbovaním parametrov na základe výpočtu gradientu chyby. Jedným z kľúčových aspektov trénovania je preto výber vhodnej funkcie na výpočet odchýlky (v angl. literatúre označovanej *loss function*) vzhľadom ku konkrétnemu typu úlohy, ktorú UNS rieši. Obrázok 8.1 znázorňuje základný princíp trénovania UNS. V tejto časti sa podrobnejšie pozrieme na jeden z prvých používaných algoritmov – perceptrónové kritérium – ale aj na v súčasnosti najbežnejšiu metódu spätného šírenia chyby. Priblížime tiež časté problémy, ktoré sa pri procese trénovania môžu vyskytnúť.

8.1 Perceptrónové kritérium

Pôvodný perceptrónový algoritmus prebiehal heuristicky pomocou elektrických obvodov, na rozdiel od súčasného chápania problému ako optimalizačnej úlohy. V každom prípade, cieľ ostáva zachovaný a je ním nájsť také váhy W , ktoré minimalizujú počet chybne klasifikovaných príkladov v množine trénovacích vstupno-výstupných párov (X, y) . Úlohu perceptrónového algoritmu je teda možné zapísať v tvare účelovej funkcie najmenších štvorcov pre všetky trénovacie objekty datasetu $\mathcal{D}$ [1] ako

$$\mathcal{L} = \arg \min_W \sum_{(X,y) \in \mathcal{D}} (y - \hat{y})^2 = \sum_{(X,y) \in \mathcal{D}} [y - \text{sign}(W \cdot X)]^2 \quad (8.1)$$

Tento typ minimalizácie účelovej funkcie sa označuje aj ako *funkcia odchýlky* (z angl. *loss function*) [1]. Problém takto formulovanej funkcie však spočíva v použití skokovej



Obr. 8.1: Základná schéma algoritmov trénovania UNS.

funkcie signum, ktorá nie je diferencovateľná, obsahuje skoky a na veľkej časti definičného oboru má konštantné hodnoty, čo spôsobuje nulový gradient, teda nie je vhodná pre metódu gradientného zostupu. Na odvodenie jej hladkej náhrady sa používa tzv. *perceptrónové kritérium*. Jeho princíp spočíva v prvotnom definovaní účelovej funkcie s výstupom 0/1 pre jeden príklad vstupno-výstupného páru (X, y) [1]:

$$L^{(0/1)}(X, y) = \frac{1}{2} (y - \hat{y})^2 = 1 - y \cdot \text{sign}(W \cdot X + \theta). \quad (8.2)$$

Táto funkcia nie je diferencovateľná kvôli prítomnosti skokovej funkcie sign, preto sa na analytické účely nahrádza hladkou účelovou funkciou [1]:

$$L(X, y) = \max \{-y(W \cdot X + \theta), 0\}. \quad (8.3)$$

Táto tzv. *hladká náhrada funkcie odchýlky* penalizuje len nesprávne klasifikované príklady a jej gradient možno využiť na aktualizáciu váh [1]:

$$W \leftarrow W + \alpha (y - \hat{y}) X, \quad (8.4)$$

kde α je rýchlosť učenia. Váhy sa menia iba v prípade, že $y \neq \hat{y}$. Tento prístup je stochastickým gradientným zostupom (SGD), ktorý optimalizuje (aj keď len približne) uvedenú hladkú funkciu.

8.2 Spätné šírenie chyby

Optimalizačné kritérium pre SLP je ľahko definovateľné, keďže výstup siete je priamou funkciou váh. To umožňuje jednoduchý výpočet gradientu pomocou diferenciácie. Pri viacvrstvových sieťach je však odchýlka výstupu komplikovanou zloženou funkciou váh v predošlých vrstvách, ktorú môžeme zjednodušene zapísať ako $\mathcal{L} = f(o(h_r(w_r)))$. Preto sa za účelom výpočtu jej gradientu používa algoritmus *spätného šírenia chyby*. Ten využíva reťazové pravidlo diferenciálneho počtu, ktoré počíta gradienty chyby ako sumu násobkov lokálnych gradientov skrytých neurónov pozdĺž rôznych ciest od daného neurónu až po výstup. Keďže počet ciest medzi skrytým neurónom a výstupom môže rásť exponenciálne s hĺbkou a šírkou siete, priamy výpočet všetkých príspevkov by bol výpočtovo náročný. Preto sa spätné šírenie realizuje efektívne pomocou dynamického programovania, ktoré opakovane (rekurzívne) využíva už vypočítané medzivýsledky. Výpočet spätného šírenia chyby prebieha vo viacerých cykloch, tzv. *epochách*, pričom každá pozostáva z dvoch hlavných fáz:

1. *Dopredná*: Cez sieť sa v smere od vstupu k výstupu postupne prepočítavajú aktivácie všetkých neurónov pre každú tréningovú vzorku na základe aktuálneho

nastavenia váh. Výstup siete je porovnaný s požadovaným výstupom tréningových dát, na základe čoho sa vypočíta odchýlka výstupu.

2. V každej vrstve v smere od výstupu k vstupu sa vypočíta lokálny gradient odchýlky voči daným váham a aktiváciám z predchádzajúcej vrstvy, na základe čoho sú prepočítané jednotlivé hodnoty váh.

Uvažujme sekvenciu skrytých neurónov $h_1 \dots h_k$, ktorá je zakončená výstupným neurónom o . Keď budeme uvažovať len jedinú cestu z neurónu h_1 do o , potom je možné gradient váh smerujúcich do r -tého neurónu, ktoré označíme $w_{(h_{r-1}, h_r)}$, vypočítať pomocou reťazového pravidla jednej premennej [1]:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \frac{\partial \mathcal{L}}{\partial o} \cdot \left[\frac{\partial o}{\partial h_k} \prod_{i=r}^{k-1} \frac{\partial h_{i+1}}{\partial h_i} \right] \cdot \frac{\partial h_r}{\partial w_{(h_{r-1}, h_r)}} \quad \forall r \in 1 \dots k \quad (8.5)$$

Vo všeobecnosti však bude v MLP sieti existovať exponenciálne väčšia množina prepojení neurónov h_r a o , ktorú označíme $\mathcal{P}$. Vzťah (8.5) je teda možné zovšeobecniť pre všetky existujúce prepojenia pomocou reťazového pravidla viacerých premenných:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \frac{\partial \mathcal{L}}{\partial o} \cdot \underbrace{\left[\sum_{[h_r, h_{r+1}, \dots, h_k, o] \in \mathcal{P}} \frac{\partial o}{\partial h_k} \prod_{i=r}^{k-1} \frac{\partial h_{i+1}}{\partial h_i} \right]}_{\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r}} \cdot \frac{\partial h_r}{\partial w_{(h_{r-1}, h_r)}} \quad (8.6)$$

Tento vzťah je logicky rozdelený na dve časti. Prvá časť, označená ako $\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r}$, predstavuje agregovaný gradient chyby vzhľadom na výstup neurónu h_r a zahŕňa vplyv všetkých ciest vedúcich z tohto neurónu až po výstup o . Nakoľko jeho veľkosť exponenciálne narastá s veľkosťou siete, jeho výpočet je komplikovanejší. Posledný činiteľ vzťahu predstavuje vplyv zmeny váh vstupujúcich do skrytého neurónu h_r na jeho výstup. Je možné ho vypočítať pomocou derivácie aktivačnej funkcie ako

$$\frac{\partial h_r}{\partial w_{(h_{r-1}, h_r)}} = h_{r-1} \cdot f'(a_{h_r}) \quad (8.7)$$

Pri výpočte už spomenutého agregovaného člena $\Delta(h_r, o)$ sa využíva fakt, že výpočtový graf siete je acyklický, preto je možné začať výpočet spätných gradientov od výstupnej vrstvy. Najskôr sa vypočíta $\Delta(h_k, o)$ pre poslednú skrytú vrstvu h_k , a následne sa gradienty šíria späť smerom k vstupným vrstvám pomocou rekurzívne definovaného vzťahu. Navyše, každý výstupný neurón je pri výpočte inicializovaný na hodnotu $\frac{\partial \mathcal{L}}{\partial o} = \Delta(o, o)$. Rekurzívny vzťah pre $\Delta(h_r, o)$ sa následne pomocou reťazového pravidla odvodí ako

$$\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r} = \sum_{h: h_r \rightarrow h} \frac{\partial \mathcal{L}}{\partial h} \frac{\partial h}{\partial h_r} = \sum_{h: h_r \rightarrow h} \frac{\partial h}{\partial h_r} \Delta(h, o), \quad (8.8)$$

kde $\Delta(h, o)$ je gradient predchádzajúcej vrstvy (bližšie k výstupu), teda je potrebné odvodiť parciálnu deriváciu $\frac{\partial h}{\partial h_r}$. Na to sa využije skutočnosť, že skryté neuróny h_r a h sú spojené váhou $w_{(h_r, h)}$ a a_h je argument aktivačnej funkcie v neuróne h . Teda pomocou reťazového pravidla jednej premennej je možné odvodiť:

$$\frac{\partial h}{\partial h_r} = \frac{\partial h}{\partial a_h} \cdot \frac{\partial a_h}{\partial h_r} = \frac{\partial f(a_h)}{\partial a_h} \cdot w_{(h_r, h)} = f'(a_h) \cdot w_{(h_r, h)} \quad (8.9)$$

Dosadením vzťahu (8.9) do (8.8) získavame konečný rekurzívny vzťah pre výpočet agregovaného gradientu chyby vzhľadom na aktiváciu neurónu h_r , ktorý umožňuje efektívny výpočet gradientov bez opakovaného prechodu rovnakých ciest v sieti. [1]:

$$\Delta(h_r, o) = \sum_{h: h_r \rightarrow h} f'(a_h) \cdot w_{(h_r, h)} \cdot \Delta(h, o). \quad (8.10)$$

Rekurzívny vzťah dynamického programovania zo vzťahu (8.10) je v skutočnosti možné vypočítať viacerými spôsobmi, v závislosti od toho, ktoré premenné sa použijú ako medzičlánky v reťazovom pravidle. Všetky tieto varianty výpočtu sú ekvivalentné z hľadiska výsledného gradientu získaného spätným šírením chyby. Vo vzťahu (8.6) sa ako premenné medzičlánku reťazového pravidla používajú výstupy skrytých vrstiev h . V literatúre sa však často uvádza alternatívna verzia, kedy sa namiesto nich použijú argumenty aktivačných funkcií neurónov a_h , teda hodnoty vypočítané po lineárnej transformácii, ale ešte pred aplikáciou aktivačnej funkcie. Preto je namiesto rovnice (8.6) možné použiť aj nasledovný variant reťazového pravidla [1]:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \underbrace{\frac{\partial \mathcal{L}}{\partial o} \cdot f'(a_o) \cdot \left[\sum_{[h_r, h_{r+1}, \dots, h_k, o] \in \mathcal{P}} \frac{\partial a_o}{\partial a_{h_k}} \prod_{i=r}^{k-1} \frac{\partial a_{h_{i+1}}}{\partial a_{h_i}} \right]}_{\delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial a_{h_r}}} \cdot \underbrace{\frac{\partial a_{h_r}}{\partial w_{(h_{r-1}, h_r)}}}_{h_{r-1}}. \quad (8.11)$$

v ňom je namiesto predošlej „medzipremennej“ $\Delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial h_r}$ použitá $\delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial a_{h_r}}$. Inicializácia počiatočného stupňa rekurzcie je daná ako

$$\delta(o, o) = \frac{\partial \mathcal{L}}{\partial a_o} = f'(a_o) \cdot \frac{\partial \mathcal{L}}{\partial o}. \quad (8.12)$$

Následne je možné opäť použiť reťazové pravidlo viacerých premenných na zostavenie vzťahu pre rekurziu agregovaného gradientu chyby [1]:

$$\delta(h_r, o) = \frac{\partial \mathcal{L}}{\partial a_{h_r}} = \sum_{h: h_r \rightarrow h} \overbrace{\frac{\partial \mathcal{L}}{\partial a_h}}^{\delta(h, o)} \underbrace{\frac{\partial a_h}{\partial a_{h_r}}}_{f'(a_{h_r}) w_{(h_r, h)}} = f'(a_{h_r}) \sum_{h: h_r \rightarrow h} w_{(h_r, h)} \cdot \delta(h, o) \quad (8.13)$$

Výsledný gradient účelovej funkcie odchýlky siete je potom vyjadrený nasledujúcim vzťahom:

$$\frac{\partial \mathcal{L}}{\partial w_{(h_{r-1}, h_r)}} = \delta(h_r, o) \cdot h_{r-1} \quad (8.14)$$

Proces tréovania UNS môže prebiehať v dvoch režimoch. Pri *vzorkovom režime* dochádza k úprave váh po privedení každej novej vstupnej vzorky. V *dávkovom režime* sa váhy korigujú až po uskutočnení celej epochy, teda po kompletnom prechode celého trénovacieho súboru cez sieť, s využitím globálnej chyby zo všetkých vzoriek a výstupov.

8.3 Problémy tréovania UNS

Neurónové siete poskytujú silný nástroj pri riešení komplexných a analyticky ťažko odvoditeľných úloh. Aby ich tréovanie nebolo kontraproduktívne, je treba si uvedomiť problémy, ktoré s ním môžu byť spojené. Medzi najzávažnejšie problémy patria *pretrénovanie* a *problém miznúceho gradientu*. Ťažkosti môžu nastať aj pri nedostatočnej konvergencii účelovej funkcie, uviaznutí v lokálnom alebo falošnom optime či nedostatočnom výpočtovom výkone.

8.3.1 Pretrénovanie

Podstata tréovania neurónových sietí, ktoré je príkladom *učenia s učiteľom*, spočíva v tom, že sieť je schopná sa na základe testovacích dát naučiť všeobecné závislosti medzi vstupnými a výstupnými hodnotami, ktoré má byť následne schopná rozlíšiť aj na neznámych dátach. Po ukončení tréovania siete teda vždy prebieha fáza testovania, kedy je na vstup siete privedená množina vzoriek, ktoré sú odlišné od tréovacích.

Pretrénovanie (angl. *overfitting*) je jav, ktorý môže nastať dôsledkom neskorého ukončenia procesu tréovania, nedostatočnej tréovacej množiny dát, či nevhodnej architektúry siete. Prejavuje sa tak, že neurónová sieť síce dosahuje vysokú úspešnosť pri tréovacích dátach, no jej úspešnosť výrazne klesá pri zovšeobecnení na testovacích dátach, ktoré sú odlišné. Tento problém nastáva často napríklad vtedy, keď UNS obsahuje viac neurónov a prepojení, než zodpovedá skutočnej zložitosti riešenej úlohy, či v prípade nedostatočne veľkej testovacej množiny, čo do počtu a rozsahu prvkov vstupných vzoriek. V prvom prípade je dôsledkom, že sieť sa naučí zaznamenať aj také súvislosti vo vstupných dátach, ktoré nie sú všeobecné a súvisia len s danou množinou vstupných dát. V druhom prípade je zase problém v tom, že sieť sa nestihne naučiť všetky vstupno-výstupné závislosti.

Existuje viacero prístupov, ktoré slúžia na minimalizáciu rizika vzniku pretrénovania:

1. *regularizácia* – obmedzuje zložitosť modelu (siete). Do účelovej funkcie je pridaný penalizačný člen, ktorý uprednostňuje menšie hodnoty váh. Dochádza tak k „preriedeniu siete“, keďže obsahuje menšie množstvo významnejších prepojení (s hodnotou ďalej od nuly). Je možné ju interpretovať ako formu biologicky motivovaného „zabúdania“ nepodstatných vzorov.

2. *prispôsobenie architektúry siete* – využíva známe súvislosti vo vstupných dátach. Keď pri návrhu siete berieme do úvahy osobitosti úlohy, ktorú chceme riešiť, je možné zapracovať do architektúry siete také súvislosti, o ktorých vieme, že sa vyskytujú vo vstupných dátach (napr. súvislosť susedných pixelov pri spracovaní obrazu alebo súvislosť nasledujúcich slov pri spracovaní textu). To umožňuje použiť tie isté sady parametrov na spracovanie viacerých častí vstupu, čím sa znižuje počet neznámych parametrov a zjednodušuje model. Príkladom takýchto sietí sú *rekurentné* alebo *konvolučné* n. s.
3. *krížová validácia* (angl. *cross validation*) – zabráňuje sieti naučiť sa nevšeobecné znaky. Zo súboru testovacích vstupov je vyčlenený validačný súbor. Učenie prebieha na zvyšných tréningových dátach, ale účelová funkcia sa paralelne vyhodnocuje aj na validačných dátach. V momente, keď hodnota validačnej účelovej funkcie začne stagnovať alebo dokonca stúpať – čo indikuje, že sieť sa prestala učiť všeobecné znaky a začína sa učiť znaky špecifické pre tréningové dáta – učenie je zastavené (často už po niekoľkých epochách).
4. *výmena šírky za hĺbku* – namiesto veľkého počtu neurónov v jednej vrstve a malému počtu skrytých vrstiev sa preferuje málo neurónov a veľa skrytých vrstiev. Takáto *hlboká sieť* je schopná dosiahnuť rovnakú, a často aj lepšiu úspešnosť, a navyše môže obsahovať menšie množstvo parametrov.

8.3.2 Miznúce a explodujúce gradienty

Problém miznúcich a explodujúcich gradientov býva zvyčajne spojený s tréňovaním hlbokých neurónových sietí a súvisí s využívaním reťazového pravidla (vzťah (8.6)) pri spätnom šírení chyby. Keďže pri výpočte celkového gradientu účelovej funkcie dochádza k početnému násobeniu lokálnych gradientov pozdĺž prepojení, zvlášť pri veľkom počte skrytých vrstiev môže spôsobiť buď exponenciálny útlm k nule alebo naopak rýchly nárast gradientu. Oba javy tak spôsobujú nestabilitu procesu tréňovania.

Častou príčinou vzniku miznúceho gradientu býva napríklad použitie aktivačnej funkcie sigmoid. Tá má v celom definičnom obore deriváciu menšiu ako 0,25. Riešením je jej náhrada funkciou ReLU. Okrem tohto riešenia existujú aj pokročilejšie prístupy, ako napríklad [1]:

1. *Adaptívne rýchlosti učenia* – namiesto jednej globálnej rýchlosti učenia α pre celú sieť sa dynamicky prispôsobuje rýchlosť učenia každého parametra na základe historických gradientov. To zvyšuje efektivitu učenia a zlepšuje konvergenciu. Napr. *AdaGrad*, *RMSProp*, *Adam* (v súčasnosti najpoužívanejší). Ich výhodou je dobrá stabilita a rýchle učenie aj v ťažko optimalizovateľných sieťach.

2. *Metóda konjugovaných gradientov* – je vhodná pre nelineárne a veľké optimalizačné úlohy. Namiesto toho, aby sa váhy aktualizovali iba v smere gradientu, táto metóda kombinuje predchádzajúce smery gradientov, aby sa vytvoril nový, efektívnejší smer. Výhodou je, že môže výrazne zrýchliť konvergenciu a vyhnúť sa osciláciám. Na druhej strane, pre výpočtovú náročnosť je vhodnejšia skôr pre menšie siete alebo ako súčasť učenia po dávkach.
3. *Normalizácia po dávkach* (angl. *batch normalization*) – normalizuje vstupy každej vrstvy v rámci jednej dávky tak, aby mali nulový priemer a jednotkovú varianciu. Tým sa potláča nežiaduce kolísanie rozdelenia vstupných hodnôt spôsobené priebežným menením váh vo vrstvách. Výsledkom je rýchlejšia a stabilnejšia konvergencia počas učenia, ako aj zmiernenie problémov s miznúcim gradientom. Normalizácia v rámci dávky tiež často umožňuje použiť vyššiu rýchlosť učenia a znižuje závislosť na počiatočnom nastavení váh. Je však menej účinná pri veľmi malých dávkach alebo v rekurentných sieťach.

8.3.3 Ťažkosti s konvergenciou

Zvlášť v prípade hlbokých neurónových sietí sa vyskytuje problém s konvergenciou účelovej funkcie, keďže veľký počet skrytých vrstiev spôsobuje ťažší tok gradientov cez sieť. Čiastočne tento problém súvisí s miznutím gradientov, ale má svoje osobitné špecifiká [1].

Jedným zo spôsobov riešenia sú tzv. *bránové siete*. Využívajú špecifické neuróny (bunky), obsahujúce adaptívne riadiace mechanizmy (brány), ktoré selektívne kontrolujú tok informácie v sieti. Ich cieľom je zabezpečiť, aby sa relevantné informácie udržali a prenášali počas spracovania vstupu, zatiaľ čo menej dôležité sa potláčajú. Tento prístup je kľúčový najmä pri modelovaní sekvenčných dát (napr. spracovanie textu, videa), kde dlhodobé závislosti často bránia efektívnemu učeniu. Takéto siete sa radia medzi rekurentné neurónové siete a patria tu napr. LSTM či GRU (bližšie o nich v časti 9.2).

Ďalšou možnosťou sú *reziduálne siete*, ktoré zavádzajú reziduálne prepojenia, teda obchádzajúce vetvy, ktoré umožňujú prenášať informáciu aj gradient priamo naprieč viacerými vrstvami bez ich transformácie. Tým sa výrazne znižuje riziko miznutia gradientu a zlepšuje sa stabilita učenia, čo umožňuje trénovať siete s desiatkami až stovkami vrstiev. Tento prístup zároveň urýchľuje konvergenciu a vedie k lepšiemu využitiu kapacity modelu. Známy príklad takejto architektúry je ResNet [27]. Princíp fungovania reziduálnych sietí spočíva v tom, že namiesto učenia sa váh, teda priamej transformácie vstupu na výstup, sa učí len rozdiel medzi vstupom a výstupom. Takéto

prepojenie umožňuje gradientom efektívne pretekať aj do veľmi hlbokých vrstiev siete počas spätného šírenia chyby.

8.3.4 Lokálne a falošné optimá

Optimalizačná funkcia neurónových sietí je silne nelineárna a obsahuje veľké množstvo lokálnych extrémov. Preto je výber vhodnej inicializácie parametrov kľúčový. Nesprávne inicializačné body môžu viesť k nevhodným (lokálnym alebo falošným) minimám. Jednou z metód, ako sa tomu vyhnúť, je tzv. *predtrénovanie* (angl. *pretraining*), ktoré spočíva v postupnom trénovaní jednotlivých vrstiev siete, často pomocou učenia bez učiteľa. Tento prístup poskytuje rozumné počiatočné hodnoty váh, ktoré obchádzajú irelevantné časti parametrového priestoru. Predtrénovanie tiež pomáha znižovať riziko pretrénovania, keďže sa vyhýba minimám, ktoré sú síce vhodné pre tréningovú množinu, no zlyhávajú na testovacích dátach – tzv. falošným optimám [1].

8.3.5 Výpočtová náročnosť

Jednou z hlavných výziev pri návrhu neurónových sietí je dlhá doba tréningovania, ktorá môže v oblastiach ako spracovanie textu či obrazu trvať aj celé týždne. Kľúčový pokrok v tomto smere priniesol vývoj výkonnejšej hardvérovej infraštruktúry, najmä grafických procesorov (GPU), ktoré sú schopné paralelne vykonávať výpočty typické pre neurónové siete. Platformy ako Torch alebo TensorFlow majú vstavanú podporu pre GPU, čo umožňuje efektívnejšie učenie aj zložitých architektúr. Hoci k pokroku v hlbokom učení prispeli aj algoritmitcké vylepšenia, značná časť úspechu spočíva v tom, že existujúce algoritmy dnes dokážeme lepšie využiť vďaka výkonnejšiemu hardvéru. Výhodou väčšiny neurónových sietí je, že náročné výpočty prebiehajú počas tréningovania, zatiaľ čo predikčná fáza je už relatívne rýchla, čo je dôležité pri aplikáciách v reálnom čase [1].

8.4 Súčasné prístupy k tréningu

Snaha o vyriešenie vyššie spomenutých problémov tréningovania UNS podnietila vznik množstva variácií učiacich algoritmov, ktoré sú síce v základoch postavené na metódach gradientného zostupu a spätného šírenia chyby, ale obsahujú aj ďalšie modifikácie a vylepšenia, týkajúce sa či už len samotného procesu tréningovania, alebo aj architektúry celej siete, resp. jej buniek.

Jedným z používaných vylepšení učenia je tzv. *prenos znalostí* (angl. *transfer learning*). Spočíva v tom, že sieť sa netrénuje od nuly, ale vychádza sa z už predtrénovaného modelu, ktorý bol učný na rozsiahlej množine údajov. Tento model sa následne „dolaďuje“ (tzv. *fine-tuning*) na konkrétnu úlohu pomocou menšieho množstva nových

dát. Transferové učenie výrazne znižuje nároky na dáta aj výpočtový čas a zároveň zvyšuje kvalitu výsledkov, najmä ak sa pracuje s málo rozsiahlymi alebo špecializovanými údajmi pre konkrétnu oblasť. Táto metóda je dnes základom mnohých aplikácií – od spracovania prirodzeného jazyka (napr. BERT, GPT) až po analýzu obrazov (napr. ResNet, EfficientNet).

Ďalším riešením pre zníženie výpočtovej náročnosti je *trénovanie so zmiešanou číselnou presnosťou* (angl. *mixed precision*). V tomto prístupe prebiehajú niektoré výpočty počas tréovania s nižšou číselnou presnosťou (napr. 16-bitové čísla namiesto štandardných 32-bitových). Výsledkom je nižšia pamäťová záťaž a výrazne rýchlejšie výpočty, najmä na grafických procesoroch (GPU) a špecializovaných akcelerátoroch (TPU), ktoré sú pre takéto výpočty optimalizované. Táto technika si zachováva presnosť tréovania pomocou špeciálnych mechanizmov (napr. škálovanie gradientov) a dnes je často využívaná v priemyselnej praxi.

Trénovanie pomocou klasickej metódy gradientného zostupu býva pri zložitejších architektúrach neefektívne, pretože používa konštantnú rýchlosť učenia pre všetky parametre siete po celú dobu procesu tréovania. Veľká rýchlosť je totiž dobrá na rýchle priblíženie sa do blízkosti dobrého riešenia, avšak zväčša neumožňuje jemné doladenia sa ku optimu, teda sa môže stať, že algoritmus tréovania ostane oscilovať v okolí optimálneho bodu alebo dokonca zdiverguje do nestabilnej oblasti. Na druhej strane, voľba malej rýchlosti učenia má za následok veľmi pomalú konvergenciu učenia. To sú dôvody pre vznik tzv. adaptívnych optimalizačných algoritmov, ktoré rýchlosť učenia dynamicky prispôbujú pre každý parameter siete zvlášť počas celého procesu tréovania.

Jedným z najrozšírenejších algoritmov pre tréovanie hlbokých neurónových sietí v súčasnosti je Adam (Adaptive Moment Estimation) [34]. Využíva adaptívne nastavovanie parametrov siete (váh a biasov) na základe priebežných štatistík gradientu, ich prvého momentu (priemeru), ktorý informuje o „smerovaní“ optimalizácie a druhého momentu (rozptylu). Zároveň využíva tzv. L2 regularizačný člen, ktorý má za cieľ udržiavať hodnoty váh blízke nule (angl. *weight decay*). Výsledný vzorec pre aktualizáciu i -teho parametru má tvar

$$w_i \leftarrow w_i - \frac{\alpha_t}{\sqrt{A_i}} F_i; \forall i, \quad (8.15)$$

kde agregovaný člen prvého momentu F_i , agregovaný člen druhého momentu A_i a rýchlosť učenia α_t sú priebežne aktualizované na základe nasledujúcich vzťahov [1]:

$$F_i \leftarrow \rho_f F_i + (1 - \rho_f) \left(\frac{\partial \mathcal{L}}{\partial \Xi_i} \right); \forall i, \quad (8.16a)$$

$$A_i \leftarrow \rho A_i + (1 - \rho) \left(\frac{\partial \mathcal{L}}{\partial \Xi_i} \right)^2; \forall i, \quad (8.16b)$$

$$\alpha_t = \alpha \left(\frac{\sqrt{1 - \rho^t}}{1 - \rho_f^t} \right), \quad (8.16c)$$

pričom $\rho, \rho_f \in (0, 1)$ sú voliteľné parametre. Novšia verzia algoritmu, AdamW [44] vylepšuje pôvodný Adam v tom, že regularizačný člen nemieša s výpočtom gradientného momentu, ale počíta ho osobitne, čo vedie k stabilnejšiemu trénovaniu a lepšiemu generalizačnému výkonu siete.

9 Hlboké učenie

Hlboké učenie (angl. *Deep Learning (DL)*) predstavuje jednu z najdôležitejších súčasných oblastí vývoja UI. Prekonáva ťažkosti klasických perceptrónových sietí v riešení komplexnejších úloh využitím viacvrstvových neurónových architektúr, kde každá vrstva extrahuje čoraz abstraktnejšie znaky z výstupov predchádzajúcich vrstiev. Vďaka tejto hierarchickej reprezentácii je možné modelovať zložité funkcie priamo z dát bez nutnosti manuálne definovaných príznakov [41]. Hlboké siete tak výrazne prevyšujú tradičné MLP v schopnosti učiť sa reprezentácie priamo zo surových dát, čím umožňujú riešiť zložité úlohy ako rozpoznávanie objektov, preklad jazykov alebo predikciu dynamiky systémov.


Na rozdiel od plytkých sietí vyžaduje trénovanie hlbokých modelov pokročilejšie optimalizačné techniky. Kým MLP siete často využívali obyčajný gradientný zostup s fixnou rýchlosťou učenia, hlboké siete zvyknú používať algoritmy ako Adam, RMSProp alebo momentové metódy, ktoré zohľadňujú historické hodnoty gradientov a adaptívne upravujú parametre učenia [34]. Za účelom predchádzania vyššie spomenutým problémom, ako je miznúci a vybuchujúci gradient, sa zároveň používajú metódy ako regularizácia (napr. L2 penalizácia alebo „dropout“), váhová inicializácia a plánovanie rýchlosti učenia [25].

9.1 Konvolučné neurónové siete

Konvolučné neurónové siete (CNN) sú špeciálne navrhnuté na efektívne spracovanie dát so štruktúrou v priestore. Hoci boli vynájdené ešte koncom 20. storočia, do širšieho používania sa dostali až po práci kolektívu A. Krizhevsky [38] a dodnes sú najúspešnejším nástrojom na rozpoznávanie a klasifikáciu obrazu z kamery. Oproti klasickým plne prepojeným sieťam majú pri rovnakom počte neurónov menej prepojení, vďaka čomu sú jednoduchšie na natrénovanie a odolnejšie voči pretrénovaniu. Princíp ich fungovania je inšpirovaný fungovaním mozgu cicavcov pri spracovaní zrakových vnemov [47].

Vstupom do CNN je obvykle obraz vo formáte dvojrozmernej bitmapy. Pri rozpoznávaní obrazu sa v niekoľkých iteráciách opakuje postup, kedy sa na vstupnú vrstvu neurónov aplikujú konvolučné filtre, tzv. *jadrá* (angl. *kernels*), pričom každé z nich obsahuje počet neurónov rádovo nižší než je rozmer vstupnej vrstvy (napr. 3×3 , 5×5 , 8×8 , ...). Jadro postupne aplikované na celú vstupnú vrstvu, pričom sa vykonáva operácia konvolúcie. Výstup jedného vstupného neurónu tak možno vyjadriť ako

$$V(i, j) = f \left(\sum_{p=1}^P \sum_{q=1}^Q x(i+p-1, j+q-1) \cdot w(p, q) - \theta \right), \quad (9.1)$$



Obr. 9.1: Schéma architektúry konvolučnej neurónovej siete. [47]

kde i, j sú súradnice vstupného neurónu, $w(p, q)$ je hodnota jedného neurónu jadra s rozmermi $P \times Q$ a $x(i + p, j + q)$ je vstupná hodnota v okolí daného vstupného neurónu a $f(\cdot)$ predstavuje nelineárnu aktivačnú funkciu (obvykle ReLU) [47].

V procese učenia sú váhy jadier nastavené tak, aby rozpoznávali určité príznaky vo vstupných dátach (napr. hrany, textúry, objekty), čím vznikajú tzv. *mapy príznakov* (angl. *feature maps*). Vlastnosťou tejto techniky je invariantnosť voči posunu, zmene mierky alebo iným formám skreslenia, vďaka čomu je použitím jedného malého jadra možné detegovať ten istý príznak vo viacerých častiach vstupu bez zmeny jeho hodnôt. Významne sa tak redukuje počet parametrov potrebných na natrénovanie takejto siete oproti plnému prepojeniu. Tento proces sa opakuje vo viacerých po sebe nasledujúcich *konvolučných vrstvách*, pričom platí, že čím viac vrstiev sa použije, tým komplexnejšie príznaky je možné rozpoznávať. Na učenie konvolučných vrstiev sa používa algoritmus spätného šírenia chyby [47].

Medzi jednotlivé konvolučné vrstvy sa umiestňujú tzv. *zhlukovacie vrstvy* (angl. *pooling layers*). Ich vstupom sú výstupy z viacerých susedných máp príznakov a redukuje ich na jediné číslo. Tieto vrstvy neobsahujú žiadne parametre, ktoré by boli predmetom tréningu. Úlohou je podvzorkovanie mapy príznakov, na čo sa obvykle využíva funkcia maxima alebo priemeru. Výstup zo zhlukovacích vrstiev slúži ako vstup pre nasledujúce konvolučné vrstvy. Napokon, výsledná klasifikácia CNN môže byť vykonaná pomocou *plne prepojených vrstiev*.

Medzi najvyužívanejšie implementácie patria TensorFlow a PyTorch, ktoré ponúkajú predpripravené moduly na tvorbu a tréning CNN, ako aj množstvo predtrénovaných modelov (napr. VGG, ResNet, MobileNet či EfficientNet) vhodných na prenos znalostí. Tieto knižnice podporujú aj hardvérovú akceleráciu (napr. pomocou GPU), čo umožňuje efektívne tréning rozsiahlych sietí. V praxi sa CNN implementácie uplatňujú v prostrediach ako OpenCV, ktoré ponúka jednoduché rozhranie na inferenciu CNN modelov v reálnom čase a je často využívaný vo vnorených systémoch a robotike. Vďaka týmto nástrojom je dnes práca s CNN prístupná aj bez potreby vlastnej implementácie architektúr od základu.

9.2 Rekurentné neurónové siete


Rekurentné neurónové siete (RNN) tvoria triedu architektúr umelých neurónových sietí navrhnutých špecificky na spracovanie sekvenčných dát. Na rozdiel od bežných dopredných sietí, ktoré spracúvajú vstupy ako nezávislé a nemajú vnútornú pamäť, RNN obsahujú mechanizmus *rekurencie*, ktorý im umožňuje uchovávať informácie o predchádzajúcich vstupoch v tzv. *skrytom stave*. Táto schopnosť ich predurčuje na úlohy, v ktorých poradie alebo časový kontext zohráva rozhodujúcu úlohu – napríklad pri spracovaní textu, zvuku, signálov zo senzorov či trajektórií v priestore.

Tento typ neurónových sietí neobsahuje iba dopredné väzby, teda zľava doprava, ale obsahujú tiež spätné väzby a pamäťové informácie o stave buniek. Zásadným rozdielom RNN oproti klasickým dopredným sieťam je tiež to, že vstupy nie sú pripojené priamo na prvú skrytú vrstvu, ale interagujú so skrytými stavmi, ktoré boli vypočítané na základe predošlých vstupov. Skrytý stav siete sa mení v čase a je reprezentovaný vektorom h_t , ktorého výpočet je funkciou aktuálneho vstupného vektora X_t a predošlého skrytého stavu h_{t-1} :

$$H_t = \sigma(W_{xh} X_t + W_{hh} H_{t-1} + b_h), \quad (9.2)$$

kde W_{xh} a W_{hh} sú váhové matice pre vstup a skrytý stav, b_h je bias a σ je aktivačná funkcia (najčastejšie hyperbolický tangens alebo ReLU). Na výpočet výstupu siete sa potom väčšinu používa aktivačná funkcia softmax alebo sigmoid. Výstup siete môže byť generovaný za každou vstupnou vzorkou alebo až po ukončení jednej dávky. Aktivačné funkcie sú rovnaké pre každú vstupnú vzorku.


Vďaka schopnosti modelovať dlhodobé závislosti v čase sú RNN vhodné na spracovanie senzorických dát, kde každé meranie tvorí súčasť väčšej sekvencie. Môžu slúžiť aj ako časový filter, nakoľko dokážu integrovať informácie z predchádzajúcich meraní a korigovať neistotu v aktuálnych pozorovaniach. K ich výhodám patrí aj prispôsobivosť a univerzálnosť, keďže tá istá architektúra sa dá použiť na rôzne typy sekvencií. Sú




Obr. 9.2: Rekurentná neurónová sieť – znázornenie toku informácií v čase.

však náročné na tréningovanie a citlivé na dĺžku a kvalitu sekvencie. Medzi najčastejšie používané implementácie RNN patria tieto architektúry:

- *Dlhá krátkodobá pamäť (LSTM)* [28] – (obr. 9.3a) zavádza vnútorný pamäťový stav bunky a sústavu brán, ktoré regulujú tok informácií: vstupná brána rozhoduje, čo nové si zapamätať, výstupná brána rozhoduje, ktorú informáciu z pamäte použiť ako výstup a zabúdacia brána rozhoduje, čo z pamäte vyhodíť. Prináša teda schopnosť udržať si informáciu z minulosti bez toho, aby došlo k miznutiu gradientu.
- *Rekurentná jednotka s bránou (GRU)* [31] – (obr. 9.3b) ide o zjednodušenú verziu LSTM, ktorá obsahuje len dve brány: aktualizácia – riadi, koľko z predchádzajúceho stavu sa preniesie ďalej – a resetovacia – rozhoduje, koľko informácie z minulosti ignorovať. Je výpočtovo efektívnejšia než LSTM, no výkonovo porovnateľná.



(a) LSTM sieť – zabúdacia, vstupná a výstupná brána



(b) GRU sieť – aktualizácia a resetovacia brána

Obr. 9.3: Porovnanie štruktúr LSTM a GRU rekurentných neurónových sietí. [33]

10 Fúzia lokalizácie pomocou UNS


Presná znalosť polohy v prostredí – lokalizácia – predstavuje jeden zo základných predpokladov pre spoľahlivú prevádzku a efektívne plnenie úloh mobilného robota. Na tento účel sa bežne využíva viacero typov senzorov, ako napríklad GNSS, INS, vizuálne systémy alebo laserové snímače. Každý z týchto senzorov však podlieha určitým obmedzeniam a v praxi neposkytuje dokonale presné ani spoľahlivé údaje. Na zníženie neistoty a zvýšenie robustnosti odhadu aktuálnej polohy sa preto využíva fúzia údajov, t. j. inteligentná integrácia viacerých dátových tokov do jedného spoločného odhadu, ktorý je spravidla presnejší a konzistentnejší než jednotlivé zdroje samostatne.

Tradičné prístupy k fúzii údajov sú založené prevažne na pravdepodobnostných modeloch (napr. Bayesovská filtrácia, Kalmanove filtre, časticové filtre) alebo metódach intervalového odhadu. Najväčšou výzvou pri použití týchto metód je však získanie presného modelu systému. V prípade komplexných a vysoko dynamických systémov môže byť odvodenie presného modelu zvlášť náročné. Navyše, senzorické dáta bývajú sprevádzané vlastnou nepresnosťou a neistotou, ktorých zapracovanie do modelu je problematické. Vo výsledku tak nepresný model systému môže vážne obmedziť úspešnosť analytických metód fúzie [19].

S nástupom moderných techník umelej inteligencie – predovšetkým umelých neurónových sietí a hlbokého učenia – sa postupne presadzuje aj ich uplatnenie v tejto oblasti. Tieto modely sú schopné spracovávať veľké objemy vysoko dimenzionálnych dát, učiť sa zložené nelineárne vzťahy medzi jednotlivými vstupmi a zohľadňovať aj ich časové závislosti bez hlbokej analytickej znalosti modelu, čo z nich robí atraktívny nástroj pre riešenie úloh lokalizácie prostredníctvom senzorickej fúzie. V nasledujúcich častiach predstavíme niekoľko konkrétnych aplikácií rôznych typov UNS na účely fúzie lokalizačných údajov pre mobilný robotický systém.

10.1 Fúzia vnímania prostredia s využitím DFFN

Príkladom využitia štandardnej, plne prepojenej DFFN siete na fúziu senzorických dát je práca autorov Barreto-Cuberto a kol [8]. Využíva sa tu kombinácia troch typov senzorov: 360-stupňový 2D lidar, stereokamera a ultrazvukové senzory (viď obr. 10.1). Pre úspešnosť lokalizácie a navigácie v neznámom prostredí bez externej lokalizačnej infraštruktúry je dôležitá spoľahlivá detekcia vzdialenosti okolitých objektov. Rôzne typy senzorov majú odlišnú schopnosť detegovať objekty a povrchy v rozličných výškach, z rôznych materiálov (sklo, betón, drevo, hliník, apod.), a to aj vzhľadom na aktuálne svetelné podmienky. Kým ultrazvuk vie spoľahlivo detegovať sklo, stereo kamera zachytáva trojrozmernú hĺbkovú štruktúru a lidar poskytuje vysoké rozlíšenie



Obr. 10.1: Rozloženie senzorov na mobilnom robote v práci [8].

v 2D rovine. Hlavným cieľom práce tak bolo pomocou kombinácie viacerých senzorov maximalizovať kvalitu mapovania pri prechode prostredím a tým znížiť lokalizačné a navigačné odchýlky.

10.1.1 Predspracovanie dát

Pred samotnou fúziou je potrebné predspracovanie surových senzorických dát, a to za účelom odstránenia odľahlých a irelevantných meraní, redukcie šumu a transformácie meraní do spoločného súradnicového systému. Ultrazvukové merania sa vyznačujú veľkým rozptylom, preto je na ne najskôr aplikovaný kľzavý mediánový filter, ktorého výstupom je medián posledných 15-tich meraní. Následne sa aplikuje Kalmanov filter pre ďalšiu redukciu šumu. Nakoľko ultrazvuk neposkytuje angulárnu informáciu, prisudzuje sa rovnaká vzdialenosť v celom jeho uhlovom rozsahu merania.

Stereokamera poskytuje vďaka porovnaniu obrazu z dvoch objektívov hĺbkovú informáciu o prostredí vo forme 3D mračna bodov. Z poskytnutého mračna bodov sú na základe zvislej z súradnice použité len tie body, ktoré môžu predstavovať prekážku pre robot. Tieto body sú projektované do 2D roviny tak, že sa ďalej využívajú len súradnice x, y . Týmto spôsobom sa redukuje objem dát zo stereokamery, ktoré vstupujú do fúzie.


Predmetom spracovania dát z lidarů je redukcia meraní z 360-stupňového okolia na uhlový výsek, ktorý sa prekrýva so zorným polom kamery alebo ultrazvukov. Napokon, keďže každý zo senzorov poskytuje merania relatívne voči vlastnej polohe, je nevyhnutná ich reprezentácia v spoločnom súradnicovom systéme. Tento prepočet sa

vykoná pomocou statických homogénnych transformácií na základe vopred nameraných vzdialeností medzi senzormi.

10.1.2 Konfigurácia a tréovanie neurónovej siete

DFFN je priamo zodpovedná za fúziu troch dátových tokov do jedného, na základe ktorého sa zostaví mapa prostredia v podobe okupačnej mriežky. Tá rozlišuje v zásade tri stavy: voľný priestor, prekážku a neznámy priestor. Vstupná vrstva siete obsahuje tri neuróny, jeden pre každý zo sensorov. Ďalej sa nachádza niekoľko skrytých vrstiev a na konci je jeden výstupný neurón, poskytujúci fúziu meranej vzdialenosti. Základná štruktúra siete je znázornená na obr. 10.2. Všetky neuróny využívajú ReLU aktivačnú funkciu. V jednom čase sú na vstup privedené merania vzdialenosti v tom istom smere. Ako už bolo spomenuté, každý zo sensorov má svoje špecifiká. Kým ultrazvuk je schopný zaznamenať prekážku prakticky bez ohľadu na jej materiál, jeho meranie môže byť zašumené a navyše nedokáže určiť presný smer. Lidar nedokáže zaznamenať sklenú prekážku, zatiaľ čo kamera zaznamená prekážky nachádzajúce sa ďalej za sklom. Navyše, lidar zaznamenáva prekážky len v jednej úrovni, takže niektoré si nemusia stihnúť. Úlohou neurónovej siete je teda určiť najpravdepodobnejšiu hodnotu vzdialenosti pre daný smer.

Na tréovanie neurónovej siete bol použitý optimalizačný algoritmus Adam, pričom kritériálnou funkciou bola RMSE. Na implementáciu UNS boli využité knižnice TensorFlow a Keras. Chyba siete bola počítaná na základe porovnania dvoch typov datasetov: skutočných a detegovaných vzdialeností k prekážkam. Datasets skutočných vzdialeností boli získané pomocou lidar, pričom prekážky boli vo výške lidar prelepené




Obr. 10.2: Fúzia sensorov pomocou DFFN podľa [8]. Vstupmi sú údaje o nameranej vzdialenosti k prekážke v danom smere po transformácii do jednotného súradnicového systému.


nepriehľadnou páskou, aby sa zaručilo neskreslené určenie vzdialenosti. Takéto páry datasetov boli vyhotovené na viacerých pozíciách v prostredí. Trénovacie a testovacie datasety boli vyhotovené na rôznych pozíciách.

10.1.3 Overenie a výsledky

Na validáciu navrhnutého prístupu fúzie autori Barreto-Cuberto a kol. [8] použili viacero experimentálnych scenárov, kde testovali úspešnosť mapovania okolia pri rôznom type prekážok. V prvom scenári stál robot pred sklenenými prekážkami a v jeho blízkosti sa nachádzali aj nízke prekážky, ktoré nedosahovali úroveň snímania lidar. Na obr. 10.3a je znázornený úspešný výsledok fúzie senzorov. V druhom experimente stál robot pred



(a) Experiment č. 1



(b) Experiment č. 2

Obr. 10.3: Výsledky experimentov [8]. Farebné body predstavujú merania z lidar, biele body sú výstupom fúzie pomocou DFFN.

prekážkami z rôznych materiálov – dreveného panelu, pred ktorým stáli dva hliníkové objekty. Výsledok fúzie tohto experimentu sa nachádza na obr. 10.3b. Analýzou výsledkov z oboch experimentov sa ukázalo, že fúzia senzorov plní svoj účel, keďže kompenzuje výpadky meraní lidar, ktorý síce poskytuje najpresnejšie meranie polohy, no má obmedzené schopnosti detekcie prekážok v prostredí.

10.2 Fúzia odometrie s využitím DL a CNN

Nakoľko je architektúra CNN sietí prispôsobená na spracovanie dvojrozmerných dát, v súvislosti s fúziou sa ich využitie objavuje najčastejšie pri spracovaní kamerového obrazu, príp. máp. Spočiatku nachádzali CNN využitie najmä pri detekcii prekážok a klasifikácii okolitých objektov na základe dát z kamery alebo lidar. Avšak čo sa týka riešenia lokalizácie samotného robota, jednou z prvých implementácií metód hlbokého učenia na účely fúzie odometrie vôbec bola práca autorov Valente a kol. z roku 2019 [73], ktorí sa zaoberali fúziou monokamery a 2D laserového skenera. Ich cieľom bolo eliminovať potrebu presnej kalibrácie medzi senzormi a zložitost' návrhu manuálne definovaných pravidiel fúzie.

Navrhnutý prístup sa zaoberá extrakciou textúr z 2D laserového skenera a monokamery, sekvenčnou fúziou ktorých následne vzniká odhad odometrie. Jedinečnosťou tejto metódy je to, že transformuje klasický regresný problém odometrie (odhad vzdialenosti a natočenia medzi snímkami) na problém ordinálnej klasifikácie, čím zjednodušuje učenie siete. Prehľad navrhnutého systému je na obr. 10.4.

Vstupom do siete sú vždy dvojice po sebe idúcich 360-stupňových laserových skenov a obrázkov z kamery, pričom sieť sa snaží predikovať transformáciu $T = (\Delta d, \Delta \theta)^\top$ – teda prejdenú vzdialenosť a rotačný uhol medzi dvoma po sebe nasledujúcimi laserovými skenmi (s_{t-1}, s_t) a kamerovými snímkami (c_{t-1}, c_t) . Cieľom CNN teda má byť optimalizácia funkcie $g(\cdot)$ takej, že:

$$T_t = g((s_{t-1}, s_t), (c_{t-1}, c_t)) \quad (10.1)$$

Akumuláciou týchto lokálnych odhadov je možné rekurzívne rekonštruovať globálnu trajektóriu robota. Algoritmus síce nezahŕňa uzavretie slučky, teda je z dlhodobého hľadiska náchylný na drift, cieľom tejto práce však bolo ukázať vôbec možnosť využitia CNN na účely fúzie dát z kamery a lidar.

10.2.1 Predspracovanie dát


Aby bolo možné využiť dáta z kamery a lidar v neurónovej sieti, aj v tomto prípade je potrebné ich predspracovanie. Ako sme spomenuli v úvode tejto kapitoly, CNN sú

prispôsobené na spracovanie dvojrozmerných dát. Údaje z lidarů sú preto upravené do podoby jednorozmerného vektora vzdialeností s fixným krokom $0,1^\circ$ a následne spojené s podobne upravenými predošlými dátami, tvoriac maticu rozmeru 2×3601 . To umožňuje využitie štandardnej CNN pre extrakciu textúr z okolitého prostredia. Čo sa týka predspracovania kamerových dát, tu sa vykoná len zmenšenie rozlíšenia obrázka pre redukciu výpočtového času. Následne sa dva nasledujúce obrázky spoja dokopy, čím vznikne tenzor reprezentujúci dve kamerové merania. Tak je možné tieto dva obrázky priviesť na vstup tej istej siete za účelom detekcie textúr v prostredí.


10.2.2 Architektúra siete

Architektúra pozostáva z dvoch vetiev konvolučných sietí (CNN pre laser, CNN pre kameru), ktoré spracúvajú surové senzorické dáta. Ich výstupy sú zlúčené vo fúzii a prevedené na odhad translácie a rotácie (viď obr. 10.5).

CNN pre laser spracúva tenzor vytvorený zrefazenými vektormi dvoch po sebe idúcich skenov. Ten je postupne spracovaný sekvenciou 1D konvolučných vrstiev a zhlukovacích vrstiev využívajúcich funkciu priemeru, ktoré extrahujú vzájomné črty medzi dvomi meraniami. Architektúra CNN pozostáva zo šiestich 1D konvolučných vrstiev, z ktorých každá je nasledovaná nelineárnou aktivačnou funkciou ReLU. Medzi každé dve konvolučné vrstvy je vložená zhlukovacia vrstva, ktorá znižuje výpočtovú



Obr. 10.4: Návrh systému fúzie kamery a lidarů pomocou CNN podľa [73]. Po sebe idúce lidarové skeny a kamerové snímky sú najskôr postupne spracované v osobitných sieťach a potom v jednej spoločnej pre určenie zmeny polohy vozidla.



Obr. 10.5: Architektúra CNN sietí pre fúziu odometrie podľa [73].

náročnosť. Na konci CNN je pridaná lineárna vrstva, ktorá zmenší rozmer tenzora pred fúziou, aby bol zabezpečený rovnaký objem informácií z oboch snímačov.

Vstupom vetvy pre spracovanie obrazu z kamery sú dve po sebe zachytené surové kamerové snímky. Vzorom pre architektúru tejto CNN bola práca autorov Wang a kol. [76], avšak podobne ako v lidarovej vetve, aj tu bola pridaná lineárna vrstva na redukciu veľkosti tenzora pred fúziou. Výstupom tejto časti sú kompaktné reprezentácie textúr obrazu pripravené na zlúčenie s výstupom z lidarovej časti.

Po extrakcii príznakov z dvojice po sebe nasnímaných laserových skenov a dvojice kamerových snímok sa tieto výstupy spoja do jedného vektora. Ten sa následne spracúva dvomi nezávislými sekvenciami lineárnych vrstiev – jedna je určená na odhad rotácie a druhá na odhad translácie vozidla. Pôvodne bola testovaná aj architektúra so spoločnými vrstvami pre oba odhady, avšak lepšie výsledky sa dosiahli ich oddelením. Na zníženie rizika pretrénovania sú pred každú z lineárnych vrstiev zaradené *dropout* vrstvy.

10.2.3 Trénovanie siete

Učenie navrhnutej siete prebiehalo v dvoch hlavných krokoch. Najskôr boli trénované konvolučné podsiete pre jednotlivé senzory (CNN-Laser a CNN-Cam) samostatne, aby sa získali čo najlepšie predtrénované váhy. Každá podsieť bola v tejto fáze napojená na dvojicu samostatných lineárnych vrstiev – jednu pre odhad rotácie a druhú pre odhad translácie.

V predchádzajúcej práci tohto autorského kolektívu [72] sa ukázalo, že lepšie výsledky sú dosiahnuté, ak sa úloha odhadu rotácie formuluje ako klasifikačný problém, zatiaľ čo translácia sa rieši regresiou. V tomto výskume sa tento prístup rozšíril – aj odhad translácie sa transformoval na klasifikačnú úlohu, čím sa uľahčil proces učenia a zlepšila stabilita konverencie siete, bez zníženia presnosti.

Pre rotáciu boli definované triedy s rozlíšením $0,1^\circ$ v intervaloch po $5,6^\circ$, čo viedlo k 112-im možným triedam. Pre transláciu bolo vytvorených 270 tried s rozlíšením $0,01$ m v rozsahu od $0,0$ m do približne $2,6$ m (čo zodpovedá maximálnemu posunu medzi dvomi snímkami v datasete KITTI).

Klasické klasifikačné prístupy však neberú do úvahy poradie hodnôt (napr. že 2° je viac ako $0,1^\circ$), preto v tomto prípade autori využili princíp tzv. *ordinálnej klasifikácie*. Tento prístup prevádza ordinálny regresný problém na sériu jednoduchších binárnych klasifikácií, kde sa pre každú triedu určuje, či je hodnota väčšia ako daný prah. Takéto značenie umožňuje sieti naučiť sa relatívne poradie medzi triedami.

Výsledná účelová funkcia sa počíta ako súčet binárnej krížovej entropie (BCE) pre rotáciu a transláciu, s váhovým faktorom b na vyrovnanie rozdielov v mierke chýb oboch veličín:

$$L = L_{BCE}(\hat{d}, d) + b \cdot L_{BCE}(\hat{q}, q), \quad (10.2)$$

kde d, q sú ordinálne značky pre transláciu a rotáciu a $\hat{d}, \hat{q}$ sú príslušné výstupy siete po aplikácii sigmoidnej funkcie.


Vo finálnej fáze sa predtrénované podsiete pripojili k fúznej časti siete a spoločne dotrénovali. Implementácia bola realizovaná v prostredí PyTorch, optimalizácia prebiehala pomocou algoritmu Adam s počiatočnou rýchlosťou učenia $0,0001$. Pri predtrénovaní kamery sa využili váhy modelu FlowNet, čím sa skrátil čas učenia.

10.2.4 Overenie a výsledky

Metóda bola testovaná na podmnožine dátovej sady KITTI [23] pre odometriu, pričom tréning prebiehal na ôsmich sekvenciách a testovanie na troch odlišných sekvenciách. Výsledky experimentov na testovacích sekvenciách môžeme vidieť na obr. 10.6. Podľa autorov sa ukázalo, že navrhnutá architektúra fúzie údajov z kamery a laserového skenera dosahuje chyby translácie a rotácie v porovnateľnom rozsahu s referenčnou metódou DeepVO [76], no s podstatne rýchlejšim spracovaním (až desaťnásobne), a to aj bez použitia GPU.

Analýza ukázala, že fúzia senzorov viedla k rovnakej alebo lepšej presnosti než samostatné spracovanie údajov z jednotlivých senzorov, pričom najväčšie zlepšenie bolo viditeľné pri odhade rotácie. V náročných prípadoch, ako je sekvencia s vysokou rýchlosťou a nízkym počtom detegovaných bodov z laseru, kamera významne prispela k presnejšiemu určeniu uhlov, hoci odhad translácie zostal menej presný.

Obmedzenia metódy súvisia s absenciou mechanizmov uzatvárania slučiek a s tým, že model nevyužíva časové závislosti, čo môže viesť k akumulácii chyby pri dlhších sekvenciách. Nedostatok trénovacích príkladov pre špecifické typy pohybov



Obr. 10.6: Výsledky experimentov na testovacích sekvenciách z KITTI datasetu. [73]

(napr. výrazné otočenia) sa tiež prejavil nižšou presnosťou v týchto situáciách. Autori konštatujú, že rozšírenie tréningovej množiny by mohlo výrazne zvýšiť spoľahlivosť a presnosť odhadu.

10.3 Fúzia GNSS a INS s využitím RNN

Ako už bolo spomenuté v časti 9.2, silnou stránkou RNN sietí je schopnosť spracúvať časovo závislé dáta a pamätať si z nich vzniknuté závislosti. Vďaka tomu je táto architektúra vhodná napríklad na spracovanie meraní z GNSS a IMU. GNSS signál môže totiž vypadávať v rôznych náročnejších prostrediach. Kompenzácia výpadku signálu GNSS pomocou INS naráža na spravidla výrazný šum IMU snímačov. To je problém, v ktorom našli autori Dai a kol. uplatnenie pre zapojenie RNN do fúzie GNSS/INS.

Autori článku [15] reagujú na obmedzenia tradičných metód integrovanej navigácie INS/GNSS, najmä rozšíreného Kalmanovho filtra (EKF), ktorý vyžaduje poznanie presného modelu chýb senzorov a trpí zníženou presnosťou pri dlhodobom výpadku GNSS signálu v silne nelineárnych alebo rušených prostrediach. Na rozdiel od statických neurónových sietí, ktoré nedokážu zachytiť časové závislosti chýb INS, navrhujú autori využitie RNN schopnej modelovať dynamické väzby medzi aktuálnymi a minulými chybami INS. RNN sa trénuje na dátach z obdobia, keď je GNSS dostupné, a následne dokáže počas výpadku GNSS predikovať chyby polohy a rýchlosti INS na základe vlastnej „pamäte“ a údajov o dynamike vozidla. Tento prístup umožňuje kontinuálne a presné určovanie polohy bez potreby zložitého modelovania alebo ladenia parametrov ako v prípade EKF.

10.3.1 Model merania

INS systém sa skladá z IMU senzora a z navigačného procesoru. IMU je schopná pomocou akcelerometra a gyroskopu merať silu f pôsobiacu na vozidlo a jeho uhlovú rýchlosť ω . Ich integráciou je možné získať odhad rýchlosti, orientácie a pozície vozidla. Kvôli odchýlkam merania (biasom) spomenutých sensorov by však tento odhad časom divergoval. Merací model IMU je možné zapísať v tvare:

$$\tilde{f} = f + \underbrace{\overbrace{b_{as}+b_{ad}}^{b_a}}_{\delta f} + w_a \quad (10.3a)$$

$$\tilde{\omega} = \omega + \underbrace{\overbrace{b_{gs}+b_{gd}}^{b_g}}_{\delta\omega} + w_g, \quad (10.3b)$$

kde b_a, b_g sú biasy akcelerometra a gyroskopu, pričom každý z nich je možné rozložiť na statickú a dynamickú zložku; w_a, w_g sú gaussovské procesné šumy. Odchýlky merania je tak možné reprezentovať pomocou δf a $\delta\omega$. Statická zložka biasov je považovaná za konštantná počas celého procesu merania, zatiaľ čo dynamická sa mení vzhľadom na prostredie a dynamiku vozidla. Výsledná chyba odhadu polohy pomocou INS je tak funkciou aktuálneho merania, predošlej odchýlky, statických biasov sensorov, dynamických vlastností vozidla a okolitých podmienok prostredia. Je však zrejmé, že táto závislosť je nelineárna a ťažko modelovateľná. V práci [15] sa tak na odhad aktuálnej chyby INS využíva RNN sieť.

10.3.2 Integrácia RNN


RNN sieť je schopná prepájať aktuálne vstupy s predošlým stavom siete, ktorý si zapamätáva. Výpočet stavu siete v čase t sa dá zapísať v tvare

$$s_t = F(U \cdot x_t + W \cdot s_{t-1}), \quad (10.4)$$


kde F je aktivačná funkcia, U sú váhy vstupu x_t a W sú váhy predošlého stavu s_{t-1} . Ilustrácia toku informácií v priebehu času v rámci siete je na obr. 10.7.

Architektúra systému s využitím RNN na predikciu chyby INS pozostáva z dvoch základných režimov: tréningového a predikčného (viď obr. 10.8).

Pokiaľ je dostupný GNSS signál, systém je v tréningovom režime, kedy je RNN tréňovaná na základe rozdielu medzi odhadovanou a skutočnou chybou INS. Vstupom do siete sú zmena rýchlosti Δv , zmena orientácie $\Delta\phi$ a predošlý odhad chyby (spätná väzba). Výstupom siete sú odhady chyby polohy $\delta\hat{p}_{INS}$ a rýchlosti $\delta\hat{v}_{INS}$. Rozdiel merania polohy a rýchlosti medzi INS a GNSS je využívaný na tréningovanie siete pomocou



Obr. 10.7: Rozbor RNN z hľadiska toku informácií v čase [15].



Obr. 10.8: Architektúra systému s RNN na predikciu odchýlky INS [15]

trénovacieho kritéria, ktoré je definované ako:

$$\delta p_{INS|GNSS}(k) = p_{INS}(k) - p_{GNSS}(k) \quad (10.5a)$$

$$\delta v_{INS|GNSS}(k) = v_{INS}(k) - v_{GNSS}(k) \quad (10.5b)$$

Zároveň sa počítajú reziduá odhadu polohy a rýchlosti:

$$\gamma_p(k) = \delta p_{INS|GNSS}(k) - \delta \hat{p}_{INS}(k) \quad (10.6a)$$


$$\gamma_v(k) = \delta v_{INS|GNSS}(k) - \delta \hat{v}_{INS}(k), \quad (10.6b)$$

pričom podmienkou úspešného natrénovania je $\gamma_p < 3\delta_p$, $\gamma_v < 3\delta_v$, kde δ_p , δ_v sú štandardné odchýlky GNSS meraní.

V prípade, že GNSS signál z akéhokoľvek dôvodu nie je k dispozícii, systém sa prepína do predikčného režimu. Vtedy sa využíva natrénovaná RNN sieť na predikciu odchýlky merania INS, na základe čoho sa následne vypočíta odhad aktuálnej polohy:

$$\hat{p}_{INS}(k) = p_{INS}(k) - \delta \hat{p}_{INS}(k) \quad (10.7a)$$

$$\hat{v}_{INS}(k) = v_{INS}(k) - \delta \hat{v}_{INS}(k) \quad (10.7b)$$



Obr. 10.9: Priebeh simulovaného experimentu pre fúziu GNSS/INS s využitím RNN. [15]

10.3.3 Overenie a výsledky

Overenie navrhovanej metódy autori uskutočnili ako v simulovaných, tak v experimentálnych podmienkach. Tento prístup bol porovnaný s metódou rozšíreného Kalmanovho filtra (EKF) aj s metódou extrémneho učenia (ELM). V simulačnom experimente bol modelovaný let bezpilotného prostriedku so známou referenčnou trajektóriou, pričom merania inerciálnej jednotky boli systematicky zatažované šumom a odchýlkami zodpovedajúcimi reálnym podmienkam. Reálne experimenty boli realizované na dátach získaných počas námorných skúšok testovacej lode, vybavenej inerciálnym navigačným systémom a GNSS prijímačom. Pre tréning a validáciu modelu boli využité dlhodobé záznamy, zatiaľ čo testovanie sa sústredilo na horizontálne polohové a rýchlostné chyby.

Výsledky zo simulácií aj reálnych experimentov ukázali, že navrhovaná metóda dosahuje výrazné zníženie chýb v porovnaní s EKF (až o 61 % v polohe a 40 % v rýchlosti) aj s ELM, čo potvrdzuje jej potenciál pre navigáciu v prostrediach s nedostupným alebo rušeným GNSS signálom.

Záver

Cieľom tejto práce bolo poskytnúť teoretické predpoklady pre prácu na zadaní dizertačného projektu, ktorého témou je fúzia senzorických dát pre účely lokalizácie mobilných robotov. Zaoberali sme sa prehľadom dostupných snímačov, ktoré je možné využiť na určenie polohy mobilných robotov, ako aj metód a algoritmov navrhnutých na spracovanie surových senzorických dát práve s cieľom získať vyhovujúce vstupné údaje pre odhad polohy. Vzhľadom na rozsiahlosť problematiky bolo dôležité zvoliť vhodnú úroveň priblíženia sa k nej tak, aby práca na jednej strane spĺňala požadovanú kvalitatívnu úroveň, no na druhej strane bola zachovaná jej vecnosť, čitateľnosť a prehľadnosť. Vo všeobecnosti bola zvýšená pozornosť venovaná najmä vysvetleniu základných princípov fungovania, popisu slabých a silných stránok opisovaných predmetov a uvedeniu konkrétnych príkladov aplikácie s odkazom na súvisiace vedecké práce.

Spomedzi viacerých zaužívaných taxonómií sme pre prehľad dostupných snímačov zvolili takú, ktorá podľa nášho úsudku najlepšie zodpovedá rozhodovaciemu procesu pri návrhu lokalizačného systému pre mobilný robotický systém. Skúmaním súčasného stavu poznania sme zistili, že väčšina aplikácií lokalizácie využíva kombináciu minimálne dvoch senzorov, pričom minimálne dva z použitých senzorov sú v komplementárnom vzťahu. Tam kde je to možné, je obvykle volená kombinácia externého a interného senzora pre extrakciu výhodných vlastností a marginalizáciu chýb.

Kľúčovým pilierom algoritmov na fúziu lokalizačných dát mobilných robotov ostáva aj v súčasnosti EKF a jeho varianty. Oblúbené sú najmä pre nenáročnú implementáciu, spoľahlivosť a schopnosť pracovať v reálnom čase. Ich vývoj smeruje k zvýšenej adaptívnosti, robustnosti, konzistentnosti a integrácii učenia, čím lepšie reagujú na výzvy dynamického a neistého prostredia.

Technológie umelých neurónových sietí a hlbokého učenia zohrávajú čoraz dôležitejšiu úlohu v oblasti vnímania a lokalizácie autonómnych vozidiel. Oblasť fúzie senzorických dát síce nepatrí medzi tradičné príklady implementácie metód umelej inteligencie, avšak problém s náročnosťou analytického modelovania komplexných systémov v súlade s rozvojom umelej inteligencie podnecuje rozvoj aplikácií aj v týchto kombináciách. UNS majú potenciál zohrať dôležitú úlohu nie len v samotnom spájaní senzorických tokov do jedného, ale najmä v inteligentnom predspracovaní senzorických dát za účelom potlačenia šumov či iných nežiadúcich faktorov. Zlepšenie lokalizácie by bolo možné tiež dosiahnuť detekciou výrazných a stabilných orientačných bodov (napr. značky, stĺpy v exteriéri alebo dvere, schodiská v interiéri) a ich porovnávaním s mapou, pričom využitie 3D neurónových sietí zvyšuje robustnosť voči rušivým vplyvom prostredia.

Poznatky z analýzy v tejto práci ako aj z vlastných skúseností nás vedú k úsudku, že aj napriek veľkému množstvu metód fúzie lokalizačných senzorov stále neexistuje ustálený, a už vôbec nie univerzálny spôsob jej riešenia. V bežnej praxi sa navyše často využívajú len tie najzákladnejšie prístupy s empiricky volenými parametrami, ktoré nie sú schopné vyťažiť všetky výhody dostupných senzorov a nezohľadňujú ich meracie modely. Stále aktuálnou otázkou je tiež dlhodobá stabilita lokalizácie, a to najmä pri nasadení v reálnom prostredí, kde nie je možné eliminovať ťažko modelovateľné vplyvy, akými sú okolité pohyblivé objekty či otrasy a vibrácie spôsobené pohybom po nerovnom povrchu. Presná lokalizácia v neznámom prostredí tiež predstavuje aktuálnu a veľmi zaujímavú výzvu, keďže jej úspešné riešenie môže prispieť k univerzálnosti a jednoduchému nasadenia mobilného robota pre široké spektrum aplikácií.

Na základe uvedených záverov sme sa teda rozhodli smerovanie nášho ďalšieho výskumu formulovať prostredníctvom nasledujúcich téz.

Tézy dizertačnej práce

1. Komplexné porovnanie metód získavania a modelovania neistoty merania jednotlivých snímačov voči vierohodnej referencii, vrátane ich vplyvu na presnosť lokalizácie mobilného robota.
2. Návrh a verifikácia vlastnej metódy adaptívneho nastavovania parametrov senzorickej fúzie s cieľom zlepšenia spoľahlivosti a robustnosti lokalizačného systému.
3. Návrh a verifikácia systému lokalizácie mobilného robota založeného na senzorickej fúzii údajov s dlhodobou stabilitou bez potreby externej kalibračnej infraštruktúry.

Literatúra

1. AGGARWAL, C. C. *Neural Networks and Deep Learning: A Textbook* [online]. Cham: Springer International Publishing, 2018 [cit. 2025-07-14]. ISBN 978-3-319-94462-3 978-3-319-94463-0. Dostupné z DOI: 10.1007/978-3-319-94463-0.
2. ALARIFI, A. et al. Ultra Wideband Indoor Positioning Technologies: Analysis and Recent Advances. *Sensors* [online]. 2016, **16**(5), 707 [cit. 2025-07-01]. ISSN 1424-8220. Dostupné z DOI: 10.3390/s16050707.
3. ALENCASTRE-MIRANDA, M.; MUNOZ-GOMEZ, L.; MURRIETA-CID, R.; MONROY, R. Local Reference Frames vs. Global Reference Frame for Mobile Robot Localization and Path Planning. In: 2006, s. 309–318. Proceedings - Fifth Mexican International Conference on Artificial Intelligence, MICAI 2006. Dostupné z DOI: 10.1109/MICAI.2006.27.
4. AQEL, M. O. A.; MARHABAN, M. H.; SARIPAN, M. I.; ISMAIL, N. B. Review of Visual Odometry: Types, Approaches, Challenges, and Applications. *SpringerPlus* [online]. 2016, **5**(1), 1897 [cit. 2025-07-02]. ISSN 2193-1801. Dostupné z DOI: 10.1186/s40064-016-3573-7.
5. BAI, H. ICP Algorithm: Theory, Practice And Its SLAM-oriented Taxonomy. *Applied and Computational Engineering* [online]. 2023, **2**(1), 451–462 [cit. 2025-07-27]. ISSN 2755-2721, ISSN 2755-273X. Dostupné z DOI: 10.54254/2755-2721/2/20220512. Comment: Accepted by CONF-CDS'22.
6. BAI, C. et al. Faster-LIO: Lightweight Tightly Coupled Lidar-Inertial Odometry Using Parallel Sparse Incremental Voxels. *IEEE Robotics and Automation Letters* [online]. 2022, **7**(2), 4861–4868 [cit. 2025-07-03]. ISSN 2377-3766. Dostupné z DOI: 10.1109/LRA.2022.3152830.
7. BARRAU, A.; BONNABEL, S. The Invariant Extended Kalman Filter as a Stable Observer. *IEEE Transactions on Automatic Control* [online]. 2017, **62**(4), 1797–1812 [cit. 2025-07-29]. ISSN 1558-2523. Dostupné z DOI: 10.1109/TAC.2016.2594085.
8. BARRETO-CUBERO, A. J.; GÓMEZ-ESPINOSA, A.; ESCOBEDO CABELLO, J. A.; CUAN-URQUIZO, E.; CRUZ-RAMÍREZ, S. R. Sensor Data Fusion for a Mobile Robot Using Neural Networks. *Sensors* [online]. 2022, **22**(1), 305 [cit. 2025-07-04]. ISSN 1424-8220. Dostupné z DOI: 10.3390/s22010305.

9. BAY, H.; TUYTELAARS, T.; VAN GOOL, L. SURF: Speeded Up Robust Features. In: LEONARDIS, A.; BISCHOF, H.; PINZ, A. (eds.). *Computer Vision – ECCV 2006*. Berlin, Heidelberg: Springer, 2006, s. 404–417. ISBN 978-3-540-33833-8. Dostupné z DOI: 10.1007/11744023_32.
10. BESL, P.; MCKAY, N. D. A Method for Registration of 3-D Shapes. *IEEE Transactions on Pattern Analysis and Machine Intelligence* [online]. 1992, **14**(2), 239–256 [cit. 2025-07-27]. ISSN 1939-3539. Dostupné z DOI: 10.1109/34.121791.
11. CAI, Y.; XU, W.; ZHANG, F. *Ikd-Tree: An Incremental K-D Tree for Robotic Applications* [online]. 2021-02-22. [cit. 2025-07-03]. Dostupné z DOI: 10.48550/arXiv.2102.10808.
12. CALONDER, M.; LEPETIT, V.; STRECHA, C.; FUA, P. BRIEF: Binary Robust Independent Elementary Features. In: DANIILIDIS, K.; MARAGOS, P.; PARAGIOS, N. (eds.). *Computer Vision – ECCV 2010*. Berlin, Heidelberg: Springer, 2010, s. 778–792. ISBN 978-3-642-15561-1. Dostupné z DOI: 10.1007/978-3-642-15561-1_56.
13. *Camera Calibration and 3D Reconstruction — OpenCV 2.4.13.7 Documentation* [online]. [cit. 2025-07-26]. Dostupné z: https://docs.opencv.org/2.4/modules/calib3d/doc/camera_calibration_and_3d_reconstruction.html.
14. CYRILL STACHNISS. *EKF-SLAM (Cyrill Stachniss)* [online]. 2020. [cit. 2025-08-21]. Dostupné z: <https://www.youtube.com/watch?v=X30sEgIws0g>.
15. DAI, H.-f.; BIAN, H.-w.; WANG, R.-y.; MA, H. An INS/GNSS Integrated Navigation in GNSS Denied Environment Using Recurrent Neural Network. *Defence Technology* [online]. 2020, **16**(2), 334–340 [cit. 2025-07-23]. ISSN 2214-9147. Dostupné z DOI: 10.1016/j.dt.2019.08.011.
16. DUCHOŇ, F. *Snímače v mobilnej robotike*. 1. vyd. Bratislava: Nakladateľstvo STU, 2012. ISBN 978-80-227-3801-9.
17. *EGNOS* [online]. EU Agency for the Space Programme. [cit. 2025-06-26]. Dostupné z: <https://www.euspa.europa.eu/eu-space-programme/egnos>.
18. ELMENREICH, W. An Introduction to Sensor Fusion. [N.d.], 29.
19. FAYYAD, J.; JARADAT, M. A.; GRUYER, D.; NAJJARAN, H. Deep Learning Sensor Fusion for Autonomous Vehicle Perception and Localization: A Review. *Sensors* [online]. 2020, **20**(15), 4220 [cit. 2025-07-23]. ISSN 1424-8220. Dostupné z DOI: 10.3390/s20154220.

20. FERREIRA, J.; VALE, A.; VENTURA, R. Vehicle Localization System Using Offboard Range Sensor Network. *IFAC Proceedings Volumes* [online]. 2013, **46**(10), 102–107 [cit. 2025-06-29]. ISSN 1474-6670. Dostupné z DOI: 10.3182/20130626-3-AU-2035.00032.
21. FISCHLER, M. A.; BOLLES, R. C. Random Sample Consensus: A Paradigm for Model Fitting with Applications to Image Analysis and Automated Cartography. *Commun. ACM* [online]. 1981, **24**(6), 381–395 [cit. 2025-07-26]. ISSN 0001-0782. Dostupné z DOI: 10.1145/358669.358692.
22. FURTADO, J.; LIU, H.; LAI, G.; LACHERAY, H.; DESOUSA-COELHO, J. Comparative Analysis Of Optitrack Motion Capture Systems [online]. 0018 [cit. 2025-06-29]. ISSN 978-1-77355-023-7. Dostupné z HDL: 10315/35247.
23. GEIGER, A.; LENZ, P.; URTASUN, R. Are We Ready for Autonomous Driving? The KITTI Vision Benchmark Suite. In: *2012 IEEE Conference on Computer Vision and Pattern Recognition* [online]. 2012, s. 3354–3361 [cit. 2025-08-15]. ISSN 1063-6919. Dostupné z DOI: 10.1109/CVPR.2012.6248074.
24. *GNSS* [online]. United Nations Office for Outer Space Affairs. [cit. 2025-06-26]. Dostupné z: <https://www.unoosa.org/oosa/de/ourwork/psa/gnss/gnss.html>.
25. GOODFELLOW, I.; BENGIO, Y.; COURVILLE, A. *Deep Learning*. Cambridge, Mass.: MIT Press, 2016. ISBN 978-0-262-03561-3. Dostupné tiež z: <http://www.deeplearningbook.org>.
26. HARRIS, C.; STEPHENS, M. A Combined Corner and Edge Detector. In: Manchester, UK, 1988, s. 147–151.
27. HE, K.; ZHANG, X.; REN, S.; SUN, J. Deep Residual Learning for Image Recognition. In: *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)* [online]. Las Vegas, NV, USA: IEEE, 2016, s. 770–778 [cit. 2025-07-20]. Dostupné z DOI: 10.1109/cvpr.2016.90.
28. HOCHREITER, S.; SCHMIDHUBER, J. Long Short-Term Memory. *Neural Computation* [online]. 1997, **9**(8), 1735–1780 [cit. 2025-07-20]. ISSN 0899-7667. Dostupné z DOI: 10.1162/neco.1997.9.8.1735.
29. CHIEN, H.-J.; CHUANG, C.-C.; CHEN, C.-Y.; KLETTE, R. When to Use What Feature? SIFT, SURF, ORB, or A-KAZE Features for Monocular Visual Odometry. In: *2016 International Conference on Image and Vision Computing New Zealand (IVCNZ)* [online]. 2016, s. 1–6 [cit. 2025-07-25]. ISSN 2151-2205. Dostupné z DOI: 10.1109/IVCNZ.2016.7804434.

30. CHRISTENSEN, H. I.; HAGER, G. D. Sensing and Estimation. In: SICILIANO, B.; KHATIB, O. (eds.). *Springer Handbook of Robotics* [online]. 2nd ed. Cham: Springer International Publishing, 2016, s. 91–112 [cit. 2025-06-29]. ISBN 978-3-319-32552-1. Dostupné z DOI: 10.1007/978-3-319-32552-1_5.
31. CHUNG, J.; GULCEHRE, C.; CHO, K.; BENGIO, Y. *Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling* [online]. 2014-12-11. [cit. 2025-07-20]. Dostupné z DOI: 10.48550/arXiv.1412.3555. Comment: Presented in NIPS 2014 Deep Learning and Representation Learning Workshop.
32. *Inertial Measurement Unit (IMU) – An Introduction* [online]. Advanced Navigation, 2023-02-13. [cit. 2025-06-29]. Dostupné z: <https://www.advancednavigation.com/tech-articles/inertial-measurement-unit-imu-an-introduction/>.
33. JIANG, C. et al. A Mixed Deep Recurrent Neural Network for MEMS Gyroscope Noise Suppressing. *Electronics* [online]. 2019, **8**(2), 181 [cit. 2025-07-23]. ISSN 2079-9292. Dostupné z DOI: 10.3390/electronics8020181.
34. KINGMA, D. P.; BA, J. *Adam: A Method for Stochastic Optimization* [online]. 2017-01-30. [cit. 2025-07-21]. Dostupné z DOI: 10.48550/arXiv.1412.6980. Comment: Published as a conference paper at the 3rd International Conference for Learning Representations, San Diego, 2015.
35. KLETTE, R. *Concise Computer Vision: An Introduction into Theory and Algorithms* [online]. London: Springer, 2014 [cit. 2025-07-26]. Undergraduate Topics in Computer Science. ISBN 978-1-4471-6319-0 978-1-4471-6320-6. ISSN 1863-7310, ISSN 2197-1781. Dostupné z DOI: 10.1007/978-1-4471-6320-6.
36. KOLAR, P.; BENAVIDEZ, P.; JAMSHIDI, M. Survey of Datafusion Techniques for Laser and Vision Based Sensor Integration for Autonomous Navigation. *Sensors* [online]. 2020, **20**(8), 2180 [cit. 2022-02-04]. ISSN 1424-8220. Dostupné z DOI: 10.3390/s20082180.
37. KRISHNAN, R. G.; SHALIT, U.; SONTAG, D. *Deep Kalman Filters* [online]. 2015-11-25. [cit. 2025-07-29]. Dostupné z DOI: 10.48550/arXiv.1511.05121. Comment: 17 pages, 14 figures: Fixed typo in Fig. 1(b) and added reference.
38. KRIZHEVSKY, A.; SUTSKEVER, I.; HINTON, G. E. ImageNet Classification with Deep Convolutional Neural Networks. In: *Advances in Neural Information Processing Systems* [online]. Curran Associates, Inc., 2012, zv. 25 [cit. 2025-07-21]. Dostupné z: https://papers.nips.cc/paper_files/paper/2012/hash/c399862d3b9d6b76c8436e924a68c45b-Abstract.html.

39. KROMBACH, N.; DROESCHEL, D.; BEHNKE, S. Combining Feature-Based and Direct Methods for Semi-dense Real-Time Stereo Visual Odometry. In: CHEN, W.; HOSODA, K.; MENEGATTI, E.; SHIMIZU, M.; WANG, H. (eds.). *Intelligent Autonomous Systems 14* [online]. Cham: Springer International Publishing, 2017, vol. 531, s. 855–868 [cit. 2025-06-28]. ISBN 978-3-319-48035-0. Dostupné z DOI: 10.1007/978-3-319-48036-7_62.
40. LAGANIÈRE, R. *Sensor Fusion for Autonomous Vehicles: Strategies, Methods, and Tradeoffs / Synopsys* [online]. 2021. [cit. 2022-01-13]. Dostupné z: <https://www.youtube.com/watch?v=2Fcmh7SLPBI>.
41. LECUN, Y.; HINTON, G. E.; BENGIO, Y. Deep Learning. *Nature* [online]. 2015 [cit. 2025-07-14]. Dostupné z DOI: 10.1038/nature14539.
42. LEE, D.; JUNG, M.; YANG, W.; KIM, A. LiDAR Odometry Survey: Recent Advancements and Remaining Challenges. *Intelligent Service Robotics* [online]. 2024, **17**(2), 95–118 [cit. 2025-06-28]. ISSN 1861-2784. Dostupné z DOI: 10.1007/s11370-024-00515-8.
43. LEPETIT, V.; MORENO-NOGUER, F.; FUA, P. EPnP: An Accurate $O(n)$ Solution to the PnP Problem. *International Journal of Computer Vision* [online]. 2009, **81**(2), 155–166 [cit. 2025-07-26]. ISSN 1573-1405. Dostupné z DOI: 10.1007/s11263-008-0152-6.
44. LOSHCHILOV, I.; HUTTER, F. *Decoupled Weight Decay Regularization* [online]. 2019-01-04. [cit. 2025-07-21]. Dostupné z DOI: 10.48550/arXiv.1711.05101. Comment: Published as a conference paper at ICLR 2019.
45. LOWE, D. Object Recognition from Local Scale-Invariant Features. In: *Proceedings of the Seventh IEEE International Conference on Computer Vision* [online]. 1999, zv. 2, 1150–1157 vol.2 [cit. 2025-07-26]. Dostupné z DOI: 10.1109/ICCV.1999.790410.
46. MCCULLOCH, W. S.; PITTS, W. A Logical Calculus of the Ideas Immanent in Nervous Activity. *The bulletin of mathematical biophysics* [online]. 1943, **5**(4), 115–133 [cit. 2025-07-05]. ISSN 1522-9602. Dostupné z DOI: 10.1007/BF02478259.
47. MEHLIG, B. *Machine Learning with Neural Networks* [online]. 2021. [cit. 2025-07-05]. Dostupné z DOI: 10.1017/9781108860604. Comment: Revised version, 241 pages.
48. MINSKY, M.; PAPERT, S. A. *Perceptrons: An Introduction to Computational Geometry* [online]. The MIT Press, 2017 [cit. 2025-07-18]. ISBN 978-0-262-34393-0. Dostupné z DOI: 10.7551/mitpress/11301.001.0001.

49. MOEBS, W.; LING, S. J.; SANNY, J. *University Physics*. Vol. 1 [online]. Houston: OpenStax, 2016 [cit. 2025-06-27]. UCF Pressbooks. 3 vols. ISBN 978-1-938168-27-7. Dostupné z: <https://pressbooks.online.ucf.edu/osuniversityphysics/>.
50. *Motion Capture for Robotics* [online]. OptiTrack. [cit. 2025-06-28]. Dostupné z: <http://optitrack.com/applications/robotics/index.html>.
51. MUR-ARTAL, R.; MONTIEL, J. M. M.; TARDOS, J. D. ORB-SLAM: A Versatile and Accurate Monocular SLAM System. *IEEE Transactions on Robotics* [online]. 2015, **31**(5), 1147–1163 [cit. 2025-07-26]. ISSN 1552-3098, ISSN 1941-0468. Dostupné z DOI: 10.1109/TR0.2015.2463671. Comment: 17 pages. 13 figures. IEEE Transactions on Robotics, 2015. Project webpage (videos, code): <http://webdiis.unizar.es/~raulmur/orbslam/>.
52. NISTER, D. An Efficient Solution to the Five-Point Relative Pose Problem. *IEEE Transactions on Pattern Analysis and Machine Intelligence* [online]. 2004, **26**(6), 756–770 [cit. 2025-07-26]. ISSN 1939-3539. Dostupné z DOI: 10.1109/TPAMI.2004.17.
53. NISTER, D.; NARODITSKY, O.; BERGEN, J. Visual Odometry. In: *Proceedings of the 2004 IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2004. CVPR 2004*. [online]. 2004, zv. 1, s. I–I [cit. 2025-06-28]. ISSN 1063-6919. Dostupné z DOI: 10.1109/CVPR.2004.1315094.
54. AL-OKBY, M. F. R.; JUNGINGER, S.; RODDELKOPF, T.; THUROW, K. UWB-Based Real-Time Indoor Positioning Systems: A Comprehensive Review. *Applied Sciences* [online]. 2024, **14**(23), 11005 [cit. 2025-07-02]. ISSN 2076-3417. Dostupné z DOI: 10.3390/app142311005.
55. QIN, T.; LI, P.; SHEN, S. VINS-Mono: A Robust and Versatile Monocular Visual-Inertial State Estimator. *IEEE Transactions on Robotics* [online]. 2018, **34**(4), 1004–1020 [cit. 2025-06-28]. ISSN 1552-3098, ISSN 1941-0468. Dostupné z DOI: 10.1109/TR0.2018.2853729. Comment: journal paper.
56. ROSENBLATT, F. The Perceptron: A Probabilistic Model for Information Storage and Organization in the Brain. *Psychological Review*. 1958, **65**(6), 386–408. ISSN 1939-1471. Dostupné z DOI: 10.1037/h0042519.
57. ROSTEN, E.; DRUMMOND, T. Machine Learning for High-Speed Corner Detection. In: LEONARDIS, A.; BISCHOF, H.; PINZ, A. (eds.). *Computer Vision – ECCV 2006*. Berlin, Heidelberg: Springer, 2006, s. 430–443. ISBN 978-3-540-33833-8. Dostupné z DOI: 10.1007/11744023_34.

58. *RTK-GPS Technology for Precise Positioning* [online]. RTLS Alliance. [cit. 2025-06-26]. Dostupné z: <https://rtlsalliance.com/rtls-digital-twin/technologies/rtk-gps>.
59. RUBLEE, E.; RABAUD, V.; KONOLIGE, K.; BRADSKI, G. ORB: An Efficient Alternative to SIFT or SURF. In: *2011 International Conference on Computer Vision* [online]. 2011, s. 2564–2571 [cit. 2025-07-26]. ISSN 2380-7504. Dostupné z DOI: 10.1109/ICCV.2011.6126544.
60. RUMELHART, D. E.; HINTON, G. E.; WILLIAMS, R. J. Learning Representations by Back-Propagating Errors. *Nature* [online]. 1986, **323**(6088), 533–536 [cit. 2025-07-14]. ISSN 1476-4687. Dostupné z DOI: 10.1038/323533a0.
61. RUSINKIEWICZ, S.; LEVOY, M. Efficient Variants of the ICP Algorithm. In: *Proceedings Third International Conference on 3-D Digital Imaging and Modeling* [online]. Quebec City, Que., Canada: IEEE Comput. Soc, [n.d.], s. 145–152 [cit. 2025-07-27]. Dostupné z DOI: 10.1109/im.2001.924423.
62. RUSSELL, S. J.; NORVIG, P.; DAVIS, E. *Artificial Intelligence: A Modern Approach*. 3rd ed. Upper Saddle River: Prentice Hall, 2010. Prentice Hall Series in Artificial Intelligence. ISBN 978-0-13-604259-4.
63. SAMPSON, P. D. Fitting Conic Sections to “Very Scattered” Data: An Iterative Refinement of the Bookstein Algorithm. *Computer Graphics and Image Processing* [online]. 1982, **18**(1), 97–108 [cit. 2025-07-26]. ISSN 0146-664X. Dostupné z DOI: 10.1016/0146-664X(82)90101-0.
64. *Satellite Navigation - WAAS - How It Works / Federal Aviation Administration* [online]. [cit. 2025-06-26]. Dostupné z: https://www.faa.gov/about/office_org/headquarters_offices/ato/service_units/techops/navservices/gnss/waas/howitworks.
65. SÄRKKÄ, S. *Bayesian Filtering and Smoothing*. Vol. 3. Cambridge: Cambridge University Press, 2013. Institute of Mathematical Statistics Textbooks. ISBN 978-1-107-03065-7. Dostupné tiež z: https://users.aalto.fi/~ssarkka/pub/cup_book_online_20131111.pdf.
66. SCHMIDHUBER, J. Deep Learning in Neural Networks: An Overview. *Neural Networks* [online]. 2015, **61**, 85–117 [cit. 2025-07-14]. ISSN 0893-6080. Dostupné z DOI: 10.1016/j.neunet.2014.09.003.

67. SIEGWART, R. *Introduction to Autonomous Mobile Robots* [online]. 2nd ed. Cambridge, MA: MIT Press, 2011 [cit. 2025-06-29]. Intelligent Robots and Autonomous Agents. ISBN 978-0-262-01535-6. Dostupné z: <https://mitpress.mit.edu/9780262015356/introduction-to-autonomous-mobile-robots/>.
68. THRUN, S.; BURGARD, W.; FOX, D. *Probabilistic Robotics*. Cambridge, Mass.: The MIT Press, 2005. ISBN 978-0-262-20162-9. Dostupné tiež z: <https://docs.ufpr.br/~danielsantos/ProbabilisticRobotics.pdf>.
69. TOMASI, C.; KANADE, T. *Detection and Tracking of Point Features*. Pittsburgh, PA, 1991-04. Technical Report, CMU-CS-91-132. Carnegie Mellon University, School of Computer Science.
70. TRAWNY, N.; ROUMELIOTIS, S. Indirect Kalman Filter for 3 D Attitude Estimation. In: [online]. 2005 [cit. 2025-07-29]. Dostupné z: <https://www.semanticscholar.org/paper/Indirect-Kalman-Filter-for-3-D-Attitude-Estimation-Trawny-Roumeliotis/56ea520b4a9a7a718c490f392f275f5f8feb2886>.
71. TZAFESTAS, S. G. 12 - Mobile Robot Localization and Mapping. In: TZAFESTAS, S. G. (ed.). *Introduction to Mobile Robot Control* [online]. Oxford: Elsevier, 2014, s. 479–531 [cit. 2022-01-12]. ISBN 978-0-12-417049-0. Dostupné z DOI: 10.1016/B978-0-12-417049-0.00012-2.
72. VALENTE, M.; JOLY, C.; FORTELLE, A. d. L. *An LSTM Network for Real-Time Odometry Estimation* [online]. 2019-02-22. [cit. 2025-08-15]. Dostupné z DOI: 10.48550/arXiv.1902.08536.
73. VALENTE, M.; JOLY, C.; FORTELLE, A. d. L. Deep Sensor Fusion for Real-Time Odometry Estimation. In: *2019 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* [online]. 2019, s. 6679–6685 [cit. 2025-07-29]. ISSN 2153-0866. Dostupné z DOI: 10.1109/IR0S40897.2019.8967803.
74. VIZZO, I. et al. KISS-ICP: In Defense of Point-to-Point ICP – Simple, Accurate, and Robust Registration If Done the Right Way. *IEEE Robotics and Automation Letters* [online]. 2023, 8(2), 1029–1036 [cit. 2025-06-30]. ISSN 2377-3766, ISSN 2377-3774. Dostupné z DOI: 10.1109/LRA.2023.3236571.
75. WAN, E.; VAN DER MERWE, R. The Unscented Kalman Filter for Nonlinear Estimation. In: *Proceedings of the IEEE 2000 Adaptive Systems for Signal Processing, Communications, and Control Symposium (Cat. No.00EX373)* [online]. 2000, s. 153–158 [cit. 2025-07-29]. Dostupné z DOI: 10.1109/ASSPCC.2000.882463.

76. WANG, S.; CLARK, R.; WEN, H.; TRIGONI, N. DeepVO: Towards End-to-End Visual Odometry with Deep Recurrent Convolutional Neural Networks. In: *2017 IEEE International Conference on Robotics and Automation (ICRA)* [online]. 2017, s. 2043–2050 [cit. 2025-08-15]. Dostupné z DOI: 10.1109/ICRA.2017.7989236. Comment: Published in 2017 IEEE International Conference on Robotics and Automation (ICRA 2017). Official version at <http://ieeexplore.ieee.org/document/7989236/>. Project website and videos at <http://senwang.gitlab.io/DeepVO/>.
77. *What Is GNSS* [online]. EU Agency for the Space Programme. [cit. 2025-06-26]. Dostupné z: <https://www.euspa.europa.eu/eu-space-programme/galileo/what-gnss>.
78. *Why Sensor Fusion?* [online]. Dell Automotive Reference Architecture | Dell Technologies Info Hub, 2024. [cit. 2025-07-29]. Dostupné z: <https://infohub.delltechnologies.com/en-us/1/dell-automotive-reference-architecture/why-sensor-fusion/>.